

AISC DEEPPAKE ÇALIŞMALARI

DenseNet121 Kaş ROI Deepfake Sınıflandırma Notebooku

Kodun Amacı, Çalışma Mantığı, Veri Güvenliği ve Çıktı Yapısı - Teknik Rapor

Alan	Açıklama
İncelenen dosya	DenseNet121_Kas_Deepfake_AISC_Standard_STABILIZE_D_V3 (2).ipynb
Bölge	Kaş (eyebrow) ROI
Model	ImageNet ön eğitilmiş DenseNet121
Görev	Real / Fake ikili deepfake sınıflandırma
Çalışma ortamı	Google Colab + Google Drive + TensorFlow/Keras
Ana güvenlik yaklaşımı	Source-group split + hash-aware leakage önleme + kalite kapıları

Bu rapor yalnızca yüklenen Stabilized V3 notebookunun gerçek kod akışına dayanır.

1. Yönetici Özeti

Kodun tek cümlelik amacı

Önceden kırılmış kaş ROI görüntülerini kaynak-video sızıntısı oluşturmayacak şekilde yeniden bölmek, ImageNet ön eğitilmiş DenseNet121 ile Real/Fake sınıflandırması yapmak, validation üzerinden karar eşiği seçmek ve tüm deney çıktısını denetlenebilir bir run klasöründe saklamaktır.

Notebook yalnızca bir model.fit() betiği değildir. Veri kaynağını doğrulayan, ROI dosyalarını kaynak videolarla eşleyen, aynı içerikteki kopyaları SHA-256 ile yakalayan, source-group seviyesinde yeniden split yapan, eğitim başlamadan kalite testleri çalıştıran, kesintiye dayanıklı checkpoint üreten ve test sonuçlarını görüntü ve video/source düzeyinde raporlayan uçtan uca bir deney hattıdır.

- Kaş ROI klasöründeki görüntüleri değiştirmez, taşımaz, yeniden kırpmaz veya yeniden adlandırmaz.
- Fiziksel train/val/test klasörlerini audit için okur; gerçek eğitim splitini bellekte source-group düzeyinde yeniden kurar.
- Real=0, Fake=1 ikili sınıflandırma yapar ve DenseNet121 çıkışını Fake olasılığı olarak yorumlar.
- Model seçimini validation ROC-AUC ile yapar; test setini yalnız final değerlendirmede kullanır.
- Metrikler, tahminler, grafikler, checkpointler, konfigürasyon, ortam bilgisi ve audit kayıtları ayrı klasörlerde saklanır.

DenseNet121 Kaş ROI Notebook - Uçtan Uca Çalışma Akışı



Şekil 1. Notebookun başlangıçtan final audit aşamasına kadar uçtan uca çalışma akışı.

2. Kodun Kapsamı ve Ne İşe Yaradığı

Kodun temel kullanım amacı, kaş bölgesinin deepfake tespitinde tek başına ne kadar ayırt edici bilgi taşıdığını kontrollü bir CNN deneyi ile ölçmektir. Bunun için önceden oluşturulmuş kaş crop görüntüleri kullanılır. ROI çıkarımı bu notebookun görevi değildir; notebook veri hazırlamanın model eğitimi ve değerlendirme bölümünü yürütür.

2.1 Kod ne yapar?

- Drive içindeki proje klasörünü bulur ve Unicode/harf duyarlılığı sorunlarına karşı yol isimlerini normalize eder.
- Kaş/Real ve Kaş/Fake altındaki görüntüleri keşfeder ve dosya sayılarını audit eder.
- ROI dosyasını, orijinal frame ve source_video bilgisine bağlar.
- Aynı kaynak video veya aynı piksel içeriği train/val/test arasında bölünmeyecek şekilde güvenli split üretir.
- DenseNet121 için tf.data veri hattı kurar, yalnız train verisine sınırlı augmentation uygular.
- İki aşamalı transfer learning/fine-tuning yapar.
- Validation setinde Youden J ile classification threshold seçer.
- Test setinde image-level ve source-level metrikleri çıkarır.
- Loss, AUC, confusion matrix, ROC ve PR görsellerini üretir.
- Deney sonunda zorunlu dosya ve audit kontrollerini yapar.

2.2 Kod ne yapmaz?

- Yüz tespiti veya kaş landmark tespiti yapmaz.
- Kaş ROİlerini yeniden kırpamaz.
- Girdi klasöründeki dosyaları silmez, taşımaz veya yeniden adlandırmaz.
- HOG/LBP/Gabor gibi elle tasarlanmış özellikler ayrıca çıkarmak zorunda değildir; temel temsil DenseNet121 tarafından öğrenilir.
- Test setini model seçimi veya threshold optimizasyonu için kullanmaz.

3. Girdi Verisi ve Dosya Yolu Politikası

Notebookun beklediği ana veri yolu aşağıdaki hiyerarşidir:

```
MyDrive/AISC DeepFake Çalışmaları/Deneyler/Nazlıcan/Deney 1/Kaş
Kaş/
├── Real/
│   ├── train/
│   ├── val/
│   └── test/
└── Fake/
    ├── train/
    ├── val/
    └── test/
```

Ayrıca kaynak-video kimliğinin güvenilir biçimde geri kazanılması için Deneyler/Deney 1 Frame/secim_metadata.csv dosyası gerekir. Doğrudan dosya adı eşleşmesi yeterli olmazsa notebook Kaş/metadata.csv dosyasını ikinci eşleme kaynağı olarak kullanmayı dener. Eşleme yine tamamlanamazsa source_video tahmin edilmez; eğitim durdurulur.

Salt-okunur girdi tasarımı

Kaş klasörü model girdisi olarak kabul edilir. Notebook bu klasöre çıktı yazmaz. Yeni dosyalar yalnız Deney 1/Sonuçlar altında oluşturulan RUN klasörüne yazılır.

4. Konfigürasyon ve Tekrar Üretilbilirlik

Parametre	Kodda kullanılan değer	İşlev
Seed	42	Python, NumPy, TensorFlow ve split işlemlerini olabildiğince tekrar üretilebilir yapar.
Girdi boyutu	224 x 224	DenseNet121 model girdisi.
Batch size	16	Bir eğitim adımında işlenen örnek sayısı.
Frozen epoch	12	Backbone dondurulmuş ilk eğitim aşaması.
Fine-tune epoch	10	Son DenseNet bloğunun kısmen açıldığı ikinci aşama hedefi.
Dropout	0.40	Classification head üzerinde regularization.
Frozen LR	1e-3	İlk aşama öğrenme oranı.
Fine-tune LR	1e-5	Ön eğitilmiş ağırlıkları bozmamak için düşük ikinci aşama LR.
Early stopping patience	4	val_auc iyileşmezse eğitimi erken durdurur.
Reduce LR patience	2	val_loss plato yapınca LRyi 0.2 ile çarpar.
Model seçimi	val_auc - max	Global best checkpoint için kullanılan validation metriği.
Pretrained weights	ImageNet	Transfer learning başlangıç ağırlıkları.

Cell 1 aynı zamanda GPUyu listeler ve mümkünse TensorFlow deterministic operations özelliğini etkinleştirir. GPU varsa mixed precision politikası mixed_float16 yapılır; GPU yoksa float32 kullanılır. Sigmoid çıkış katmanı özellikle float32 dtype ile tanımlanır.

5. Deney Run Klasörü ve Çıktı Organizasyonu

Her çalıştırma için zaman damgalı benzersiz bir run_id üretilir. Aynı dakika içinde klasör varsa _r02, _r03 gibi eklerle mevcut sonuçların üzerine yazılması engellenir.

```

Sonuçlar/
├── DenseNet121_Kas_Results_<RUN_ID>/
│   ├── checkpoints/
│   ├── logs/
│   ├── metrics/
│   ├── predictions/
│   ├── figures/
│   ├── artifacts/
│   ├── config_resolved.yaml
│   ├── environment.json
│   ├── requirements_lock.txt
│   ├── run_summary.json
│   └── output_manifest.csv

```

Öge	Ne saklar?
-----	------------

checkpoints	best.keras, last.keras, training_state.json ve BackupAndRestore kayıtları
logs	Frozen ve fine-tune epoch CSV logları
metrics	Eğitim geçmişleri, quality gates, threshold ve final metrikler
predictions	Her test ROI ve her source için olasılık/tahmin kayıtları
figures	Loss, AUC, confusion matrix, ROC ve PR grafikleri
artifacts	Manifest, leakage audit, count audit, model özeti ve final audit
config_resolved.yaml	Deneyde gerçekten kullanılan hiperparametreler ve yollar
environment.json	Python/TensorFlow/Keras/NumPy/Pandas/GPU ve seed bilgisi
requirements_lock.txt	pip freeze çıktısı
output_manifest.csv	Run içindeki her dosyanın yolu, boyutu ve SHA-256 özeti

6. Hücre Hücre Çalışma Mantığı

Hücre	Başlık	Görev
Cell 1	Environment / imports / reproducibility	Kütüphaneler, seed, determinism ve GPU kontrolü.
Cell 2	Drive + yol çözümleme	Drive mount ve proje klasörlerinin güvenli bulunması.
Cell 3	Config + output tree	Hiperparametreler, run ID, klasörler, environment/requirements kaydı.
Cell 4	ROI keşfi + count audit	Görüntüleri toplar; sınıf/split sayıları ve dosya adı benzersizliği.
Cell 5	Source mapping + hash-aware split	Source video eşleme, SHA-256, duplicate component, group 80/10/10.
Cell 6	Manifest + leakage gates	Standart metadata, accounting equality ve leakage kontrolleri.
Cell 7	tf.data pipeline	Resize-with-pad, augmentation, preprocess_input, batch/prefetch.
Cell 8	Model kurma	ImageNet DenseNet121 + GAP + Dropout + sigmoid.
Cell 9	Quality gates	Schema, split, 2-batch smoke, NaN/Inf ve save/load testi.
Cell 10	Callbacks / checkpoint	Atomic best/last kayıt, finite guard, CSV log, LR/early stop, resume.
Cell 11	Frozen training	Backbone kapalı ilk eğitim.
Cell 12	Fine-tuning	conv5_block katmanlarının kısmi açılması; BatchNorm frozen.
Cell 13	Validation threshold + test	Youden J threshold; image/source metrics ve CSV prediction.
Cell 14	Figures	5 standart İngilizce grafik + çözünürlük audit.
Cell 15	Final audit	Zorunlu çıktı kontrolü, run_summary, final_audit, output_manifest.

Cell 1 - Ortam ve tekrar üretilebilirlik

Kod gerekli Python/TensorFlow/Pandas/Scikit-learn kütüphanelerini yükler, SEED=42 değerini Python random, NumPy ve TensorFlowa uygular. TensorFlow deterministic ops mümkünse etkinleştirilir. GPU sayısı ekrana basılır. Bu bölümün amacı aynı konfigürasyonla çalıştırılan deneylerin mümkün olduğunca aynı davranışı göstermesidir.

Cell 2 - Google Drive ve kesin proje yolları

Drive mount edilir. normalize_name fonksiyonu Unicode NFC, strip ve casefold uygular. find_child_folder fonksiyonu Kaş/Kas veya Nazlıcan/Nazlıcan gibi ad farklılıklarına tolerans sağlar ama yanlış klasör uydurmaz; bulunamazsa mevcut klasörleri listeleterek FileNotFoundError üretir. Çıktı yazılabilen tek ana kök Sonuçlar klasörüdür.

Cell 3 - Konfigürasyon ve run oluşturma

Model, epoch, learning rate, dropout, split ve label mapping ayarları CONFIG sözlüğünde merkezi tutulur. Tarih-saat tabanlı run ID oluşturulur ve mevcut run asla overwrite edilmez. Aynı anda config_resolved.yaml, environment.json ve requirements_lock.txt yazılarak deneyin yeniden kurulabilmesi amaçlanır.

Cell 4 - ROI görüntülerini keşfetme ve count audit

JPG/JPEG/PNG/BMP/WEBP uzantıları desteklenir. Real/Fake içindeki train/val/test dizinleri taranır. Boş split bulunursa durur. Dosya adları metadata join işleminde anahtar olarak kullanıldığı için duplicate filename bulunması hata kabul edilir. Güncel sayılar tarihsel ROI extraction sayılarıyla karşılaştırılır; fark varsa uyarı verilir fakat aşağıdaki güvenlik kapıları geçerse eğitim devam edebilir.

6.5 Cell 5 - Source Mapping ve Hash-Aware Source-Group Split

Notebookun en kritik veri güvenliği bölümü budur. Amaç, aynı videodan veya aynı içeriğin kopyasından gelen framerin farklı splitlere düşmesini engellemektir.

1. secim_metadata.csv okunur ve sinif, split, orijinal_yol, yeni_yol, dosya_adi sütunları zorunlu tutulur.
2. orijinal_yol içinden source_video ve frame_index geri kazanılır. ROI dosya adı ile metadata birebir eşleştirilir.
3. Doğrudan eşleşme %100 değilse Kaş/metadata.csv içinden ROI -> frame adı eşlemesi denir. Hala source_video bulunamıyorsa eğitim durdurulur.
4. Her ROI için SHA-256 hesaplanır. Aynı hash hem Real hem Fake etiketi taşıyorsa bu bir data label conflict kabul edilir.
5. Real için source_group doğrudan gerçek video kimliğidir. FF++ fake örneklerinde Deepfakes/FaceSwap/Face2Face/NeuralTextures/FaceShifter yöntem adından bağımsız olarak aynı kaynak video çifti tek grup kabul edilir. DeepFakeDetection için de kaynak çift kimliği kanonikleştirilir.
6. Aynı piksel içeriği farklı source_group değerlerinde geçiyorsa Union-Find ile bu gruplar tek split bileşeninde birleştirilir. Böylece duplicate zincirleri de ayrılmaz.
7. Real ve Fake sınıfları ayrı ayrı GroupShuffleSplit ile önce %80 train / %20 temp, sonra temp %50/%50 ile yaklaşık %10 validation / %10 test olarak bölünür.
8. split_group setleri arasında train-val, train-test ve val-test kesişimi kesinlikle sıfır olmak zorundadır.

Neden frame-level random split yok?

Aynı videodan üretilmiş benzer framerler train ve testte birlikte bulunursa model deepfake artefaktı yerine videoya/kimliğe özgü ipuçlarını ezberleyebilir. Kod bu riski source-group ve içerik-hash seviyesinde engellemeye çalışır.

6.6 Cell 6 - Standart Manifest ve Leakage Gate

Her örnek için hash tabanlı kararlı sample_id üretilir. Manifest, model eğitiminde kullanılan her ROIyi kaynak video, frame index, label, split, SHA-256 ve yol bilgisiyle izlenebilir hale getirir.

Manifest alanı	Anlamı
sample_id	label + source_video + frame_index + filename + hash üzerinden 16 karakterlik kararlı kimlik
source_video	Orijinal videoyu temsil eden kaynak kimlik
frame_index	Kaynak videodaki frame numarası
roi_state	eyebrow_pair
label / label_id	real/fake ve 0/1 sayısal etiketi
split	Bellekte yeniden üretilen train/val/test
sha256	Dosya içerik bütünlüğü ve duplicate kontrolü
source_group	Bilimsel kaynak grubu
split_group	Hash-aware leakage-proof bileşen

output_path	Bu notebook bağlamında modelin okuduğu mevcut ROI yolu
-------------	--

Ardından accounting equality, exact source overlap, split_group overlap, cross-split duplicate hash ve her splitte iki sınıfın bulunması kontrolleri çalışır. Bunlardan biri başarısızsa model eğitimi başlamaz.


6.7 Cell 7 - tf.data Veri Hattı

Manifest train/val/test DataFramelerine ayrılır. Görseller tf.io ile okunur, üç kanala çevrilir ve aspect ratio korunarak resize_with_pad ile 224x224 boyutuna getirilir. Yalnız train kümesine horizontal flip, çok küçük rotation, küçük zoom ve contrast augmentation uygulanır. Ardından görüntü 0-255 aralığına clip edilir ve DenseNet121 preprocess_input fonksiyonundan geçirilir. Etiketler Dense(1) çıkışına uyumlu biçimde (batch,1) tutulur. Dataset shuffle, batch ve prefetch kullanır; validation/test shuffle edilmez.

6.8 Cell 8 - DenseNet121 Mimarisi

DenseNet121 weights=imagenet ve include_top=False ile yüklenir. İlk aşamada backbone tamamen frozen durumdadır. Backbone çıktısı GlobalAveragePooling2D ile 1024 boyutlu vektöre indirgenir, %40 Dropout uygulanır ve Dense(1, sigmoid) katmanı Fake olasılığı üretir. Loss BinaryCrossentropy, optimizer Adamdır. Metrikler accuracy, ROC-AUC, PR-AUC, precision ve recall olarak tanımlanır.

Model Mimarisi ve Fine-Tuning Stratejisi



Şekil 2. DenseNet121 tabanlı kaş ROI sınıflandırma mimarisi ve iki aşamalı fine-tuning yaklaşımı.

7. Eğitim Başlamadan Önceki Kalite Kapıları

Kapı	Kontrol	Başarısız olursa
Schema test	Manifest zorunlu kolonları ve sample_id benzersizliği	Eğitim başlamaz
Split test	Önceki leakage_pass sonucu	Eğitim başlamaz
Smoke test	Train datasetten 2 batch forward/backward train_on_batch	Eğitim başlamaz
Numerical test	Loss ve metriklerde NaN/Inf olmaması	Eğitim başlamaz / durur
Checkpoint test	Model save-load sonrası tahminlerin allclose olması	Eğitim başlamaz

Smoke test ana modeli bozmamak için clone_model ile ayrı bir kopyada yapılır. train_on_batch return_dict=True kullanılması Keras sürümleri arasında skaler/liste dönüş farklarını ortadan kaldırır. Checkpoint testi geçici .keras dosyasını kaydeder, yeniden yükler ve aynı iki validation örneğindeki predictionların rtol=1e-5, atol=1e-6 toleransında aynı olduğunu doğrular.

Quality gate mantığı

Kodun felsefesi "önce kısa ve ucuz doğrulama, sonra pahalı tam eğitim"dir. Veri şeması, leakage veya checkpoint mekanizması hatalıysa saatler süren eğitim başlatılmaz.

8. Checkpoint, Logging ve Kesintiden Devam Mekanizması

Cell 10, sıradan ModelCheckpoint kullanımından daha sıkı bir atomik kayıt yaklaşımı uygular. AtomicModelCheckpoint önce modeli .tmp.keras dosyasına kaydeder, dosyayı yeniden load_model ile açıp output shape kontrol eder ve ancak doğrulama geçerse os.replace ile hedef dosyanın yerine yayınlar.

Bileşen	Görev
best.keras	val_auc en iyi olduğunda kaydedilen global en iyi model
last.keras	Her epoch sonunda son durum
training_state.json	completed_epoch, stage, best metric ve seed bilgisi
FiniteMetricsGuard	Batch/epoch loglarında NaN/Inf bulursa hata
CSVLogger append=True	Resume sonrası eski epoch loglarını korur
ReduceLROnPlateau	val_loss plato yaparsa LRyi düşürür
EarlyStopping	val_auc 4 epoch iyileşmezse durur
BackupAndRestore	Runtime kesilirse stage bazlı eğitimi sürdürmeye yardım eder

read_stage_history fonksiyonu yalnız geçerli CSV logunu esas alır; aynı epoch birden fazla kez yazılmışsa son kaydı tutar ve epoch sırasını normalize eder. Böylece notebook kesinti sonrası History nesnesine körü körüne güvenmez.

9. İki Aşamalı Transfer Learning Stratejisi

9.1 Aşama 1 - Frozen backbone

İlk 12 epoch boyunca DenseNet121 backbone trainable=False durumundadır. Yalnız GlobalAveragePooling sonrası classification head öğrenir. Amaç, ImageNetten gelen genel görsel temsil üzerinde kaş Real/Fake karar sınırını nispeten güvenli ve hızlı biçimde kurmaktır.

9.2 Aşama 2 - Partial fine-tuning

İkinci aşamada en iyi frozen checkpoint yüklenir. DenseNet121 genel olarak trainable=True yapılır fakat önce tüm backbone katmanları tekrar dondurulur. Sadece adı conv5_block ile başlayan son DenseNet bloğundaki BatchNormalization olmayan katmanlar açılır. Tüm BatchNormalization katmanları frozen kalır. Model daha düşük 1e-5 learning rate ile yeniden compile edilir ve 10 ek epoch hedefiyle eğitilir.

Bu yaklaşım, küçük/orta boy ROI veri setinde tüm DenseNeti bir anda açarak ön eğitilmiş temsili bozma riskini azaltır. Fine-tune başlangıç epochu frozen CSV logundan hesaplandığı için resume senaryosuyla uyumludur.

10. Validation Threshold Seçimi ve Final Test

Best checkpoint yüklendikten sonra önce validation seti üzerinde Fake olasılıkları üretilir. roc_curve ile tüm eşikler hesaplanır ve Youden J = TPR - FPR değerini maksimize eden eşik SELECTED_THRESHOLD olarak seçilir. Bu eşik validation_threshold.json dosyasına kaydedilir.

Test izolasyonu

Kodda test_dataset, model ve threshold seçimi tamamlandıktan sonra ilk kez final değerlendirme için kullanılır. Böylece test setinden hiperparametre veya threshold sızıntısı yapılmaz.

10.1 Image-level metrikler

Metrik	Kodda anlamı
Accuracy	Tüm ROİlerde doğru tahmin oranı
Balanced Accuracy	Sınıfların recall değerlerini dengeli biçimde özetler
Precision	Fake tahmini yapılanların gerçekten Fake olma oranı
Recall / Sensitivity	Gerçek Fake ROİlerin yakalanma oranı
Specificity	Gerçek Real ROİlerin doğru Real kalma oranı
F1	Fake precision ve recall harmonik ortalaması
ROC-AUC	Threshold bağımsız ayırt etme/sıralama gücü
PR-AUC	Precision-recall performansı
MCC	Tüm confusion matrix hücrelerini kullanan dengeli korelasyon metriği

10.2 Source/video-level metrikler

Test ROI tahminleri source_key = label::source_video ile gruplanır. Aynı source içindeki Fake olasılıklarının ortalaması alınır, aynı SELECTED_THRESHOLD uygulanır ve accuracy, balanced accuracy, precision, recall, F1, ROC-AUC ve PR-AUC yeniden hesaplanır. Bu, frame/ROI seviyesinden bağımsız olarak video/kaynak seviyesinde karar kalitesini ölçmeyi amaçlar.

11. Üretilen Görseller ve Kalite Standardı

Dosya	Ne gösterir?
training_validation_loss.png	Epoch boyunca training ve validation loss
training_validation_auc.png	Epoch boyunca training ve validation ROC-AUC
test_confusion_matrix.png	Real/Fake doğru ve yanlış sayıları
test_roc_curve.png	Test ROC eğrisi ve ROC-AUC
test_precision_recall_curve.png	Test precision-recall eğrisi ve PR-AUC

save_figure fonksiyonu her görseli 150 dpi ile kaydeder, dosyanın gerçekten oluştuğunu kontrol eder ve Pillow ile piksel boyutunu açarak kısa kenarın en az 600 px olmasını zorunlu tutar. Tam olarak 5 standart grafik beklenir; eksik veya düşük çözünürlüklü grafik final aşamayı durdurur. Grafik başlıkları ve eksenleri İngilizcedir.

12. Final Audit ve Deney Bütünlüğü

Son hücre training_state.json içinden best validation metriğini ve tamamlanan epoch sayısını okur; bunların finite olduğunu doğrular. run_summary.json içinde model, input/output path, seed, split policy, örnek sayıları, best validation AUC, seçilen threshold, image/source metrikleri ve quality gate sonuçları bir araya getirilir.

Ardından aşağıdaki zorunlu klasör ve dosyaların mevcut ve boş olmayan dosyalar olduğu kontrol edilir. Eksik çıktı varsa final audit geçmez. final_audit.json üretildikten sonra run klasöründeki her dosyanın relative_path, size_bytes ve SHA-256 değeri output_manifest.csv dosyasına yazılır. Böylece deney klasörünün bütünlüğü daha sonra denetlenebilir.

Output manifest ne işe yarar?

Bir dosya sonradan değişmiş, silinmiş veya bozulmuşsa boyut ve SHA-256 değeri üzerinden fark edilebilir. Bu, araştırma çıktılarının izlenebilirliğini güçlendirir.

13. Kodun Özellikle Önlediği Hata Türleri

Risk	Kodun aldığı önlem
Frame-level data leakage	Source-group 80/10/10 split
Aynı içeriğin farklı splitlerde olması	SHA-256 + Union-Find duplicate component
Aynı görüntüye çelişkili etiket	Hash başına label sayısı >1 ise stop
Yanlış source_video uydurma	Metadata eşleşmezse eğitim durur
Yanlış klasöre yazma	Input/output root ayrımı ve yalnız Sonuçlar altına run
Eski sonucu ezme	Benzersiz run ID + _r02, _r03 suffix
NaN/Inf ile sessiz eğitim	TerminateOnNaN + FiniteMetricsGuard
Bozuk checkpoint	Temp save -> load verify -> atomic os.replace
Keras train_on_batch sürüm farkı	return_dict=True ve scalar doğrulama
Label shape uyumsuzluğu	Etiketleri (batch,1) olarak reshape
Test ile model seçimi	Threshold yalnız validationdan, test finalde
Düşük kaliteli rapor görselleri	Kısa kenar >=600px audit

14. Tasarımın Güçlü Yönleri

- Veri sızıntısını yalnız dosya adına değil source video, kanonik manipülasyon çifti ve içerik hashine göre ele alması.
- Fiziksel split yapısını bozmadan, eğitim splitini bellekte yeniden kurması.
- Real ve Fake sınıflarını bağımsız grouped split etmesi.
- Eğitim başlamadan smoke/checkpoint/numerical kalite kapıları uygulaması.
- ImageNet transfer learningi önce frozen, sonra kontrollü partial fine-tuning ile kullanması.
- Validation ve test rollerini net biçimde ayırması.
- Kesinti sonrası devam etmeyi ve log bütünlüğünü düşünmesi.
- Her runı konfigürasyon, ortam, bağımlılık, manifest ve hashlerle izlenebilir hale getirmesi.

15. Kodun Varsayımları ve Sınırlılıkları

9. secim_metadata.csv şemasının beklenen sütunları taşıdığı ve orijinal yol içindeki parent klasörün source_video kimliği olduğu varsayılır.
10. ROI dosya adlarının benzersiz olması gerekir; duplicate filename metadata eşlemesini belirsizleştirir.
11. FF++ ve DeepFakeDetection kaynak gruplaması dosya/video adlandırma örüntülerine bağlıdır; farklı isimlendirme yapıları fallback fake_video::source_video grubuna düşer.
12. Source-level aggregation basit aritmetik ortalama olasılık kullanır; median, top-k veya temporal modelleme uygulanmaz.
13. Augmentation kaş bölgesine zarar vermemesi için sınırlıdır; daha güçlü augmentation veya ROIye özgü dönüşümler ayrıca denenebilir.
14. Bu notebook yalnız DenseNet121 baselineını ele alır; kaş bölgesinin genel deepfake potansiyeli tek modelle kesin hükme bağlanamaz.
15. Tek run seed=42 varsayılanıdır; bilimsel karşılaştırmalarda çoklu seed denemeleri ayrıca yapılmalıdır.

16. Notebook Nasıl Çalıştırılır?

16. Notebooku Google Colabda aç.
17. Runtime türünü GPU olarak seçmek önerilir; CPUda da çalışabilir ancak yavaştır.

18. Hücreleri yukarıdan aşağı Run all ile çalıştır.
19. Google Drive mount izni istenirse onayla.
20. Metadata mapping, hash-aware group build, source-group re-split, leakage ve TF.DATA PASS mesajlarını kontrol et.
21. ALL PRE-TRAINING QUALITY GATES: PASS mesajından sonra tam eğitim otomatik devam eder.
22. Frozen stage, partial fine-tune, validation threshold, final test, grafik ve audit aşamalarının tamamlanmasını bekle.
23. Sonuçları Deney 1/Sonuçlar altındaki o runa ait klasörde incele.

Beklenen kritik mesajlar:

```
Metadata mapping      : PASS
Hash-aware group build : PASS
Source-group re-split  : PASS
Accounting equality    : PASS
Exact source isolation : PASS
Source-group isolation : PASS
Content leakage        : PASS
TF.DATA PIPELINE: PASS
ALL PRE-TRAINING QUALITY GATES: PASS
```

17. Genel Değerlendirme

Stabilized V3 notebooku, kaş ROI deepfake sınıflandırmasını yalnızca model eğitimi olarak değil, deney güvenilirliği ve yeniden üretilebilirlik açısından ele alan bütünleşik bir pipeline olarak tasarlanmıştır. Kodun en ayırt edici yönü, kaynak/video bilgisi ve SHA-256 içerik hashlerini birlikte kullanarak split güvenliğini sağlaması; tam eğitime geçmeden önce kalite kapıları uygulaması; ardından iki aşamalı DenseNet121 transfer learning, validation-only threshold seçimi ve hem ROI hem source düzeyi final değerlendirme yapmasıdır.

Bu nedenle notebookun işlevi "kaş görüntülerini DenseNet121e verip bir accuracy almak"tan daha geniştir. Aynı zamanda hangi verinin işlendiğini, hangi splitte olduğunu, hangi modelin hangi ayarlarla eğitildiğini, hangi checkpointin en iyi olduğunu ve hangi çıktı dosyalarının üretildiğini sonradan doğrulanabilir hale getiren deney yönetim sistemidir.

Kısa sonuç

Kod, önceden kırpılmış kaş ROİlerini güvenli biçimde eğitime hazırlayan, DenseNet121i transfer learning ve partial fine-tuning ile eğiten, validationda threshold seçen, testte ayrıntılı metrik/grafik üreten ve bütün deneyi audit edilebilir biçimde saklayan leakage-aware bir deepfake deney notebookudur.

Ek A - Ana Konfigürasyon Özeti

Anahtar	Değer
region	eyebrow
model	DenseNet121
framework	TensorFlow/Keras
image_size	224 x 224
batch_size	16
label_mapping	real: 0, fake: 1
split_policy	source_group_80_10_10_real_fake_independent
resize_policy	resize_with_pad_preserve_aspect_ratio
model_selection_metric	val_auc
pretrained_weights	imagenet

Ek B - Ana Dosyaların Görevleri

Dosya	Amaç
model_manifest.csv	Eğitimdeki tüm ROİlerin izlenebilir metadata manifesti
source_group_split_assignment.csv	Eski fiziksel split ile yeni leakage-safe split eşlemesi
content_duplicate_clusters.csv	Aynı içeriği paylaşan source-group clusterları
leakage_check.json	Source/group/hash kesişim audit sonucu
accounting_summary.json	Toplam/SUCCESS/SKIPPED/ERROR muhasebesi
quality_gates.json	Pre-training test kapılarının sonucu
training_state.json	En iyi metric ve tamamlanan epoch bilgisi
validation_threshold.json	Youden J ile seçilen validation eşiği
final_image_level_metrics.csv	ROI düzeyi test metrikleri
final_source_level_metrics.csv	Kaynak/video düzeyi test metrikleri
test_image_predictions.csv	Her test ROI için probability ve prediction
test_source_predictions.csv	Kaynak bazında ortalama probability ve prediction
run_summary.json	Deneyin tek dosyalık özet kaydı
final_audit.json	Teslim öncesi tüm zorunlu koşulların kontrolü
output_manifest.csv	Run içindeki dosyaların boyut + SHA-256 envanteri