

Çok Bölgeli Füzyon Notebooku

Kod ve İş Akışı Açıklama Raporu

Notebook: 20260809_multi_region_calibrated_weighted_score_fusion_seed42_V4_PROVE
NANCE_FIXED.ipynb

Temel yöntem: Calibrated Weighted Score-Level Late Fusion

Seed: 42

Bu doküman, sonuçları üreten son V4 notebookunun ne yaptığını hücre grupları ve veri akışı üzerinden açıklar. Amaç kodu satır satır tekrarlamak değil; her bölümün girişini, işlemini, kontrolünü ve çıktısını teknik olarak anlaşılır biçimde göstermektir.

Özet iş akışı: Drive çözümüleme -> kaynak dosya preflight -> validation calibration -> validation AUC tabanlı ağırlık -> göz source-video provenance geri yükleme -> frame skorlarını video skoruna toplama -> strict 3-way alignment -> weighted fusion -> metrik/grafik/audit kaydı.

1. Notebookun genel mimarisi

Adım	Bölüm	İşlev
1	Environment gate	scikit-learn 1.6.1 uyumluluğunu sağlar.
2	Drive + imports	Google Drive mount edilir; numpy/pandas/sklearn/joblib/yaml vb. yüklenir.
3	SSOT YAML config	Tüm yollar ve hiperparametreler tek config bloğunda tutulur.
4	Utility functions	Atomic write, SHA256, canonical video ID, metrik ve score yardımcıları tanımlanır.
5	Shared Drive preflight	AISC shared-folder root provider ID ile çözülür; tüm girdiler var mı kontrol edilir.
6	Run initialization	Yalnız preflight geçerse yeni run klasörü oluşturulur; overwrite yapılmaz.
7-8	Environment + input audit	requirements, environment ve input manifest/hash kayıtları oluşturulur.
8	Validation calibration	Her bölge score sinyali validation etiketleriyle calibration edilir.
8	Weight estimation	Validation ROC-AUC - 0.5 güvenilirliği normalize edilerek ağırlık üretilir.
9A	Eye provenance restore	Göz için flattened frame adı secim_metadata üzerinden orijinal videoya bağlanır.
9B	Video aggregation	Kalibre frame P(fake) değerleri source_video bazında mean ile toplanır.
10	Strict alignment	Üç bölgede ortak video anahtarları denetlenir.
11	Fusion	Üç bölgesel olasılık ağırlıklı toplamla final skora çevrilir.
12-13	Evaluation + finalize	Metrikler, görseller, run summary ve output manifest üretilir.

2. Reproducible environment gate

Notebook, bölgesel modellerin kaydedildiği scikit-learn sürümüyle uyumlu çalışmak için başlangıçta scikit-learn==1.6.1 kontrolü yapar. Sürüm farklıysa gerekli sürümü kurar. Bu, joblib ile kaydedilmiş sklearn nesnelerinin farklı sürüm davranışlarından etkilenme riskini azaltır.

Ana mantık:

```
REQUIRED_SKLEARN = "1.6.1"
mevcut_sürüm != 1.6.1 ise pip install
sonra sklearn/joblib modelleri import edilir
```

3. Drive mount ve SSOT YAML konfigürasyonu

Drive mount edildikten sonra notebook bütün önemli yolları ve ayarları tek bir YAML konfigürasyonunda tanımlar. Bu yaklaşımda kaynak run klasörleri, prediction dosyaları, validation artifactleri, model dosyaları, output root, calibration yöntemi, weighting stratejisi, threshold ve figure kalite kuralları ayrı ayrı kod içine dağılmaz.

- Shared folder ID: AISC paylaşımlı klasörünü stabil provider-ID yolu üzerinden bulmak için kullanılır.
- source_runs: eyebrow, eye ve mouth için relative run dizinleri ve gerekli artifact adları.
- provenance.selection_metadata: Deney 1 Frame/secim_metadata.csv.
- calibration.method: logistic.

- weighting.strategy: validation_auc_reliability.
- fusion.final_threshold: 0.5.
- fusion.strict_alignment: true.

4. Yardımcı fonksiyonlar ve audit yaklaşımı

Fonksiyon / grup	Ne yapıyor?
atomic_write_*	CSV/JSON/YAML/text yazımını geçici dosyaya yapar, doğrular ve os.replace ile atomik biçimde finalize eder.
sha256_file	Kaynak ve çıktı dosyaları için SHA256 hash üretir.
canonical_video_id	Sınıf prefixi ve dosya uzantısı gibi farkları temizleyerek stabil video kimliği oluşturur.
normalize_binary_target	real/fake, 0/1 ve boolean benzeri etiketleri tek 0/1 forma çevirir.
positive_decision_scores	Binary SVM decision_function yönünü pozitif/FAKE sınıfına göre standartlaştırır.
positive_probability	predict_proba içinden FAKE sınıfına ait olasılığı seçer.
compute_binary_metrics	Accuracy, precision, recall, F1, specificity, confusion matrix, ROC-AUC ve AP üretir.
verify_figure	Oluşturulan grafiğin kısa kenarının en az 600 px olduğunu doğrular.

Bu tasarımın amacı yalnızca sonuç üretmek değil; sonucun nasıl üretildiğini tekrar izlenebilir ve denetlenebilir hale getirmektir.

5. Shared Drive root çözümleme ve preflight

AISC klasörü MyDrive altında sabit bir klasör gibi varsayılmaz. resolve_aisc_root() önce `.shortcut-targets-by-id//AISC DeepFake Çalışmaları` yolunu kontrol eder; yalnızca gerçekten mevcutsa kullanır. Ardından eyebrow/eye/mouth ve provenance için gereken her dosya kontrol edilir.

Önemli koruma: kaynaklardan biri eksikse output run klasörü oluşturulmadan notebook durur. Böylece hatalı bir Drive yolunda boş veya yanıltıcı sonuç klasörleri oluşmaz.

6. Run klasörü ve reproducibility kayıtları

Preflight başarılı olduğunda timestamp, yöntem adı ve seed içeren benzersiz run_id oluşturulur. Var olan bir klasör üzerine yazılmaz. Alt klasörler checkpoints, logs, metrics, predictions, figures ve artifacts şeklinde oluşturulur. config_resolved.yaml, environment.json ve requirements_lock.txt kaydedilir.

Ayrıca input_manifest.csv her kaynak artifact için path, dosya boyutu ve SHA256 değerini saklar. Bu, daha sonra aynı kaynakların kullanılıp kullanılmadığını doğrulamak için önemlidir.

7. Validation skorlarının hazırlanması ve calibration

Kaş ve göz için validation NPZ dosyalarındaki HOG, GIST ve VGG blokları kaydedilmiş scalerlar ile dönüştürülür, birleştirilir ve kaydedilmiş PCA ile indirgenir. Daha sonra RBF-SVM decision score üretilir. Ağız için kaydedilmiş PCA validation özelliklerinden modelin native fake probability değeri alınır ve logit dönüşümüne sokulur.

Her bölge için bu tek boyutlu score sinyali validation target ile bir LogisticRegression calibrator üzerinde fit edilir. Böylece üç farklı skor tipi ortak P(fake) yorumuna çevrilir.

Calibration modeli:

raw regional signal -> LogisticRegression(C=1.0, random_state=42) -> calibrated P(fake)

8. Validation-AUC reliability ağırlıkları

Calibration sonrası her bölgenin validation ROC-AUC değeri hesaplanır. Notebook reliability değerini aşağıdaki gibi kurar:

$$\text{reliability}_r = \max(\text{AUC}_r - 0.5, \text{floor})$$

$$w_r = \text{reliability}_r / \sum \text{reliability}$$

Bölge	Validation ROC-AUC	Ağırlık
Kaş	0.667	0.326
Göz	0.668	0.329
Ağız	0.677	0.345

Ağırlıkların test setinden değil validation verisinden türetilmesi, test leakage riskini önleyen en kritik tasarım kararlarından biridir.

9. Göz modeli için source-video provenance geri yükleme

Göz prediction çıktısında source_video alanı gerçek video adı yerine fake_test / real_test gibi toplu değerler içerdiği için doğrudan video-level fusion yapılamazdı. V4 notebook bunun için ayrı bir provenance restoration katmanı ekler.

- 1 secim_metadata.csv okunur ve yalnız test satırları seçilir.
- 2 dosya_adi alanının duplicate olmadığı doğrulanır.
- 3 orijinal_yol içindeki parent klasör adı orijinal source_video olarak alınır.
- 4 Göz prediction dosyasındaki resolved_output_path içinden örneğin fake_test_00000__face_00.jpg -> fake_test_00000.jpg dönüşümü yapılır.
- 5 Bu flattened dosya adı secim_metadata ile dictionary lookup üzerinden eşleştirilir.
- 6 Tahmin dosyasındaki sınıf etiketi ile provenance tablosundaki sınıf etiketi aynı mı kontrol edilir.
- 7 Restoration audit CSV dosyası kaydedilir.

Kritik özellik: Bu süreçte hiçbir satır-index veya row-order eşleştirmesi kullanılmaz. Eşleştirme dosya adı -> provenance kaydı -> orijinal yol üzerinden yapılır.

10. Test skorlarının standardizasyonu ve video-level aggregation

Her bölgenin test prediction CSV dosyası okunur. Kaş ve göz decision_score, ağız fake_probability sinyalinin calibration input üretilir; ilgili calibrator ile frame düzeyinde P(fake) hesaplanır. Daha sonra gerçek source_video kimliğine göre frame olasılıkları mean ile toplanarak video-level bölgesel skor oluşturulur.

Üretilen ana ara dosyalar:

eyebrow_standardized_frame_scores.csv / eyebrow_video_scores.csv
 eye_standardized_frame_scores.csv / eye_video_scores.csv
 mouth_standardized_frame_scores.csv / mouth_video_scores.csv

11. Strict three-way alignment

Her video için $\text{fusion_key} = \text{target} + "::" + \text{canonical_video}$ oluşturulur. Kaş, göz ve ağız key setleri karşılaştırılır. Üçlü kesişim 138 video olarak bulunmuştur. Ayrıca kaş tarafındaki tüm 138 videonun üçlü ortak kümede bulunması zorunlu tutulur; aksi durumda notebook hata verir.

Bölge / kesişim	Sayı
Kaş	138
Göz	196
Ağız	196
Üçlü kesişim	138

12. Weighted score-level late fusion

Ortak video tablosu oluşturulduktan sonra her video için üç kalibre edilmiş olasılık ağırlıklı toplanır:

$$P_{\text{fusion}} = 0.3258 \cdot P_{\text{kaş}} + 0.3287 \cdot P_{\text{göz}} + 0.3455 \cdot P_{\text{ağız}}$$

$P(\text{fusion}) \geq 0.5$ ise FAKE, aksi halde REAL kararı üretilir. Bu aşamada yeni bir meta-classifier eğitilmez; dolayısıyla yöntem score-level late fusion olarak kalır.

13. Evaluation ve figure üretimi

Nihai y_{true} ve fusion_score üzerinden threshold 0.5 ile accuracy, precision, recall, F1, specificity ve confusion matrix hesaplanır. İki sınıf bulunduğu için ROC-AUC ve Average Precision da hesaplanır.

Notebook ayrıca dört figure üretir:

- Multi-Region Fusion Confusion Matrix
- Multi-Region Fusion ROC Curve
- Multi-Region Fusion Precision-Recall Curve
- Validation-Derived Regional Fusion Weights

Her figure kaydedildikten sonra PIL ile açılır ve kısa kenarın en az 600 px olduğu doğrulanır. Bu kontrol araştırma raporunda kullanılacak görsellerin düşük çözünürlüklü kaydedilmesini engeller.

14. Final accounting ve bütünlük kontrolleri

- Beklenen common key sayısı ile fused prediction satır sayısı eşit olmalı.
- fusion_key duplicate olmamalı.
- Bölgesel olasılık ve fusion_score sütunlarında NaN olmamalı.
- Tüm olasılıklar 0-1 aralığında olmalı.
- run_summary.json içine calibration, weights, provenance ve leakage guard bilgileri yazılmalı.
- README.md ile koşunun yöntem ve güvenlik özeti oluşturulmalı.
- $\text{output_manifest.csv}$ her çıktı dosyasının SHA256 hashini içermeli.

15. Notebookun ürettiği dosya ağacı

```
run_id/
config_resolved.yaml
environment.json
requirements_lock.txt
README.md
run_summary.json
output_manifest.csv
checkpoints/
logs/fusion.log
metrics/
validation_region_reliability.csv
fusion_weights.json
fusion_test_metrics.json
predictions/
fused_video_predictions.csv
figures/
confusion_matrix_....png
roc_curve_....png
precision_recall_curve_....png
regional_weights_....png
artifacts/
input_manifest.csv
regional_calibrators.joblib
eye_source_video_provenance_map.csv
eye_source_video_restoration_audit.csv
*_standardized_frame_scores.csv
*_video_scores.csv
alignment_audit.json / .csv
```

16. Neden bu kod yapısı güvenilir?

- Reproducibility: seed, environment ve requirements kayıtlıdır.
- Single source of truth: kritik ayarlar tek YAML config içindedir.
- Leakage guard: test verisi calibration veya ağırlık seçimine girmez.
- Provenance: göz kimliği gerçek kaynak metadata ile geri yüklenir.
- Strict alignment: video kimlikleri eşleşmeden fusion yapılmaz.
- Auditability: input/output manifest ve SHA256 kayıtları vardır.
- Fail-fast: dosya, label, duplicate, NaN, range veya alignment sorunu varsa notebook sonuç üretmeden durur.

Bu nedenle notebook yalnızca bir füzyon hesabı yapan script değil; veri kökeni, deney ayrımı, kaynak bütünlüğü ve çıktı denetimi dahil olmak üzere araştırma deneyinin tamamını izlenebilir kılan bir pipeline olarak tasarlanmıştır.

17. Sonuç üreten kritik parametreler

Parametre	Değer / Anlam
seed	42
calibration	Logistic calibration
weighting	validation_auc_reliability
frame-to-video aggregation	mean
final threshold	0.5
strict alignment	true
minimum common videos	20
actual common videos	138
row-order matching	false
test used for calibration / weights / threshold	false / false / false

Kaynak: son V4 notebook kodu ve koşunun run_summary/alignment audit çıktıları.