DenseNet121_Goz_ROI_Kod_Aciklama_Raporu.pdf - local repository text copy

DENSENET121 GÖZ ROI DEEPFAKE SINIFLANDIRMA

Kod Açıklama ve Deney Analizi Raporu

Raporun amacı

Bu doküman, DenseNet121_Eye_Deepfake_Colab_REVISED notebookundaki veri hazırlama, kalite kontrolleri, model mimarisi, iki aşamalı eğitim, eşik seçimi, test değerlendirmesi, checkpoint ve çıktı üretim mantığını ekip arkadaşlarının kodu okumadan da anlayabileceği şekilde açıklar.

Başlık	Değer
Problem	Göz bölgesinden (combined eye ROI) real/fake deepfake ikili sınıflandırması
Ana model	ImageNet ön-eğitimli DenseNet121
Framework	TensorFlow / Keras
Girdi	224 × 224 × 3 RGB combined eye ROI
Çıktı	Tek sigmoid olasılığı: P(fake)
Etiketleme	real = 0, fake = 1
Seed	42
Eğitim yaklaşımı	Transfer learning: frozen backbone + kısmi fine-tuning
Run	20260808_1214_eye_densenet121_seed42

1. Projenin ve Notebookun Genel Mantığı

Bu notebook, daha önce çıkarılmış göz bölgelerini doğrudan sınıflandırma girdisi olarak kullanır. Amaç, yalnızca göz ROI görüntüsüne bakarak bir örneğin gerçek (real) veya manipüle edilmiş/sahte (fake) olup olmadığını tahmin etmektir. Notebook yalnızca model eğitimi yapmaz; veri yolunun doğruluğunu, metadata tutarlılığını, train/validation/test ayrımını, içerik tekrarlarını, checkpoint bütünlüğünü ve nihai raporlama çıktılarının varlığını da kontrol eden çok aşamalı bir deney hattı kurar.

Pipeline özeti

local source package ve klasör doğrulama → Metadata keşfi ve şema kontrolü → SUCCESS/OK kayıtlarının kanonikleştirilmesi → combined_eye_path çözümleme → split ve SHA-256 sızıntı kontrolleri → tf.data veri hattı ve augmentation → ImageNet DenseNet121 transfer learning → 2 batch smoke test → frozen eğitim → conv5 kısmi fine-tuning → validation üzerinde Youden J eşik seçimi → bağımsız test → image-level ve source-level metrikler → final audit ve ZIP export.

2. Veri Yapısı ve Metadata Yönetimi

Notebook, göz deneyinin sabit local source dizinini kullanır: AISC DeepFake Çalışmaları / Deneyler / Kader / Deney 1 / Göz / eye_roi_output. Sonuçlar aynı Deney 1 klasörü altındaki Sonuçlar dizinine yazılır. Böylece girdi ve deney çıktıları birbirinden ayrılır.

Kontrol	Uygulanan yöntem	Amaç
Status normalizasyonu	OK → SUCCESS, NO_FACE → SKIPPED; bilinmeyen durumlar hata üretir.	Başarılı/atlanmış/hatalı örneklerin muhasebesini korumak
Path resolution	combined_eye_path; absolute/relative yol ve taşınmış local source klasörleri için yeniden çözümleme	Metadata yolu değişse bile gerçek görüntüyü bulmak

DenseNet121 Eye ROI Deepfake - Kod Açıklama Raporu | Sayfa

Kontrol	Uygulanan yöntem	Amaç
Canonical sample_id	Çakışan/boş sample_id değerleri SHA-256 tabanlı deterministik kimlikle onarılır	Her örneği benzersiz ve tekrarlanabilir tanımlamak

Split kayıtları train / val / test için ayrı path, label ve
sample_id listeleri
Model veri hattını metadata üzerinden
kurmak
Accounting equality Toplam = success + skipped + error Veri kaybını veya sessiz atlamayı
yakalamak
3. Çalıştırılan Veri Setinin Sayısal Özeti
Split Real Fake Toplam
Train 1.197 1.191 2.388
Validation 155 141 296
Test 146 156 302
Toplam kullanılabilir 1.498 1.488 2.986
Metadata toplamında 3.097 kayıt bulunmaktadır. Bunların 2.986 tanesi OK/SUCCESS olarak kullanılabilir,
111
tanesi NO_FACE nedeniyle SKIPPED kabul edilmiştir ve bu run çıktısında ERROR sayısı 0'dır. Sınıf dağılımı

özellikle eğitim kümesinde oldukça dengelidir; bu nedenle notebook ayrıca sınıf ağırlığı uygulamaz.
4. Veri Sızıntısını Önleme ve Bütünlük Kontrolleri
Notebookun en güçlü yönlerinden biri, yalnızca dosya adına güvenmemesi ve iki ayrı sızıntı katmanı
kullanmasıdır.
Birincisi source_video düzeyinde split izolasyonu, ikincisi görüntü içeriğinin SHA-256 hash değerine göre
split
izolasyonudur.
Kalite kapısı Ne kontrol edilir? Bu run sonucu
sample_id benzersizliği Kanonik örnek kimlikleri tekrar ediyor
mu? 2.986 / 2.986 benzersiz
Dosya varlığı SUCCESS görüntüleri gerçekten diskte
var mı? PASS
Source-video leakage Aynı source_video farklı splitlerde mi? train-val=0, train-test=0, val-test=0
Content-hash leakage Aynı piksel içeriğine sahip dosya farklı
splitlerde mi? Tüm karşılaştırmalarda 0
SHA-256 cache Hash hesapları kesinti sonrası tekrar
kullanılabilir mi? sha256_cache.csv ile resume edilebilir
Neden SHA-256?
İki dosyanın adı farklı olsa bile içerikleri birebir aynıysa hash değeri aynı olur. Bu nedenle yalnızca
path veya filename
kontrolüyle yakalanamayabilecek içerik tekrarları da sızıntı kontrolüne dahil edilir.
5. Görüntü Ön İşleme ve tf.data Veri Hattı
Görüntüler TensorFlow tf.data üzerinden okunur. Her görüntü 3 kanallı RGB biçiminde decode edilir,
224×224
piksele bilinear interpolation ve antialiasing ile yeniden boyutlandırılır ve DenseNet121'in
preprocess_input
fonksiyonundan geçirilir. Validation ve test verisine augmentation uygulanmaz.
Augmentation Parametre Yalnızca Train?
Horizontal flip RandomFlip(horizontal) Evet
Rotation factor = 0.03 Evet
Zoom height/width = -0.08…0.08 Evet
Translation height/width = 0.04 Evet
Contrast factor = 0.10 Evet
Resize 224×224, bilinear + antialias Tüm splitler

Augmentation Parametre Yalnızca Train?
DenseNet preprocessing keras.applications.densenet.preprocess
_input Tüm splitler
Train dataset shuffle edilir (seed=42, her epoch yeniden karıştırma açık), batch boyutu
16'dır ve pipeline
AUTOTUNE ile parallel map + prefetch kullanır. Validation ve test sıralaması deterministik tutulur; bu,
tahminlerin
manifest sırasıyla eşleştirilebilmesini kolaylaştırır.
6. Kullanılan Model: DenseNet121
Model bir CNN tabanlı transfer learning modelidir. DenseNet121, ImageNet ağırlıklarıyla
include_top=False
şeklinde yüklenir; yani ImageNet'in orijinal 1000 sınıflı sınıflandırma başlığı kullanılmaz. Bunun yerine
göz ROI
deepfake problemi için yeni bir ikili sınıflandırma başlığı eklenir.
Bileşen Açıklama
Backbone ImageNet-pretrained DenseNet121, include_top=False
Girdi 224 × 224 × 3 RGB eye ROI
Feature pooling GlobalAveragePooling2D

Regularization Dropout = 0.40
Çıkış katmanı Dense(1, activation="sigmoid")
Çıkış yorumu 0'a yakın = real, 1'e yakın = fake
Loss BinaryCrossentropy
Optimizer Adam
Model selection Validation ROC-AUC (val_auc) maksimum
Mixed precision mixed_float16; final sigmoid output float32
Parametre durumu Değer
Toplam parametre 7.038.529
Frozen aşamada trainable 1.025
Frozen aşamada non-trainable 7.037.504
Fine-tuning aşamasında trainable 2.130.945
Fine-tuning aşamasında non-trainable 4.907.584
Frozen aşamadaki 1.025 trainable parametre, DenseNet121 backbone donukken yalnızca yeni sigmoid sınıflandırma başlığının öğrenildiğini gösterir. Fine-tuning aşamasında ise son DenseNet bloğunun bir bölümü açıldığı için eğitilebilir parametre sayısı yaklaşık 2,13 milyona çıkar.

7. Neden İki Aşamalı Eğitim Kullanılıyor?

7.1 Aşama 1 - Frozen Backbone

İlk aşamada DenseNet121'in bütün backbone katmanları dondurulur. Yalnızca yeni classification head eğitilir.
Öğrenme oranı 1e-3, maksimum epoch sayısı 12'dir. Bu aşama, ImageNet'ten gelen genel görsel özellikleri hemen bozmak yerine önce yeni göreve uygun karar katmanını oturtmayı hedefler.

7.2 Aşama 2 - Partial Fine-Tuning

Frozen aşamasında elde edilen en iyi checkpoint tekrar yüklenir. Ardından DenseNet121'in yalnızca final dense block'u olan conv5_block1…conv5_block16 katmanları açılır. BatchNormalization katmanları özellikle frozen tutulur. Fine-tuning öğrenme oranı 1e-5'tir ve maksimum 20 epoch çalışır. Bu aşamada model, genel ImageNet özelliklerini göz bölgesindeki deepfake ipuçlarına daha fazla uyarlayabilir.

Aşama	LR	Maks. epoch	Trainable alan	Model seçim ölçütü
Frozen	1e-3	12	Yalnızca classification head	val_auc
Fine-tuning	1e-5	20	conv5 final block + head; BN frozen	val_auc

8. Eğitim Güvenliği, Checkpoint ve Resume Mekanizması

Notebook model eğitimini doğrudan başlatmadan önce iki batchlik bir smoke test yapar. Gradientlerin varlığı ve finite olması, optimizer step sayısının iki artması, kaydedilen modelin yeniden yüklenmesi, reload sonrası loss ve tahminlerin eşleşmesi kontrol edilir. Smoke test sonunda gerçek eğitim başlamadan önce model ağırlıkları ve optimizer temiz duruma geri alınır.

Mekanizma	Görevi
AtomicModelCheckpoint	best.keras ve last.keras dosyalarını atomik biçimde günceller
BackupAndRestore	Epoch bazlı eğitim kurtarma yedeği tutar
CSVLogger	Frozen ve fine-tuning eğitim loglarını CSV olarak saklar
ReduceLROnPlateau	val_loss gelişmezse LR'yi 0.5 katsayısıyla düşürür
EarlyStopping	val_auc gelişmezse eğitimi durdurur; gerçek callback patience=4
TerminateOnNaN	NaN loss oluşursa eğitimi sonlandırır
FiniteMetricsGuard	Epoch metriklerinde NaN/Inf varsa hata üretir

Kod inceleme notu

CELL 1 içindeki CONFIG alanında early_stopping_patience = 5 tanımlı olmasına rağmen frozen ve fine-tuning callbacklerinde patience değeri doğrudan 4 olarak yazılmıştır. Yani çalıştırılan eğitimde fiilen kullanılan patience 4'tür.
Bu, Single Source of Truth yaklaşımı açısından ileride CONFIG üzerinden bağlanabilecek küçük bir tutarsızlıktır.

9. Kullanılan Eğitim Metrikleri

Keras eğitim sırasında BinaryAccuracy, Precision, Recall, ROC-AUC ve PR-AUC metriklerini izler. Model seçiminde temel ölçüt validation ROC-AUC'dur. Bu tercih, karar eşiğine bağlı tek bir accuracy değerinden ziyade modelin sınıfları olasılık düzeyinde ayırma yeteneğini izlemeye yarar.

Metrik	Notebooktaki rolü
Accuracy	Genel doğru sınıflandırma oranı
Precision	Fake dediğinde ne kadar doğru olduğunu ölçer
Recall	Gerçek fake örneklerin ne kadarını yakaladığını ölçer
ROC-AUC	Model seçimi ve genel ayırma gücü için ana metrik
PR-AUC	Özellikle pozitif/fake sınıf performansını tamamlayıcı olarak izler
F1-score	Final testte precision-recall dengesi
Specificity	Real sınıfı doğru reddetme gücü
Balanced Accuracy	Sınıf başına başarımı dengeli özetler
MCC	Karışıklık matrisi temelli dengeli korelasyon metriği

10. Threshold Seçimi ve Test Protokolü

Modelin sigmoid çıktısı doğrudan sınıf değildir; önce bir fake olasılığı üretir. Notebook 0.5'i otomatik kabul etmek yerine karar eşiğini yalnızca validation seti üzerinde ROC eğrisinden Youden J = TPR - FPR maksimum olacak şekilde seçer. Test seti eşik seçiminde kullanılmaz; seçilen eşik daha sonra bağımsız teste uygulanır.

Öğe	Bu run değeri
Seçim seti	Validation
Yöntem	Youden J
Seçilen threshold	0.468565
Validation ROC-AUC	0.738321
Validation F1	0.706949
Test eşik seçiminde kullanıldı mı?	Hayır

11. Nihai Test Sonuçları

11.1 Image-Level Test

Metrik	Değer
Sample count	302
Accuracy	0.602649
Balanced Accuracy	0.596944
Precision	0.588235
Recall	0.769231
Specificity	0.424658
F1-score	0.666667
ROC-AUC	0.667896
PR-AUC	0.708702
MCC	0.206948
Confusion Matrix	TN=62, FP=84, FN=36, TP=120

Bu sonuçlarda recall (0.769) specificity'den (0.425) belirgin biçimde yüksektir. Yani seçilen threshold, fake örnekleri yakalamaya daha eğilimli; bunun karşılığında real örneklerin bir bölümünü fake olarak işaretlemektedir. ROC-AUC 0.668 düzeyinde olduğu için model ayrım sinyali öğrenmiştir ancak performans hâlâ geliştirmeye açıktır.

11.2 Source/Video-Level Test

Notebook aynı source_video içindeki birden fazla ROI'nin fake olasılığını ortalayıp source-level tahmin üretir. Bu run'da source-level test sample_count yalnızca 2'dir. Bu nedenle source-level ROC-AUC=1.0 ve PR-AUC=1.0 gibi değerler istatistiksel olarak güvenilir bir genel performans göstergesi olarak yorumlanmamalıdır; örnek sayısı çok küçüktür.

Metrik	Değer
Source count	2
Accuracy	0.500000
Recall	1.000000
Specificity	0.000000
F1-score	0.666667
ROC-AUC	1.000000*
PR-AUC	1.000000*

12. Eğitimde Elde Edilen En İyi Model

Öğe	Değer
Global best stage	Fine-tuning
Global best epoch	32
Best validation ROC-AUC	0.738710
Fine-tuning trainable layers	80 non-BN conv5 layers
Frozen BatchNorm layers	32
Checkpoint	checkpoints/best.keras

Frozen eğitim sonrası fine-tuning performansı iyileştirmiş ve global en iyi checkpoint fine-tuning

aşamasının 32.
epochunda elde edilmiştir. Bu, son DenseNet bloğunun kontrollü biçimde açılmasının validation AUC açısından
katkı sağladığını gösterir.
13. Üretilen Çıktılar ve Dosya Yapısı
Klasör/Dosya İçerik
checkpoints/ best.keras, last.keras, training backup ve smoke checkpoint
logs/ Frozen ve fine-tuning CSV training logları
metrics/ Training history, image/source metrics, classification report,

Klasör/Dosya İçerik
threshold JSON, final summary
predictions/ Test image predictions ve source-level predictions
figures/ Training curves, confusion matrices, ROC/PR curves,
probability distribution
metadata/ canonical manifest, model_manifest, leakage_check,
SHA-256 cache, accounting summary
config_resolved.yaml Çalıştırmada kullanılan çözülmüş deney/model konfigürasyonu
requirements_snapshot.txt Çalışma anındaki kütüphane sürümleri
RUN_SUMMARY.txt İnsan tarafından okunabilir deney özeti
ZIP export Run klasörünün teslim/arsiv için paketlenmiş hali
14. Cell-by-Cell Kısa Rehber
Cell İşlev
1 Environment, seed, CONFIG ve GPU kontrolü
2-3 local source mount ve hızlı local source görünürlük kontrolleri
4 Gerçek göz deney yolu ve Sonuçlar dizini
6 / CELL 3 Metadata auto-discovery ve zorunlu şema kontrolü
7 / CELL 4 Status normalizasyonu, path resolution, canonical ID, split kayıtları ve run dizinleri
8 / CELL 5 tf.data, resize, augmentation ve DenseNet preprocessing
9-11 Source/sample audit, split leakage precheck ve metadata özetleri
12 / CELL 9 SHA-256 manifest ve source/hash leakage quality gates
13 / CELL 10 DenseNet121 modelinin kurulması
14 / CELL 11 İki batch smoke test + checkpoint reload testi
15 / CELL 12 Frozen-backbone training
16 / CELL 13 Partial conv5 fine-tuning
17 / CELL 14 Validation threshold seçimi + bağımsız test + grafikler
19 Recovery cell
20 / CELL 15 Final audit, clean-load inference, dependency snapshot ve ZIP export
21-22 Figure quality ve final notebook state check
15. Kodun Güçlü Yönleri
☐ Veri ve model akışı yalnızca eğitime odaklanmıyor; metadata, path, duplicate, hash ve split kontrolleri bulunuyor.
☐ Test seti threshold seçimi için kullanılmıyor; validation ve test rolleri ayrılmış durumda.
☐ ImageNet ön-eğitimli DenseNet121 transfer learning ile kullanılıyor ve önce frozen, sonra kontrollü partial fine-
tuning uygulanıyor.
☐ BatchNormalization katmanlarının fine-tuning sırasında frozen tutulması açıkça kontrol ediliyor.
☐ Atomic best/last checkpoint, BackupAndRestore ve smoke test sayesinde kesinti ve bozuk checkpoint riskleri
azaltılıyor.
☐ SHA-256 cache, uzun hash sürecini tekrar başlatmak yerine resume etmeye izin veriyor.
☐ Final clean-load inference testi, kaydedilen best.keras dosyasının gerçekten bağımsız biçimde yüklenip tahmin
ürettiğini doğruluyor.
☐ Grafiklerin minimum 600 px kısa kenar şartı ayrıca kalite kapısı olarak kontrol ediliyor.
16. Teknik İnceleme Notları / İyileştirme Noktaları
Konu Gözlem Öneri
SSOT tekrarı
IMAGE_HEIGHT=224 ve
BATCH_SIZE=16 CELL 5 içinde tekrar
sabitlenmiş; MODEL_CONFIG içinde de
CONFIG değerlerini doğrudan referans
ederek tek doğruluk kaynağını
güçlendirmek.

Konu	Gözlem	Öneri
	bazı değerler tekrar yazılmış.	
Early stopping	CONFIG patience=5 iken callback içinde 4 kullanılıyor.	patience=int(CONFIG["early_stopping_patience"]) kullanmak.
Source-level test	Nihai testte yalnızca 2 source_video var.	Video/source-level performans için daha fazla bağımsız kaynak ile split yapısını gözden geçirmek.
Test performansı	Image-level ROC-AUC 0.668; specificity 0.425.	ROI kalite filtresi, daha güçlü augmentasyon/regularization denemeleri veya farklı backbone karşılaştırması düşünülebilir.
Notebook yardımcı hücreleri	local source teşhisi için ek hücreler notebookta kalmış.	Final paylaşım sürümünde yalnızca üretim akışında gerekli cell'leri bırakmak.

17. Arkadaşlara 1 Dakikalık Anlatım

Kısa anlatım

Bu deneyde göz bölgesinden çıkarılmış combined eye ROI görüntülerini kullanarak real/fake sınıflandırması yapıyoruz. Ana modelimiz ImageNet ön-eğitimli DenseNet121. Önce backbone tamamen frozen şekilde sadece yeni sigmoid başlığı eğitiliyor, sonra DenseNet'in son conv5 bloğu açılarak düşük learning rate ile fine-tuning yapılıyor; BatchNorm katmanları frozen kalıyor. Train verisine kontrollü augmentation uygulanıyor, validation ve test verisine uygulanmıyor. Veri sızıntısını önlemek için hem source_video hem de SHA-256 görüntü içeriği seviyesinde train/val/test kesişimi kontrol ediliyor. En iyi model val_auc'a göre seçiliyor. Karar threshold'u testten değil validation setinden Youden J ile belirleniyor ve son olarak bağımsız testte image-level ve source-level metrikler raporlanıyor.

Tüm checkpointler, manifestler, metrikler, tahminler ve grafikler run bazlı klasörlerde saklanıyor.

18. Sonuç

Notebook, göz ROI tabanlı deepfake sınıflandırmasını yalnızca bir CNN eğitimi olarak değil, tekrarlanabilir ve denetlenebilir bir deney hattı olarak ele alıyor. DenseNet121 transfer learning, iki aşamalı eğitim, validation tabanlı threshold seçimi, source/hash leakage quality gates, atomik checkpoint ve clean-load testleri kodun ana yöntemleridir. Bu run'da validation ROC-AUC yaklaşık 0.739, bağımsız image-level test ROC-AUC yaklaşık 0.668 ve F1 yaklaşık 0.667 elde edilmiştir. Buna karşın source-level testin yalnızca iki kaynaktan oluşması nedeniyle o seviyedeki metrikler genellenebilir performans olarak yorumlanmamalıdır.