Goz_SwinV2_Tiny_Kod_Raporu.pdf - local repository text copy

Deepfake Detection - Eye ROI / Swin V2 Tiny
Kader - Deney 1 | Kod ve Yöntem Analiz Raporu
DEEPFAKE DETECTION
Eye ROI - Swin V2 Tiny Baseline
Kod, Model ve Yöntem Analiz Raporu
Rapor Alanı Değer
Deney Kader - Deney 1
Bölge Combined Eye ROI
Model Torchvision Swin V2 Tiny (swin_v2_t)
Görev Real / Fake ikili sınıflandırma
Notebook Deney1_Eye_SwinV2_Tiny_Baseline_v3_Stabilized
Tarih 7 Ağustos 2026
Raporun kapsamı
Bu doküman eğitim sonucu raporu değildir. Notebook kodunun tasarımını, model mimarisini, hiperparametrelerini,
veri akışını, güvenlik kontrollerini ve bu seçimlerin teknik gerekçelerini açıklar. Notebook çalıştırılmadan elde
edilmeyen accuracy/AUC gibi sonuçlar burada uydurulmamıştır.
Deepfake Detection - Eye ROI / Swin V2 Tiny
Kader - Deney 1 | Kod ve Yöntem Analiz Raporu
İçindekiler
1. Yönetici Özeti
2. Deneyin Amacı ve Hipotezi
3. Model: Swin V2 Tiny Nedir?
4. Neden Swin V2 Tiny Seçilmiştir?
5. Modelin Notebook İçindeki Özelleştirilmesi
6. Veri Girişi, Metadata ve Leakage Denetimi
7. Ön İşleme ve Data Augmentation
8. Eğitim Hiperparametreleri ve Gerekçeleri
9. Loss, Optimizer ve Scheduler
10. FP32 / Mixed Precision Kararı
11. Eğitim Döngüsü, Model Seçimi ve Threshold
12. Checkpoint, Resume ve Reproducibility
13. Smoke Test ve Kalite Kapıları
14. Metrikler, Tahminler ve Grafikler
15. Modüler Kod Mimarisi
16. Güçlü Yönler, Sınırlılıklar ve Dikkat Noktaları
17. ML Kod Standardına Uyum
18. Sonuç
Ek A. Tam Konfigürasyon Özeti
Ek B. Modül ve Fonksiyon Haritası
Deepfake Detection - Eye ROI / Swin V2 Tiny
Kader - Deney 1 | Kod ve Yöntem Analiz Raporu
1. Yönetici Özeti
Bu notebook, daha önce çıkarılmış combined-eye ROI görüntülerini kullanarak gerçek ve sahte örnekleri ayırmak için ImageNet ön-eğitimli Swin V2 Tiny modelini fine-tune eden bir baseline deneyidir. Kod yalnızca
model eğitimi yapmaz; veri şeması, dosya varlığı, split izolasyonu, sayısal kararlılık, checkpoint bütünlüğü,
kaldığı yerden devam, final inference ve çıktı kalite kontrollerini de deney akışının parçası haline getirir.
☐ Girdi: metadata.csv içindeki combined_eye_path ile işaret edilen 224x224 göz ROI görüntüleri.
☐ Model: torchvision.models.swin_v2_t, ImageNet-1K pretrained backbone.
☐ Sınıflandırıcı: 768 boyutlu Swin özelliği -> LayerNorm -> Dropout(0.20) -> Linear(1).
☐ Kayıp: BCEWithLogitsLoss; FAKE pozitif sınıf, pos_weight yalnızca train dağılımından hesaplanır.
☐ Optimizer: AdamW; backbone LR=1e-5, yeni head LR=1e-4.
☐ Scheduler: CosineAnnealingLR; üst sınır 20 epoch, early stopping patience=6.
☐ Kararlılık: varsayılan mixed_precision=False, gradient clipping=1.0, FP32 smoke test ve NaN/Inf hard-fail.
☐ Model seçimi: validation ROC-AUC; threshold seçimi: validation F1; test yalnızca final değerlendirmede kullanılır.
2. Deneyin Amacı ve Hipotezi
Deneyin amacı, tüm yüz yerine yalnızca göz bölgesinden çıkarılmış ROI görüntülerinin, transformer tabanlı

bir görüntü modeliyle deepfake ayrımı için ne kadar bilgi taşıdığını ölçebilecek güvenilir bir baseline oluşturmaktır. Combined-eye ROI kullanılması iki gözün aynı örnekte tutulmasını sağlar; böylece model yalnızca lokal bir göz dokusuna değil, iki göz arasındaki simetri, ortak ışık yapısı, kenar ve doku

ilişkileri gibi
bölgesel örüntülere de erişebilir.
Hipotez
Swin V2 Tiny, göz ROI içindeki lokal ve orta ölçekli yapıları hiyerarşik shifted-window attention ile temsil ederek
real/fake ayrımına yarayan görsel tutarsızlıkları öğrenebilir. Bu notebook bu hipotezi test etmek için baseline sağlar;
tek başına Swin V2 Tiny'nin diğer mimarilerden üstün olduğunu kanıtlayan bir model karşılaştırması içermez.
3. Model: Swin V2 Tiny Nedir?
Swin Transformer, görüntüyü küçük patch'lere ayırıp attention işlemini tüm görüntü üzerinde küresel olarak
yapmak yerine yerel pencerelerde uygular. Ardışık bloklarda pencerelerin kaydırılması (shifted windows), farklı pencerelerdeki tokenların bilgi paylaşmasını sağlar. Mimari hiyerarşiktir: ilerleyen stage'lerde uzamsal
çözünürlük azalırken kanal/özellik boyutu artar. Bu nedenle CNN'lerdeki çok ölçekli özellik piramidine benzer
bir temsil üretirken self-attention mekanizmasının bağlamsal gücünü korur.
Notebook torchvision'un Swin V2 Tiny uygulamasını kullanır. Teknik arka plan açısından torchvision yapılandırması patch_size=4x4, embed_dim=96, stage depth=[2,2,6,2], attention head=[3,6,12,24] ve window_size=8x8'dir. Orijinal ImageNet sınıflandırma başlığı 1000 sınıflıdır; notebook bu başlığı kaldırıp ikili
deepfake görevi için tek logit üreten yeni bir head ekler.
Özellik Swin V2 Tiny yapılandırması
Girdi ölçeği Notebook: 224 x 224
Patch boyutu 4 x 4
İlk embedding 96 kanal
Stage derinlikleri 2 / 2 / 6 / 2 blok
Attention head sayıları 3 / 6 / 12 / 24
Window 8 x 8
Backbone çıkışı 768 özellik
Torchvision özgün parametre 28,351,570
Notebook özelleştirilmiş yaklaşık parametre 27,584,875

Şekil 1. Notebook içindeki Swin V2 Tiny ikili sınıflandırma akışı.
4. Neden Swin V2 Tiny Seçilmiştir?
Notebook içinde "alternatif modelleri tarayıp Swin'in en iyi olduğunu ispatlayan" bir hiperparametre/model
seçimi yoktur. Bu nedenle model seçimi deneysel bir üstünlük iddiası değil, teknik ve proje bağlamlı bir baseline kararıdır.
Gerekçe Açıklama
Göz ROI için yerel attention
Göz ROI'de iris, sclera, göz kapağı, kenar ve üretim artefaktları lokal bölgelerde bulunabilir. Window attention bu
lokal yapıları verimli işler.
Pencereler arası bağlam
Shifted windows, farklı lokal bölgelerin zamanla birbirine bilgi aktarmasını sağlar; iki gözlü combined ROI için
yararlıdır.
Hiyerarşik temsil
Farklı ölçeklerde özellik çıkarımı, yalnızca tek piksel dokusu değil daha geniş şekil/konum ilişkilerini de yakalamayı
destekler.
Transfer learning ImageNet pretrained ağırlıklar, sınırlı alan verisinde sıfırdan öğrenmeye göre daha güçlü başlangıç temsili sağlar.
Tiny varyant Swin ailesinin daha küçük varyantıdır; Colab/GPU belleği ve eğitim maliyeti ile temsil gücü arasında pratik denge sunar.
Baseline değeri
Sonraki texture-fusion çalışmalarında Transformer kolunun tek başına performansını ölçmek için temiz bir karşılaştırma
noktası oluşturur.
5. Modelin Notebook İçindeki Özelleştirilmesi
Kod, pretrained Swin V2 Tiny modelinin head katmanını nn.Identity() ile çıkarır. Backbone artık sınıf skorları
yerine 768 boyutlu özellik vektörü üretir. Bunun üzerine yeni ikili sınıflandırıcı eklenir: LayerNorm -> Dropout(0.20) -> Linear(768,1).

☐ LayerNorm: Transformer özelliklerinin ölçeğini dengeler ve yeni sınıflandırıcıya daha düzenli giriş sağlar.
☐ Dropout 0.20: Head'in eğitim örneklerini ezberlemesini azaltmak için orta düzey düzenlileştirme uygular.
☐ Linear(768,1): İkili sınıflandırma için tek logit üretir. Sigmoid model forward içinde uygulanmaz; olasılık
gerektiğinde sonradan sigmoid kullanılır.
Neden tek logit?
BCEWithLogitsLoss tek logitli binary classification için uygundur ve sigmoid + binary cross entropy işlemlerini sayısal
olarak daha kararlı biçimde birleştirir.
6. Veri Girişi, Metadata ve Leakage Denetimi
Notebook yeni ROI üretmez; upstream eye_roi_output/metadata.csv dosyasını tüketir. Temel eğitim şeması sample_id, video_id, label, split, status ve combined_eye_path alanlarını zorunlu tutar. Başarılı kayıtlar
status="ok" ile filtrelenir. Boş path, eksik dosya, beklenmeyen label/split, mükerrer sample_id, aynı video
kimliğinin birden fazla label veya splitte görülmesi hard-fail ile eğitimi durdurur.
☐ Mevcut train/val/test split yeniden üretilmez; upstream ayrım korunur.
☐ train/val/test video_id kümeleri için isdisjoint kontrolü yapılır.
☐ SSOT standardındaki eksik kolonlar uydurulmaz; metadata_schema_audit.json içinde raporlanır.
☐ video_id değerlerinin gerçek kaynak videoyu temsil edip etmediği ayrıca denetlenir. Eğer değerler fake_train /
real_test gibi kaba label-split kovaları görünümündeyse video-level metric yayınlanmaz.
Önemli metodolojik sınır
video_identity_reliable=False çıkarsa kod frame-level eğitimi sürdürebilir; ancak gerçek source-video düzeyinde
leakage bağımsız olarak kanıtlanmış sayılmaz. Bu durumda notebook yanıltıcı per-video sonuç üretmemeyi tercih
eder.
7. Ön İşleme ve Data Augmentation

Parametre	Değer	Neden
ROI	Combined eye	İki gözü tek örnekte tutup bölgesel/simetrik bağlamı korumak.
Resize	224 x 224	Swin V2 Tiny pretrained kullanımına uygun standart görüntü ölçeği.
Horizontal flip	p=0.50	Sağ-sol yönüne aşırı bağımlılığı azaltmak.
Rotation	±5°	Küçük ROI hizalama ve baş açısı farklarına dayanıklılık; artefaktları bozmamak için düşük şiddet.
Brightness	0.10	Hafif ışık değişimlerine dayanıklılık.
Contrast	0.10	Kamera/aydınlatma kontrast farklarına tolerans.
Saturation	0.05	Renk doygunluğundaki küçük değişimleri tolere etmek.
Hue	0.02	Çok sınırlı renk tonu değişimi; forensic izleri agresif biçimde bozmamak.
Normalization	ImageNet weights mean/std	Pretrained backbone'un beklediği giriş dağılımını korumak; val/test'ten istatistik öğrenilmez.

Augmentation yalnızca train setine uygulanır. Validation ve test sadece resize + normalization kullanır. Böylece değerlendirme sırasında rastlantısal transform eklenmez ve ölçüm tekrarlanabilir kalır.

8. Eğitim Hiperparametreleri ve Gerekçeleri

Hiperparametre	Değer	Teknik gerekçe / yorum
Epoch üst sınırı	20	Tek bir kesin "doğru epoch" iddiası yoktur. 20, fine-tuning için makul bir üst sınırdır; early stopping 6 ile gereksiz uzun eğitim engellenir.
Early stopping patience	6	Validation skoru iyileşmeden 6 epoch bekleyerek küçük dalgalanmalara tolerans verir, uzun overfit sürecini keser.

Batch size 32
224x224 Swin Tiny için GPU
throughput/bellek arasında pratik
denge.
Backbone LR 1e-5 Pretrained temsilleri agresif biçimde
bozmadan yavaş fine-tuning.
Head LR 1e-4
Yeni eklenen sınıflandırıcı sıfırdan
öğrendiği için backbone'dan 10 kat
daha hızlı güncellenir.
Weight decay 1e-2 AdamW ile parametre büyümesini
sınırlayan düzenlileştirme.
Gradient clipping 1.0 Transformer gradient patlamasına
karşı global norm sınırı.
Dropout 0.20 Yeni head'de overfitting riskini
azaltmak için.
Seed 42 Deney tekrar üretilebilirliğini
güçlendirmek için sabit seed.
Workers 2
Colab/local source I/O ile stabilite ve paralel
veri yükleme arasında muhafazakâr
tercih.
Mixed precision False (varsayılan)
Swin attention qkv gradient overflow
gözlendiği için stabil FP32 baseline
önceliklendirildi.
20 epoch neden?
Notebook 20 epoch değerinin bir grid-search sonucu olduğunu göstermiyor. Bu nedenle raporda "optimum epoch=20" denmemelidir. Doğru yorum: 20 maksimum bütçedir; gerçek eğitim uzunluğu validation ROC-AUC ve patience=6 early stopping tarafından belirlenir.
9. Loss, Optimizer ve Scheduler
9.1 BCEWithLogitsLoss
Model tek logit üretir ve FAKE sınıfı 1.0, REAL sınıfı 0.0 olarak kodlanır. BCEWithLogitsLoss, sigmoid ve

binary cross entropy hesaplarını tek sayısal kararlı operasyonda birleştirir. pos_weight = train_real / train_fake yalnızca train setinden hesaplanır; bu, olası sınıf dengesizliğinde FAKE örneklerinin kayıptaki
ağırlığını ayarlar.
9.2 AdamW
AdamW, adaptif öğrenme oranı ile decoupled weight decay'i birleştirir. Transformer fine-tuning'de yaygın bir
seçimdir. Notebook parametreleri iki gruba böler: pretrained backbone ve yeni classifier head. Böylece her
grubun öğrenme hızı amacına göre ayrı ayarlanır.

9.3 CosineAnnealingLR
Scheduler, learning rate'i epochlar boyunca kosinüs biçiminde kademeli düşürür. Başlangıçta daha fazla adaptasyon, sonlara doğru daha küçük güncellemeler sağlar. T_max=20; eta_min backbone_lr x 0.1 olarak belirlenir. Scheduler adımı checkpoint kaydından önce ilerletilir; last.ckpt bir sonraki epoch için tamamlanmış
end-of-epoch state'i temsil eder.
10. FP32 / Mixed Precision Kararı
Notebook'un v3 stabilized sürümünde mixed_precision varsayılan olarak False'dur. Bu tercih rastgele değildir: daha önce AMP/FP16 ile Swin attention qkv ağırlıklarında non-finite gradient overflow görülmüştür.
Bu nedenle baseline deneyde hız yerine sayısal güvenilirlik önceliklendirilmiştir.
☐ FP32 modunda herhangi bir NaN/Inf gradient hard-fail ile eğitimi durdurur.
☐ AMP açılırsa GradScaler transient overflow'u kendisi yönetir; tek overflow fatal değildir.
☐ Ardışık AMP overflow sayısı 8'e ulaşırsa persistent instability kabul edilip eğitim durur.
☐ Smoke test özellikle autocast kullanmadan FP32 çalışır; model/veri problemi ile AMP problemi birbirinden
ayrılır.
11. Eğitim Döngüsü, Model Seçimi ve Threshold
Her epoch'ta önce train, sonra validation çalıştırılır. Train metriklerinde sabit 0.5 threshold kullanılır.
Validation için 0.05-0.95 aralığında 181 eşik denenir ve F1'i en yüksek yapan threshold seçilir. Ancak "best
model" seçimi threshold-bağımsız validation ROC-AUC ile yapılır; ROC-AUC hesaplanamazsa fallback

olarak F1 kullanılır.
Karar Kullanılan veri Kriter
Optimizer güncellemesi Train BCEWithLogitsLoss
Best checkpoint Validation ROC-AUC (fallback F1)
Binary threshold Validation En yüksek F1
Final performans Test Validation'dan dondurulmuş model +
threshold
Neden ROC-AUC?
ROC-AUC karar eşiğinden bağımsız olarak pozitif/negatif örneklerin sıralanma kalitesini ölçer. Bu nedenle
model
checkpoint seçimi için 0.5 gibi keyfi bir threshold'a bağlı kalmaz. Threshold ise daha sonra yalnızca
validation
üzerinde F1 hedefiyle seçilir.
12. Checkpoint, Resume ve Reproducibility
Checkpoint mekanizması sadece model ağırlıklarını değil, eğitimin tam durumunu saklar. last.ckpt kesinti sonrası devam, best.ckpt validation'a göre en iyi model, epoch_N.ckpt ise dönen yedek için kullanılır.
Son 3
epoch checkpoint'i korunur.
Checkpoint içeriği Neden saklanıyor?
epoch Kaldığı epoch'u bilmek.
model_state_dict Model parametreleri.
optimizer_state_dict AdamW momentum/adaptif durumunu korumak.
scheduler_state_dict Learning-rate takvimini aynı noktadan devam ettirmek.
scaler_state_dict AMP açıksa GradScaler durumunu korumak.
best_metric_score / threshold / best_epoch Model seçim geçmişini korumak.
epochs_without_improvement Early stopping sayacını doğru sürdürmek.
history Epoch metrik geçmişini kaybetmemek.
Python/NumPy/Torch/CUDA RNG Rastlantısal süreçleri mümkün olduğunca aynı noktadan
Deepfake Detection - Eye ROI / Swin V2 Tiny
Kader - Deney 1 | Kod ve Yöntem Analiz Raporu
devam ettirmek.
DataLoader generator state Shuffle dizisinin resume sonrası tutarlılığını güçlendirmek.
config / run_id Checkpoint'in hangi deneye ait olduğunu doğrulamak.
Atomik kayıt önce .tmp dosyasına yapılır, tekrar yüklenerek required-key ve epoch bütünlüğü doğrulanır, ardından os.replace ile hedef dosyanın yerine atomik geçirilir. Yazma hatası sessizce yutulmaz.
Checkpoint continuity test ayrıca deterministik validation batch'i üzerinde save öncesi ve fresh-load
sonrası
logits/loss eşitliğini atol=1e-7, rtol=1e-6 toleranslarıyla doğrular.
13. Smoke Test ve Kalite Kapıları
Kalite kapısı Kontrol
Schema gate Training-required kolonların varlığı; SSOT eksikleri ayrıca
audit.
File gate Her combined_eye_path diskte gerçekten mevcut.
Sample ID gate Mükerrer sample_id yok.
Label/split gate Yalnızca real/fake ve train/val/test kabul edilir.
Leakage gate Train/val/test video_id kümeleri kesişmemeli; video kimliği
güvenilirliği ayrıca ölçülür.
Input numerical gate İlk batch images/labels NaN/Inf içeremez.
FP32 smoke test 2 batch forward/backward + finite logits/loss/gradient + clip +
optimizer step.
Checkpoint continuity Save/load sonrası aynı batch logits/loss eşleşir.
Fresh inference gate best.ckpt sıfırdan modelde yüklenip test batch'i tahmini
üretir.
Final artifact gate Beklenen JSON/CSV/checkpoint/grafik dosyalarının tamamı
mevcut.
Figure gate Her PNG kısa kenar en az 600 px.
Deepfake Detection - Eye ROI / Swin V2 Tiny
Kader - Deney 1 | Kod ve Yöntem Analiz Raporu
Şekil 2. Deney akışı ve kalite kapılarının sıralaması.
14. Metrikler, Tahminler ve Grafikler
Metrik Ne ölçer? Neden raporlanır?
Accuracy Toplam doğru sınıflandırma oranı Genel performansın anlaşılır özeti.
Precision Fake dediği örneklerin ne kadarı
gerçekten fake Yanlış pozitiflere duyarlılık.
Recall Gerçek fake örneklerin ne kadarını
yakaladı Kaçırılan deepfake oranını anlamak.
F1 Precision ve Recall harmonik
ortalaması İki hata türünü dengeli değerlendirmek.
ROC-AUC Threshold bağımsız sıralama gücü Best checkpoint için ana metric.

PR-AUC / AP Pozitif sınıf odaklı precision-recall alanı Sınıf dengesizliğinde özellikle bilgilendirici.
Kod test_frame_predictions.csv içinde her örnek için sample_id, video_id, image_path, true label, fake probability, predicted label ve threshold kaydeder. video_identity_reliable=True ise frame olasılıkları source-video bazında ortalanarak video-level sonuç üretilebilir; kimlik güvenilir değilse bu sonuçlar bilinçli olarak disabled edilir.
Oluşturulan grafikler: training-validation loss, training-validation accuracy, validation ROC-AUC history, test confusion matrix, test ROC curve ve test precision-recall curve. Başlık/eksen/legend İngilizcedir ve 150 DPI + min 600 px kalite gate'i uygulanır.

15. Modüler Kod Mimarisi

Notebook tek hücre yığını olarak bırakılmamıştır; çalışma anında /content/eye_swinv2_experiment/src/deepfake_roi altında küçük bir Python paketi üretir. Bu yaklaşım veri, model, eğitim, değerlendirme ve yardımcı fonksiyon sorumluluklarını ayırır.

Modül	Sorumluluk
utils/repro.py	Seed, worker seed, RNG capture/restore.
utils/io.py	Atomik checkpoint, checkpoint load, SHA256, atomik JSON, source hash.
data/dataset.py	Transformlar, ImageNet normalization, EyeROIDataset.
models/swin.py	Swin V2 Tiny ikili sınıflandırıcı mimarisi.
training/engine.py	Metrikler, threshold, finite kontroller, train/eval epoch.
evaluation/plots.py	Grafik üretimi ve çözünürlük kontrolü.
Notebook orchestration	Path/config, audit, model/optimizer kurulumu, training loop, final değerlendirme.

Ayrıca new run'da kaynak modüller run klasörüne source_snapshot olarak kopyalanır, SHA256 manifest yazılır ve exact runtime paket sürümleri requirements_runtime.lock.txt dosyasına kaydedilir. Böylece deney yalnızca "hangi config?" değil "hangi kod ve hangi ortam?" sorularına da cevap verir.

16. Güçlü Yönler, Sınırlılıklar ve Dikkat Noktaları

16.1 Güçlü yönler

☐ Validation/test izolasyonu güçlüdür; threshold testten öğrenilmez.
☐ FP32 stabilized baseline sayısal hata durumlarını erken görünür kılar.
☐ Checkpoint/resume durumu kapsamlıdır ve atomic save kullanır.
☐ Kaynak kod, config, environment ve çıktılar run-id altında denetlenebilir biçimde arşivlenir.
☐ Video kimliği güvenilir değilse misleading video-level metrik üretmeme yaklaşımı metodolojik olarak temkinlidir.
☐ Pretrained backbone ve ayrı learning rate grupları transfer learning mantığına uygundur.

16.2 Sınırlılıklar

☐ Model seçimi bir benchmark/grid-search sonucu değildir; Swin'in diğer modellere üstünlüğü bu notebook tarafından kanıtlanmaz.
☐ 20 epoch optimum olarak doğrulanmış değildir; yalnızca maksimum eğitim bütçesidir.
☐ video_id upstream metadata'da gerçek source-video kimliği değilse video-level leakage bağımsız kanıtlanamaz.
☐ ImageNet normalization train-derived mean/std kuralına literal olarak uymaz; transfer learning için bilinçli ve audit edilmiş istisnadır.
☐ Combined eye ROI tek kareli spatial sınıflandırmadır; blink/temporal tutarlılık gibi zaman bilgilerini modellemez.
☐ Horizontal flip, rotation ve renk jitter forensic mikro-izleri etkileyebilir; şiddet düşük tutulmuş olsa da augmentation ablation ile doğrulanabilir.

17. ML Kod Standardına Uyum

Standart maddesi	Durum	Notebook uygulaması
Görünürlük / audit	UYUMLU	Schema, missing image, split, normalization, video identity, numerical sanity ve final artifact audit dosyaları.
Modülerlik	BÜYÜK ÖLÇÜDE UYUMLU	Runtime src/deepfake_roi modülleri ayrılmış; orchestration notebook'ta kalıyor.

Reproducibility UYUMLU
Seed, deterministic settings,
environment lock, source hash, RNG +
DataLoader generator state.
Atomic checkpoint UYUMLU tmp -> load integrity -> os.replace;
best/last/epoch yedekleri.
True resume UYUMLU
Model, optimizer, scheduler, scaler,
RNG, history, patience counter ve
epoch restore.
Split leakage KOŞULLU
video_id isdisjoint yapılır; gerçek
source-video kimliği güvenilir değilse
bağımsız kanıt sınırlıdır ve audit edilir.
Train-only augmentation UYUMLU Val/test deterministik.
Normalization GEREKÇELİ İSTİSNA
ImageNet pretrained weights
normalization; val/test istatistiği
kullanılmaz.
Smoke / numerical test UYUMLU 2 batch FP32 backward ve NaN/Inf
hard-fail.
Checkpoint continuity UYUMLU Fresh save/load logits ve loss eşitliği.
Test isolation UYUMLU Best model ve threshold yalnız
validation ile; test final aşamada.
Grafik kalite UYUMLU İngilizce, 150 DPI, min short-edge 600
px.

18. Sonuç

Deney 1 Swin V2 Tiny notebook'u yalnızca bir model eğitim scripti değil, denetlenebilir bir araştırma deney
altyapısıdır. Temel model ImageNet pretrained Swin V2 Tiny olup combined-eye ROI üzerinde 768 boyutlu
temsil çıkarır ve tek logitli yeni bir classifier ile real/fake ayrımı yapar. Fine-tuning'de pretrained backbone
düşük learning rate ile korunurken yeni head daha hızlı öğrenir. 20 epoch bir üst sınırdır; gerçek durdurma
validation performansı ve patience=6 ile belirlenir.

Metodolojik açıdan en önemli taraf, test setinin model/threshold seçimine karıştırılmaması, sayısal hata ve
checkpoint problemlerinin sessiz geçilmemesi, kesinti sonrası gerçek resume sağlanması ve güvenilir
olmayan video kimlikleri için video-level iddiaların bilinçli biçimde engellenmesidir. Bu nedenle notebook,
sonraki texture-fusion veya farklı backbone deneylerinin karşılaştırılabileceği güçlü bir Swin V2 Tiny baseline
olarak konumlandırılabilir.

Ek A - Tam Konfigürasyon Özeti

Grup	Parametre	Değer
Experiment	region	eye
Experiment	model_name	swinv2_tiny
Experiment	seed	42
Data	image_column	combined_eye_path
Data	image_size	224
Data	batch_size	32
Data	num_workers	2
Data	accepted_status	ok
Model	pretrained	True
Model	dropout	0.20
Training	epochs	20
Training	backbone_lr	1e-5
Training	head_lr	1e-4
Training	weight_decay	1e-2
Training	gradient_clip_norm	1.0
Training	mixed_precision	False
Training	AMP overflow abort	8 consecutive
Training	early_stopping_patience	6
Training	monitor_metric	roc_auc
Training	fallback_metric	f1
Checkpoint	keep last N	epoch 3
Augmentation	horizontal_flip	0.50

Augmentation rotation ±5°
Augmentation brightness 0.10
Augmentation contrast 0.10
Augmentation saturation 0.05
Augmentation hue 0.02
Quality smoke_test_batches 2
Quality min figure edge 600 px
Quality continuity atol / rtol 1e-7 / 1e-6
Ek B - Modül ve Fonksiyon Haritası
Fonksiyon / sınıf Görev
seed_everything Python/NumPy/Torch/CUDA deterministik seed ayarları.
seed_worker DataLoader worker seed tutarlılığı.
capture_rng_state / restore_rng_state Resume için random durum kaydı/geri yükleme.
atomic_save_checkpoint Bozulmaya dayanıklı checkpoint yazımı.
load_checkpoint Required-key doğrulamalı checkpoint yükleme.
sha256_file / hash_source_tree Kod kaynağı bütünlük hash'i.
build_transforms Train ve eval transformlarını ayırma, pretrained
normalization.
EyeROIDataset ROI dosyası okuma, RGB dönüşüm, tensor/label üretimi.
SwinV2TinyBinaryClassifier Pretrained backbone + yeni binary head.
compute_metrics Accuracy, precision, recall, F1, ROC-AUC, PR-AUC.
select_best_f1_threshold Validation üzerinde 181 eşik taraması.
assert_finite_tensor / gradients NaN/Inf kalite gate'i.
run_epoch Train/eval forward, backward, AMP/FP32, clipping, tahmin
toplama.
checkpoint_continuity_test Save/load eşdeğerliği testi.
run_smoke_test Tam eğitim öncesi 2 batch FP32 forward/backward.
generate_all_figures Standart test ve training grafiklerinin üretimi.
Deepfake Detection - Eye ROI / Swin V2 Tiny
Kader - Deney 1 | Kod ve Yöntem Analiz Raporu
Kaynaklar ve Dayanaklar
1. Deney1_Eye_SwinV2_Tiny_Baseline_v3_Stabilized(1).ipynb - bu raporun birincil kod kaynağı.
2. ML PROJE & KOD STANDARDI - Güvenilir Makine Öğrenmesi Geliştirme, SSOT v2.0 (Ağustos 2026) - modülerlik, split, checkpoint, reproducibility, grafik ve quality-gate kuralları.
3. Liu et al., Swin Transformer V2: Scaling Up Capacity and Resolution - Swin V2 mimarisinin teknik arka planı.
4. PyTorch / Torchvision Swin V2 Tiny uygulaması - patch size, stage depth, head count, window size ve pretrained weight yapısı için teknik arka plan.
5. Loshchilov & Hutter, Decoupled Weight Decay Regularization - AdamW yaklaşımının teknik arka planı.