

DEEPPFAKE DETECTION

Eye ROI - Swin V2 Tiny Baseline

Kod, Model ve Yöntem Analiz Raporu

Rapor Alanı	Değer
Deney	Kader - Deney 1
Bölge	Combined Eye ROI
Model	Torchvision Swin V2 Tiny (swin_v2_t)
Görev	Real / Fake ikili sınıflandırma
Notebook	Deney1_Eye_SwinV2_Tiny_Baseline_v3_Stabilized
Tarih	7 Ağustos 2026

Raporun kapsamı

Bu doküman eğitim sonucu raporu değildir. Notebook kodunun tasarımını, model mimarisini, hiperparametrelerini, veri akışını, güvenlik kontrollerini ve bu seçimlerin teknik gerekçelerini açıklar. Notebook çalıştırılmadan elde edilmeyen accuracy/AUC gibi sonuçlar burada uydurulmamıştır.

İçindekiler

1. Yönetici Özeti
2. Deneyin Amacı ve Hipotezi
3. Model: Swin V2 Tiny Nedir?
4. Neden Swin V2 Tiny Seçilmiştir?
5. Modelin Notebook İçindeki Özelleştirilmesi
6. Veri Girişi, Metadata ve Leakage Denetimi
7. Ön İşleme ve Data Augmentation
8. Eğitim Hiperparametreleri ve Gerekçeleri
9. Loss, Optimizer ve Scheduler
10. FP32 / Mixed Precision Kararı
11. Eğitim Döngüsü, Model Seçimi ve Threshold
12. Checkpoint, Resume ve Reproducibility
13. Smoke Test ve Kalite Kapıları
14. Metrikler, Tahminler ve Grafikler
15. Modüler Kod Mimarisi
16. Güçlü Yönler, Sınırlılıklar ve Dikkat Noktaları
17. ML Kod Standardına Uyum
18. Sonuç
- Ek A. Tam Konfigürasyon Özeti
- Ek B. Modül ve Fonksiyon Haritası

1. Yönetici Özeti

Bu notebook, daha önce çıkarılmış combined-eye ROI görüntülerini kullanarak gerçek ve sahte örnekleri ayırmak için ImageNet ön-eğitilmiş Swin V2 Tiny modelini fine-tune eden bir baseline deneyidir. Kod yalnızca model eğitimi yapmaz; veri şeması, dosya varlığı, split izolasyonu, sayısal kararlılık, checkpoint bütünlüğü, kaldığı yerden devam, final inference ve çıktı kalite kontrollerini de deney akışının parçası haline getirir.

- Girdi: metadata.csv içindeki combined_eye_path ile işaret edilen 224x224 göz ROI görüntüleri.
- Model: torchvision.models.swin_v2_t, ImageNet-1K pretrained backbone.
- Sınıflandırıcı: 768 boyutlu Swin özelliği -> LayerNorm -> Dropout(0.20) -> Linear(1).
- Kayıp: BCEWithLogitsLoss; FAKE pozitif sınıf, pos_weight yalnızca train dağılımından hesaplanır.
- Optimizer: AdamW; backbone LR=1e-5, yeni head LR=1e-4.
- Scheduler: CosineAnnealingLR; üst sınır 20 epoch, early stopping patience=6.
- Kararlılık: varsayılan mixed_precision=False, gradient clipping=1.0, FP32 smoke test ve NaN/Inf hard-fail.
- Model seçimi: validation ROC-AUC; threshold seçimi: validation F1; test yalnızca final değerlendirmede kullanılır.

2. Deneyin Amacı ve Hipotezi

Deneyin amacı, tüm yüz yerine yalnızca göz bölgesinden çıkarılmış ROI görüntülerinin, transformer tabanlı bir görüntü modeliyle deepfake ayrımı için ne kadar bilgi taşıdığını ölçebilecek güvenilir bir baseline oluşturmaktır. Combined-eye ROI kullanılması iki gözün aynı örnekte tutulmasını sağlar; böylece model yalnızca lokal bir göz dokusuna değil, iki göz arasındaki simetri, ortak ışık yapısı, kenar ve doku ilişkileri gibi bölgesel örüntülere de erişebilir.

Hipotez

Swin V2 Tiny, göz ROI içindeki lokal ve orta ölçekli yapıları hiyerarşik shifted-window attention ile temsil ederek real/fake ayrımına yarayan görsel tutarsızlıkları öğrenebilir. Bu notebook bu hipotezi test etmek için baseline sağlar; tek başına Swin V2 Tiny'nin diğer mimarilerden üstün olduğunu kanıtlayan bir model karşılaştırması içermez.


3. Model: Swin V2 Tiny Nedir?

Swin Transformer, görüntüyü küçük patch'lere ayırıp attention işlemini tüm görüntü üzerinde küresel olarak yapmak yerine yerel pencerelerde uygular. Ardışık bloklarda pencerelerin kaydırılması (shifted windows), farklı pencerelerdeki tokenların bilgi paylaşmasını sağlar. Mimari hiyerarşiktir: ilerleyen stage'lerde uzamsal çözünürlük azalırken kanal/özellik boyutu artar. Bu nedenle CNN'lerdeki çok ölçekli özellik piramidine benzer bir temsil üretirken self-attention mekanizmasının bağlamsal gücünü korur.

Notebook torchvision'un Swin V2 Tiny uygulamasını kullanır. Teknik arka plan açısından torchvision yapılandırması patch_size=4x4, embed_dim=96, stage_depth=[2,2,6,2], attention_head=[3,6,12,24] ve window_size=8x8'dir. Orijinal ImageNet sınıflandırma başlığı 1000 sınıflıdır; notebook bu başlığı kaldırıp ikili deepfake görevi için tek logit üreten yeni bir head ekler.

Özellik	Swin V2 Tiny yapılandırması
Girdi ölçeği	Notebook: 224 x 224
Patch boyutu	4 x 4
İlk embedding	96 kanal
Stage derinlikleri	2 / 2 / 6 / 2 blok
Attention head sayıları	3 / 6 / 12 / 24
Window	8 x 8
Backbone çıkışı	768 özellik
Torchvision özgün parametre	28,351,570
Notebook özelleştirilmiş yaklaşık parametre	27,584,875

Swin V2 Tiny Binary Deepfake Classifier



Şekil 1. Notebook içindeki Swin V2 Tiny ikili sınıflandırma akışı.

4. Neden Swin V2 Tiny Seçilmiştir?

Notebook içinde “alternatif modelleri tarayıp Swin’in en iyi olduğunu ispatlayan” bir hiperparametre/model seçimi yoktur. Bu nedenle model seçimi deneysel bir üstünlük iddiası değil, teknik ve proje bağlamı bir baseline kararıdır.

Gerekçe	Açıklama
Göz ROI için yerel attention	Göz ROI’de iris, sclera, göz kapağı, kenar ve üretim artefaktları lokal bölgelerde bulunabilir. Window attention bu lokal yapıları verimli işler.
Pencereler arası bağlam	Shifted windows, farklı lokal bölgelerin zamanla birbirine bilgi aktarmasını sağlar; iki gözlü combined ROI için yararlıdır.
Hiyerarşik temsil	Farklı ölçeklerde özellik çıkarımı, yalnızca tek piksel dokusu değil daha geniş şekil/konum ilişkilerini de yakalamayı destekler.
Transfer learning	ImageNet pretrained ağırlıklar, sınırlı alan verisinde sıfırdan öğrenmeye göre daha güçlü başlangıç temsili sağlar.
Tiny varyant	Swin ailesinin daha küçük varyantıdır; Colab/GPU belleği ve eğitim maliyeti ile temsil gücü arasında pratik denge sunar.
Baseline değeri	Sonraki texture-fusion çalışmalarında Transformer kolunun tek başına performansını ölçmek için temiz bir karşılaştırma noktası oluşturur.

5. Modelin Notebook İçindeki Özelleştirilmesi

Kod, pretrained Swin V2 Tiny modelinin head katmanını `nn.Identity()` ile çıkarır. Backbone artık sınıf skorları yerine 768 boyutlu özellik vektörü üretir. Bunun üzerine yeni ikili sınıflandırıcı eklenir: `LayerNorm -> Dropout(0.20) -> Linear(768,1)`.

- LayerNorm: Transformer özelliklerinin ölçeğini dengeler ve yeni sınıflandırıcıya daha düzenli giriş sağlar.
- Dropout 0.20: Head'in eğitim örneklerini ezberlemesini azaltmak için orta düzey düzenleme uygular.
- Linear(768,1): İkili sınıflandırma için tek logit üretir. Sigmoid model forward içinde uygulanmaz; olasılık gerektiğinde sonradan sigmoid kullanılır.

Neden tek logit?

BCEWithLogitsLoss tek logitli binary classification için uygundur ve sigmoid + binary cross entropy işlemlerini sayısal olarak daha kararlı biçimde birleştirir.

6. Veri Girişi, Metadata ve Leakage Denetimi

Notebook yeni ROI üretmez; upstream eye_roi_output/metadata.csv dosyasını tüketir. Temel eğitim şeması sample_id, video_id, label, split, status ve combined_eye_path alanlarını zorunlu tutar. Başarılı kayıtlar status="ok" ile filtrelenir. Boş path, eksik dosya, beklenmeyen label/split, mükerrer sample_id, aynı video kimliğinin birden fazla label veya splitte görülmesi hard-fail ile eğitimi durdurur.

- Mevcut train/val/test split yeniden üretilmez; upstream ayırım korunur.
- train/val/test video_id kümeleri için isdisjoint kontrolü yapılır.
- SSOT standardındaki eksik kolonlar uydurulmaz; metadata_schema_audit.json içinde raporlanır.
- video_id değerlerinin gerçek kaynak videoyu temsil edip etmediği ayrıca denetlenir. Eğer değerler fake_train / real_test gibi kaba label-split kovaları görünümündeyse video-level metric yayınlanmaz.

Önemli metodolojik sınır

video_identity_reliable=False çıkarsa kod frame-level eğitimi sürdürebilir; ancak gerçek source-video düzeyinde leakage bağımsız olarak kanıtlanmış sayılmaz. Bu durumda notebook yanıltıcı per-video sonuç üretmemeyi tercih eder.

7. Ön İşleme ve Data Augmentation

Parametre	Değer	Neden
ROI	Combined eye	İki gözü tek örnekte tutup bölgesel/simetrik bağlamı korumak.
Resize	224 x 224	Swin V2 Tiny pretrained kullanımına uygun standart görüntü ölçeği.
Horizontal flip	p=0.50	Sağ-sol yönüne aşırı bağımlılığı azaltmak.
Rotation	$\pm 5^\circ$	Küçük ROI hizalama ve baş açısı farklarına dayanıklılık; artefaktları bozmamak için düşük şiddet.
Brightness	0.10	Hafif ışık değişimlerine dayanıklılık.
Contrast	0.10	Kamera/aydınlatma kontrast farklarına tolerans.
Saturation	0.05	Renk doygunluğundaki küçük değişimleri tolere etmek.
Hue	0.02	Çok sınırlı renk tonu değişimi; forensic izleri agresif biçimde bozmamak.
Normalization	ImageNet weights mean/std	Pretrained backbone'un beklediği giriş dağılımını korumak; val/test'ten istatistik öğrenilmez.

Augmentation yalnızca train setine uygulanır. Validation ve test sadece resize + normalization kullanır. Böylece değerlendirme sırasında rastlantısal transform eklenmez ve ölçüm tekrarlanabilir kalır.

8. Eğitim Hiperparametreleri ve Gerekçeleri

Hiperparametre	Değer	Teknik gerekçe / yorum
Epoch üst sınırı	20	Tek bir kesin "doğru epoch" iddiası yoktur. 20, fine-tuning için makul bir üst sınırdır; early stopping 6 ile gereksiz uzun eğitim engellenir.
Early stopping patience	6	Validation skoru iyileşmeden 6 epoch bekleyerek küçük dalgalanmalara tolerans verir, uzun overfit sürecini keser.
Batch size	32	224x224 Swin Tiny için GPU throughput/bellek arasında pratik denge.
Backbone LR	1e-5	Pretrained temsilleri agresif biçimde bozmadan yavaş fine-tuning.
Head LR	1e-4	Yeni eklenen sınıflandırıcı sıfırdan öğrendiği için backbone'dan 10 kat daha hızlı güncellenir.
Weight decay	1e-2	AdamW ile parametre büyümesini sınırlayan düzenleme.
Gradient clipping	1.0	Transformer gradient patlamasına karşı global norm sınırı.
Dropout	0.20	Yeni head'de overfitting riskini azaltmak için.
Seed	42	Deney tekrar üretilebilirliğini güçlendirmek için sabit seed.
Workers	2	Colab/Drive I/O ile stabilite ve paralel veri yükleme arasında muhafazakâr tercih.
Mixed precision	False (varsayılan)	Swin attention qkv gradient overflow gözlemlendiği için stabil FP32 baseline önceliklendirildi.

20 epoch neden?

Notebook 20 epoch değerinin bir grid-search sonucu olduğunu göstermiyor. Bu nedenle raporda "optimum epoch=20" denmemelidir. Doğru yorum: 20 maksimum bütçedir; gerçek eğitim uzunluğu validation ROC-AUC ve patience=6 early stopping tarafından belirlenir.

9. Loss, Optimizer ve Scheduler

9.1 BCEWithLogitsLoss

Model tek logit üretir ve FAKE sınıfı 1.0, REAL sınıfı 0.0 olarak kodlanır. BCEWithLogitsLoss, sigmoid ve binary cross entropy hesaplarını tek sayısal kararlı operasyonda birleştirir. pos_weight = train_real / train_fake yalnızca train setinden hesaplanır; bu, olası sınıf dengesizliğinde FAKE örneklerinin kayıptaki ağırlığını ayarlar.

9.2 AdamW

AdamW, adaptif öğrenme oranı ile decoupled weight decay'i birleştirir. Transformer fine-tuning'de yaygın bir seçimdir. Notebook parametreleri iki gruba böler: pretrained backbone ve yeni classifier head. Böylece her grubun öğrenme hızı amacına göre ayrı ayarlanır.

9.3 CosineAnnealingLR

Scheduler, learning rate'i epochlar boyunca kosinüs biçiminde kademeli düşürür. Başlangıçta daha fazla adaptasyon, sonlara doğru daha küçük güncellemeler sağlar. $T_{max}=20$; η_{min} backbone_lr x 0.1 olarak belirlenir. Scheduler adımı checkpoint kaydından önce ilerletilir; last.ckpt bir sonraki epoch için tamamlanmış end-of-epoch state'i temsil eder.

10. FP32 / Mixed Precision Kararı

Notebook'un v3 stabilized sürümünde mixed_precision varsayılan olarak False'dur. Bu tercih rastgele değildir: daha önce AMP/FP16 ile Swin attention qkv ağırlıklarında non-finite gradient overflow görülmüştür. Bu nedenle baseline deneyde hız yerine sayısal güvenilirlik önceliklendirilmiştir.

- FP32 modunda herhangi bir NaN/Inf gradient hard-fail ile eğitimi durdurur.
- AMP açılırsa GradScaler transient overflow'u kendisi yönetir; tek overflow fatal değildir.
- Ardışık AMP overflow sayısı 8'e ulaşırsa persistent instability kabul edilip eğitim durur.
- Smoke test özellikle autocast kullanmadan FP32 çalışır; model/veri problemi ile AMP problemi birbirinden ayrılır.

11. Eğitim Döngüsü, Model Seçimi ve Threshold

Her epoch'ta önce train, sonra validation çalıştırılır. Train metriklerinde sabit 0.5 threshold kullanılır. Validation için 0.05-0.95 aralığında 181 eşik denenir ve F1'i en yüksek yapan threshold seçilir. Ancak "best model" seçimi threshold-bağımsız validation ROC-AUC ile yapılır; ROC-AUC hesaplanamazsa fallback olarak F1 kullanılır.

Karar	Kullanılan veri	Kriter
Optimizör güncellemesi	Train	BCEWithLogitsLoss
Best checkpoint	Validation	ROC-AUC (fallback F1)
Binary threshold	Validation	En yüksek F1
Final performans	Test	Validation'dan dondurulmuş model + threshold

Neden ROC-AUC?

ROC-AUC karar eşiğinden bağımsız olarak pozitif/negatif örneklerin sıralanma kalitesini ölçer. Bu nedenle model checkpoint seçimi için 0.5 gibi keyfi bir threshold'a bağlı kalmaz. Threshold ise daha sonra yalnızca validation üzerinde F1 hedefiyle seçilir.

12. Checkpoint, Resume ve Reproducibility

Checkpoint mekanizması sadece model ağırlıklarını değil, eğitimin tam durumunu saklar. last.ckpt kesinti sonrası devam, best.ckpt validation'a göre en iyi model, epoch_N.ckpt ise dönen yedek için kullanılır. Son 3 epoch checkpoint'i korunur.

Checkpoint içeriği	Neden saklanıyor?
epoch	Kaldığı epoch'u bilmek.
model_state_dict	Model parametreleri.
optimizer_state_dict	AdamW momentum/adaptif durumunu korumak.
scheduler_state_dict	Learning-rate takvimini aynı noktadan devam ettirmek.
scaler_state_dict	AMP açıksa GradScaler durumunu korumak.
best_metric_score / threshold / best_epoch	Model seçim geçmişini korumak.
epochs_without_improvement	Early stopping sayacını doğru sürdürmek.
history	Epoch metrik geçmişini kaybetmemek.
Python/NumPy/Torch/CUDA RNG	Rastlantısal süreçleri mümkün olduğunca aynı noktadan

	devam ettirmek.
DataLoader generator state	Shuffle dizisinin resume sonrası tutarlılığını güçlendirmek.
config / run_id	Checkpoint'in hangi deneye ait olduğunu doğrulamak.


Atomik kayıt önce .tmp dosyasına yapılır, tekrar yüklenerek required-key ve epoch bütünlüğü doğrulanır, ardından os.replace ile hedef dosyanın yerine atomik geçirilir. Yazma hatası sessizce yutulmaz.

Checkpoint continuity test ayrıca deterministik validation batch'i üzerinde save öncesi ve fresh-load sonrası logits/loss eşitliğini $atol=1e-7$, $rtol=1e-6$ toleranslarıyla doğrular.

13. Smoke Test ve Kalite Kapıları

Kalite kapısı	Kontrol
Schema gate	Training-required kolonların varlığı; SSOT eksikleri ayrıca audit.
File gate	Her combined_eye_path diskte gerçekten mevcut.
Sample ID gate	Mükerrer sample_id yok.
Label/split gate	Yalnızca real/fake ve train/val/test kabul edilir.
Leakage gate	Train/val/test video_id kümeleri kesişmemeli; video kimliği güvenilirliği ayrıca ölçülür.
Input numerical gate	İlk batch images/labels NaN/Inf içeremez.
FP32 smoke test	2 batch forward/backward + finite logits/loss/gradient + clip + optimizer step.
Checkpoint continuity	Save/load sonrası aynı batch logits/loss eşleşir.
Fresh inference gate	best.ckpt sıfırdan modelde yüklenip test batch'i tahmini üretir.
Final artifact gate	Beklenen JSON/CSV/checkpoint/grafik dosyalarının tamamı mevcut.
Figure gate	Her PNG kısa kenar en az 600 px.

Experiment Workflow and Quality Gates



Şekil 2. Deney akışı ve kalite kapılarının sıralaması.

14. Metrikler, Tahminler ve Grafikler

Metrik	Ne ölçer?	Neden raporlanır?
Accuracy	Toplam doğru sınıflandırma oranı	Genel performansın anlaşılır özeti.
Precision	Fake dediği örneklerin ne kadarı gerçekten fake	Yanlış pozitiflere duyarlılık.
Recall	Gerçek fake örneklerin ne kadarını yakaladı	Kaçırılan deepfake oranını anlamak.
F1	Precision ve Recall harmonik ortalaması	İki hata türünü dengeli değerlendirmek.
ROC-AUC	Threshold bağımsız sıralama gücü	Best checkpoint için ana metric.
PR-AUC / AP	Pozitif sınıf odaklı precision-recall alanı	Sınıf dengesizliğinde özellikle bilgilendirici.

Kod test_frame_predictions.csv içinde her örnek için sample_id, video_id, image_path, true label, fake probability, predicted label ve threshold kaydeder. video_identity_reliable=True ise frame olasılıkları source-video bazında ortalananarak video-level sonuç üretilebilir; kimlik güvenilir değilse bu sonuçlar bilinçli olarak disabled edilir.

Oluşturulan grafikler: training-validation loss, training-validation accuracy, validation ROC-AUC history, test confusion matrix, test ROC curve ve test precision-recall curve. Başlık/eksen/legend İngilizcedir ve 150 DPI + min 600 px kalite gate'i uygulanır.

15. Modüler Kod Mimarisi

Notebook tek hücre yığını olarak bırakılmamıştır; çalışma anında /content/eye_swinv2_experiment/src/deepfake_roi altında küçük bir Python paketi üretir. Bu yaklaşım veri, model, eğitim, değerlendirme ve yardımcı fonksiyon sorumluluklarını ayırır.

Modül	Sorumluluk
utils/repro.py	Seed, worker seed, RNG capture/restore.
utils/io.py	Atomik checkpoint, checkpoint load, SHA256, atomik JSON, source hash.
data/dataset.py	Transformlar, ImageNet normalization, EyeROIDataset.
models/swin.py	Swin V2 Tiny ikili sınıflandırıcı mimarisi.
training/engine.py	Metrikler, threshold, finite kontroller, train/eval epoch.
evaluation/plots.py	Grafik üretimi ve çözünürlük kontrolü.
Notebook orchestration	Path/config, audit, model/optimizer kurulumu, training loop, final değerlendirme.

Ayrıca new run'da kaynak modüller run klasörüne source_snapshot olarak kopyalanır, SHA256 manifest yazılır ve exact runtime paket sürümleri requirements_runtime.lock.txt dosyasına kaydedilir. Böylece deney yalnızca “hangi config?” değil “hangi kod ve hangi ortam?” sorularına da cevap verir.

16. Güçlü Yönler, Sınırlılıklar ve Dikkat Noktaları

16.1 Güçlü yönler

- Validation/test izolasyonu güçlüdür; threshold testten öğrenilmez.
- FP32 stabilized baseline sayısal hata durumlarını erken görünür kılar.
- Checkpoint/resume durumu kapsamlıdır ve atomic save kullanır.
- Kaynak kod, config, environment ve çıktılar run-id altında denetlenebilir biçimde arşivlenir.
- Video kimliği güvenilir değilse misleading video-level metrik üretmeme yaklaşımı metodolojik olarak temkinlidir.
- Pretrained backbone ve ayrı learning rate grupları transfer learning mantığına uygundur.

16.2 Sınırlılıklar

- Model seçimi bir benchmark/grid-search sonucu değildir; Swin'in diğer modellere üstünlüğü bu notebook tarafından kanıtlanmaz.
- 20 epoch optimum olarak doğrulanmış değildir; yalnızca maksimum eğitim bütçesidir.
- video_id upstream metadata'da gerçek source-video kimliği değilse video-level leakage bağımsız kanıtlanamaz.
- ImageNet normalization train-derived mean/std kuralına literal olarak uymaz; transfer learning için bilinçli ve audit edilmiş istisnadır.
- Combined eye ROI tek kareli spatial sınıflandırmadır; blink/temporal tutarlılık gibi zaman bilgilerini modellemez.
- Horizontal flip, rotation ve renk jitter forensic mikro-izleri etkileyebilir; şiddet düşük tutulmuş olsa da augmentation ablation ile doğrulanabilir.

17. ML Kod Standardına Uyum

Standart maddesi	Durum	Notebook uygulaması
Görünürlük / audit	UYUMLU	Schema, missing image, split, normalization, video identity, numerical sanity ve final artifact audit dosyaları.
Modülerlik	BÜYÜK ÖLÇÜDE UYUMLU	Runtime src/deepfake_roi modülleri ayrılmış; orchestration notebook'ta kalıyor.

Reproducibility	UYUMLU	Seed, deterministic settings, environment lock, source hash, RNG + DataLoader generator state.
Atomic checkpoint	UYUMLU	tmp -> load integrity -> os.replace; best/last/epoch yedekleri.
True resume	UYUMLU	Model, optimizer, scheduler, scaler, RNG, history, patience counter ve epoch restore.
Split leakage	KOŞULLU	video_id isdisjoint yapılır; gerçek source-video kimliği güvenilir değilse bağımsız kanıt sınırlıdır ve audit edilir.
Train-only augmentation	UYUMLU	Val/test deterministik.
Normalization	GEREKÇELİ İSTİSNA	ImageNet pretrained weights normalization; val/test istatistiği kullanılmaz.
Smoke / numerical test	UYUMLU	2 batch FP32 backward ve NaN/Inf hard-fail.
Checkpoint continuity	UYUMLU	Fresh save/load logits ve loss eşitliği.
Test isolation	UYUMLU	Best model ve threshold yalnız validation ile; test final aşamada.
Grafik kalite	UYUMLU	İngilizce, 150 DPI, min short-edge 600 px.

18. Sonuç

Deney 1 Swin V2 Tiny notebook'u yalnızca bir model eğitim scripti değil, denetlenebilir bir araştırma deney altyapısıdır. Temel model ImageNet pretrained Swin V2 Tiny olup combined-eye ROI üzerinde 768 boyutlu temsil çıkarır ve tek logitli yeni bir classifier ile real/fake ayrımı yapar. Fine-tuning'de pretrained backbone düşük learning rate ile korunurken yeni head daha hızlı öğrenir. 20 epoch bir üst sınırdır; gerçek durdurma validation performansı ve patience=6 ile belirlenir.

Metodolojik açıdan en önemli taraf, test setinin model/threshold seçimine karıştırılmaması, sayısal hata ve checkpoint problemlerinin sessiz geçilmemesi, kesinti sonrası gerçek resume sağlanması ve güvenilir olmayan video kimlikleri için video-level iddiaların bilinçli biçimde engellenmesidir. Bu nedenle notebook, sonraki texture-fusion veya farklı backbone deneylerinin karşılaştırılabileceği güçlü bir Swin V2 Tiny baseline olarak konumlandırılabilir.

Ek A - Tam Konfigürasyon Özeti

Grup	Parametre	Değer
Experiment	region	eye
Experiment	model_name	swinv2_tiny
Experiment	seed	42
Data	image_column	combined_eye_path
Data	image_size	224
Data	batch_size	32
Data	num_workers	2
Data	accepted_status	ok
Model	pretrained	True
Model	dropout	0.20
Training	epochs	20
Training	backbone_lr	1e-5
Training	head_lr	1e-4
Training	weight_decay	1e-2
Training	gradient_clip_norm	1.0
Training	mixed_precision	False
Training	AMP overflow abort	8 consecutive
Training	early_stopping_patience	6
Training	monitor_metric	roc_auc
Training	fallback_metric	f1
Checkpoint	keep last N epoch	3
Augmentation	horizontal_flip	0.50
Augmentation	rotation	$\pm 5^\circ$
Augmentation	brightness	0.10
Augmentation	contrast	0.10
Augmentation	saturation	0.05
Augmentation	hue	0.02
Quality	smoke_test_batches	2
Quality	min figure edge	600 px
Quality	continuity atol / rtol	1e-7 / 1e-6

Ek B - Modül ve Fonksiyon Haritası

Fonksiyon / sınıf	Görev
seed_everything	Python/NumPy/Torch/CUDA deterministik seed ayarları.
seed_worker	DataLoader worker seed tutarlılığı.
capture_rng_state / restore_rng_state	Resume için random durum kaydı/geri yükleme.
atomic_save_checkpoint	Bozulmaya dayanıklı checkpoint yazımı.
load_checkpoint	Required-key doğrulamalı checkpoint yükleme.
sha256_file / hash_source_tree	Kod kaynağı bütünlük hash'i.
build_transforms	Train ve eval transformlarını ayırma, pretrained normalization.
EyeROIDataset	ROI dosyası okuma, RGB dönüşüm, tensor/label üretimi.
SwinV2TinyBinaryClassifier	Pretrained backbone + yeni binary head.
compute_metrics	Accuracy, precision, recall, F1, ROC-AUC, PR-AUC.
select_best_f1_threshold	Validation üzerinde 181 eşik taraması.
assert_finite_tensor / gradients	NaN/Inf kalite gate'i.
run_epoch	Train/eval forward, backward, AMP/FP32, clipping, tahmin toplama.
checkpoint_continuity_test	Save/load eşdeğerliği testi.
run_smoke_test	Tam eğitim öncesi 2 batch FP32 forward/backward.
generate_all_figures	Standart test ve training grafiklerinin üretimi.

Kaynaklar ve Dayanaklar

1. Deney1_Eye_SwinV2_Tiny_Baseline_v3_Stabilized(1).ipynb - bu raporun birincil kod kaynağı.
2. ML PROJE & KOD STANDARDI - Güvenilir Makine Öğrenmesi Geliştirme, SSOT v2.0 (Ağustos 2026) - modülerlik, split, checkpoint, reproducibility, grafik ve quality-gate kuralları.
3. Liu et al., Swin Transformer V2: Scaling Up Capacity and Resolution - Swin V2 mimarisinin teknik arka planı.
4. PyTorch / Torchvision Swin V2 Tiny uygulaması - patch size, stage depth, head count, window size ve pretrained weight yapısı için teknik arka plan.
5. Loshchilov & Hutter, Decoupled Weight Decay Regularization - AdamW yaklaşımının teknik arka planı.