HOG_LBP_SVM_Goz_Deepfake_Kod_Aciklamasi.pdf - local repository text copy

HOG + LBP + SVM - Göz Deepfake Tespiti Kod Açıklama Raporu
HOG + LBP + SVM ile Göz Bölgesi Üzerinden
Deepfake Tespiti
Kod ve Deney Açıklama Raporu
Combined Eye ROI tabanlı klasik makine öğrenmesi notebook'unun veri güvenliği, özellik çıkarımı, SVM seçimi, kalite kapıları, test değerlendirmesi ve çıktı üretim sürecinin teknik açıklaması
Alan Değer
Deney yaklaşımı HOG + LBP özellik füzyonu + SVM
İncelenen bölge Göz - Combined Eye ROI
Önceden eğitilmiş model Kullanılmıyor
Pozitif sınıf Fake
Seed 42
Gerçek Run ID 20260807_1119_eye_hog_lbp_svm_seed42
Nihai seçilen sınıflandırıcı RBF SVM
HOG + LBP + SVM - Göz Deepfake Tespiti Kod Açıklama Raporu
1. Raporun Amacı
Bu rapor, HOG + LBP + SVM tabanlı göz bölgesi deepfake tespit notebook'unun ne yaptığını, neden bu şekilde tasarlandığını ve her ana kod bloğunun deney açısından hangi görevi üstlendiğini açıklamak amacıyla
hazırlanmıştır. Notebook derin öğrenme ağı eğitmek yerine klasik makine öğrenmesi yaklaşımı kullanır. Combined Eye ROI görüntülerinden önce elle tasarlanmış görsel özellikler çıkarılır; ardından bu özellikler
SVM sınıflandırıcısına verilir.
Temel bilimsel soru şudur: Göz bölgesindeki kenar/yönelim bilgisi ile mikro-doku bilgisinin birlikte kullanılması,
Real ve Fake örnekleri ayırmada ne kadar faydalıdır?
2. Genel Çalışma Akışı
Adım İşlem
1 local source bağlantısı ve merkezi YAML config
2 Eye ROI metadata şema doğrulaması
3 Veri muhasebesi ve leakage quality gate'leri
4 Combined-eye görüntülerini grayscale okuyup 128x64 resize
5 HOG ve LBP özellik çıkarımı
6 HOG + LBP concatenation ile özellik füzyonu
7 StandardScaler'ın yalnız train setinde fit edilmesi
8 12 SVM adayının validation setinde karşılaştırılması
9 Validation F1 ile model + threshold seçimi
10 Atomik checkpoint ve fresh-load inference testleri
11 Test setinde frame-level ve metadata-group-level değerlendirme
12 Metrik, tahmin, grafik, config, environment ve manifest çıktıları
2.1. Neden HOG + LBP + SVM?
HOG, göz çevresindeki kenarların, göz kapağı sınırlarının, kirpiklerin ve lokal şekil değişimlerinin yönelim
bilgisini özetler.
LBP, iris çevresi, göz çevresi deri dokusu ve mikro-kontrast örüntülerini yerel komşuluk ilişkileri üzerinden
temsil eder.
İki özellik uç uca birleştirilerek aynı örnekte hem geometrik/yönelim hem de mikro-doku bilgisi kullanılır.
SVM, bu yüksek boyutlu özellik uzayında Real ve Fake sınıflarını ayıran karar sınırını öğrenir. Yaklaşım hafif,
açıklanabilir ve deep learning modellerine karşı kullanılabilecek klasik bir baseline'dır.
3. Konfigürasyon ve Deney Ayarları
Parametre Notebook değeri Amaç
Görüntü boyutu 128 x 64 HOG/LBP için sabit geometri
HOG orientations 9 Dokuz gradyan yönünü temsil etmek
HOG pixels_per_cell 8 x 8 Yerel yönelim histogramları
HOG cells_per_block 2 x 2 Komşu hücreleri birlikte normalize etmek
HOG block norm L2-Hys Kontrast/aydınlık değişimine dayanıklılık
LBP points 8 Sekiz komşuluk ilişkisi
LBP radius 1 Yerel mikro-doku
LBP method uniform Düşük boyutlu ve kararlı histogram
SVM kernels linear, rbf Doğrusal ve doğrusal olmayan sınırları karşılaştırmak
C adayları 0.1, 1.0, 10.0 Düzenlileştirme/uyum dengesini taramak
RBF gamma scale, 0.001, 0.0001 RBF etki alanını taramak
Class weight balanced Sınıf sayı farkını otomatik dengelemek

Seçim metriği Validation F1 Precision ve Recall'u birlikte optimize
etmek
HOG + LBP + SVM - Göz Deepfake Tespiti Kod Açıklama Raporu
Figure DPI 150 Rapor görsellerinde yeterli çözünürlük
3.1. YAML hata koruması
Config dosyası bozuk YAML üretirse notebook belirsiz biçimde devam etmez. Bozuk dosya .yaml.broken
uzantısıyla yedeklenir, varsayılan geçerli config yeniden yazılır ve tekrar okunur. Ayrıca gerekli config

anahtarlarının tamamının bulunduğu doğrulanır.
4. Run Klasörü, Tekrar Üretilebilirlik ve Dosya Güvenliği
Her çalışma tarih-saat, bölge, yöntem ve seed içeren benzersiz bir Run ID ile Deney 1/Sonuçlar altında
ayrı
klasöre yazılır. Mevcut run klasörünün üzerine bilinçsizce yazılması engellenir; resume_run_id yalnızca
bilinçli
devam senaryosu için kullanılabilir.
Öğe Yol / davranış
Girdi Deney 1/Göz/eye_roi_output
Metadata Göz/eye_roi_output/metadata.csv
Çıktı Deney 1/Sonuçlar/<run_id>/
Kaynak veri Salt okunur; taşınmaz/silinmez/yeniden adlandırılmaz
Seed Python + NumPy + PYTHONHASHSEED = 42
Log logs/run.log
JSON, CSV, NPZ ve joblib çıktıları geçici .tmp dosyalarına yazılır, tekrar okunarak doğrulanır ve
yalnızca
başarılı doğrulamadan sonra os.replace ile atomik biçimde hedef dosyaya geçirilir.
5. Eye ROI Metadata Doğrulaması ve Veri Muhasebesi
Notebook doğrudan göz ROI metadata'sını kullanır ve sample_id, source_frame, label, split, video_id,
frame_stem, face_id, combined_eye_path ve status gibi zorunlu alanların varlığını kontrol eder.
Önemli düzeltme: no_face satırlarında sample_id boş olabilir. Bu nedenle SUCCESS satırlarında gerçek
sample_id zorunlu ve benzersiz tutulurken, SKIPPED/ERROR satırlarına yalnız izlenebilirlik amacıyla
deterministik audit ID üretilir. Bu audit ID gerçek ROI kimliği gibi değerlendirilmez.
Gerçek run veri muhasebesi Değer
Toplam metadata satırı 3,097
SUCCESS 2,986
SKIPPED (no_face) 111
ERROR 0
Eğitime uygun combined-eye örneği 2,986
Üretilen audit ID 111
Split REAL FAKE Toplam
Train 1,197 1,191 2,388
Validation 155 141 296
Test 146 156 302
5.1. SHA256 ve exact-content leakage kontrolü
SUCCESS statüsündeki 2,986 combined-eye dosyasının SHA256 değeri gerçek dosya içeriğinden
hesaplanır. Aynı görüntü içeriği farklı splitlerde bulunursa deney durdurulur. Gerçek çalıştırmada cross-
split
duplicate SHA256 sayısı 0'dır.
HOG + LBP + SVM - Göz Deepfake Tespiti Kod Açıklama Raporu
Aynı dosya yolunun farklı splitlerde görünmesi de ayrıca kontrol edilir; gerçek run'da bu sayı da 0'dır.
5.2. video_id alanının bilimsel yorumu
Notebook mevcut metadata'daki video_id alanını olduğu gibi korur; ancak bu alan real_train, fake_test
gibi
split/sınıf grup kimliği taşıyabildiğinden authoritative original source-video kimliği olarak kabul
edilmez.
Bu nedenle mevcut video_id grupları arasında train/val/test kesişimi 0 olsa da gerçek video-level leakage

durumu PASS olarak işaretlenmez. Kalite kapısında durum
NOT_VERIFIABLE_FROM_CURRENT_METADATA olarak raporlanır.
6. Görüntü Ön İşleme
Her combined-eye ROI OpenCV ile grayscale okunur ve 128x64 piksele yeniden boyutlandırılır. İşlem RAM
üzerindeki kopyada yapılır; local source'daki kaynak ROI dosyasına yazılmaz.
İşlem Neden kullanılıyor?
Grayscale Renk bilgisini kaldırıp yapı/dokuya odaklanmak
128x64 resize Tüm örnekleri sabit HOG/LBP geometrisine getirmek
uint8 kontrolü Piksel veri tipini tutarlı tutmak
INTER_AREA Küçültmede kararlı yeniden örnekleme
7. HOG Özellik Çıkarımı
HOG (Histogram of Oriented Gradients), görüntüdeki lokal gradyan yönelimlerini histogramlar. Göz
bölgesinde göz kapağı kıvrımı, kirpik çizgileri, göz köşeleri ve genel geometrik sınırlar gibi

şekil/yönelim
ipuçlarını temsil etmek için kullanılır.
Notebook 9 yönelim, 8x8 hücre, 2x2 blok ve L2-Hys normalizasyonu kullanır.
Gerçek çalıştırmada her görüntü için HOG özellik boyutu 3,780'dir.
8. LBP Özellik Çıkarımı
LBP (Local Binary Pattern), merkez piksel ile komşu pikseller arasındaki yerel yoğunluk ilişkilerini kodlayan
klasik bir mikro-doku tanımlayıcısıdır. Göz çevresi deri dokusu, iris çevresi ve ince kontrast değişimlerinin
Real/Fake ayrımına katkısını ölçmek için kullanılır.
P=8, R=1 ve uniform yöntem kullanılır. LBP görüntüsü doğrudan modele verilmez; normalize histogram üretilir.
Gerçek çalıştırmada LBP histogram boyutu 10'dur.
9. HOG + LBP Özellik Füzyonu
Özellik Boyut
HOG 3,780
LBP 10
Birleştirilmiş vektör 3,790
İki vektör np.concatenate ile uç uca eklenir. Böylece SVM aynı örneğin hem şekil/yönelim hem de mikro-doku
bilgisini birlikte görür. Birleştirilmiş vektörde NaN veya Inf tespit edilirse süreç hata verir.

10. Classical-ML Smoke Test
Tüm veri üzerinde uzun işlem başlamadan önce train setinden iki Real ve iki Fake örnek seçilir. Bu dört örnekte HOG + LBP çıkarımı, StandardScaler fit'i, Linear SVM eğitimi ve tahmin çalıştırılır.
Bu test feature extraction, scaler ve SVM zincirinin temel olarak çalıştığını doğrular. Gerçek run'da Classical-
ML smoke test PASS olmuştur ve özellik boyutu 3,790 olarak doğrulanmıştır.
11. Feature Cache Mekanizması
Train, validation ve test özellikleri ayrı NPZ cache dosyalarına atomik olarak kaydedilir. Cache dosyası varsa
yeniden HOG/LBP hesaplamak yerine doğrudan yüklenir.
Split Gerçek extraction süresi
Train - 2,388 örnek 34.68 s
Validation - 296 örnek 3.37 s
Test - 302 örnek 3.13 s
Cache yaklaşımı özellikle Colab kesintileri veya aynı run'ın devam ettirilmesi durumunda ciddi süre kazandırır.
12. StandardScaler: Neden Yalnız Train Üzerinde?
HOG ve LBP özelliklerinin sayısal ölçekleri farklıdır. SVM özellikle RBF kernel kullanırken feature ölçeğine
duyarlıdır; bu nedenle özellikler StandardScaler ile standartlaştırılır.
Scaler yalnız X_train üzerinde fit edilir. Validation yalnız transform edilir; test ise model ve threshold seçimi
tamamlanana kadar dönüştürülmez. Bu tasarım validation/test istatistiklerinin train aşamasına sızmasını engeller.
13. SVM Adayları ve Model Seçimi
Notebook tek bir SVM seçip test etmez. Linear ve RBF kernel için önceden tanımlı hiperparametre kombinasyonlarını train setinde fit eder ve yalnız validation setinde karşılaştırır.
Kernel C Gamma Aday sayısı
Linear 0.1, 1.0, 10.0 Yok 3
RBF 0.1, 1.0, 10.0 scale, 0.001, 0.0001 9
Toplam - - 12
Her aday için decision_function skoru üretilir. Precision-Recall eğrisi üzerinden validation F1'i maksimum
yapan karar threshold'u aday bazında ayrıca seçilir.
13.1. Gerçek run'da seçilen model
Seçilen ayar Değer
Kernel RBF
C 10.0
Gamma 0.0001
Threshold -0.543336
Selection split Validation
Selection metric F1
Validation Accuracy 0.6284
Validation Precision 0.5721
Validation Recall 0.8723
HOG + LBP + SVM - Göz Deepfake Tespiti Kod Açıklama Raporu
Validation F1 0.6910

Validation Specificity 0.4065
Validation ROC-AUC 0.6794
Validation Avg. Precision 0.6485
12 adayın tamamının taranması yaklaşık 557 saniye sürmüştür. En iyi validation F1, RBF kernel C=10 ve gamma=0.0001 kombinasyonunda elde edilmiştir.
14. Threshold Neden Ayrı Seçiliyor?
SVC decision score üretir ve varsayılan karar sınırı 0 olabilir. Notebook sabit 0 kullanmak yerine validation
setindeki Precision-Recall eğrisini tarayarak F1'i en yüksek yapan threshold'u seçer.
Seçilen threshold daha sonra sabitlenir ve test setinde değiştirilmez. Böylece test sonuçlarına bakarak karar
sınırı ayarlama yoluyla veri sızıntısı oluşması engellenir.
15. Checkpoint ve Yeniden Yükleme Kalite Kapıları
Bu deney PyTorch sinir ağı değildir; dolayısıyla optimizer_state_dict, scheduler veya epoch tabanlı gradient
training state'i doğal olarak yoktur. Notebook bunları varmış gibi üretmek yerine N/A olarak açıkça işaretler.
Çıktı İçerik / amaç
best.ckpt Seçilen SVC + scaler + threshold + config + RNG state
last.ckpt Son klasik-ML kayıt durumu
checkpoint_quality_gate.ckpt Atomik save/reload doğrulaması
svm_model.joblib Bağımsız inference için model paketi
Checkpoint yeniden yüklendikten sonra validation decision score'larının orijinal modelle np.allclose düzeyinde
aynı olduğu doğrulanır. Ayrıca svm_model.joblib sıfırdan yüklenip örnek inference üreterek fresh-load testinden geçirilir.
16. Quality Gate Sonuçları
Kontrol Durum
Metadata schema PASS
Current video_id group split test PASS_FOR_CURRENT_VIDEO_ID_GROUPS
True video-level split test NOT_VERIFIABLE_FROM_CURRENT_METADATA
Data accounting PASS
Exact duplicate SHA256 PASS
Numerical feature check PASS
Classical ML smoke test PASS
PyTorch forward/backward NOT_APPLICABLE_CLASSICAL_ML
Checkpoint atomic save/reload PASS
Fresh-load inference PASS
Test used for selection? False
True video-level testinin NOT_VERIFIABLE olması hata değildir; mevcut metadata'nın original source-video kimliğini kanıtlamadığını açık biçimde raporlar. Bu, yanlış bir PASS iddiası üretmekten daha doğru ve denetlenebilir bir davranıştır.
HOG + LBP + SVM - Göz Deepfake Tespiti Kod Açıklama Raporu
17. Nihai Test Değerlendirmesi
Test setine model ve threshold seçimi tamamlandıktan sonra ilk kez bakılır. Frame düzeyinde her combined-eye ROI bağımsız örnek olarak değerlendirilir.
Frame-level test metriği Değer
Accuracy 0.5927
Precision 0.5714
Recall 0.8462
F1 0.6822
Specificity 0.3219
ROC-AUC 0.6032
Average Precision 0.6051
Frame-level sonuçta Fake recall yüksektir (%84.62); buna karşılık specificity %32.19'dur. Bu nedenle model
Fake örnekleri yakalamaya eğilimli, fakat Real örneklerde yanlış alarm üretmeye açıktır. ROC-AUC 0.6032 olması, ayrıştırma gücünün rastgele seviyenin üzerinde fakat sınırlı olduğunu gösterir.
17.1. Group-level (metadata video_id) sonuçları
Group-level metrik Değer
Accuracy 0.5000
Precision 0.5000
Recall 1.0000
F1 0.6667
Specificity 0.0000
ROC-AUC 1.0000
Average Precision 1.0000
Bu değerler gerçek video-level genelleme metriği olarak yorumlanmamalıdır. Mevcut metadata'da train, validation ve test için yalnızca 2'şer video_id grubu vardır ve bu video_id alanı gerçek orijinal video

kimliği
olmayabilir.
ROC-AUC=1.0 görünmesine rağmen accuracy=0.5 ve specificity=0 olması, score sıralamasının iki grup arasında doğru olabilse bile seçilen threshold'un tüm group kararlarını Fake tarafına taşıdığını gösterir. Küçük
grup sayısı nedeniyle bu sonuç keşifsel/yardımcıdır.
18. Üretilen Grafikler
Grafik Amaç
dataset_distribution.png Split-sınıf dağılımı
svm_validation_f1_comparison.png 12 SVM adayının validation F1 karşılaştırması
test_confusion_matrix_frame_level.png Frame-level hata dağılımı
test_confusion_matrix_group_level.png Metadata-group-level hata dağılımı
test_roc_curve_frame_level.png Frame-level ROC
test_roc_curve_group_level.png Group-level ROC
test_precision_recall_curve_frame_level.png Frame-level PR
test_precision_recall_curve_group_level.png Group-level PR
test_decision_score_distribution.png Real/Fake decision score dağılımı ve threshold
Tüm grafiklerin kısa kenarı en az 600 piksel olmalıdır. Gerçek run'da 9 grafiğin tamamı quality_pass=True

çıkmıştır.

19. Sonuç Klasörüne Kaydedilen Yapı
Her run aşağıdaki mantıkla saklanır:

```
<run_id>/
  checkpoints/
    best.ckpt
    last.ckpt
    checkpoint_quality_gate.ckpt
  logs/
    run.log
  metrics/
    data_accounting.json
    svm_validation_search.csv
    svm_selection.json
    quality_gates.json
    test_metrics_frame_level.json
    test_metrics_group_level.json
    test_metrics_summary.csv
    fresh_load_inference_test.json
    figure_quality_audit.csv
  predictions/
    test_predictions_frame_level.csv
    test_predictions_group_level.csv
  figures/
  artifacts/
    metadata_used.csv
    features_train.npz
    features_val.npz
    features_test.npz
    feature_dimensions.json
    feature_pipeline.json
    feature_preprocessing.joblib
    svm_model.joblib
  config_resolved.yaml
  requirements_lock.txt
  environment.json
  output_manifest.csv
  run_summary.json
```

20. Notebook'un Yapmadığı Şeyler
• Combined-eye görüntülerini yeniden kırpmaz veya kaynak ROI'lerin üzerine yazmaz.
• Frame düzeyinde yeni rastgele train/validation/test bölmesi oluşturmaz; metadata splitlerini kullanır.
• Pretrained CNN, ResNet, EfficientNet, Xception veya Transformer kullanmaz.
• HOG veya LBP'yi eğitmez; bunlar deterministik feature extractor'lardır.
• Test setini SVM veya threshold seçimi için kullanmaz.
HOG + LBP + SVM - Göz Deepfake Tespiti Kod Açıklama Raporu
• Metadata video_id alanını gerçek source-video kimliği diye uydurmaz.
• Klasik SVM deneyine PyTorch optimizer/epoch state'i yapay biçimde eklemez.
21. Genel Teknik Değerlendirme
Bu notebook göz bölgesine özgü, izlenebilir ve yeniden üretilebilir bir klasik makine öğrenmesi

baseline'ı
oluşturur. Combined-eye ROI'den HOG ile yönelim/geometri, LBP ile mikro-doku özellikleri çıkarılır; 3,790

boyutlu birleşik temsil train-fitted StandardScaler ile normalize edilir ve validation setinde 12 SVM
adayı
arasından en iyisi seçilir.
Gerçek çalıştırmada RBF SVM (C=10, gamma=0.0001) seçilmiş ve validation F1=0.691 elde edilmiştir. Testte
frame-level recall=0.846 ve F1=0.682 iken ROC-AUC=0.603 ve specificity=0.322'dir. Bu sonuç, HOG+LBP
özelliklerinin Fake örnekleri yakalama açısından yararlı sinyal taşıdığını; ancak Real/Fake ayrımında tek

başına güçlü bir çözüm olmadığını göstermektedir.
En önemli metodolojik güçlü yönler; test izolasyonu, train-only scaling, validation-only threshold
seçimi, exact-
content SHA256 leakage kontrolü, atomik kayıt, fresh-load inference ve metadata anlamı hakkında yanlış
iddiadan kaçınılmasıdır.