

DEEPPFAKE DETECTION

Göz ROI - Xception Deneyi

Kod, Model ve Yöntem Analiz Raporu

Deney: Kader / Deney 1
Run ID: 20260807_1004_eye_xception_seed42
Model: timm legacy_xception (ImageNet pretrained)
ROI: Combined Eye
Seed: 42

Kaynaklar: Kader_Deney1_Eye_Xception_SSOT_v2 (1).ipynb ve ML Proje & Kod Standardı v2.0

1. Yönetici Özeti

Bu rapor, göz bölgesinden (combined eye ROI) deepfake sınıflandırması yapmak üzere hazırlanan Xception tabanlı PyTorch/timm notebook'unu hücre düzeyinde incelemektedir. Rapor; veri hattı, model mimarisi, kayıp fonksiyonu, optimizasyon, iki aşamalı transfer öğrenme stratejisi, epoch ve öğrenme oranı seçimleri, checkpoint mekanizması, değerlendirme metrikleri, sonuçların yorumu ve kod standardına uyum açısından ayrıntılı teknik açıklama sunar.

Deneyin ana sonucu

Frozen aşamada en iyi validation ROC-AUC 0.60355 iken, tüm Xception omurgasının kontrollü fine-tuning'i sonunda validation ROC-AUC 0.72523'e yükselmiştir. Nihai test ROC-AUC 0.67698, test F1 0.70345 ve FAKE recall 0.98077'dir. Bununla birlikte specificity 0.13699 olduğundan model gerçek örnekleri yanlışlıkla FAKE olarak işaretlemeye çok yatkındır; bu nedenle mevcut threshold ile üretim düzeyi dengeli bir sınıflandırıcı değildir.

Kritik kod bulgusu

Cell 5 video-level leakage denetimini NOT_AVAILABLE olarak doğru raporlarken Cell 14 final özetinde split_leakage_check ve "Video split leakage" değerleri sabit biçimde PASSED yazılmıştır. Bu raporlama tutarsızlığı düzeltilmelidir. Ayrıca fine-tuning öncesi BatchNorm katmanları eval() moduna alınsa da run_epoch içindeki model.train(True) çağrısı bu durumu geri çevirdiği için "BatchNorm running stats frozen" iddiası kodda fiilen korunmamaktadır.

2. Deneyin Amacı ve Sistem Akışı

Amaç, yalnızca göz bölgesine ait birleşik ROI görüntülerini kullanarak REAL ve FAKE sınıflarını ayırmaktır. Notebook, ham videodan ROI çıkarma yapmaz; daha önce oluşturulmuş eye_roi_output yapısını tüketir. Sınıflandırma ikili problemdir: REAL=0 ve FAKE=1.

Aşama	Kodda yapılan işlem	Amaç
1. Ortam	PyTorch, timm, seed=42, CUDA tespiti	Tekrarlanabilir çalışma ortamı
2. Yol/config	Drive klasörleri ve YAML konfigürasyonu	Tek doğruluk kaynağı ve deney kimliği
3. Metadata	2.986 ROI dosyasını doğrulama, SHA256, audit alanları	Veri muhasebesi ve izlenebilirlik
4. Leakage	sample_id, SHA256 ve kaynak kimliği kontrolleri	Split sızıntısını yakalama
5. Dataset	299x299 RGB, augmentation, ImageNet normalization	Xception girdisini hazırlama
6. Smoke test	2 batch forward/backward	Tam eğitim öncesi kalite kapısı
7. Frozen eğitim	Sadece 2.049 classifier parametresi eğitilir	Pretrained özelliklerden güvenli başlangıç
8. Fine-tuning	20.809.001 parametrenin tamamı açılır	Göz ROI alanına uyarlama
9. Seçim	Validation ROC-AUC ile aşama seçimi; val F1 ile threshold	Test setinden bağımsız model seçimi
10. Test/rapor	Fresh-load inference, metrikler ve grafikler	Nihai performans ve denetlenebilir çıktı

3. Veri Yapısı ve Veri Kalitesi

Split	REAL	FAKE	Toplam
Train	1.197	1.191	2.388
Validation	155	141	296
Test	146	156	302
Toplam	1.498	1.488	2.986

Sınıf dağılımı oldukça dengelidir. Train setinde REAL/FAKE oranı 1197/1191 olduğu için BCEWithLogitsLoss içindeki pos_weight yaklaşık 1.005038'dir. Bu değer 1'e çok yakın olduğundan sınıf ağırlıklandırmasının bu deneyde etkisi sınırlıdır; ancak kodun dengesiz veri senaryolarına dayanıklı kalmasını sağlar.

3.1 Metadata ve bütünlük kontrolleri

Cell 4; dosya adı şemasını, label/split tutarlılığını, dosya okunabilirliğini ve isteğe bağlı SHA256 bütünlük hash'ini kontrol eder. Her ROI için sample_id, source_frame, frame_index, face_index, roi_state, label, split, status, skip_reason, sha256, output_path, relative_path ve run_id alanları üretilir. Bu yaklaşım, sadece "dosya var mı" kontrolü yerine her örneğin denetlenebilir bir kayda sahip olmasını sağlar.

3.2 Leakage denetiminin gerçek durumu

Exact-content (SHA256) split izolasyonu PASSED, sample-id izolasyonu PASSED ve source-frame/face kimliği tekilliği PASSED olmuştur. Ancak 2.986 örneğin hiçbirinde authoritative source_video bulunmadığı için video-level leakage denetimi NOT_AVAILABLE'dır. Bu, kodun doğru şekilde "kanıtlanamayan şeyi geçmiş saymama" ilkesidir. Önemli bir ayrıntı: sample_id üretiminde split bilgisi de hash girdisine dahil edildiğinden sample_id disjoint kontrolü tek başına güçlü bir leakage kanıtı değildir; aynı örnek farklı splitte farklı sample_id alabilir. En güçlü mevcut kontrol SHA256'dır. Video kimliği metadata ile geri kazanılınca gerçek video-level disjoint kontrolü yapılmalıdır.

4. Model: Xception Nedir ve Neden Seçilmiştir?

Notebook doğrudan timm.create_model("legacy_xception", pretrained=True, num_classes=1) kullanır. Model 20.809.001 parametreye sahiptir. Frozen aşamada yalnızca son classifier katmanındaki 2.049 parametre eğitilir; bu değer 2.048 boyutlu özellik vektöründen tek logit üreten lineer başlık (2048 ağırlık + 1 bias) ile uyumludur.

4.1 Xception mimarisinin temel özellikleri

Özellik	Açıklama	Bu deney açısından anlamı
Depthwise separable convolution	Uzamsal filtreleme ile kanal karıştırmayı ayırıştırır.	Daha verimli özellik çıkarımı; ince doku ve yerel artefaktların modellenmesine uygundur.
Residual bağlantılar	Derin ağlarda gradyan akışını kolaylaştırır.	Pretrained ağı yeni göz ROI alanına fine-tune etmeyi daha kararlı hale getirir.
2048-d özellik uzayı	Classifier öncesinde yüksek boyutlu temsil üretir.	Göz dokusu, kenar, yansıma ve lokal bozulma ipuçlarını birlikte temsil edebilir.
299x299 giriş	Legacy Xception'ın tipik giriş çözünürlüğüdür.	ROI'yi aşırı küçültmeden ayrıntı korunur.
ImageNet pretrained	Genel görsel kenar/doku/şekil filtreleri hazır gelir.	2.986 örnekli veri setinde sıfırdan eğitime göre daha veri-verimli başlangıç sağlar.

Model seçiminin koddaki açıklanmış resmi bir hiperparametre araması veya model karşılaştırması yoktur. Bu nedenle “neden Xception” gerekçesi, notebook’un doğrudan kanıtladığı bir seçim sonucu değil, teknik rasyoneldir. Deepfake görüntülerinde lokal doku, sınır, yeniden örnekleme ve frekans benzeri görsel ipuçları önemli olduğundan Xception gibi konvolüsyonel ve güçlü transfer öğrenme omurgaları mantıklı bir başlangıç modelidir. Ancak bu deney tek başına Xception’ın diğer modellerden daha iyi olduğunu kanıtlamaz.

5. Girdi Ön İşleme ve Augmentation

Parametre	Değer	Gerekçe / etkisi
ROI	combined eye	İki gözü aynı örnekte birlikte vererek simetri ve bölgesel tutarlılık bilgisini korur.
Girdi boyutu	299 x 299	Xception’ın doğal giriş ölçeğiyle uyumlu.
Horizontal flip	p=0.5	Sağ-sol yön bağımlılığını azaltır.
Rotation	$\pm 5^\circ$	Küçük baş/ROI hizalama hatalarına dayanıklılık sağlar; agresif dönüşümden kaçınır.
Brightness	0.08	Işık koşulu değişimine sınırlı dayanıklılık.
Contrast	0.08	Kamera/ışık kaynaklı kontrast değişimine dayanıklılık.
Normalization	ImageNet mean/std	Pretrained backbone’un eğitim dağılımıyla uyumlu giriş ölçeği.
Batch size	16	GPU belleği, 299x299 giriş ve 20.8M parametrelili model arasında pratik denge.

Augmentation sadece train setinde uygulanır; validation ve test deterministik resize + normalization kullanır. Bu ayrım değerlendirme setlerine yapay varyasyon eklenmesini önler. Augmentation şiddeti bilerek düşüktür; deepfake tespiti ince adli ipuçlarına dayandığı için güçlü rotation veya renk değişimleri gerçek artefaktları bozabilir.

Standartla ilgili nüans

SSOT metni normalizasyon istatistiklerinin train setinden hesaplanmasını önerir. Bu notebook ise ImageNet pretrained Xception kullandığı için ImageNet mean/std kullanır. Transfer öğrenmede teknik olarak yaygın ve mantıklı bir tercihtir; ancak standardın harfiyle tam uyumlu değildir.

6. Kayıp Fonksiyonu, Optimizer ve Scheduler

6.1 BCEWithLogitsLoss

Model tek logit üretir. BCEWithLogitsLoss sigmoid işlemini kayıp içinde sayısal olarak kararlı biçimde uygular. FAKE pozitif sınıftır. pos_weight=REAL/FAKE=1.005038 kullanıldığı için olası sınıf dengesizliği telafi edilir. Veri neredeyse dengeli olduğundan bu deneyde ağırlık etkisi minimaldir.

6.2 AdamW

Optimizör AdamW ve $\text{weight_decay}=1e-4$ 'tür. AdamW adaptif öğrenme oranının kolaylığını ağırlık çürümesini optimizör güncellemesinden ayırıştırarak sunar. Transfer öğrenmede farklı katman ölçekleri ve küçük öğrenme oranlarıyla pratik bir seçenektir.

6.3 ReduceLROnPlateau

Scheduler validation ROC-AUC değerini "max" modunda izler. İki epoch boyunca anlamlı gelişme görülmezse LR 0.5 katsayısıyla azaltılır. Loss yerine ROC-AUC izlenmesi, ikili sınıflandırmada olasılık sıralama kalitesine odaklanır ve sabit threshold'a daha az bağımlıdır.

6.4 Gradient clipping


Gradient norm üst sınırı 5.0'dır. Fine-tuning öncesi FP32 probe'da norm 6.744028 ölçülmüş, dolayısıyla clipping gerçekten aktif bir stabilizasyon bileşenidir. Kod NaN/Inf gradient gördüğünde eğitimi durdurur; hatayı yutmaz.

7. Neden 12 Frozen + 8 Fine-tuning Epoch?


Aşama	Epoch	LR	Eğitilen parametre	Amaç
Frozen	12	$1e-4$	2.049	Classifier başlığını pretrained özelliklere uyarlamak.
Fine-tuning	8	konfigürasyonda $1e-5$, efektif $5e-6$	20.809.001	Tüm özellik çıkarıcıyı göz ROI domainine düşük LR ile uyarlamak.

12 ve 8 değerleri kodda sabit konfigürasyon tercihidir; notebook bunların grid search, Bayesian optimization veya ayrı bir ablation çalışmasıyla "optimal" bulunduğunu göstermemektedir. Bu nedenle raporda bu sayılar "kanıtlanmış optimum" değil, kontrollü transfer öğrenme için seçilmiş eğitim bütçesi olarak değerlendirilmelidir.

Frozen aşamanın 12 epoch sürmesi mantıklıdır çünkü yalnızca çok küçük bir classifier başlığı eğitilir ve validation AUC 0.50176'dan 0.60355'e kadar istikrarlı yükselmiştir. Fine-tuning'de 8 epoch boyunca validation AUC 0.64356'dan 0.72523'e yükselmeye devam ettiği için eğitim bütçesi boşa gitmemiştir. Erken stopping patience=4 yapılandırılmıştır; ardışık iyileşmeler nedeniyle iki aşamada da erken durma tetiklenmemiştir.



Şekil 1. İki aşamalı eğitim boyunca validation ROC-AUC gelişimi.



Şekil 2. Frozen ve fine-tuning aşamalarında train/validation loss eğrileri.

8. Fine-tuning Stabilizasyonu: Neden FP32 ve 5e-6 LR?

İlk full fine-tuning denemesinde AMP/FP16 altında “Non-finite gradient norm detected” hatası oluşmuştur. Kod standardına uygun olarak NaN/Inf kontrolü eğitimi durdurmuştur. Revize Cell 10, bu problemi gizlemek yerine sayısal koşulları daha güvenli hale getirmiştir: AMP kapatılmış, efektif LR 5e-6'ya düşürülmüş ve eğitim öncesi tek-batch FP32 numerical smoke test eklenmiştir. Probe loss 0.663541 ve gradient norm 6.744028 ile finite çıkmış, ardından fine-tuning başarıyla tamamlanmıştır.

Stabilizasyon	Neden kullanıldı?	Sonuç
AMP kapatma	FP16 backward sırasında Inf/NaN gradient oluştu.	Stage 2 FP32 ile stabil çalıştı.
LR 1e-5 -> 5e-6	Tüm backbone açıldığında büyük ağırlık güncellemelerini azaltmak.	Val AUC 0.6035 -> 0.7252.
Numerical smoke test	Tam epoch maliyetinden önce finite logits/loss/gradient doğrulamak.	Probe başarıyla geçti.
Gradient clipping 5.0	Gradient patlamasını sınırlamak.	Probe norm 6.744 olduğu için clipping devreye girdi.
NaN/Inf hard fail	Bozuk ağırlıklarla sessizce devam etmeyi engellemek.	SSOT sayısal kalite kapısı korunuyor.

BatchNorm uygulama hatası

Cell 10'da 40 BatchNorm katmanı eval() moduna alınarak running statistics'in dondurulduğu belirtiliyor. Ancak train_stage -> run_epoch(train) içinde model.train(True) çağrısı tüm BatchNorm katmanlarını yeniden training moduna geçirir. Bu nedenle mevcut notebook'ta running statistics fiilen frozen değildir. Gerçekten dondurmak için model.train() sonrasında BatchNorm modüllerine tekrar eval() uygulanmalıdır.

9. Reproducibility, Checkpoint ve Kesinti Sonrası Devam

Seed 42 Python, NumPy, Torch ve CUDA için uygulanır; cudnn deterministic=True ve benchmark=False seçilir. DataLoader worker seed'i ayrıca torch.initial_seed üzerinden türetilir. Checkpoint state'i model, optimizer, scheduler, scaler, best score, early-stopping wait, config ve RNG durumlarını içerir.

atomic_save_checkpoint önce .tmp dosyasına yazar, dosyayı tekrar yükleyip gerekli anahtarları doğrular ve son olarak os.replace ile hedefe atomik taşır. last.ckpt kesintiden devam, best.ckpt en iyi validation performansı ve epoch_N.ckpt dönen yedekler için kullanılır. Son 3 epoch checkpoint'i korunur. Bu tasarım, Colab/Drive kesintilerinde ağırlık veya optimizer durumunun yarım yazılması riskini azaltır.

10. Model Seçimi ve Threshold Stratejisi


Frozen ve fine-tune best checkpoint'leri validation setinde yeniden değerlendirilir. Model aşaması validation ROC-AUC'ye göre seçilir. Fine-tune checkpoint'i ROC-AUC 0.72503 ile frozen checkpoint'in 0.60355 değerini geçtiği için seçilmiştir. Test seti bu kararda kullanılmamıştır.

Validation metrik	Frozen	Fine-tune
Loss	0.68107	0.61963
Accuracy	0.56081	0.65878
Balanced Accuracy	0.56783	0.66202
Precision	0.52880	0.62048
Recall	0.71631	0.73050
F1	0.60843	0.67101
ROC-AUC	0.60355	0.72503
PR-AUC	0.57944	0.71084

Threshold 0.05 ile 0.95 arasında 181 noktalı grid üzerinde yalnızca validation setinde taranır ve en yüksek F1'i veren threshold=0.305 seçilir. Düşük threshold FAKE sınıfını yakalamayı kolaylaştırır; bunun doğal bedeli daha fazla false positive'dir. Nihai test sonuçları bu trade-off'u çok net göstermektedir.

11. Nihai Test Sonuçları ve Yorum

Metrik	Değer	Yorum
Accuracy	0.57285	Genel doğruluk düşük-orta.
Balanced Accuracy	0.55888	İki sınıf dengeli değerlendirildiğinde sınırlı performans.
Precision (FAKE)	0.54839	FAKE denilen örneklerin yaklaşık %55'i gerçekten FAKE.
Recall (FAKE)	0.98077	FAKE örneklerin neredeyse tamamı yakalanıyor.
Specificity (REAL)	0.13699	REAL örneklerin yalnızca yaklaşık %14'ü doğru REAL kalıyor.
F1 (FAKE)	0.70345	Yüksek recall nedeniyle güçlü görünen pozitif-sınıf F1.
ROC-AUC	0.67698	Threshold bağımsız ayırım yeteneği orta düzey.
PR-AUC	0.68654	Pozitif sınıf sıralama performansı orta düzey.



Şekil 3. Nihai test confusion matrix: $TN=20$, $FP=126$, $FN=3$, $TP=153$.

Modelin karakteri “yüksek duyarlılık, düşük özgüllük” şeklindedir. 156 FAKE örneğin 153’ünü yakalarken 146 REAL örneğin 126’sını FAKE olarak işaretlemiştir. Bu davranış $\text{threshold}=0.305$ seçiminin doğrudan sonucudur. Amaç deepfake kaçırmamak ise bu tercih anlaşılabilir; amaç dengeli sınıflandırma ise threshold seçim hedefi F1 yerine balanced accuracy, Youden J, specificity kısıtı veya maliyet duyarlı bir hedef olarak yeniden tanımlanmalıdır.

Validation ROC-AUC 0.7250’dan test ROC-AUC 0.6770’ye düşmüştür. Fark aşırı büyük değildir fakat genelleme kaybına işaret eder. Test accuracy’nin düşük olmasına rağmen F1’in 0.703 olması, tek başına F1 raporlamanın yanıltıcı olabileceğini gösterir; specificity, balanced accuracy ve confusion matrix birlikte değerlendirilmelidir.

12. Hücre Bazlı Kod Analizi

Cell	İşlev	Teknik amaç / kalite kapaşı
1	Bağımlılıklar, seed, device	Reproducibility ve GPU/AMP koşullarını belirler.
2	Drive + path resolver + config	Klasör adlarını normalize eder, run ID ve output yapısını kurar.
3	Atomic I/O, hash, RNG state	Bozulmaya dayanıklı kayıt ve çevre kilidi üretir.
4	Metadata build	2.986 ROI’yi şema, dosya ve SHA256 açısından denetler.

5	Leakage quality gate	Exact hash ve kimlik izolasyonu; video audit mevcut durumda NOT_AVAILABLE.
6	Dataset + transforms + loaders	None-safe metadata, sınıf kontrolü, first-batch collation gate.
7	Xception + smoke test	Full eğitim öncesi 2 batch forward/backward ve finite gradient testi.
8	Training engine	Metrikler, AMP, clipping, scheduler, checkpoint, resume, early stopping.
9	Frozen stage	Classifier-only 12 epoch transfer learning.
10	Stable fine-tune	FP32, düşük LR, numerical probe, full backbone 8 epoch.
11	Validation-only selection	Model aşamasını ROC-AUC, threshold'u validation F1 ile seçer.
12	Fresh model test	best.ckpt'i yeni modelde yükleyip nihai test ve tahmin CSV'si üretir.
13	Figures	Confusion, ROC, PR, loss/AUC ve final metrics; >=600px doğrulama.
14	Final audit	Dosya varlıklarını kontrol eder ve özet üretir; leakage durumunda hard-code hatası var.

13. ML Kod Standardına Uyum Değerlendirmesi

Kural	Durum	Açıklama
Run ID ve izole output	UYUMLU	YYYYMMDD_HHMM_eye_xception_seed 42 yapısı kullanılıyor.
Atomic checkpoint	UYUMLU	tmp + integrity load + os.replace.
RNG state / seed	UYUMLU	Python, NumPy, Torch, CUDA ve DataLoader worker seed.
Smoke test	UYUMLU	2 batch forward/backward + finite gradient.
NaN/Inf hard fail	UYUMLU	Non-finite loss/gradient eğitim durduruyor.
Test izolasyonu	UYUMLU	Model ve threshold seçimi validation ile.
Grafik standardı	UYUMLU	İngilizce, 150 DPI, short-edge >=600 px.
Video-level split izolasyonu	EKSİK KANIT	source_video yok; Cell 5 NOT_AVAILABLE.
Final leakage raporu	HATALI	Cell 14 hard-coded PASSED yazıyor.
BatchNorm frozen iddiası	UYGULAMA HATASI	model.train() BN'leri yeniden training mode'a geçiriyor.
Train-derived normalization	KİSMİ UYUM	ImageNet pretrained nedeniyle ImageNet mean/std kullanılıyor.
Production modüler repo	KİSMİ UYUM	Notebook tek dosya; src/scripts ayrımı yok.

14. Düzeltilmesi / İyileştirilmesi Gereken Noktalar

- 1) Video leakage durumunu final özete dinamik bağla:** Cell 14 içinde split_leakage_check="PASSED" sabit yazılmamalı. leakage_audit["video_level_split_isolation"] değeri doğrudan kullanılmalı; NOT_AVAILABLE ise final raporda da aynı kalmalı.
- 2) BatchNorm freeze'i gerçekten uygula:** run_epoch içinde model.train(True) sonrasında, fine-tuning sırasında tüm _BatchNorm modüllerine eval() tekrar uygulanmalı veya freeze_bn flag'i run_epoch'a geçirilmeli.
- 3) sample_id leakage kontrolünü güçlendir:** sample_id üretiminden split bilgisini çıkarmak ya da ayrıca splitteden bağımsız stable_content_id oluşturmak daha anlamlı cross-split kimlik kontrolü sağlar.
- 4) source_video metadata join:** ROI üretim metadata'sındaki gerçek video kimliği yeni manifest'e bağlanmalı; train/val/test video isdisjoint ancak bundan sonra PASSED sayılmalı.
- 5) Threshold hedefini kullanım senaryosuna göre seç:** Mevcut F1 optimizasyonu specificity'yi çok düşürüyor. Balanced accuracy veya minimum specificity kısıtlı threshold karşılaştırması eklenmeli.
- 6) Hyperparameter gerekçesini deneysel hale getir:** 12/8 epoch, batch=16, augmentation ve LR değerleri için küçük bir ablation tablosu, "neden bu değer?" sorusunu varsayımdan kanıta dönüştürür.
- 7) GradScaler API güncellemesi:** torch.cuda.amp.GradScaler eski API uyarısı veriyor; torch.amp.GradScaler("cuda", enabled=...) kullanılmalı.
- 8) Modülerleştirme:** Notebook deney yürütmek için kullanılabilir; production/ekip standardında Dataset, model, training, evaluation ve config ayrı src modüllerine taşınmalı.

15. Sonuç

Notebook, deneysel ML kodu açısından güçlü bir omurgaya sahiptir: denetlenebilir metadata, SHA256 bütünlük kontrolü, deterministic seed yönetimi, iki batch smoke test, NaN/Inf kalite kapısı, atomik checkpoint/resume, validation-only seçim ve fresh-model test inference gibi kritik bileşenler yerindedir. Xception'ın iki aşamalı transfer öğrenme stratejisi de sayısal olarak fayda sağlamış; validation ROC-AUC yaklaşık 0.604'ten 0.725'e çıkmıştır.

Bununla birlikte nihai model performansı sınıflar arasında dengeli değildir. Threshold 0.305, FAKE recall'u %98'e çıkarırken REAL specificity'yi %13,7'ye düşürmüştür. Bu nedenle model "deepfake kaçırmama" yönünde agresif bir dedektör davranışı göstermektedir. Ayrıca video-level leakage'in kanıtlanamamış olması, Cell 14'ün bunu yanlışlıkla PASSED raporlaması ve BatchNorm freeze'in fiilen uygulanmaması çözülmesi gereken teknik konulardır. Bu düzeltmeler yapıldıktan sonra deney, metodolojik olarak daha güçlü ve raporlanabilir hale gelecektir.

16. Kaynaklar ve Dayanaklar

1. Kader_Deney1_Eye_Xception_SSOT_v2 (1).ipynb - bu raporun birincil kod ve deney çıktısı kaynağı.
2. ML Proje & Kod Standardı - Güvenilir Makine Öğrenmesi Geliştirme, SSOT v2.0 (Ağustos 2026) - checkpoint, split, görsel kalite ve kalite kapıları için ekip standardı.
3. Chollet, F. (2017). Xception: Deep Learning with Depthwise Separable Convolutions. CVPR - Xception mimarisinin teknik arka planı.
4. Loshchilov, I. & Hutter, F. (2019). Decoupled Weight Decay Regularization - AdamW optimizasyon yaklaşımının teknik arka planı.

5. PyTorch / timm teknik dokümantasyonu - BCEWithLogitsLoss, ReduceLROnPlateau, AMP ve legacy_xception uygulama ayrıntıları için genel teknik referans.

Ek A - Deney Konfigürasyonu

Parametre	Değer
seed	42
region	eye
roi_variant	combined
model_name	legacy_xception
pretrained	True
image_size	299
batch_size	16
num_workers	2
initial_epochs	12
finetune_epochs	8
initial_lr	1e-4
configured_finetune_lr	1e-5
effective_finetune_lr	5e-6
weight_decay	1e-4
early_stopping_patience	4
scheduler_patience	2
scheduler_factor	0.5
gradient_clip_norm	5.0
checkpoint_keep_last_n	3
threshold_grid_points	181
compute_sha256	True
verify_image_files	True