

Ağız ROI - Swin V2 Tiny Baseline

Kod, Model ve Yöntem Analiz Raporu

Rapor türü	Teknik kod raporu
Bölge	Ağız ROI (Mouth ROI)
Model	Torchvision Swin V2 Tiny (swin_v2_t)
Görev	Real / Fake ikili sınıflandırma
Run ID	20260807_2235_mouth_swinv2_tiny_seed42
Tarih	8 Ağustos 2026

Hazırlayan: Dilara Öztürk

1. Yönetici Özeti

Bu rapor, göz bölgesi için hazırlanmış Swin V2 Tiny baseline yaklaşımının ağız ROI verisine uyarlanmış notebook sürümünü açıklar. Uyarlamada modelin özellik çıkarım mekanizması değiştirilmemiş; veri kaynağı, ROI yolu, dataset sınıfı ve deney kimliği ağız bölgesine çevrilmiştir. Böylece göz ve ağız deneyleri mimari olarak karşılaştırılabilir kalmıştır.

Doğrulanmış nihai durum

Notebook, eğitim sonunda ALL FINAL QUALITY GATES PASSED mesajını üretmiştir. Checkpoint devamlılığı, CPU-GPU resume geçişi, dosya/audit kontrolleri, final inference ve çıktı kayıtları başarıyla tamamlanmıştır.

Bileşen	Uygulanan yapı
Girdi	224 x 224 RGB ağız ROI
Backbone	ImageNet-1K ön-eğitimli Swin V2 Tiny
Head	LayerNorm -> Dropout(0.20) -> Linear(768,1)
Loss	BCEWithLogitsLoss
Optimizer	AdamW; backbone 1e-5, head 1e-4
Seçim	Validation ROC-AUC; threshold validation F1
Kararlılık	FP32, gradient clipping, checkpoint/resume, early stopping

2. Ağız Bölgesine Uyarlanan ve Korunan Unsurlar

Bu çalışmada “özellik çıkarımını ağıza göre elle değiştirme” yapılmamıştır. Swin V2 Tiny ağız görüntülerindeki doku, dudak sınırı, renk geçişi, kompresyon izi ve sentez artefaktlarını eğitim sırasında otomatik öğrenir. Bu, transfer learning yaklaşımının doğal sonucudur.

Değiştirilen	Korunan
Eye ROI yolları -> Mouth ROI yolları	Swin V2 Tiny backbone ve pretrained ağırlıklar
EyeROIDataset -> MouthROIDataset	224 x 224 RGB giriş ve ImageNet normalizasyonu
combined_eye_path -> ağız ROI görüntü yolu	LayerNorm, Dropout(0.20), Linear(1) head
Deney adı, run ID ve çıktı klasörleri	Loss, optimizier, LR grupları, scheduler
Dosya yolu çözümleme/audit ağız köküne uyarlandı	Leakage kontrolü, checkpoint, resume ve kalite kapıları

Neden mimariyi değiştirmedik?

Amaç, yalnızca yüz bölgesinin etkisini incelemektir. Model mimarisi de değiştirilseydi performans farkının ağız bölgesinden mi yoksa yeni mimariden mi geldiği ayırt edilemezdi. Bu nedenle kontrollü deney yaklaşımı korunmuştur.

3. Modüler Kod Mimarisi

Dosya/modül	Sorumluluk
utils/repro.py	Seed, worker seed, RNG state kaydetme ve geri yükleme
utils/io.py	Atomik checkpoint/JSON yazma, kaynak ağacı hash işlemleri
data/dataset.py	Ağız ROI okuma, dönüşümler ve etiket üretimi
models/swin.py	Pretrained Swin V2 Tiny ve binary classification head
training/engine.py	Epoch döngüsü, metrikler, eşik seçimi, sayısal kontroller
evaluation/plots.py	ROC, PR, confusion matrix ve eğitim grafiklerinin üretimi
Notebook hücreleri	Konfigürasyon, yol çözümleme, audit, eğitim ve final kayıt akışı

Akış sırası

Ortam ve paket oluşturma -> Drive bağlama -> konfigürasyon -> yol/run çözümleme -> metadata audit -> dataset/dataloader -> model ve optimizer -> smoke test -> checkpoint testi -> resume -> eğitim -> best checkpoint inference -> kare/video değerlendirmesi -> grafikler -> final kalite kapıları.

Kaynak snapshot ve hash

Notebook çalışma anındaki modüler kaynak dosyalarını deney klasörüne kopyalar ve hash bilgisi üretir. Böylece daha sonra kod değişse bile hangi sürümle eğitim yapıldığı denetlenebilir.

4. Metadata, Dosya Yolları ve Leakage Denetimi

Metadata toplam 3.098 kayıt içerirken kabul edilen başarılı ağız ROI kaydı 2.987, atlanan kayıt sayısı 111'dir. Eğitim yalnızca status=success kayıtlarında yapılmıştır.

Split	Real kare	Fake kare	Toplam
Train	1.197	1.192	2.389
Validation	155	141	296
Test	146	156	302
Toplam	1.498	1.489	2.987

Yol uyumsuzluğu düzeltilmesi

Drive kökü bazı oturumlarda "AISC Çalışmalar", bazılarında "AISC DeepFake Çalışmaları" olarak çözüldüğü için ilk kontrolde 2.987 ROI eksik görünmüştür. Dosyalar kayıp değildi. Çözümleyici, metadata içindeki mouth_roi_output sonrasındaki görelî yolu güncel MOUTH_ROI_ROOT ile birleştirecek şekilde güvenli olarak güncellenmiştir.

Leakage savunması

Split/label şeması, dosya varlığı, çoğaltılmış yol/kayıtlar ve video kimliği ayrışması kontrol edilir. Validation veya test istatistikleri normalizasyon öğrenmekte kullanılmaz; ImageNet pretrained ağırlıklarının sabit mean/std değerleri uygulanır.

5. Model ve Özellik Çıkarımı

Swin Transformer görüntüyü 4 x 4 patch'lere ayırır. Window attention yerel ağız dokularını işler; shifted-window blokları komşu pencereler arasında bilgi aktarır. Hiyerarşik stage yapısı düşük seviyeli kenar/doku bilgisini daha geniş biçim ve bağlam özellikleriyle birleştirir.

Mimari ögesi	Değer / İşlev
Patch size	4 x 4
Embedding	96 kanal
Stage derinlikleri	2 / 2 / 6 / 2
Attention head	3 / 6 / 12 / 24
Window	8 x 8
Backbone çıkışı	768 özellik
Binary head	LayerNorm -> Dropout 0.20 -> Linear(1)

Önemli ayrım

Bu model MAR gibi elle hesaplanan bir biyometrik özellik kullanmaz. Girdi doğrudan ağız ROI görüntüsüdür ve özellikler Swin backbone tarafından öğrenilir. Tek logit üretilir; sigmoid yalnızca olasılık gerektiğinde uygulanır.

6. Eğitim Tasarımı ve Sayısal Kararlılık

Ayar	Değer	Gerekçe
Seed	42	Tekrar üretilebilirlik
Maksimum epoch	20	Early stopping için üst sınır
Patience	6	Aşırı öğrenme ve gereksiz süreyi azaltma
Backbone LR	1e-5	Pretrained temsili yavaş uyarlama
Head LR	1e-4	Yeni başlığı daha hızlı öğrenme
Weight decay	0.01	Düzenleştirme
Precision	FP32	Kararlı baseline
Gradient clipping	1.0	Patlayan gradyan riskini azaltma

Pozitif sınıf ve loss

FAKE pozitif sınıftır. Train dağılımı neredeyse dengeli olduğundan pos_weight yaklaşık 1.004'tür. BCEWithLogitsLoss sigmoid ve binary cross entropy işlemlerini sayısal olarak kararlı biçimde birleştirir.

Smoke test

Gerçek eğitimden önce 32 x 3 x 224 x 224 giriş üzerinde sonluluk kontrolü ve iki FP32 mini-batch testi yapılmış; loss değerleri sonlu bulunmuş ve smoke test geçmiştir.

7. Checkpoint ve Gerçek Resume Mantığı

Her tamamlanan epoch sonunda last.ckpt, validation ROC-AUC iyileştiğinde best.ckpt kaydedilir. Checkpoint; model, optimizer, scheduler, scaler, history, eşik, en iyi skor/epoch, RNG durumları ve config bilgilerini taşır.

CPU'dan T4'e geçiş

İlk epoch CPU'da tamamlandıktan sonra T4 oturumuna geçildi. PyTorch çalışma zamanı RNG durumunu ByteTensor beklediği için resume hücrelerine CPU-GPU güvenli dönüşüm eklendi. Son doğrulamada RNG ve DataLoader generator geri yüklemesi PASS olmuş, eğitim epoch 2 üzerinden devam etmiştir.

Neden bu önemlidir?

Sadece ağırlıkları yüklemek gerçek resume değildir. Optimizer momentleri, scheduler konumu, erken durdurma sayacı, geçmiş ve veri karıştırma durumu da korunmalıdır. Notebook bunların tümünü geri yükleyerek önceki eğitimi devam ettirmiştir.

8. Model Seçimi, Eşik ve Final Çıktılar

Model seçimi validation ROC-AUC ile yapılır. Sınıflandırma eşiği validation kümesinde F1'i en iyi yapan değerden seçilir. Test kümesi ne checkpoint ne de threshold seçimi için kullanılır; yalnızca final değerlendirmeye ayrılmıştır.

Çıktı	İçerik
checkpoints/best.ckpt	En iyi validation ROC-AUC checkpoint'i
checkpoints/last.ckpt	Son tamamlanan epoch durumu
figures/	ROC, PR, confusion matrix ve eğitim grafikleri
artifacts/ / audit/	Metrikler, tahminler, config, denetim kayıtları
Kaynak snapshot	Deneyde kullanılan modüler kod sürümü

Teknik sonuç

Kod, arkadaşın göz ROI baseline metodolojisini ağız bölgesine kontrollü biçimde uyarlamış; SwinV2-Tiny özellik çıkarımını, eğitim rejimini ve kalite kontrollerini korumuştur. Yapılan düzeltmeler deney hedefini değiştirmemiş, yalnızca Drive yol taşınabilirliği ve CPU-GPU checkpoint uyumluluğunu sağlamıştır.

Notebook durumu: TAMAMLANDI - ALL FINAL QUALITY GATES PASSED