

XCEPTION İLE AĞIZ BÖLGESİNDEN DEEPPFAKE TESPİTİ

*Deney Tasarımı, Özellik Çıkarımı, Literatür Gerekçesi ve
Göz-Kaş-Ağız Bölgesel Füzyona Katkısı*

Dokümanın kapsamı: Bu rapor, Mouth ROI hazırlama aşamasından sonra seçilen ilk derin öğrenme deneyi olan Xception modelinin neden seçildiğini, modelin hangi özellikleri otomatik öğrendiğini, literatür dayanaklarını, Colab deney akışını ve daha sonra göz-kaş-ağız bölgesel sistemine nasıl katkı vereceğini açıklamaktadır.

Hazırlanan deney: 224×224 Mouth ROI → Xception → Real/Fake sınıflandırma

1. Deneyin Amacı ve Projedeki Yeri

Bu deneyin temel amacı, yalnızca ağız bölgesinden çıkarılan görüntülerin deepfake tespiti için yeterli ayırt edici bilgi taşıyıp taşımadığını ölçmektir. Önceki notebook'ta yüz framelerinden MediaPipe Face Landmarker kullanılarak ağız landmarkları çıkarılmış, ağız bounding box'ı hesaplanmış, %25 padding uygulanmış ve en-boy oranı korunarak 224×224 Mouth ROI görüntüleri üretilmiştir. Böylece Xception modeline doğrudan verilebilecek standart bir veri yapısı elde edilmiştir.

```
3000 frame
↓
Real / Fake + Train / Val / Test
↓
MediaPipe Face Landmarker
↓
40 mouth landmark
↓
Mouth bounding box + %25 padding
↓
Aspect ratio korunarak 224×224 Mouth ROI
↓
Xception deneyi
```

Araştırma sorusu: “Yalnızca ağız bölgesinden öğrenilen deep convolutional özellikler, gerçek ve sahte görüntüleri ayırt etmek için ne kadar yeterlidir?”

2. Neden Ağız Bölgesi?

- Ağız; dudak sınırları, ağız köşeleri, diş yapısı, ağız içi, cilt-dudak geçişleri ve konuşmayla değişen geometrisi nedeniyle sentezlenmesi zor bir yüz bölgesidir.
- Deepfake üretiminde tüm yüz aynı kalitede sentezlenmeyebilir. Lokal bölgelerde bulanıklık, doku uyumsuzluğu, kenar kırılması, renk-geçiş hataları veya yapısal tutarsızlıklar kalabilir.
- Bu nedenle ağız bölgesini yüzün geri kalanından bağımsız incelemek, “hangi yüz bölgesi daha ayırt edici?” sorusuna daha temiz bir cevap üretir.

DFT-MF çalışmasının katkısı: Bu çalışma doğrudan ağız ve diş framelerini biyolojik/görsel sinyal olarak ele almış ve çok sayıda transfer-learning mimarisini ağız temelli deepfake tespiti için değerlendirmiştir. Bu, bizim Mouth ROI → CNN sınıflandırıcı yaklaşımımızın literatürde doğrudan karşılığı olduğunu gösterir.

3. Neden İlk Model Olarak Xception?

Xception'ın seçilmesinin ana nedeni yalnızca genel deepfake literatüründe güçlü bir CNN olması değil, bölgesel deepfake analizi içinde ağız bölgesiyle birlikte doğrudan değerlendirilmiş olmasıdır.

Tolosana ve arkadaşlarının “DeepFakes Evolution: Analysis of Facial Regions and Fake Detection Performance” çalışması, yüzü göz, burun, ağız ve kalan yüz bölgesi gibi alt bölgelere ayırarak her bölgenin deepfake tespit performansına katkısını analiz eder. Çalışmada Xception ve Capsule Network gibi sınıflandırıcılar bölgesel girişlerle değerlendirilmiştir. Bu yaklaşım bizim deney tasarımıımıza yöntemsel dayanak sağlar: “Tüm yüz yerine yalnızca Mouth ROI verildiğinde Xception ne kadar ayırt edici bilgi öğrenebilir?”

Bilimsel ifade önerisi: “Literatürde bölgesel deepfake analizinin başarılı örneklerinden hareketle, ağız ROI’leri üzerinde Xception tabanlı bağımsız bir sınıflandırıcı değerlendirilmiştir.” Bu ifade, literatürü kopyaladığımızı değil, yöntemsel motivasyon aldığımızı doğru biçimde anlatır.

4. Xception Hangi Özellikleri Çıkarıyor?

Bu deneyde HOG, LBP veya Gabor özelliklerini elle çıkarmıyoruz. Xception bir CNN olduğu için feature extraction işlemini convolutional katmanlarında otomatik olarak gerçekleştirir. Dolayısıyla Stage 4 (feature extraction) ve Stage 5 (classifier) tek mimari içinde ardışık biçimde çalışır.

224×224 Mouth ROI
↓
Xception convolutional backbone
↓
Low-level features: kenar, parlaklık, renk geçişleri, lokal doku
↓
Mid-level features: dudak konturu, ağız köşeleri, dış/ağız içi örüntüleri
↓
High-level deep representation
↓
Global Average Pooling / classifier
↓
P(fake | mouth)

Önemli metodolojik sınır: “Xception kesin olarak dış bulanıklığını veya blending izini öğrenmiştir” demek doğru değildir. Modelin hangi bölgelere odaklandığını söylemek için Grad-CAM gibi açıklanabilirlik analizleri gerekir. Bu aşamada doğru ifade, modelin ağız bölgesindeki uzamsal, dokusal ve yapısal deep feature’ları otomatik öğrenmesinin hedeflendiğidir.

5. Xception Mimarisinin Bu Deneye Uygunluğu

Xception, François Chollet tarafından geliştirilen ve depthwise separable convolution kullanan bir mimaridir. Bu yaklaşım, uzamsal filtreleme ile kanal kombinasyonunu ayırıştırır. Deepfake gibi lokal görsel artefaktların önemli olduğu görevlerde bu tür bir CNN, küçük ve orta ölçekli dokusal/uzamsal örüntüleri etkili şekilde temsil edebilir.

Feature map

↓
Depthwise convolution
↓
Uzamsal örüntülerin filtrelenmesi
↓
1×1 pointwise convolution
↓
Kanallar arası bilgi kombinasyonu

6. Literatür Dayanakları

Tolosana et al. - DeepFakes Evolution: Analysis of Facial Regions and Fake Detection Performance

<https://arxiv.org/abs/2004.07532>

Bölgesel deepfake analizi; ağız dahil yüz alt bölgelerinin ayrı değerlendirilmesi ve Xception kullanımına doğrudan yöntemsel dayanak.

DFT-MF: Enhanced deepfake detection using mouth movement and transfer learning

<https://www.sciencedirect.com/science/article/pii/S2352711022000759>

Ağız ve dış framerlerini doğrudan deepfake sinyali olarak kullanan çalışma; Xception dahil çok sayıda transfer-learning modelini değerlendirir.

Chollet - Xception: Deep Learning with Depthwise Separable Convolutions (CVPR 2017)

https://openaccess.thecvf.com/content_cvpr_2017/html/Chollet_Xception_Deep_Learning_CVPR_2017_paper.html

Kullandığımız Xception mimarisinin orijinal teknik kaynağı.

7. Bizim Deneyimiz Literatürü Nasıl Uyarlıyor?

Literatürden alınan ana fikir, yüzün tamamı yerine bölgesel deepfake izlerinin ayrıca değerlendirilebilmesidir. Bizim deneyimizde ise kendi veri hazırlama pipeline'ımız ve kendi train/validation/test bölünmemiz kullanılmaktadır.

Literatür fikri
Bölgesel yüz analizi + CNN
↓
Bizim uyarlamamız
Hazır Mouth ROI → Xception transfer learning
↓
Bağımsız Mouth Model
↓
Accuracy / Precision / Recall / F1 / ROC-AUC

Dolayısıyla “Tolosana sonuçlarını yeniden ürettik” denmemelidir. Doğru yaklaşım, bölgesel deepfake analizi fikrinin kendi Mouth ROI veri setimize Xception ile uygulanmasıdır.

8. Colab Deney Akışı

Yeni Colab notebook yalnızca Xception deneyine ayrılmıştır. MediaPipe ve ağız kırpma kodları önceki notebook'ta tamamlandığı için yeniden kullanılmaz.

Hücre	Görev
Cell 1	TensorFlow/Keras, Xception, metrikler, random seed ve GPU kontrolü
Cell 2	Google Drive, mouth_roi_output yolları ve deney klasörlerinin tanımlanması
Cell 3	ROI sayıları, sınıf dengesi, train/val/test doğrulaması
Cell 4	tf.data veri yükleme pipeline'ı
Cell 5	Güvenli data augmentation ve Xception preprocess_input
Cell 6	ImageNet-pretrained Xception backbone + binary classifier
Cell 7	Frozen-backbone ilk eğitim
Cell 8	Düşük learning-rate ile fine-tuning
Cell 9	Test setinde tahminlerin alınması
Cell 10	Accuracy, Precision, Recall, F1 ve ROC-AUC
Cell 11	Confusion Matrix, ROC Curve ve eğitim grafiklerinin üretilmesi
Cell 12	Model, metrikler, grafikler ve deney özetinin Drive'a kaydedilmesi

9. Neden Önce Frozen Backbone, Sonra Fine-Tuning?

İlk eğitim aşamasında Xception backbone'u dondurulur. Böylece ImageNet üzerinde önceden öğrenilmiş genel görsel temsiller korunur ve yalnızca yeni binary classifier katmanları Mouth ROI görevine uyarlanır. Bu yaklaşım, veri setinin sınırlı olduğu durumda tüm ağı aynı anda güncellenmenin yol açabileceği aşırı öğrenme riskini azaltır.

Aşama 1

Xception backbone = FROZEN

Classifier = TRAINABLE

↓

Validation performansı gözlenir

↓

Aşama 2

Üst Xception katmanlarının bir bölümü UNFREEZE
Düşük learning rate
↓
Fine-tuning

10. Ağız Modelinden Beklenen Çıktı

Modelin nihai çıktısı yalnızca sınıf etiketi değil, ağız bölgesinin sahte olma olasılığıdır:

Mouth ROI
↓
Mouth Xception
↓
 $P(\text{fake} \mid \text{mouth}) = 0.87 \leftarrow \text{örnek skor}$

Bu skor daha sonra tek başına Mouth Model performansını ölçmek için veya diğer yüz bölgelerinin skorlarıyla birleştirilmek üzere kullanılabilir.

11. Göz ve Kaş Çalışmalarına Katkısı

Ağızda eğitilen Xception ağırlıkları doğrudan göz veya kaşa uygulanmayacaktır. Ancak aynı deney protokolünün göz ve kaş ROI'lerine uygulanması çok değerlidir. Böylece aynı model mimarisi, aynı metrikler ve mümkün olduğunca aynı eğitim protokolü altında yalnızca yüz bölgesi değiştirilmiş olur.

Mouth ROI → Mouth Xception → $P(\text{fake} \mid \text{mouth})$
Eye ROI → Eye Xception → $P(\text{fake} \mid \text{eye})$
Eyebrow ROI → Eyebrow Xception → $P(\text{fake} \mid \text{eyebrow})$

Bu deney tasarımı şu araştırma sorusunu mümkün kılar: “Aynı sınıflandırıcı ailesi altında hangi yüz bölgesi deepfake tespiti için daha ayırt edicidir?”

12. Bölgesel Füzyona Katkısı

Bağımsız ağız, göz ve kaş modelleri oluşturulduğunda her model ayrı bir fake olasılığı üretir. Bu skorlar daha sonraki füzyon aşamasında birleştirilebilir:

$P(\text{fake} \mid \text{mouth})$ ————
 $P(\text{fake} \mid \text{eye})$ ————+——→ Fusion Model → Final $P(\text{fake})$
 $P(\text{fake} \mid \text{eyebrow})$ ————

Bilimsel avantaj: Bölgeleri en baştan tek görüntüde karıştırmak yerine ayrı modellerle ölçmek, hangi yüz bölgesinin güçlü/zayıf olduğunu ve füzyonun gerçekten ek performans getirip getirmediğini analiz etmeyi sağlar.

13. Değerlendirme Metrikleri

Xception deneyinin yalnızca accuracy ile değerlendirilmesi yeterli değildir. Binary deepfake sınıflandırmada aşağıdaki metrikler birlikte raporlanacaktır:

Metrik	Amaç
Accuracy	Tüm örnekler içinde doğru sınıflandırma oranı.
Precision	Fake tahmini verilen örneklerin ne kadarının gerçekten fake olduğu.
Recall	Gerçek fake örneklerin ne kadarının yakalandığı.
F1-score	Precision ve Recall'un dengeli özeti.
ROC-AUC	Karar eşiğinden bağımsız ayırt etme gücü.
Confusion Matrix	Real/Fake hata türlerinin doğrudan görülmesi.

14. Rapor İçin Kullanılabilecek Yöntem Paragrafı

Örnek metodoloji metni: Bu deneyde, deepfake üretim süreçlerinde ağız ve çevresindeki lokal yapısal ve dokusal bozulmaların ayırt edici özellik taşıyabileceği varsayımından hareketle Xception tabanlı bölgesel bir sınıflandırıcı tasarlanmıştır. Bölgesel deepfake analizini inceleyen çalışmalar ile ağız ve dış bölgelerini doğrudan sinyal olarak kullanan DFT-MF yaklaşımı, ağız bölgesinin bağımsız olarak değerlendirilmesinin anlamlı olabileceğini göstermektedir. Bu doğrultuda, daha önce 224×224 piksel boyutunda hazırlanmış Mouth ROI görüntüleri ImageNet üzerinde önceden eğitilmiş Xception omurgasına verilmiş ve görüntülerden uzamsal, dokusal ve yapısal deep feature'ların otomatik olarak öğrenilmesi hedeflenmiştir. Model performansı accuracy, precision, recall, F1-score ve ROC-AUC metrikleriyle değerlendirilmiştir.

15. Sonuç: Bu Deneyin Projeye Katkısı

- Ağız bölgesinin tek başına ne kadar güçlü bir deepfake sinyali taşıdığını ölçer.
- Handcrafted özellik çıkarmadan, Xception'ın otomatik deep feature öğrenme kapasitesini sınar.
- Göz ve kaş için aynı deney protokolünü uygulamaya uygun ortak bir baseline oluşturur.
- Üç bölgenin aynı model ailesi altında karşılaştırılmasını mümkün kılar.
- Bölgesel skorları daha sonra fusion modeline taşıyarak final deepfake kararına katkı sağlar.
- Daha sonraki deneylerde HOG+LBP+KAZE+SVM, DenseNet121 veya hybrid feature-fusion gibi alternatiflerle karşılaştırılabilecek güçlü bir ilk referans model üretir.

Kaynakça ve Makale Linkleri

1. Tolosana et al. - DeepFakes Evolution: Analysis of Facial Regions and Fake Detection Performance

<https://arxiv.org/abs/2004.07532>

2. DFT-MF: Enhanced deepfake detection using mouth movement and transfer learning

<https://www.sciencedirect.com/science/article/pii/S2352711022000759>

3. Chollet - Xception: Deep Learning with Depthwise Separable Convolutions (CVPR 2017)

https://openaccess.thecvf.com/content_cvpr_2017/html/Chollet_Xception_Deep_Learning_CVPR_2017_paper.html