

AĞIZ BÖLGESİ ÜZERİNDEN DEEPFAKE SINIFLANDIRMA KODU

Xception (ImageNet Transfer Learning) + Fine-Tuning

Kodun amacı, deney mantığı, model mimarisi ve üretilen çıktılar

Çalışma bölgesi	Ağız (mouth ROI)
Model yaklaşımı	ImageNet ön-eğitilmiş Xception + iki aşamalı transfer learning
Çalışma ortamı	Google Colab / Google Drive / TensorFlow-Keras
Rapor kapsamı	12 Colab hücresinin mimarisi, işlevi ve çıktı düzeni

Çalışma ortamı: Google Colab / TensorFlow / Keras
Ağustos 2026

1. Yönetici Özeti

Kodun temel amacı

Bu notebook, daha önce hazırlanmış 224×224 ağız ROI görüntülerini kullanarak gerçek ve sahte sınıfları Xception tabanlı bir derin öğrenme modeliyle ayırır. Kod yalnızca model.fit çağrısından ibaret değildir; veri yolu denetimi, sınıf dengesi, tf.data pipeline, kontrollü augmentation, ImageNet transfer learning, frozen-backbone eğitimi, fine-tuning, validation tabanlı model seçimi, bağımsız test değerlendirmesi, 600 DPI grafik üretimi ve final artefakt kaydı içeren uçtan uca bir deney pipeline'ı kurar.

Başlık	Açıklama
Girdi	2987 geçerli Mouth ROI; Real/Fake ve train/val/test yapısı
Model	Xception, ImageNet ağırlıkları, include_top=False
Giriş boyutu	224×224×3 RGB
Sınıf eşleme	REAL=0, FAKE=1
İlk eğitim	Backbone frozen; yalnız classifier eğitilir
Fine-tuning	Son 30 Xception katmanından uygun olanlar açılır; BatchNorm frozen
Seçim ölçütü	Validation ROC-AUC
Nihai değerlendirme	302 görüntülük test kümesi; test yalnız final aşamada kullanılır

2. Uçtan Uca Çalışma Akışı

1. Google Drive bağlanır; Mouth ROI ve deney klasörleri doğrulanır.
2. Fake/Real train, validation ve test görüntü sayıları kontrol edilir.
3. tf.data ile 224×224 RGB batch pipeline'ı kurulur.
4. Yalnız train kümesine hafif augmentation; tüm kümelere Xception preprocess_input uygulanır.
5. ImageNet ağırlıklı Xception backbone oluşturulur ve ilk aşamada dondurulur.
6. Frozen eğitimde classifier katmanları öğrenilir; en iyi validation AUC checkpointi saklanır.
7. Fine-tuning aşamasında üst Xception katmanlarının bir bölümü düşük learning rate ile açılır.
8. Frozen ve fine-tuned modeller validation AUC ile karşılaştırılır; en iyi model testte bir kez değerlendirilir.
9. Accuracy, precision, recall, specificity, F1, ROC-AUC ve confusion matrix hesaplanır.
10. 600 DPI grafikler ve tüm deney artefaktları final Sonuçlar/Xception_Mouth klasörüne aktarılır.

3. Cell 1-3: Ortam, Yollar ve Dataset Denetimi

3.1 Cell 1 - Kütüphaneler ve deney ortamı

İlk hücre TensorFlow/Keras, NumPy, Pandas, Matplotlib ve scikit-learn metriklerini hazırlar. Xception sınıfı ve preprocess_input fonksiyonu import edilir; tekrar üretilebilirlik için Python, NumPy ve TensorFlow seed değeri 42 olarak sabitlenir. Giriş boyutu 224×224, batch size 16 ve sınıf adları real/fake olarak belirlenir.

```
SEED = 42
IMG_SIZE = (224, 224)
BATCH_SIZE = 16
CLASS_NAMES = ['real', 'fake']
Xception(...); preprocess_input(...)
```

3.2 Cell 2 - Drive ve klasör yapısı

Drive bağlandıktan sonra proje kökü, mouth_roi_output, train/val/test alt klasörleri ve xception_experiment altında models, plots/results benzeri çıktı klasörleri tanımlanır. Kritik klasörlerin exists() ile doğrulanması, yanlış path nedeniyle saatler süreceğ eğitimin yanlış veride başlamasını önler.

3.3 Cell 3 - Veri sayısı ve sınıf dengesi

Split	Fake	Real	Toplam
Train	1192	1197	2389
Validation	141	155	296
Test	156	146	302
Genel	1489	1498	2987

Kalite bulgusu

Başlangıçta 3000 frame bulunmasına rağmen 2987 geçerli Mouth ROI modele girebilmiştir. Yalnız 13 örnek kaybedilmiştir; ROI elde etme başarısı yaklaşık %99,57'dir. Train/validation/test sınıf dağılımları dengeli olduğu için class_weight uygulanmamıştır.

4. Cell 4-5: TensorFlow Data Pipeline ve Augmentation

4.1 Cell 4 - tf.data yapısı

Görüntü yolları ve etiketler bir araya getirilir. REAL=0, FAKE=1 eşlemesi deney boyunca değişmez. load_image fonksiyonu dosyayı okur, 3 kanallı RGB olarak decode eder, 224×224 boyutunu garanti eder ve float32 türüne çevirir. Train shuffle edilir; validation ve test sıraları korunur. Batch ve prefetch ile GPU/CPU besleme hattı oluşturulur.

```
dataset = tf.data.Dataset.from_tensor_slices((file_paths, labels))
if training:
    dataset = dataset.shuffle(..., seed=42)
dataset = dataset.map(load_image, num_parallel_calls=tf.data.AUTOTUNE)
dataset = dataset.batch(16).prefetch(tf.data.AUTOTUNE)
```

Cell 4 doğrulama çıktısı

Train 2389, validation 296 ve test 302 örnek olarak doğrulanmıştır. İlk batch shape değeri (16, 224, 224, 3) ve label shape değeri (16,) olarak görülmüştür.

4.2 Cell 5 - Kontrollü augmentation

Dönüşüm	Ayar	Neden
Horizontal flip	Aktif	Sağ-sol yön varyasyonuna tolerans
Random rotation	factor=0.02	Çok küçük poz farklarına tolerans
Random zoom	±0.05	Hafif ölçek farklılıkları
Random contrast	0.05	Kamera/ışık kontrast değişimi
Blur / güçlü renk bozma	Kullanılmadı	İnce deepfake artefaktlarını silmemek

Augmentation yalnız train kümesine uygulanır. Validation ve test deterministiktir. Ardından Xception preprocess_input ile piksel değerleri yaklaşık [-1, 1] aralığına dönüştürülür. Cell 5 çıktısında minimum -1.0 ve maksimum 1.0 görülmesi preprocessing'in doğru çalıştığını doğrulamıştır.

5. Cell 6: Xception Model Mimarisi

Modelin amacı

Ağız ROI içindeki uzamsal, dokusal ve yapısal ayırt edici deep feature'ları otomatik öğrenmek ve her örnek için $P(\text{fake} \mid \text{mouth})$ olasılığı üretmektir. HOG/LBP/Gabor gibi el yapımı özellikler bu deneyde ayrıca çıkarılmaz; özellik çıkarımı Xception convolutional backbone içinde gerçekleşir.

```
xception_base = Xception(include_top=False, weights='imagenet', input_shape=(224,224,3))
xception_base.trainable = False
x = GlobalAveragePooling2D(xception_base(inputs, training=False))
x = Dropout(0.30)(x)
x = Dense(256, activation='relu')(x)
x = Dropout(0.20)(x)
outputs = Dense(1, activation='sigmoid')(x)
```

Bileşen	Çıktı / Ayar
Input	224×224×3
Xception backbone	7×7×2048 feature map
Global Average Pooling	2048 boyutlu deep feature
Dropout	0.30
Dense	256, ReLU
Dropout 2	0.20
Output	1 sigmoid = $P(\text{fake})$
Toplam parametre	21,386,281
İlk aşamada trainable	524,801
Frozen	20,861,480

Neden Xception?

Xception depthwise separable convolution kullanır. Uzamsal örüntüleri ve kanal kombinasyonlarını verimli biçimde işler. Bölgesel deepfake literatüründe Xception'ın yüz alt bölgeleriyle değerlendirilmiş olması ve ağız/diş odaklı transfer-learning çalışmalarının bulunması, bu modeli güçlü bir ilk deep-learning baseline yapar.

6. Cell 7-8: İki Aşamalı Transfer Learning

6.1 Cell 7 - Frozen backbone eğitimi


İlk aşamada yaklaşık 20,86 milyon parametrelili Xception omurgası sabit tutulur; yalnızca eklenen classifier katmanları öğrenir. Adam optimizasyonu $1e-4$ learning rate ile başlar. ModelCheckpoint validation AUC en iyi olduğunda modeli kaydeder; EarlyStopping ve ReduceLROnPlateau gereksiz uzun eğitimi ve kararsız optimizasyonu sınırlar.

Ayar	Değer
Maksimum epoch	15
Gerçekleşen epoch	14
En iyi epoch	10
En iyi validation AUC	0.7280
En iyi validation accuracy	0.6892
Eğitim süresi	147.30 dakika

6.2 Cell 8 - Fine-tuning

Cell 7'de validation AUC açısından en iyi checkpoint yeniden yüklenir. Xception backbone trainable=True yapılır, ancak yalnızca son 30 katman içinden BatchNormalization olmayan katmanlar eğitime açılır. Learning rate $1e-5$ 'e düşürülür. Böylece ImageNet'ten gelen genel görsel temsil tamamen bozulmadan ağız deepfake problemine daha özel bir adaptasyon yapılır.

Ayar / Sonuç	Değer
Unfreeze	Son 30 katman; BatchNorm frozen
Learning rate	$1e-5$
Maksimum epoch	10
Gerçekleşen epoch	10
En iyi epoch	9
En iyi validation AUC	0.8228
En iyi validation accuracy	0.7669
Fine-tuning süresi	159.62 dakika



Şekil. Frozen ve fine-tuned validation performansı.

7. Cell 9-11: Model Seçimi, Test ve Grafikler

7.1 Cell 9 - Nihai model seçimi


Frozen ve fine-tuned modeller test setine bakılmadan yalnız validation AUC üzerinden karşılaştırılır. Fine-tuned model 0.8228 ile frozen 0.7280 değerini geçtiği için nihai model olarak seçilmiştir. Test seti bu seçimden sonra yalnız bir kez değerlendirilir; böylece test verisi hiperparametre/model seçimine sızmaz.

7.2 Cell 10 - Final metrikler

Metrik	Değer
Accuracy	0.7020 (%70.20)
Balanced Accuracy	0.7003
Precision (Fake)	0.6964
Recall / Sensitivity	0.7500
Specificity	0.6507
F1-score	0.7222
ROC-AUC	0.7662
NPV	0.7090

7.3 Cell 11 - Rapor grafikleri

Cell 11 confusion matrix, ROC curve, frozen eğitim accuracy/AUC/loss eğrileri, fine-tuning eğitim eğrileri, frozen-vs-fine-tuned karşılaştırması ve final metrik bar grafiğini üretir. PNG çıktıları 600 DPI kaydedilir ve figure_manifest.json ile listelenir.



Şekil. Nihai test confusion matrix.

8. Cell 12: Final Kayıt, Klasör Düzeni ve Tekrar Üretilirlik

Son hücre yeniden eğitim yapmaz. Seçilen nihai .keras modeli, test metrikleri, tahmin CSV'si, eğitim logları, konfigürasyon JSON'ları ve 600 DPI figürleri kullanıcı tarafından belirlenen final klasöre kopyalar.

```
/content/drive/MyDrive/AISC Çalışmalar/Deneyler/Dilara/Deney 1/Sonuçlar/Xception_Mouth/
├── model/Xception_Mouth_Final.keras
├── metrics/
├── figures/
├── training_logs/
├── predictions/test_predictions.csv
└── summary/
```

8.1 Kaydedilen başlıca artefaktlar

Dosya	İşlev
Xception_Mouth_Final.keras	Nihai model
final_test_metrics.json / .csv	Test metrikleri
classification_report.txt	Sınıf bazlı precision/recall/F1
test_predictions.csv	302 test örneğinin P(fake), tahmin ve doğruluk bilgisi
frozen_training_history.csv	Frozen eğitim epoch geçmişi
finetune_training_history.csv	Fine-tuning epoch geçmişi
augmentation_config.json	Augmentation ayarları
xception_model_config.json	Model mimarisi ve compile ayarları
figures/*.png	600 DPI rapor görselleri
Xception_Mouth_Final_Experiment.json	Tek dosyada deney özeti

8.2 Deneyin kod açısından güçlü yönleri

- Test setinin model seçimi için kullanılmaması.
- Validation AUC tabanlı checkpoint seçimi.
- Frozen ve fine-tuned aşamaların ayrı loglanması.
- Sınıf dağılımının eğitim öncesi kontrol edilmesi.
- Augmentation'ın yalnız train kümesine uygulanması.
- Deney ayarlarının JSON ve CSV artefaktlarıyla saklanması.
- Sonuçların final klasöründe düzenli ve tekrar kullanılabilir biçimde toplanması.

9. Literatür ve Yöntemsel Dayanaklar

Tolosana et al., “DeepFakes Evolution: Analysis of Facial Regions and Fake Detection Performance” - yüz alt bölgelerinin ayrı değerlendirilmesi ve Xception kullanımına yöntemsel dayanak.

<https://arxiv.org/abs/2004.07532>

DFT-MF: Enhanced deepfake detection using mouth movement and transfer learning - ağız ve dış framelerinin deepfake sinyali olarak kullanılması ve transfer-learning mimarilerinin değerlendirilmesi. <https://www.sciencedirect.com/science/article/pii/S2352711022000759>

François Chollet, “Xception: Deep Learning with Depthwise Separable Convolutions”, CVPR 2017. https://openaccess.thecvf.com/content_cvpr_2017/html/Chollet_Xception_Deep_Learning_CVPR_2017_paper.html