

AISC DEEPFAKE ÇALIŞMALARI

DenseNet121 ile Kaş ROI Tabanlı Deepfake Sınıflandırma

Detaylı Deney Sonuçları ve Performans Analiz Raporu

Alan	Değer
Deney	Nazlıcan / Deney 1 / Kaş
Model	DenseNet121 (ImageNet ön eğitilmiş)
Run ID	20260808_1335_eyebrow_densenet121_seed42
Problem	Kaş ROI üzerinden Real / Fake ikili sınıflandırma
Seed	42
Tamamlanan epoch	21
Rapor tarihi	08 Ağustos 2026

Bu rapor, ilgili run klasöründeki metrik, tahmin, audit ve grafik çıktıları temel alınarak hazırlanmıştır.

Yönetici Özeti

Ana sonuç

Deney hattı teknik olarak başarılı, tekrarlanabilir ve veri sızıntısı kontrollerinden geçmiş durumdadır; ancak DenseNet121 modeli kaş ROI üzerinde deepfake sınıflarını güvenilir biçimde ayıramamıştır. Görüntü düzeyi test ROC-AUC 0.554, accuracy %50.3, fake recall/sensitivity yalnızca %16.5 ve MCC -0.025 olarak elde edilmiştir. Bu nedenle sonuç, 'başarısız pipeline' değil; teknik olarak temiz fakat ayırt edici gücü düşük bir model baseline'ı olarak değerlendirilmelidir.

Model eğitim sırasında belirli ölçüde öğrenme göstermiştir: training ROC-AUC yaklaşık 0.50 seviyesinden 0.67'ye yükselmiş, validation ROC-AUC en iyi 0.575 değerine ulaşmıştır. Bununla birlikte validation ve test düzeyindeki kazanım sınırlı kalmış, özellikle fake sınıfında ciddi kaçırma problemi oluşmuştur.

Öne çıkan sayısal bulgular

Gösterge	Sonuç	Kısa yorum
Test görüntüsü	189	98 Real, 91 Fake
Test kaynak/video	141	Kaynak seviyesinde ayrıca değerlendirildi
Image Accuracy	%50.26	Rastlantısal iki sınıflı sınıflandırmaya çok yakın
Balanced Accuracy	%49.06	Sınıflar arası dengeli performans %50'nin altında
Fake Recall / Sensitivity	%16.48	91 fake görüntünün yalnızca 15'i yakalandı
Specificity	%81.63	Real örnekleri çoğunlukla doğru korunuyor
ROC-AUC	0.5540	Zayıf ayırt edicilik
PR-AUC	0.5293	Fake prevalansına göre sınırlı artış
MCC	-0.0248	0'a çok yakın ve hafif negatif
Source-level Accuracy	%41.13	Video/kaynak birleştirme performansı artırmadı
Source-level ROC-AUC	0.5337	Görüntü düzeyinden de düşük

Raporun temel kararı

- DenseNet121 + yalnız kaş ROI kombinasyonu, mevcut veri ve eğitim ayarlarıyla tek başına güvenilir bir deepfake dedektörü olarak yeterli değildir.
- Deneyin bilimsel değeri korunmaktadır; çünkü split, leakage, checkpoint, smoke ve numerical kalite kapıları başarıyla geçmiştir.
- Modelde küçük bir sıralama sinyali vardır (ROC-AUC > 0.50), fakat karar eşiğinde fake sınıfını yakalamaya dönüşmemiştir.
- Sonraki deneylerde temporal/video toplulaştırma, farklı mimariler, kaş bölgesine özgü texture özellikleri ve çoklu seed değerlendirmesi önceliklidir.

1. Deneyin Amacı ve Teknik Yapısı

Deneyin amacı, daha önce kırılmış ve yalnızca kaş bölgesini içeren ROI görüntülerinden yola çıkarak bir örneğin gerçek (Real) veya manipüle edilmiş (Fake) olup olmadığını DenseNet121 mimarisiyle tahmin etmektir. Bu aşamada yeniden ROI çıkarımı yapılmamış; mevcut kaş görüntüleri model girdisi olarak kullanılmıştır.

1.1 Model mimarisi

Bileşen	Konfigürasyon
Backbone	DenseNet121
Ön eğitim	ImageNet
Girdi	224 x 224 x 3
Resize	Aspect ratio korunarak resize_with_pad
Backbone çıktısı	7 x 7 x 1024
Pooling	GlobalAveragePooling2D
Dropout	0.40
Çıkış	Dense(1, sigmoid) - Fake olasılığı
Toplam parametre	7,038,529
İlk aşama trainable parametre	1,025

İlk eğitim aşamasında DenseNet121 backbone'u dondurulmuş, yalnızca son ikili sınıflandırma başlığı optimize edilmiştir. Ardından düşük öğrenme oranıyla fine-tuning uygulanmıştır.

1.2 Eğitim konfigürasyonu

Parametre	Değer
Batch size	16
Frozen stage	12 epoch
Frozen learning rate	1e-3
Fine-tuning stage	10 epoch hedefi
Fine-tuning learning rate	1e-5
Early stopping patience	4
Reduce LR patience	2
Model seçimi	Validation ROC-AUC (maksimum)
Label mapping	Real = 0, Fake = 1
Seed	42
Deterministic ops	Aktif
Framework	TensorFlow 2.20.0 / Keras 3.13.2
GPU	Aktif

1.3 Validation threshold seçimi

Nihai karar eşiği test setinden seçilmemiştir. Validation seti üzerinde Youden J yöntemi kullanılarak 0.556743 eşiği belirlenmiştir. Bu noktadaki Youden J değeri yalnızca 0.121'tür. Düşük J değeri, validation setinde dahi sensitivity ve specificity arasında güçlü bir ayrım noktası bulunamadığını göstermektedir.

2. Veri Seti, Split ve Güvenilirlik Denetimi

2.1 Kaş ROI veri sayıları

Sınıf	Fiziksel split	ROI sayısı	Referans	Audit
Fake	test	95	95	PASS
Fake	train	776	776	PASS
Fake	val	98	98	PASS
Real	test	101	101	PASS
Real	train	786	786	PASS
Real	val	106	106	PASS

Fiziksel kaş klasöründeki toplam 1.962 ROI'nin tamamı audit dosyasında beklenen sayılarla birebir eşleşmektedir. Toplam veri 969 Fake ve 993 Real örnekten oluşmaktadır; dolayısıyla giriş veri setinde belirgin bir sınıf dengesizliği yoktur.

2.2 Model için kullanılan source-group split

Split	Görüntü sayısı	Oran
Train	1548	%78.9
Validation	225	%11.5
Test	189	%9.6
Toplam	1962	%100

Model, fiziksel klasörlerdeki frame-level ayrımı doğrudan kullanmak yerine kaynak/video gruplarını koruyacak şekilde Real ve Fake sınıflarını bağımsız olarak yaklaşık %80/%10/%10 oranında yeniden ayırmıştır. Bu sayede aynı kaynak video veya aynı split-group train ile validation/test arasında taşınmamıştır.

Leakage denetimi

Exact source-video overlap: 0 | Source-group overlap: 0 | Cross-split duplicate SHA-256: 0 | Unique split groups: Train=811, Val=101, Test=103. Tüm leakage kapıları PASS.


2.3 Eğitim öncesi kalite kapıları

Kalite kapısı	Durum	Anlamı
Schema test	PASS	Manifest alanları ve veri şeması
Split test	PASS	Kaynak gruplarının izolasyonu
Smoke test	PASS	Kısa forward/backward eğitim testi
Numerical test	PASS	NaN/Inf kontrolü
Checkpoint test	PASS	Model kayıt/yükleme doğrulaması

Final audit ayrıca test setinin model seçimi için kullanılmadığını, best/last checkpoint dosyalarının bulunduğunu ve tüm grafiklerin kısa kenarının en az 600 piksel olduğunu doğrulamaktadır.

3. Eğitim Sürecinin Analizi

3.1 Training / Validation Loss




Şekil 1. DenseNet121 kaş ROI eğitim ve validation loss eğrileri. Kaynak: figures/training_validation_loss.png

Training loss ilk epoch'ta 0.7485 iken 21. epoch sonunda 0.6460'e gerilemiştir. Validation loss ise 0.7319 seviyesinden 0.6799'e düşmüştür. Bu durum optimizasyonun tamamen başarısız olmadığını, modelin eğitim örneklerinden bazı düzenlilikler öğrendiğini göstermektedir.

Bununla birlikte ikinci yarıda training loss validation loss'tan belirgin biçimde daha hızlı düşmektedir. Validation loss yaklaşık 0.68 çevresinde plato yaparken training loss 0.65'in altına inmektedir. Bu desen, güçlü bir katastrofik overfitting yerine sınırlı ama artan bir train-validation generalization gap bulunduğuna işaret eder.

3.2 Training / Validation ROC-AUC



Şekil 2. Epoch bazında training ve validation ROC-AUC. Kaynak: figures/training_validation_auc.png

Training ROC-AUC 1. epoch'ta 0.505 iken son epoch'ta 0.674'e yükselmiştir. Validation ROC-AUC en yüksek 0.575 değerini 17. epoch'ta elde etmiştir. Frozen aşamanın sonundaki validation AUC 0.545 olduğundan fine-tuning'in en iyi noktaya katkısı yaklaşık 0.030 AUC puanıdır.

21. epoch sonunda training AUC 0.674, validation AUC 0.575'tür. Yaklaşık 0.10'luk fark, backbone'un açılmasından sonra eğitim verisine uyumun validation genellemesine göre daha hızlı arttığını gösterir. Validation AUC'nin 0.57 civarında plato yapması, daha fazla epoch'un tek başına belirgin bir sıçrama yaratmasının olası olmadığını düşündürmektedir.

Fine-tuning yorumu

Fine-tuning tamamen etkisiz değildir; validation AUC yaklaşık 0.545'ten 0.575'e çıkmıştır. Ancak bu kazanım, nihai testte yüksek bir ayırt ediciliğe dönüşmemiştir. Dolayısıyla darboğaz yalnızca 'yetersiz epoch' değildir.


4. Görüntü Düzeyi Nihai Test Performansı

4.1 Ana metrikler

Metrik	Değer	Yüzde	Yorum
Accuracy	0.5026	%50.26	Toplam doğru sınıflandırma
Balanced Accuracy	0.4906	%49.06	Real/Fake recall ortalaması
Precision (Fake)	0.4545	%45.45	Fake denilenlerin ne kadarı gerçekten Fake
Recall / Sensitivity (Fake)	0.1648	%16.48	Gerçek Fake örneklerin yakalanma oranı
Specificity (Real)	0.8163	%81.63	Real örneklerin doğru korunma oranı
F1 (Fake)	0.2419	%24.19	Precision-recall dengesi
ROC-AUC	0.5540	-	Eşik bağımsız sıralama gücü
PR-AUC	0.5293	-	Fake sınıfı precision-recall alanı
MCC	-0.0248	-	Dengeli korelasyon; 0 yaklaşık rastlantısal

Accuracy için yaklaşık %95 Wilson güven aralığı %43.2-%57.3'dir. Fake sensitivity için yaklaşık aralık %10.3-%25.4, specificity için %72.8-%88.1'dir. Bu aralıklar, özellikle fake sensitivity'nin düşük olduğuna ilişkin sonucun örneklem belirsizliğine rağmen güçlü biçimde devam ettiğini gösterir.

4.2 Confusion Matrix



Şekil 3. Test confusion matrix: satırlar gerçek sınıfı, sütunlar model tahminini gösterir. Kaynak: *figures/test_confusion_matrix.png*

189 test ROI'sinde confusion matrix şu şekildedir: 80 True Negative (Real doğru), 18 False Positive (Real iken Fake), 76 False Negative (Fake iken Real) ve yalnızca 15 True Positive (Fake doğru). Modelin en belirgin davranışı, örnekleri Real sınıfına yığmasıdır. Toplam 156 örneğe Real, yalnız 33 örneğe Fake tahmini verilmiştir.

Gerçek sınıf	Doğru	Yanlış	Recall
Real	80	18	%81.63
Fake	15	76	%16.48


Bu tablo, genel accuracy'nin neden tek başına yanıltıcı olabileceğini açık biçimde gösterir: toplam doğruluk yaklaşık %50 olsa da iki sınıf arasında performans simetrik değildir. Real sınıfı %81.63 oranında korunurken Fake sınıfının yalnızca %16.48'i yakalanmıştır.

4.3 Sınıf bazlı classification report

Sınıf	Precision	Recall	F1	Support
Real	0.5128	0.8163	0.6299	98
Fake	0.4545	0.1648	0.2419	91
Macro avg	0.4837	0.4906	0.4359	189
Weighted avg	0.4848	0.5026	0.4431	189

5. Eşik Bağımsız Ayırt Edicilik: ROC ve Precision-Recall


5.1 ROC eğrisi



Şekil 4. Test ROC eğrisi. ROC-AUC = 0.5540. Turuncu kesikli diyagonal rastlantısal sınıflandırıcı referansıdır. Kaynak: [figures/test_roc_curve.png](#)

ROC-AUC 0.5540'tür. 0.50 değeri rastlantısal sıralama sınırını temsil ettiğinden modelin skorlarında tamamen sıfır olmayan fakat oldukça zayıf bir ayırım sinyali vardır. Eğrinin uzun bölümler boyunca diyagonale yakın ilerlemesi, Real ve Fake skor dağılımlarının önemli ölçüde çakıştığını destekler.

5.2 Precision-Recall eğrisi



Şekil 5. Test Precision-Recall eğrisi. PR-AUC = 0.5293. Kaynak: figures/test_precision_recall_curve.png

Test setindeki Fake prevalansı %48.1'dir. Rastlantısal bir sıralayıcının PR-AUC referansı yaklaşık bu prevalans düzeyindedir. Modelin PR-AUC'si 0.5293 olup prevalansın yalnızca yaklaşık 0.048 üzerinde kalmaktadır. Bu da Fake örnekleri üst sıralarda yoğunlaştırma becerisinin sınırlı olduğunu gösterir.

ROC-AUC ve karar metriği birlikte nasıl okunmalı?

ROC-AUC 0.554 model skorunda küçük bir sıralama bilgisi olduğunu söyler; fakat seçilen 0.5567 eşik bu zayıf sinyali yüksek fake recall'a dönüştürememiştir. Balanced accuracy 0.491 ve MCC -0.025 olması, operasyonel karar çıktısının bu eşikte kullanışlı olmadığını gösterir.

6. Karar Eşiği ve Kalibrasyon Analizi

Deneyde kullanılan eşik 0.556743 olup validation setinde Youden J ile seçilmiştir. Bu yaklaşım metodolojik olarak doğrudur; test seti eşik seçimi için kullanılmamıştır. Ancak validation'da seçilen eşik testte yüksek specificity (%81.63) ve çok düşük sensitivity (%16.48) üreten konservatif bir çalışma noktasına dönüşmüştür.

Çalışma noktası	Accuracy	Balanced Acc.	Fake Recall	Specificity	F1	MCC
Validation seçili eşik 0.5567	%50.3	%49.1	%16.5	%81.6	0.242	-0.025
Sabit eşik 0.5000 (yalnız diagnostik)	%53.4	%53.1	%42.9	%63.3	0.470	0.063

0.50 eşiği burada yalnızca duyarlılık analizi amacıyla gösterilmiştir ve yeni bir model seçimi değildir. Bu sabit eşikte fake recall %42.9'a yükselse de balanced accuracy yalnızca %53.1 ve MCC 0.063'tür. Dolayısıyla sorun sadece eşik seçimi değildir; sınıfların skor uzayında yeterince ayrışmaması temel problemdir.

6.1 Olasılık dağılımlarındaki çakışma

Gerçek sınıf	Ortalama Fake olasılığı	Medyan	Std.	Min	Max
Real	0.457	0.464	0.102	0.165	0.678
Fake	0.485	0.482	0.099	0.277	0.847

Real ve Fake olasılık ortalamaları sırasıyla yaklaşık 0.457 ve 0.485'tir; medyanlar 0.464 ve 0.482'dir. İki dağılımın merkezleri birbirine çok yakındır. Bu sayısal çakışma, ROC ve confusion matrix sonuçlarının temel nedenini açıklar.

7. Kaynak / Video Düzeyi Değerlendirme

Frame/ROI tahminlerinin aynı kaynağa ait örnekler için birleştirilmesi, deepfake çalışmalarında tek frame gürültüsünü azaltmak için önemlidir. Bu deneyde 189 test görüntüsü 141 farklı source/video kimliğine karşılık gelmektedir.

Metrik	Source-level sonuç
Accuracy	0.4113 (%41.13)
Balanced Accuracy	0.4636 (%46.36)
Precision (Fake)	0.5000
Recall (Fake)	0.1687 (%16.87)
F1	0.2523
ROC-AUC	0.5337
PR-AUC	0.6153
Test source sayısı	141

Kaynak seviyesinde 83 Fake kaynağın 14'ü doğru Fake, 69'u yanlış Real sınıfına atanmıştır. 58 Real kaynağın 44'ü doğru, 14'ü yanlış sınıflandırılmıştır.

Source-level accuracy'nin görüntü düzeyinden daha düşük olması, basit kaynak toplulaştırmasının bu veri üzerinde hataları ortalayarak ortadan kaldırmadığını gösterir. Bunun bir nedeni birçok source için testte yalnızca tek veya çok az frame bulunması olabilir; bu nedenle gerçek video-level faydayı değerlendirmek için kaynak başına daha çok frame içeren bir protokol daha uygun olacaktır.

8. Ayrıntılı Hata Analizi

8.1 Manipülasyon ailesine göre Fake yakalama

Fake ailesi	Test ROI	Ort. fake skoru	ROI recall	Test source	Source recall
Face2Face	22	0.457	0.000	21	0.000
Deepfakes	20	0.480	0.250	16	0.312
FaceSwap	17	0.440	0.118	16	0.062
FaceShifter	15	0.487	0.133	14	0.143
NeuralTextures	12	0.500	0.083	11	0.091
DeepFakeDetection	5	0.743	1.000	5	1.000

En dikkat çekici sonuç, DeepFakeDetection alt grubunda 5/5 ROI'nin ve 5/5 source'un Fake olarak yakalanmasıdır. Ancak örnek sayısı yalnızca 5 olduğundan bu sonuç genellenebilir bir üstünlük olarak yorumlanmamalıdır.

Buna karşılık Face2Face ailesinde 22 test ROI'nin hiçbirisi seçili eşikte Fake olarak yakalanmamıştır. FaceSwap, FaceShifter ve NeuralTextures gruplarında da recall çok düşüktür. Bu dağılım, modelin farklı deepfake üretim yöntemlerine karşı genelleme gücünün homojen olmadığını gösterir ve genel fake recall kaybının belirli ailelerde yoğunlaştığını ortaya koyar.

8.2 Skorların en güvenli yanırları

Yanlış negatif Fake source	Frame	Fake olasılığı
FaceSwap_790_014	19	0.277
FaceSwap_609_596	4	0.303
FaceSwap_371_367	0	0.315
Deepfakes_367_371	28	0.321
FaceSwap_220_219	14	0.355
Face2Face_577_593	5	0.358
Face2Face_275_887	10	0.358
Deepfakes_773_652	13	0.358

Yukarıdaki örnekler modelin bazı sahte framelere yalnızca 0.28-0.36 bandında Fake olasılığı verdiğini göstermektedir. Bu örneklerde hata yalnızca eşik sınırında değildir; model belirgin biçimde Real yönünde güven göstermiştir.

Yanlış pozitif Real source	Frame	Fake olasılığı
035	21	0.678
188	3	0.616
188	7	0.614
951	4	0.608
788	18	0.607
937	23	0.601
898	8	0.598
280	6	0.596

Bazı Real örneklerde ise Fake skoru 0.60-0.68 seviyesine çıkmaktadır. Bu iki yönlü skor çakışması, modelin kaş bölgesinde manipülasyon artefaktı yerine kimlik, aydınlatma, crop geometrisi veya texture gibi başka görsel ipuçlarına kısmen duyarlı olabileceği hipotezini destekleyen bir bulgudur. Bu son cümle deney çıktılarından yapılan bir çıkarımdır; doğrudan nedensellik kanıtı değildir.

9. Sonuçların Bilimsel Yorumu

9.1 'Model öğrenmedi' demek doğru mu?

Tam olarak değil. Training AUC'nin 0.67'ye, validation AUC'nin 0.575'e çıkması ve validation loss'un azalması modelin veri içinde bazı düzenlilikler öğrendiğini gösterir. Fakat bu düzenlilikler testte güçlü, stabil ve sınıflar arasında dengeli bir ayırım üretmemiştir. Daha doğru ifade: 'Model öğrenmiştir, ancak öğrendiği temsil kaş ROI üzerinden deepfake ayırımı için yeterince genellenebilir değildir.'

9.2 Kaş bölgesinin tek başına sinyali

Test ROC-AUC'nin 0.554 olması kaş ROI içinde tamamen sıfır olmayan bir sinyal olduğunu gösterir; ancak bu sinyal zayıftır. Bu deney tek başına 'kaş bölgesinde deepfake bilgisi yoktur' sonucunu kanıtlamaz. Sonuç yalnızca DenseNet121 + mevcut crop politikası + mevcut eğitim konfigürasyonu kombinasyonunun güçlü bir dedektör üretmediğini gösterir.

Ayrıca DeepFakeDetection örneklerinin belirgin biçimde daha kolay yakalanması, bazı manipülasyon yöntemlerinde kaş çevresinde daha görünür ipuçları bulunabileceğini; diğer yöntemlerde ise sinyalin ağız, göz, yüz sınırı veya temporal tutarlılık gibi başka bölgelerde yoğunlaşabileceğini düşündürür. Bu yorum, yöntemler arası performans farkından türetilen bir hipotezdir ve yeni kontrollü deneylerle doğrulanmalıdır.

9.3 Overfitting ve domain uyumu

Training-validation AUC farkının fine-tuning sonrasında büyümesi sınırlı overfitting belirtisidir. ImageNet ön eğitimi genel doğal görüntü özellikleri sağlar; ancak kaş ROI'leri çok dar, texture ağırlıklı ve geometrik olarak alışılmadık görüntülerdir. Bu nedenle ImageNet temsiliinin kaş çevresindeki manipülasyon artefaktlarına doğrudan uyumu sınırlı olabilir.

9.4 Class imbalance temel problem mi?

Hayır. Girdi veri seti yaklaşık dengelidir (969 Fake, 993 Real) ve test seti de 91 Fake / 98 Real'dir. Dolayısıyla çok düşük fake recall'ı yalnızca sınıf dengesizliğiyle açıklamak mümkün değildir. Seçilen eşik, kalibrasyon ve zayıf sınıf ayırımı daha önemli görünmektedir.

10. Deneyin Güçlü Yönleri

- Kaynak/video bazlı split uygulanmış; frame-level leakage önlenmiştir.
- Real ve Fake sınıfları bağımsız source-group mantığıyla ayrılmıştır.
- Train/val/test arasında aynı source veya aynı içerik hash'i bulunmadığı audit ile doğrulanmıştır.
- Test seti threshold veya model seçimi için kullanılmamıştır.
- Best ve last checkpoint ayrı tutulmuş; checkpoint doğrulaması PASS olmuştur.
- Schema, split, smoke, numerical ve checkpoint quality gate'lerinin tamamı PASS'tir.
- Seed 42 ve deterministic ops kaydedilmiştir.
- Config, environment, requirements lock, metric, prediction ve figure çıktıları run klasöründe saklanmıştır.
- Tüm grafikler okunabilir çözünürlük standardını geçmiştir.

Bu özellikler, düşük performansın pipeline hatası veya veri sızıntısı nedeniyle yapay biçimde oluşmuş bir metrik olmadığını; aksine model/veri kombinasyonunun gerçek sınırını daha güvenilir biçimde gösterdiğini düşündürür.

11. Sınırlılıklar

1. Tek run / tek seed raporlanmıştır. Seed varyansı bilinmemektedir.
2. Kaş ROI'leri tek frame görüntüleridir; temporal hareket veya video tutarlılığı kullanılmamıştır.
3. Source-level değerlendirmede birçok source'un az sayıda test frame'i vardır; aggregation kazancı sınırlı kalabilir.
4. Tek mimari ve tek temel eğitim reçetesi bu raporun odağıdır; kaş bölgesinin genel olarak başarısız olduğu sonucu çıkarılamaz.
5. Manipülasyon ailelerinin test örnek sayıları eşit değildir. Özellikle DeepFakeDetection için $n=5$ olduğundan aile bazlı sonuç çok belirsizdir.
6. Olasılık kalibrasyonu ayrıca yapılmamıştır; validation Youden J eşiği testte sensitivity-specificity dengesini korumamıştır.
7. Kaş ROI boyutları ve crop içerikleri örnekler arasında değişken olabilir; `resize_with_pad` oranı korusa da bilgi yoğunluğu farklılaşabilir.

12. Sonraki Deneyler İçin Önerilen Yol Haritası

12.1 Birinci öncelik - baseline karşılaştırması

- Aynı source-group split manifestini sabitleyerek DenseNet121'i SwinV2-Tiny, EfficientNet-B0, Xception ve ConvNeXt-Tiny gibi mimarilerle birebir karşılaştır.
- Her modelde aynı test setini ve aynı metrik setini kullan; böylece mimari etkisini veri split etkisinden ayır.
- En az 3-5 seed ile tekrarla ve ROC-AUC / balanced accuracy için ortalama $\pm$ standart sapma raporla.

12.2 İkinci öncelik - kaş bölgesine özgü temsil

- CNN özelliğine LBP, HOG, Gabor veya wavelet gibi texture odaklı özellikler eklenen fusion deneyleri yap.
- İki kaş tek geniş ROI yerine sol/sağ kaş ayrı branch'lerde işleyen ve sonra feature fusion yapan bir mimariyi test et.
- 224×224 yanında 320 veya 384 giriş çözünürlüğünü dene; kaş kılları ve ince texture artefaktları resize sırasında kayboluyor olabilir.
- Crop içindeki alın/göz kapağı oranını standardize eden alternatif ROI politikalarını ablation olarak karşılaştır.

12.3 Üçüncü öncelik - video düzeyi bilgi

- Her source için sabit sayıda frame örnekle ve video skorunu mean yerine median, trimmed mean ve top-k aggregation ile kıyasla.
- Kaş hareketi, kaş-göz mesafesi veya temporal texture kararlılığı gibi zaman boyutlu özellikleri ekle.
- Frame-level modelin zayıf olduğu yöntemlerde temporal aggregation'ın yöntem bazında iyileşme sağlayıp sağlamadığını ayrı raporla.

12.4 Threshold ve kalibrasyon

- Threshold seçimini validation üzerinde Youden J yanında F1-optimal, balanced accuracy-optimal ve hedef sensitivity operating point olarak karşılaştır.

- Platt scaling / isotonic calibration gibi olasılık kalibrasyonlarını yalnız train/validation ile fit ederek testte calibration curve ve Brier score raporla.
- Test üzerinde bulunan herhangi bir 'en iyi threshold' değerini model seçimi için kullanma; test yalnız nihai doğrulama olarak kalmalı.

12.5 Hata analizi protokolü

- Face2Face, FaceSwap, Deepfakes, FaceShifter, NeuralTextures ve DeepFakeDetection için ayrı confusion/ROC sonuçları üret.
- En güvenli false-negative ve false-positive ROI'leri görsel olarak inceleyerek ortak crop, blur, aydınlatma ve poz örüntülerini etiketle.
- Yanlış tahminleri source bazında gruplayarak aynı kimliğin sistematik olarak zor olup olmadığını kontrol et.

En kritik sonraki deney

Aynı leakage-safe split ile 'DenseNet121 baseline vs. texture+CNN fusion vs. transformer' üçlü karşılaştırması yapılması en yüksek bilgi kazancını sağlar. Mevcut sonuç, yalnızca daha fazla epoch eklemekten çok temsil/mimari değişikliğine ihtiyaç olduğunu göstermektedir.

13. Genel Sonuç

Bu deneyde DenseNet121, 1.962 kaş ROI görüntüsü üzerinde source-group leakage kontrolü uygulanarak eğitilmiş; 1.548 train, 225 validation ve 189 test görüntüsüyle değerlendirilmiştir. Eğitim hattı tüm kalite kapılarından geçmiş, best validation ROC-AUC 0.575 olarak kaydedilmiştir.

Nihai testte image-level accuracy %50.26, balanced accuracy %49.06, ROC-AUC 0.554, PR-AUC 0.529 ve Fake F1 0.242 elde edilmiştir. En kritik zayıflık Fake recall'ın yalnızca %16.48 olmasıdır. 91 Fake test ROI'nin 76'sı Real olarak kaçırılmıştır.

Sonuç olarak DenseNet121'in bu kaş ROI kurulumu, mevcut haliyle standalone deepfake tespiti için yeterli performans göstermemektedir. Bununla birlikte deney, bilimsel olarak değerli ve güvenilir bir baseline sağlamaktadır: veri sızıntısı yoktur, test seti seçim süreçlerinden izole edilmiştir, çıktılar yeniden üretilebilir biçimde kayıt altındadır ve başarısızlığın yönü açıkça tanımlanmıştır. Sonraki çalışmaların odağı daha uzun eğitim yerine kaş bölgesine uygun temsil öğrenme, manipulation-family genellemesi ve temporal/source-level bilgi olmalıdır.

Tek cümlelik değerlendirme

Teknik olarak temiz ve tekrarlanabilir bir deney; fakat kaş ROI üzerinde DenseNet121'in ayırt edici gücü zayıf, Fake sınıfı duyarlılığı yetersiz ve model mevcut haliyle kullanılabilir bir dedektör değildir.

Ek A - Grafik Kalite Denetimi

Grafik	Boyut (px)	Kısa kenar	>=600 px
test_confusion_matrix.png	1124 x 1185	1124	PASS
test_precision_recall_curve.png	1485 x 885	885	PASS
test_roc_curve.png	1485 x 885	885	PASS
training_validation_auc.png	1485 x 885	885	PASS
training_validation_loss.png	1484 x 885	885	PASS

Ek B - Kullanılan Ana Run Çıktıları

Dosya	Rapor içindeki rolü
run_summary.json	Run özeti, split ve ana metrikler
config_resolved.yaml	Hiperparametre ve deney konfigürasyonu
environment.json	Python/TensorFlow/Keras/GPU ortamı
metrics/final_image_level_metrics.csv	Görüntü düzeyi nihai test metrikleri
metrics/final_source_level_metrics.csv	Kaynak/video düzeyi nihai metrikler
metrics/classification_report.csv	Sınıf bazlı precision/recall/F1
metrics/combined_training_history.csv	Epoch bazlı training/validation geçmişi
metrics/validation_threshold.json	Validation threshold seçimi
predictions/test_image_predictions.csv	Örnek bazlı test olasılıkları ve tahminler
predictions/test_source_predictions.csv	Source bazlı agregasyon sonuçları
artifacts/leakage_check.json	Leakage denetimi
artifacts/final_audit.json	Final kalite denetimi
figures/*.png	Loss, AUC, confusion matrix, ROC ve PR görselleri

Ek C - Metriklerin Kısa Anlamı

Metrik	Tanım
Accuracy	Tüm örneklerde doğru tahmin oranı.
Balanced Accuracy	Real ve Fake recall değerlerinin ortalaması; sınıf performansını daha dengeli gösterir.
Precision (Fake)	Model Fake dediğinde bunun gerçekten Fake olma oranı.
Recall / Sensitivity	Gerçek Fake örneklerin ne kadarının yakalandığı.
Specificity	Gerçek Real örneklerin ne kadarının doğru Real olarak korunduğu.
F1	Precision ve recall'un harmonik ortalaması.
ROC-AUC	Karar eşiğinden bağımsız olarak Fake örneği Real örneğin üzerinde sıralama olasılığıyla ilişkili ayrım metriği.
PR-AUC	Özellikle pozitif sınıf performansını precision-recall düzleminde özetler.
MCC	Tüm confusion matrix hücrelerini kullanan dengeli korelasyon ölçüsü; 0 yaklaşık rastlantısal, +1 mükemmel.

Rapor sonu