

EFFICIENTNET-B0 KAŞ ROI DEEPFAKE TESPİTİ

Detaylı Deney Sonuç ve Performans Analiz Raporu

AISC DeepFake Çalışmaları
Nazlıcan / Deney 1 / Kaş

Run ID: 20260808_1248_eyebrow_efficientnet_b0_seed42
Model: torchvision EfficientNet-B0
Tarih: 08 Ağustos 2026

Raporun amacı

Bu rapor, kaş bölgesinden çıkarılmış ROI görüntüleri üzerinde transfer learning ile eğitilen EfficientNet-B0 modelinin veri yapısını, eğitim davranışını, validasyon sürecini, test performansını, hata profilini ve deneyin metodolojik sınırlılıklarını ayrıntılı olarak değerlendirmektedir.

1. Yönetici Özeti

Deney teknik olarak başarıyla tamamlanmıştır. Run COMPLETE durumuna ulaşmış, en iyi fine-tuning checkpointi kaydedilmiş ve checkpointin sıfırdan yeniden yüklenerek inference üretmesi doğrulanmıştır. Bununla birlikte, nihai test performansı modelin kaş ROI üzerinden real/fake ayrımını güçlü ve dengeli biçimde gerçekleştiremediğini göstermektedir.

Metrik	Final Test	Kısa yorum
Accuracy	%54,59	Genel doğruluk düşük; çoğunluk-sınıfı taban çizgisinin yalnızca yaklaşık 3,06 puan üzerinde.
Balanced Accuracy	%55,57	Sınıflar dengeli değerlendirildiğinde ayırt etme gücü zayıf.
Precision (Fake)	%51,88	Fake tahminlerinin yaklaşık yarısı gerçekten fake.
Recall / Sensitivity (Fake)	%87,37	Fake örnekleri yakalama oranı yüksek.
F1 (Fake)	%65,10	Yüksek recall nedeniyle görece yüksek; tek başına yeterli performans göstergesi değil.
Specificity (Real)	%23,76	Gerçek örnekleri doğru tanıma oranı çok düşük.
ROC-AUC	0,587	Rastgele sıralamanın yalnızca sınırlı ölçüde üzerinde.
Average Precision	0,576	Pozitif/fake sınıf ayrımı sınırlı.

Ana bulgu

Model fake örnekleri kaçırmamaya odaklanan bir karar profiline sahiptir. Testte 95 fake örneğin 83'ünü doğru yakalamış, ancak 101 gerçek örneğin yalnızca 24'ünü doğru tanımış ve 77 gerçek örneği yanlış biçimde fake olarak işaretlemiştir. Bu nedenle modelin yüksek recall değeri, düşük specificity ve yüksek false-positive oranı ile birlikte yorumlanmalıdır.

2. Deney Tasarımı ve Teknik Yapı

Deney, kaş bölgesi için önceden çıkarılmış ham renkli ROI görüntülerini kullanarak ImageNet ön-eğitilmiş EfficientNet-B0 üzerinde transfer learning yaklaşımı ile gerçekleştirilmiştir. Girdi görüntülerinin yatay kaş geometrisini bozmayı azaltmak için görüntüler 224 x 224 giriş alanına aspect-ratio korunarak ölçeklenmiş, boş alanlar ImageNet ortalamasıyla doldurulmuş ve ImageNet ön-eğitim normalizasyonu uygulanmıştır.

Bileşen	Değer
Model	torchvision EfficientNet-B0
Ön-eğitim	EfficientNet_B0_Weights.DEFAULT
Girdi	Raw color eyebrow ROI crops
Görüntü boyutu	224 x 224
Preprocessing	Aspect-ratio preserving resize + ImageNet-mean padding + ImageNet normalization
Seed	42
Çalışma cihazı	CUDA GPU
Eğitim yaklaşımı	5 epoch frozen classifier stage + 15 epoch full fine-tuning
Fine-tuning LR	2e-5; son epoch 1e-5

3. Veri Muhasebesi ve Split Yapısı

Metadata toplam 3.000 satır içermektedir. ROI çıkarma aşamasından 1.962 örnek SUCCESS durumunda eğitim için kullanılabilir kalmış, 1.038 örnek SKIPPED olarak audit kayıtlarında tutulmuş ve ERROR kaydı oluşmamıştır. SUCCESS olarak işaretlenen örneklerin hiçbirinde eksik dosya tespit edilmemiştir.

Split	Fake	Real	Toplam	Fake oranı
Train	776	786	1.562	%49,68
Validation	98	106	204	%48,04
Test	95	101	196	%48,47
Toplam kullanılabilir	969	993	1.962	%49,39

Sınıf dağılımı bütün splitlerde yaklaşık dengelidir; bu nedenle testteki yüksek fake tahmin eğilimi sınıf sayılarındaki belirgin bir dengesizlikle açıklanamaz. Path ve input SHA-256 düzeyinde train/validation/test kesişimleri sıfırdır.

Metodolojik sınırlılık - kaynak video/kişi izolasyonu

Metadata içinde doğrulanabilir source_video, person veya subject kimliği bulunmadığı için kaynak-grup düzeyinde leakage kontrolü NOT_VERIFIABLE durumundadır. Dolayısıyla mevcut dosya ve hash kesişimlerinin sıfır olması olumlu olsa da, bu deney için "video-level leakage kesin olarak yoktur" ifadesi kullanılmamalıdır.


4. Eğitim Sürecinin Analizi

4.1 Frozen aşama


İlk 5 epoch boyunca ön-eğitilmiş backbone dondurularak sınıflandırma katmanı adapte edilmiştir. Frozen aşamada validation ROC-AUC yaklaşık 0,603 ile 0,644 aralığında seyretilmiş ve 5. epoch sonunda 0,644 düzeyine ulaşmıştır. Bu aşama, kaş ROI verisine hızlı bir başlangıç adaptasyonu sağlamıştır.

4.2 Full fine-tuning aşama

Backbone açıldıktan sonra düşük öğrenme oranıyla 15 epoch fine-tuning uygulanmıştır. Train loss genel olarak düzenli biçimde düşerken train ROC-AUC hızlı şekilde yükselmiştir. Validation tarafında ise kazanım daha sınırlı kalmış ve belirli bir noktadan sonra train-validation ayrışması belirginleşmiştir.



Şekil 1. Frozen ve fine-tuning dönemlerini kapsayan training-validation loss eğrisi. Train loss sürekli azalırken validation loss belirli bir taban seviyesinden sonra iyileşmeyi durdurmaktadır.



Şekil 2. Validation ROC-AUC, F1 ve balanced accuracy değerlerinin global epoch boyunca değişimi.

Nokta	Train ROC-AUC	Val ROC-AUC	AUC farkı	Train loss	Val loss
Fine-tune epoch 1	0,536	0,535	0,001	0,747	0,719
Best checkpoint - fine-tune epoch 12	0,853	0,682	0,171	0,496	0,647
Fine-tune epoch 15	0,885	0,679	0,207	0,448	0,669


Overfitting değerlendirmesi

Best checkpoint civarında train ROC-AUC ile validation ROC-AUC arasında yaklaşık 0,171 fark vardır. Son epochta bu fark yaklaşık 0,207 seviyesine çıkmaktadır. Aynı dönemde train loss düşmeye devam ederken validation loss yeniden yükselmektedir. Bu desen, modelin eğitim verisine giderek daha iyi uyum sağladığını ancak aynı kazanımı validation verisine aktaramadığını; dolayısıyla overfitting eğiliminin oluştuğunu göstermektedir.

5. Best Checkpoint ve Validation Sonuçları

Fine-tuning aşamasındaki en iyi validation ROC-AUC değeri 0,68194 ile 12. fine-tuning epochunda elde edilmiştir. Bu checkpoint nihai değerlendirme için best.ckpt olarak saklanmıştır. Model seçimi test setinden bağımsız olarak validation performansına göre yapılmıştır.

Validation metriği	Değer
Selected threshold	0,28
Accuracy	%59,31
Balanced Accuracy	%60,43
Precision	%54,72
Recall	%88,78
F1	%67,70
Specificity	%32,08
ROC-AUC	0,68194
Average Precision	0,69764
Confusion counts	TN=34, FP=72, FN=11, TP=87




Şekil 3. Validation threshold analizi. Seçilen 0,28 eşliğinde F1 yüksek tutulurken specificity belirgin biçimde düşmektedir.

Threshold 0,28, modelin fake sınıfına daha kolay pozitif karar vermesine neden olmaktadır. Bu seçim validation recall değerini %88,78 seviyesine çıkarırken specificity değerini %32,08 seviyesine düşürmüştür. Dolayısıyla eşik, fake kaçırmama yönünde agresif bir karar profili üretmektedir.

6. Nihai Test Sonuçları

Nihai test kümesi 101 real ve 95 fake olmak üzere toplam 196 ROI görüntüsünden oluşmaktadır. Validation aşamasında belirlenen 0,28 threshold testte değiştirilmeden uygulanmıştır. Böylece test seti yalnızca nihai değerlendirme amacıyla kullanılmıştır.


Metrik	Değer	Değerlendirme
Accuracy	%54,59	Düşük genel doğruluk
Balanced Accuracy	%55,57	Sınıf dengeli performans zayıf
Precision	%51,88	Fake tahminlerinde yüksek yanlış pozitif yükü
Recall	%87,37	Fake tespiti açısından güçlü duyarlılık
F1	%65,10	Recall ağırlıklı olarak yükselmiş
Specificity	%23,76	Real sınıfını tanıma ciddi derecede zayıf
ROC-AUC	0,58739	Sınıfları sıralama/ayırma kapasitesi sınırlı
Average Precision	0,57611	Pozitif sınıf ayırımı sınırlı




Şekil 4. Nihai test confusion matrix (threshold=0,28). Model 77 real örneği yanlış biçimde fake olarak sınıflandırmıştır.

Gerçek durum	Tahmin Real	Tahmin Fake	Doğru oran
Real (n=101)	24 (TN)	77 (FP)	%23,76
Fake (n=95)	12 (FN)	83 (TP)	%87,37

Model toplam 160/196 örneği (%81,63) fake olarak tahmin etmiştir; oysa test setinde gerçek fake oranı yalnızca %48,47'dir. Bu büyük fark, karar mekanizmasının fake yönüne kaydığını açık biçimde göstermektedir. False Positive Rate, $77/101 = \%76,24$; False Negative Rate ise $12/95 = \%12,63$ 'tür.



Şekil 5. Test ROC eğrisi. $AUC=0,587$; eğri şans çizgisinin üzerinde olmakla birlikte güçlü bir ayırım kapasitesi göstermemektedir.



Şekil 6. Test Precision-Recall eğrisi. Average Precision=0,576.

7. Validation-Test Genelleme Analizi

Metrik	Validation	Test	Değişim
Accuracy	%59,31	%54,59	-4,72 puan
Balanced Accuracy	%60,43	%55,57	-4,86 puan
F1	%67,70	%65,10	-2,60 puan
Specificity	%32,08	%23,76	-8,31 puan
ROC-AUC	0,6819	0,5874	-0,0946
Average Precision	0,6976	0,5761	-0,1215

En dikkat çekici düşüş ROC-AUC ve Average Precision metriklerinde görülmektedir. Validation ROC-AUC 0,682 iken test ROC-AUC 0,587'ye gerilemiştir. Bu, validation üzerinde yakalanan ayrıştırıcı örüntülerin bağımsız test kümesine yeterince taşınmadığını göstermektedir. Specificity de validationdan teste yaklaşık 8,31 puan düşmüştür.

8. Ek Tanısal Değerlendirmeler

8.1 Majority-class taban çizgisi

Test kümesinde çoğunluk sınıfı real olup $101/196 = \%51,53$ oranındadır. Sadece her örneğe real diyen naif bir sınıflandırıcının accuracy değeri %51,53 olurdu. EfficientNet-B0 test accuracy değeri %54,59 ile bu taban çizgisinin yaklaşık 3,06 yüzde puan üzerindedir. Bu karşılaştırma tek başına model kalitesini belirlemez; ancak mevcut accuracy kazanımının sınırlı olduğunu gösterir.

8.2 Threshold=0,50 tanısal karşılaştırması

Kaydedilmiş test olasılıkları üzerinde yalnızca hata profilini anlamak için, resmi sonucu değiştirmeden 0,50 threshold ile ek bir tanısal hesap yapılmıştır. Bu işlem test üzerinde threshold seçimi yapmak amacıyla kullanılmamalıdır ve raporlanan resmi sonuç 0,28 threshold sonucudur.

Threshold	Accuracy	Recall	Specificity	F1	TN/FP/FN/TP
0,28 (resmi)	%54,59	%87,37	%23,76	%65,10	24 / 77 / 12 / 83
0,50 (tanısal)	%55,10	%61,05	%49,50	%56,86	50 / 51 / 37 / 58

Bu karşılaştırma, modelin temel ayrıştırma gücünün zaten sınırlı olduğunu ve 0,28 thresholdun esas olarak recall-specificity dengesini fake yönünde kaydırıldığını göstermektedir. Threshold 0,50 specificityyi yaklaşık iki katına çıkarırken recall ve F1 belirgin biçimde düşmektedir.

9. Teknik Güvenilirlik ve Reproducibility Kontrolleri

- Run durumu COMPLETE olarak kaydedilmiştir.
- Fine-tuning best checkpoint başarıyla kaydedilmiştir.

- Checkpoint yeniden yükleme/inference testi PASSED sonucuyla tamamlanmıştır.
- Inference reload testinde 4 örnek için geçerli olasılık çıktıları üretilmiştir.
- Toplam 38 çıktı dosyası oluşturulmuştur.
- SUCCESS durumundaki 1.962 ROI dosyasının tamamı diskte mevcuttur; missing_files_among_success=0.
- Splitler arasında path ve input SHA-256 çakışması 0 olarak doğrulanmıştır.

Teknik sonuç

Az önce Colab ekranında görülen tqdm progress-bar yüzde değerlerinin 1/2 veya 4/5 görünmesi bu run sonucunu bozan bir durum değildir. Run başarıyla COMPLETE olmuş, checkpoint reload testi geçmiş ve nihai metrik/prediction dosyaları üretilmiştir.

10. Bilimsel Yorum ve Sonuç

Bu deney, EfficientNet-B0 transfer learning yaklaşımının kaş ROI üzerinde belirli düzeyde ayrıştırıcı sinyal öğrendiğini, ancak bu sinyalin bağımsız test verisinde güçlü bir deepfake sınıflandırıcısına dönüşmediğini göstermektedir. ROC-AUC=0,587 ve balanced accuracy=%55,57, modelin rastgele/naif karar düzeyinin üzerinde ancak pratik olarak sınırlı bir ayırım gücüne sahip olduğunu göstermektedir.

Modelin en belirgin özelliği fake sınıfına karşı yüksek duyarlılıktır. Recall=%87,37 olduğundan fake görüntülerin büyük kısmı yakalanmıştır; ancak specificity=%23,76 olması, gerçek görüntülerin büyük bölümünün yanlış alarm üretmesine yol açmıştır. Bu nedenle F1=%65,10 değeri tek başına "model %65 başarılı" şeklinde yorumlanmamalıdır. F1, yüksek recall tarafından desteklenirken real sınıf performansını doğrudan temsil etmemektedir.

Eğitim eğrileri ayrıca overfitting eğilimine işaret etmektedir. Fine-tuning sırasında train ROC-AUC 0,885'e kadar çıkarken validation ROC-AUC yaklaşık 0,679 seviyesinde kalmıştır. Best checkpoint 0,682 validation AUC ile seçilmiş olsa da test AUC 0,587'ye gerilemiştir. Bu nedenle mevcut model, kaş ROI için güçlü bir final modelden çok karşılaştırmalı deney tablosunda kullanılabilecek bir EfficientNet-B0 baseline sonucu olarak değerlendirilmelidir.

11. Önerilen Sonraki Adımlar

1. Bu deney sonucunu değiştirmeden deney tablosuna baseline olarak kaydedin: Accuracy %54,59; Balanced Accuracy %55,57; F1 %65,10; ROC-AUC 0,587; Specificity %23,76.
2. Aynı kaş ROI verisi üzerinde farklı mimarileri (ör. Xception, SwinV2-Tiny, ConvNeXt, ViT türevleri) aynı split ve seed politikasıyla karşılaştırın.
3. Overfittingi azaltmak için daha erken early stopping, daha güçlü fakat kaş geometrisini bozmayan augmentation, weight decay ve katman-kademeli unfreezing gibi stratejileri ayrı deney olarak test edin.
4. Threshold seçim hedefini deney protokolünde açıkça tanımlayın. F1 optimizasyonu ile balanced accuracy/specificity odaklı kullanım senaryoları farklı sonuçlar üretir.
5. En kritik metodolojik iyileştirme olarak source_video veya subject/person kimliklerini metadata'ya ekleyin ve splitleri video/kişi bazında doğrulayın.
6. Kaş ROI boyutlandırma/padding yaklaşımının model performansına etkisini ayrıca ablation deneyi ile karşılaştırın; doğrudan resize, letterbox/padding ve daha yüksek giriş çözünürlüğü ayrı koşullar olarak test edilebilir.

12. Makale/Deney Tablosu İçin Önerilen Kayıt

Model	ROI	Input	Acc.	Bal. Acc.	Prec.	Recall	F1	Spec.	ROC-AUC	AP
Efficient Net-B0	EyeBrow	224x224	54,59	55,57	51,88	87,37	65,10	23,76	58,74	57,61

Önerilen kısa sonuç cümlesi: "EfficientNet-B0 transfer learning modeli kaş ROI'lerinde yüksek fake recall (%87,37) elde etmiş, ancak düşük specificity (%23,76) ve yüksek false-positive oranı nedeniyle dengeli sınıflandırma performansı sınırlı kalmıştır. Nihai test ROC-AUC değeri 0,587 ve balanced accuracy değeri %55,57 olarak ölçülmüştür."

13. Sınırlılıklar

- Kaynak video/kişi kimliği metadata içinde bulunmadığından video-level leakage kesin olarak doğrulanamamaktadır.
- Test seti 196 örnekten oluşmaktadır; sonuçların güven aralığı ayrıca raporlanmamıştır.
- Bu rapor tek seed=42 çalışmasına dayanmaktadır; çoklu seed ortalaması ve standart sapma bulunmamaktadır.
- Threshold 0,28 validation üzerinde seçilmiştir; farklı operasyon hedefleri için başka thresholdlar gerekebilir.
- ROI çıkarma pipelineında 3.000 girdinin 1.038'i skipped olduğu için model, yalnızca ROI kalite/geometri kontrollerini geçen 1.962 örnek üzerinde değerlendirilmiştir.

14. Raporun Dayandığı Deney Çıktıları

- run_summary.json
- data_accounting.json
- frozen_training_history.csv
- finetune_training_history.csv / finetune_training_summary.json
- validation_selected_threshold_metrics.json
- final_test_metrics.csv
- test_predictions.csv
- inference_reload_test.json
- RUN_COMPLETE.json
- training_validation_loss_curve.png
- validation_metrics_curve.png
- validation_threshold_analysis.png
- test_confusion_matrix.png
- test_roc_curve.png
- test_precision_recall_curve.png

Not: Rapor içindeki 0,50 threshold karşılaştırması, test_predictions.csv dosyasındaki kayıtlı test olasılıkları üzerinden yalnızca tanısal amaçla hesaplanmıştır; resmi test sonucu 0,28 validation-selected threshold ile raporlanan sonuçtur.