

KAŞ BÖLGESİ DEEPPFAKE TESPİTİ

HOG + LBP + KAZE Özellikleri ile RBF-SVM ve Random Forest

Deney 1 - Detaylı Sonuç ve Değerlendirme Raporu

Run ID	20260808_121903_eyebrow_hog_lbp_kaze_seed42
Bölge	Kaş (Eyebrow ROI)
Kullanılan ROI	1962
Deneyler	E1 HOG+LBP SVM E2 HOG+LBP+KAZE SVM E3 HOG+LBP+KAZE RF
Durum	COMPLETED
Toplam çalışma süresi	32,60 dakika

Hazırlanma tarihi: 8 Ağustos 2026

1. Yönetici Özeti

Bu rapor, Nazlıcan/Deney 1 altında kaş bölgesine önceden kırılmış ROI framları üzerinde yürütülen HOG, LBP ve KAZE tabanlı üç klasik makine öğrenmesi deneyinin tüm çıktıların ayrıntılı analizidir. Deney; veri muhasebesi, özellik çıkarımı, model seçimi, validation sonuçları, bağımsız test sonuçları, confusion matrix, ROC eğrileri, tahmin dosyaları, model checkpointleri ve tekrar yükleme/audit kayıtları birlikte değerlendirilerek yorumlanmıştır.

En kritik sonuç

Validation setinde seçilen modeller yaklaşık %61,8-%65,2 accuracy bandına ulaşırken, bağımsız test setinde accuracy %49.0-%53.1 bandına gerilemiştir. Testte en yüksek accuracy E2'de %53,06, en yüksek ROC-AUC ise E3'te 0,556 olarak elde edilmiştir. Ancak test setindeki çoğunluk-sınıfı baseline'ı %51,53 olduğundan, E2 ve E3'ün mutlak kazancı sınırlıdır. Bu nedenle bu sonuçlar güçlü bir deepfake ayırtıcısı değil, kaş ROI üzerinde klasik feature setinin sınırlı genelleme gücü olduğunu göstermektedir.

1.1 Öne çıkan bulgular

- 3000 kaynak framelik kaş kırma çalışmasında 1962 ROI başarıyla üretilmiş, 1038 örnek atlanmış ve hata sayısı 0 olmuştur. Model eğitimi bu 1962 başarılı ROI üzerinde yapılmıştır.
- Veri dağılımı dengelidir: train 1562 (786 real / 776 fake), validation 204 (106 / 98), test 196 (101 / 95).
- E1 için C=10, E2 için C=1 seçilmiş; E3 için 300 ağaçlı, sınırsız derinlikli RF-1 konfigürasyonu validation F1 kriteriyle seçilmiştir.
- Testte E2 en yüksek accuracy (%53,06) ve fake F1 (%51,06) değerini; E3 ise en yüksek ROC-AUC (0,556) ve real specificity (%57,43) değerini vermiştir.
- Üç model 196 test örneğinin 139 tanesinde aynı kararı vermiştir. Tüm modellerin birlikte doğru olduğu örnek sayısı 71, birlikte yanlış olduğu örnek sayısı 68'dir.
- Random Forest'ın tahminlerinin 167/196'sı (%85,20) 0,50 karar eşiğinin $\pm 0,10$ çevresindedir; bu durum modelin test örneklerinin büyük bölümünde güçlü bir güven marjı oluşturamadığını düşündürmektedir.
- Exact ROI hash kontrolü PASSED ve splitler arasında aynı ROI hash'i bulunmamıştır. Ancak source_video alanı dolu olmadığı için video-level split izolasyonu bağımsız olarak doğrulanamamıştır.

1.2 Metrik bazında en iyi model

Metrik	En iyi deney	Değer
Accuracy	E2 - HOG + LBP + KAZE - RBF-SVM	%53,06
Fake Precision	E2	%51,61
Fake Recall	E1 - HOG + LBP - RBF-SVM	%54,74
Fake F1	E2	%51,06
ROC-AUC	E3 - HOG + LBP + KAZE - Random Forest	0,556
Real Specificity	E3	%57,43

2. Veri Seti ve Kaş ROI Hazırlama Süreci

2.1 Kullanılan veri kaynağı

Model, Deney 1 kapsamında daha önce kaş bölgesine kırılmış görüntüleri doğrudan kullanmıştır. Eğitim notebooku yüz veya kaş tespiti yapmamış, hazır ROI dosyalarını okumuş ve bu dosyalardan feature çıkarmıştır. Bu ayırım önemlidir: görüntüye önceden HOG/LBP/KAZE feature eklenmemiştir; feature vektörleri deney sırasında hesaplanmıştır.

Girdi yolu: /content/drive/MyDrive/AISC DeepFake Çalışmaları/Deneyler/Nazlıcan/Deney 1/Kaş

2.2 ROI üretim muhasebesi

Kalem	Adet	Oran/Açıklama
Toplam kaynak girdi	3000	Kaş ROI kırma pipelineına giren frame
Başarılı ROI	1962	%65,40
Atlanan örnek	1038	%34,60
Hatalı örnek	0	0

Burada atlanan 1038 örnek model eğitime hiç girmemiştir. Bu nedenle model sonuçları 3000 ham giriş üzerinden değil, başarılı şekilde üretilen 1962 kaş ROI üzerinden değerlendirilmelidir.

2.3 Train / validation / test dağılımı

Split	Toplam	Real	Fake	Toplam içindeki oran
Train	1562	786	776	%79,61
Validation	204	106	98	%10,40
Test	196	101	95	%9,99
Toplam	1962	993	969	%100,00

Sınıf dağılımları bütün splitlerde yaklaşık dengelidir. Bu nedenle sonuçların düşük olmasını basit bir sınıf dengesizliğiyle açıklamak mümkün değildir. Test setinde çoğunluk sınıfı real olup 101/196 örnektir; yalnızca tüm testleri “real” tahmin eden bir baseline bile yaklaşık %51,53 accuracy elde edecektir.

3. Deney Pipelineı ve Özellik Çıkarımı

Her kaş ROI 224 x 224 piksele yeniden boyutlandırılmış ve gri seviyeye dönüştürülmüştür. Ardından aynı görüntüden üç farklı el yapımı özellik ailesi çıkarılmıştır. Bu özellikler farklı görsel ipuçlarını temsil ettiği için birlikte kullanıldığında tamamlayıcı bilgi sağlamaları amaçlanmıştır.

Feature	Açılım/Yöntem	Deneydeki rol	Boyut
---------	---------------	---------------	-------

HOG	Histogram of Oriented Gradients	Kenar ve lokal yönelim dağılımları; kaş konturu/kıl yönelimi gibi geometrik ipuçları	6084
LBP	Local Binary Pattern	Lokal mikro-doku örüntüleri ve komşuluk farkları	26
KAZE	Nonlinear scale-space local descriptors	Lokal anahtar noktalar ve descriptor istatistikleri	128
Fusion	HOG + LBP + KAZE	Üç feature ailesinin tek vektörde birleştirilmesi	6238

3.1 HOG ayarları

- Orientations: 9
- Pixels per cell: [16, 16]
- Cells per block: [2, 2]
- Feature uzunluğu: 6084

3.2 LBP ayarları

- Radius: 3
- Points: 24
- Method: uniform
- Feature uzunluğu: 26

3.3 KAZE pooling

KAZE descriptor sayısı görüntüden görüntüye değiştiği için sabit boyutlu bir temsil oluşturmak amacıyla descriptorların ortalaması ve standart sapması birleştirilmiştir. Böylece 64 boyutlu mean + 64 boyutlu standard deviation = 128 boyutlu KAZE feature elde edilmiştir.

4. Modeller ve Model Seçim Stratejisi

Model seçimi yalnızca validation seti üzerinde yapılmıştır. Birincil seçim metriği fake sınıfı F1, ikincil metrik ROC-AUC olarak tanımlanmıştır. Test seti model/hiperparametre seçimi için kullanılmamıştır; seçilen konfigürasyonlar en son bağımsız test setinde değerlendirilmiştir.

Deney	Feature seti	Model	Arama	Seçilen
E1	HOG + LBP	RBF-SVM	$C \in \{0,1; 1; 10\}$	$C=10$
E2	HOG + LBP + KAZE	RBF-SVM	$C \in \{0,1; 1; 10\}$	$C=1$
E3	HOG + LBP + KAZE	Random Forest	3 konfigürasyon	RF-1: 300 trees, depth=None, leaf=1, max_features=sqrt

SVM deneylerinde feature ölçekleme StandardScaler ile pipeline içinde uygulanmıştır. Random Forest doğrudan fused feature vektörleriyle eğitilmiştir. Class weight ayarları dengeli sınıfları koruyacak şekilde kullanılmıştır.

5. Validation Sonuçları ve Hiperparametre Seçimi

5.1 E1 - HOG + LBP / RBF-SVM

C	Accuracy	Fake Precision	Fake Recall	Fake F1	ROC-AUC
0,1	%55,39	%52,67	%70,41	%60,26	0,565
1,0	%59,31	%57,73	%57,14	%57,44	0,632
10,0	%61,76	%58,93	%67,35	%62,86	0,611

E1 için C=10 seçilmiştir. Bu konfigürasyon validation fake F1 değerini %62,86 ile en yüksek seviyeye taşımıştır. C=1 ROC-AUC açısından daha yüksek olsa da (%63,16), seçim kuralında F1 birincil metrik olduğu için C=10 tercih edilmiştir.

5.2 E2 - HOG + LBP + KAZE / RBF-SVM

C	Accuracy	Fake Precision	Fake Recall	Fake F1	ROC-AUC
0,1	%53,92	%51,52	%69,39	%59,13	0,575
1,0	%62,75	%61,00	%62,24	%61,62	0,641
10,0	%58,33	%55,96	%62,24	%58,94	0,617

KAZE eklenen E2 deneyinde C=1 açık biçimde en dengeli validation sonucu vermiştir: accuracy %62,75, fake F1 %61,62 ve ROC-AUC 0,641. C=0,1 yüksek recall üretmesine rağmen precision/accuracy tarafında zayıf kalmış; C=10 ise genel performansı geriletmiştir.

5.3 E3 - HOG + LBP + KAZE / Random Forest

Config	n_estimators / depth / leaf / max_features	Accuracy	Precision	Recall	F1	AUC
RF-1	300 / None / 1 / sqrt	%65,20	%63,92	%63,27	%63,59	0,653
RF-2	300 / 20 / 1 / sqrt	%63,73	%62,24	%62,24	%62,24	0,653
RF-3	300 / None / 2 / sqrt	%63,73	%62,00	%63,27	%62,63	0,650

RF-1, fake F1 açısından %63,59 ile en iyi validation sonucunu verdiği için seçilmiştir. RF-2 ROC-AUC bakımından çok küçük bir farkla daha yüksek (0,65349 vs 0,65340) olsa da F1 öncelikli seçim kuralı RF-1'i seçmiştir.

Validation düzeyindeki genel tablo

Üç deney arasında en yüksek validation accuracy ve fake F1 Random Forest RF-1 konfigürasyonunda görülmüştür. Ancak bu üstünlük bağımsız test setine aynı ölçüde taşınmamıştır. Bu durum raporun test ve genelleme bölümlerinde kritik olarak ele alınmıştır.

6. Bağımsız Test Sonuçları

Deney	Model	Accuracy	Fake Precision	Fake Recall	Fake F1	ROC-AUC	Real Specificity
E1	HOG + LBP - SVM	%48,98	%47,71	%54,74	%50,98	0,487	%43,56
E2	HOG + LBP + KAZE - SVM	%53,06	%51,61	%50,53	%51,06	0,539	%55,45
E3	HOG + LBP + KAZE - RF	%52,55	%51,14	%47,37	%49,18	0,556	%57,43

6.1 Sonuçların doğrudan yorumu

- E1: accuracy %48,98, ROC-AUC 0,487. AUC 0,50'nin altında ve accuracy çoğunluk sınıfı baseline'ının da altındadır. HOG+LBP bu test setinde anlamlı bir ayırt edicilik göstermemiştir.
- E2: accuracy %53,06 ile üç modelin en yükseğidir. Fake F1 %51,06, ROC-AUC 0,539. KAZE eklenmesi E1'e göre özellikle accuracy, AUC ve specificity tarafında iyileşme sağlamıştır; ancak performans hâlâ random/baseline seviyesine yakındır.
- E3: accuracy %52,55, ROC-AUC 0,556. Üç model arasında en yüksek AUC ve specificity E3'tedir. Buna karşılık fake recall ve fake F1 E2'den düşüktür; yani RF sıralama kabiliyetinde biraz daha iyi olsa da 0,50 eşliğinde fake sınıfını yakalamada daha muhafazakâr davranmıştır.

6.2 Çoğunluk-sınıfı baseline ile karşılaştırma

Yaklaşım	Accuracy	Baseline farkı	ROC-AUC	Yorum
Always Real baseline	%51,53	-	-	Testte 101 real / 95 fake
E1	%48,98	-2,55 puan	0,487	Baseline altı
E2	%53,06	+1,53 puan	0,539	Sınırlı artış
E3	%52,55	+1,02 puan	0,556	Sınırlı artış

Test setinde sınıflar neredeyse dengeli olsa da real sınıfı 6 örnek fazladır. Bu nedenle yalnızca real tahmin eden basit bir sistem %51,53 accuracy üretmektedir. E2'nin %53,06 accuracy değeri bu baseline'ın yalnızca yaklaşık 1,53 yüzde puan üzerindedir. Bu karşılaştırma, tek başına accuracy değerinin “başarılı model” yorumu için yeterli olmadığını gösterir.


6.3 Validation -> test genelleme farkı

Deney	Val Acc	Test Acc	Acc düşüş	Val F1	Test F1	F1 düşüş	Val AUC	Test AUC
E1	%61,76	%48,98	-12,79 puan	%62,86	%50,98	-11,88 puan	0,611	0,487
E2	%62,75	%53,06	-9,68 puan	%61,62	%51,06	-10,55 puan	0,641	0,539
E3	%65,20	%52,55	-12,65 puan	%63,59	%49,18	-14,41 puan	0,653	0,556

Bütün modellerde validation performansının testte belirgin biçimde düşmesi, genelleme sorunu bulunduğuna işaret eder. Bu fark; feature setinin kaş bölgesindeki gerçek/fake ayrımını yeterince kararlı yakalayamaması, validation ve test dağılımları arasındaki farklılıklar, ROI kalite çeşitliliği veya

frame/video kaynaklı bağımlılıkların yeterince temsil edilememesi gibi nedenlerle açıklanabilir. Mevcut dosyalar bu olasılıklardan hangisinin ana neden olduğunu kesin olarak belirlemeye yetmez.

7. Görsel 1 - Model Performance Comparison




Şekil 1. Bağımsız test setinde üç modelin temel performans metriklerinin karşılaştırılması.

Grafik, modeller arasında büyük bir üstünlük bulunmadığını görsel olarak açık biçimde göstermektedir. E1 fake recall'da öne çıkarken real specificity'de zayıftır; E3 specificity ve ROC-AUC'da daha iyi fakat fake recall/F1'da daha zayıftır. E2 ise accuracy, precision ve F1 açısından daha dengeli görünmektedir. Bu nedenle “tek bir metrikte en yüksek değer” ile “genel olarak en dengeli model” ayrımını yapmak gerekir.

- Accuracy: E2 %53,06 > E3 %52,55 > E1 %48,98.
- ROC-AUC: E3 0,556 > E2 0,539 > E1 0,487.
- Specificity: E3 %57,43 ile real örnekleri doğru tanımda en güçlü modeldir.
- Fake recall: E1 %54,74 ile en yüksek değeri verir; ancak bunu 57 false positive pahasına yapmaktadır.

8. Görsel 2 - Confusion Matrix Analizi



Şekil 2. Üç modelin 196 örneklilik bağımsız test setindeki confusion matrixleri.

Deney	Model	TN	FP	FN	TP	Toplam hata
E1	HOG+LBP SVM	44	57	43	52	100
E2	HOG+LBP+KAZE SVM	56	45	47	48	92
E3	HOG+LBP+KAZE RF	58	43	50	45	93

8.1 E1 hata davranışı

E1, 101 real örneğin yalnızca 44'ünü doğru real olarak sınıflandırmış ve 57 real örneği fake olarak işaretlemiştir. Buna karşılık 95 fake örneğin 52'sini yakalamıştır. Bu yapı modelin fake tahmine doğru eğilimli olduğunu ve yüksek fake recall'ın yüksek false positive maliyetiyle geldiğini gösterir.


8.2 E2 hata davranışı

E2'de real sınıf performansı belirgin şekilde toparlanır: TN 56'ya yükselirken FP 45'e düşer. Fake tarafında TP 48, FN 47'dir. Hatalar iki sınıfa daha dengeli dağılır. Bu nedenle E2'nin accuracy ve macro/weighted metrikleri üç model arasında en dengeli görünümü verir.

8.3 E3 hata davranışı

E3 real sınıfı koruma konusunda en iyi modeldir: 58 TN ve 43 FP üretir. Fakat fake sınıfta yalnızca 45 TP ve 50 FN vardır. Yani Random Forest real sınıfa biraz daha muhafazakâr yaklaşmakta; fake örneklerin yarısından fazlasına yakın bir bölümünü kaçırmaktadır.

9. Görsel 3 - ROC Eğrisi ve AUC Analizi



Şekil 3. Test seti ROC eğrileri ve random classifier referans çizgisi.

ROC eğrileri üç modelin de random classifier çizgisine oldukça yakın seyrettiğini göstermektedir. E1'in AUC değeri 0,487 ile random düzeyinin biraz altındadır. E2 0,539 ve E3 0,556 ile random seviyesinin üstüne çıkmasına rağmen ayırım gücü hâlâ zayıftır. Özellikle deployment veya makale düzeyinde güçlü bir kaş tabanlı deepfake tespit iddiası için bu AUC değerleri yeterli değildir.

AUC neden önemli?

Accuracy tek bir karar eşiğindeki sonucu gösterirken ROC-AUC model skorlarının real ve fake örnekleri genel olarak ne kadar iyi sıraladığını ölçer. E3'ün accuracy'si E2'den az düşük olmasına rağmen AUC'sinin daha yüksek olması, farklı bir eşik seçilirse E3'ün trade-off'unun değişebileceğini gösterir. Ancak 0,556 AUC yine de sınırlı ayırt edicilik anlamına gelir.

10. Tahmin Dosyası Üzerinden Ek Analiz

Sonuç paketindeki test_predictions.csv dosyası 196 test örneği için üç modelin tahminlerini ve skorlarını içerir. Bu dosya üzerinden rapor için ek bir model-uyumu ve güven analizi yapılmıştır. Bu analiz notebookun standart metriklerine ek olarak hesaplanmıştır; kaynak tahminler değiştirilmemiştir.

Ek analiz	Değer	Oran/Yorum
Üç modelin aynı karar verdiği örnek	139	%70,92
Üç modelin birlikte doğru olduğu örnek	71	%36,22
Üç modelin birlikte yanlış olduğu örnek	68	%34,69
3-model majority vote accuracy	53,06%	E2 ile aynı düzey
RF olasılığı 0,50±0,05 aralığında	109	%55,61
RF olasılığı 0,50±0,10 aralığında	167	%85,20

Üç modelin 68 örnekte birlikte hata yapması, bu örneklerde kullanılan el yapımı feature ailelerinin ortak bir ayırt edici sinyal yakalayamadığını düşündürmektedir. Öte yandan 71 örnekte üç modelin birlikte doğru olması, bazı ROI'lerde sinyalin daha belirgin olduğunu gösterir. Modellerin kararlarının %70,92 oranında aynı olması, yöntemler farklı olsa da önemli ölçüde aynı feature uzayına dayandıkları için hata kalıplarının da benzer olduğunu düşündürmektedir.

Random Forest tahminlerinin %85,20'si 0,40-0,60 olasılık bandındadır. Bu yüksek oran, modelin örneklerin çoğunda karar sınırından uzak, güçlü olasılıklar üretmediğini gösterir. Bu sonuç, ROC-AUC'nin yalnızca 0,556 olmasıyla da tutarlıdır.

11. Tekrarlanabilirlik, Audit ve Çıktı Paketi

11.1 Ortam bilgileri

Bileşen	Sürüm / Ortam
python	3.12.13
platform	Linux-6.6.122+-x86_64-with-glibc2.35
opencv	4.13.0
numpy	2.0.2
pandas	2.2.2
scikit_learn	1.6.1
scikit_image	0.25.2

OpenCV 4.13.0 kullanılmıştır. KAZE Python binding uyumluluğu için deney ortamı bu sürüme sabitlenmiştir. Seed değeri 42'dir.

11.2 Veri ve split auditleri

Kontrol	Sonuç
---------	-------

Kaynak ROI dosyaları değiştirildi mi?	Hayır
Feature deney sırasında çıkarıldı mı?	Evet
NaN / Inf	Tespit edilmedi
Test seti model seçiminde kullanıldı mı?	Hayır
Saved model fresh-load inference	PASSED - 3 model
Exact ROI hash cross-split	PASSED - 0 duplicate hash
Source-video cross-split	NOT_AVAILABLE

Önemli sınırlılık: video-level split doğrulaması

metadata.csv içindeki source_video alanı dolu olmadığı için aynı kaynak videodan gelen framelelerin train/validation/test arasında dağılıp dağılmadığı bu sonuç paketi üzerinden bağımsız olarak doğrulanamamıştır. Exact ROI duplicate kontrolünün geçmesi yalnızca birebir aynı görüntünün splitler arasında olmadığını gösterir; aynı videonun farklı frameleleri için garanti vermez.

11.3 Kaydedilen model checkpointleri

Dosya	Deney	Boyut
best_hog_lbp_rbf_svm.joblib	E1	≈ 76,0 MB
best_hog_lbp_kaze_rbf_svm.joblib	E2	≈ 76,4 MB
best_hog_lbp_kaze_random_forest.joblib	E3	≈ 8,24 MB

Üç checkpoint de kaydedildikten sonra yeniden yüklenmiş ve test tahminlerinin kaydetme öncesi tahminlerle birebir eşleştiği doğrulanmıştır. fresh_load_inference_test sonucu PASSED olarak kaydedilmiştir.

11.4 Artifacts ve sonuç dosyaları

- dataset_index.csv - modele giren ROI örneklerinin indeks ve metadata tablosu
- features_full.npz - HOG/LBP/KAZE feature matrislerinin birleşik cache dosyası
- feature_metadata.csv - feature satırlarının split/label/KAZE keypoint metadata kaydı
- feature_chunks/ - feature çıkarımında resume için parça bazlı cache
- final_test_metrics.csv - bağımsız test metrikleri
- classification_report_*.csv - sınıf bazlı precision/recall/F1 raporları
- test_predictions.csv - örnek bazında üç modelin test tahminleri ve skorları
- model_performance_comparison.png / confusion_matrices.png / roc_curves.png - görsel sonuçlar
- config_resolved.yaml / environment.json / requirements_lock.txt / run_summary.json - deney konfigürasyonu ve yeniden üretilebilirlik kayıtları

12. Bilimsel Yorum ve Deneyin Anlamı

12.1 KAZE eklemek işe yaradı mı?

KAZE'nin etkisini en doğrudan E1 ve E2 karşılaştırması gösterir. Test accuracy E1'de %48,98 iken E2'de %53,06; ROC-AUC 0,487'den 0,539'e, real specificity %43,56'den %55,45'e yükselmiştir. Fake F1 ise yalnızca çok küçük bir artış göstermiştir (%50,98 -> %51,06). Dolayısıyla KAZE bazı tamamlayıcı ayırım bilgisi katmıştır ancak tek başına sorunu çözmemiştir.

12.2 SVM mi Random Forest mi?

Fused feature setinde E2 ve E3 kıyaslandığında SVM accuracy ve fake F1 açısından daha iyi; Random Forest ise ROC-AUC ve real specificity açısından daha iyidir. E2 accuracy %53,06, E3 %52,55; E2 fake F1 %51,06, E3 %49,18. Buna karşılık AUC E2'de 0,539, E3'te 0,556. Bu nedenle mevcut 0,50 sınıflandırma eşliğinde en dengeli seçim E2 olarak görülebilir; ancak genel performans her iki modelde de zayıftır.

12.3 Neden validation daha iyi, test daha düşük?

- Validation setinin belirli ROI kalite örüntülerini test setinden farklı oranlarda içermesi mümkündür.
- Kaş bölgesindeki deepfake artefaktları yalnızca HOG/LBP/KAZE ile kararlı biçimde temsil edilemiyor olabilir.
- ROI boyutu ve kaş kırpma kalitesi, özellikle 1038 örneğin upstream aşamada atlanmış olması, veri seçim etkisi oluşturabilir.
- source_video metadata eksik olduğu için video-bazlı bağımsızlık doğrulanamamıştır; bu, genelleme analizi açısından önemli bir eksikliktir.
- Validation seti 204 örnekle nispeten küçüktür; hiperparametre seçimi bu setin rastlantısal özelliklerine duyarlı olabilir.

Bu maddeler sonuçlardan çıkarılabilecek olası açıklamalardır; mevcut sonuç dosyaları hangisinin baskın neden olduğunu tek başına kanıtlamaz. Bu nedenle raporda neden-sonuç iddiası yerine gözlenen genelleme farkı vurgulanmaktadır.

12.4 Bu sonuç makalede nasıl ifade edilmeli?

Önerilen bilimsel ifade

“Kaş ROI üzerinde HOG+LBP tabanına KAZE eklenmesi test ROC-AUC ve specificity değerlerinde sınırlı iyileşme sağlamıştır. Bununla birlikte tüm klasik modeller bağımsız test setinde yaklaşık random düzeyine yakın performans göstermiş ve validation-test arasında belirgin genelleme kaybı gözlenmiştir. Bu bulgu, kaş bölgesindeki deepfake ipuçlarının yalnızca bu el yapımı feature setleriyle yeterince kararlı temsil edilemediğini ve daha güçlü bölgesel/derin özellik çıkarım yöntemlerinin araştırılması gerektiğini düşündürmektedir.”

13. Sonraki Deneyler İçin Öneriler

1. Video-bazlı split: metadata içine gerçek source_video kimliğini ekleyip train/val/test ayrımını video seviyesinde yeniden doğrulamak. Aynı videodan farklı framelerin splitler arasında bulunmasını kesin olarak engellemek.

2. ROI kalite analizi: Başarılı 1962 ROI ile atlanan 1038 örneğin kalite/çözünürlük/poz açısından karşılaştırılması; düşük kaliteli ROI'lerin model performansını etkileyip etkilemediğinin incelenmesi.

3. Per-video değerlendirme: Frame skorlarını video seviyesinde mean/median/voting ile birleştirip video-level metric üretmek. Deepfake tespitinde frame tek başına gürültülü olabilir.

4. Feature ablation: HOG-only, LBP-only, KAZE-only ve HOG+LBP+KAZE kombinasyonlarını ayrı ayrı test ederek hangi feature ailesinin gerçek katkısını ölçmek.

5. Bölgeye özgü yeni featurelar: Kaş/çevre dokusu için Gabor, GLCM, wavelet, frequency-domain veya landmark/geometri tabanlı featurelar eklemek.

6. Deep feature baseline: Kaş ROI üzerinde transfer learning tabanlı CNN/ViT/Swin/Xception feature extractor ve klasik classifier kombinasyonlarını test etmek.

7. Threshold tuning: AUC'si daha iyi olan RF için validation setinde decision threshold optimize edip testte önceden sabitlenmiş eşikle değerlendirmek; test thresholduna göre ayar yapılmamalı.

8. Daha sağlam model seçimi: Tek validation split yerine video-level grouped cross-validation veya birden fazla seed ile tekrarlı deney yapmak; ortalama $\pm$ standart sapma raporlamak.

14. Genel Sonuç

Bu deney teknik olarak eksiksiz ve yeniden üretilebilir bir klasik feature pipelineı oluşturmuştur: hazır kaş ROI'leri alınmış, HOG/LBP/KAZE featureları çıkarılmış, validation tabanlı hiperparametre seçimi uygulanmış, üç model bağımsız test setinde karşılaştırılmış, checkpointler ve audit çıktıları kaydedilmiş ve görsel sonuçlar üretilmiştir. Deney altyapısı açısından süreç başarılı biçimde tamamlanmıştır.

Model performansı açısından ise sonuçlar sınırlıdır. E2 test accuracy ve fake F1 açısından en dengeli; E3 ROC-AUC ve real specificity açısından en iyi modeldir. Buna rağmen accuracy değerlerinin %53 civarında ve AUC'nin en fazla 0,556 olması, kaş ROI üzerinde HOG/LBP/KAZE + SVM/RF yaklaşımının bu veri setinde güçlü bir deepfake tespit çözümü oluşturmadığını göstermektedir.

Bu sonuç başarısız bir deney olarak değil, önemli bir negatif/karşılaştırmalı bulgu olarak değerlendirilebilir: klasik el yapımı özelliklerin kaş bölgesinde hangi sınırdaki kaldığı gösterilmiş, KAZE'nin küçük fakat yetersiz katkısı ölçülmüş ve sonraki derin/textural/frequency tabanlı yöntemlerle karşılaştırılabilir güvenilir bir baseline elde edilmiştir.

15. Raporun Dayandığı Sonuç Dosyaları

- run_summary.json
- config_resolved.yaml
- environment.json
- metrics/data_accounting.json
- metrics/split_audit.json
- metrics/hog_lbp_svm_validation_metrics.csv
- metrics/hog_lbp_kaze_svm_validation_metrics.csv
- metrics/hog_lbp_kaze_rf_validation_metrics.csv
- metrics/final_test_metrics.csv
- metrics/classification_report_E1_HOG_LBP_SVM.csv
- metrics/classification_report_E2_HOG_LBP_KAZE_SVM.csv

- metrics/classification_report_E3_HOG_LBP_KAZE_RF.csv
- predictions/test_predictions.csv
- logs/audit_summary.txt
- metrics/fresh_load_inference_test.json
- figures/model_performance_comparison.png
- figures/confusion_matrices.png
- figures/roc_curves.png
- Kaş/summary.json (ROI kırpma muhasebesi)

Not: Bu rapordaki ek model-uyum ve RF güven analizleri test_predictions.csv dosyasındaki kayıtlar üzerinden ayrıca hesaplanmıştır; kaynak tahmin dosyaları üzerinde değişiklik yapılmamıştır.