

KAŞ BÖLGESİ DEEPPFAKE TESPİTİ

Swin V2 Tiny - Detaylı Deney Sonuç ve Analiz Raporu

Bölge: Eyebrow ROI | Seed: 42 | Ön-eğitimli model: ImageNet-1K

Run: 20260807_1158_eyebrow_swinv2_tiny_seed42

0.682

Frame ROC-AUC

0.709

Video ROC-AUC

92.6%

Frame Recall

0.738

Video F1

Yönetici Özeti

Bu deney, yalnızca kaş bölgesinden (Eyebrow ROI) elde edilen görüntüler kullanılarak ImageNet ön-eğitimli Swin V2 Tiny modelinin gerçek/sahte ayrım gücünü ölçmektedir. Test sonuçları, kaş bölgesinin tek başına rastgele sınıflandırmanın üzerinde ayırt edici sinyal taşıdığını; ancak seçilen karar eşiğinde modelin sahte sınıfını çok agresif işaretlediğini göstermektedir. Frame düzeyinde ROC-AUC 0.6815, video düzeyinde ROC-AUC 0.7091 elde edilmiştir. Video seviyesinde birleştirme performansı belirgin biçimde iyileştirmiştir.

En kritik bulgu karar eşiği davranışdır: validation üzerinden seçilen 0.12 eşiği yüksek sahte yakalama oranı (recall %92.63) üretirken gerçek framelerin önemli bölümünü sahte olarak etiketlemiştir. Bu nedenle bu koşu, kaş bölgesinde öğrenilebilir deepfake izleri bulunduğuna dair olumlu bir sinyal vermekte; fakat tek başına üretim seviyesi dengeli bir sınıflandırıcı olarak yeterli görünmemektedir.

Deney bütünlüğü: Metadata, veri muhasebesi, source-video split izolasyonu, iki-batch smoke test, checkpoint continuity, NaN/Inf kontrolü ve fresh-best-checkpoint inference kontrollerinin tamamı geçmiş durumdadır.

1. Deney Tasarımı ve Veri Bütünlüğü

1.1 Model ve eğitim yapılandırması

Bileşen	Değer
Model	Swin V2 Tiny
Girdi bölgesi	Kaş (Eyebrow ROI)
Ön-eğitim	ImageNet-1K / Swin_V2_T_Weights.IMAGENET1K_V1
Görüntü boyutu	224 x 224
Batch size	32
Dropout	0.20
Backbone LR	1e-5
Head LR	1e-4
Weight decay	0.01
Hedef epoch	20; çalışma kesinti sonrası devam ederek 21 history satırı üretmiştir
Model seçim metriği	Validation ROC-AUC; fallback F1
Threshold seçimi	Validation üzerinden 0.05-0.95 aralığında arama

1.2 Veri muhasebesi

3000 Toplam giriş	1962 Başarılı ROI	1038 Atlanan	0 Hata
-----------------------------	-----------------------------	------------------------	------------------

Toplam 3000 girdinin 1962 tanesi eğitim/değerlendirme için kullanılabilir kaş ROI üretmiştir. 1038 örnek atlanmış, hata sayısı 0 olarak kaydedilmiştir. İncelenen artifact setinde atlanma nedenlerinin kategorik dağılımı yer almadığı için bu rapor nedenlere ilişkin varsayım yapmamaktadır.

1.3 Split ve sınıf dağılımı


Split	Real/Fake frame	Toplam frame	Real/Fake video	Toplam video
Train	786 / 776	1562	455 / 690	1145
Val	106 / 98	204	60 / 86	146
Test	101 / 95	196	57 / 81	138

Frame dağılımları her split içinde birbirine yakın olduğu için sınıf dengesizliği temel performans sorunu olarak görünmemektedir. Train 1562, validation 204 ve test 196 frame içermektedir.

Source-video izolasyon kontrolü başarıyla geçmiştir: train-val overlap=0, train-test overlap=0, val-test overlap=0. Bu nokta özellikle frame tabanlı deepfake çalışmalarında aynı videodan gelen görüntülerin farklı splitlere sızarak yapay performans artışı yaratmasını önlemek açısından güçlü bir deney tasarımı unsurudur.

2. Eğitim Dinamikleri

2.1 Training ve validation loss




Şekil 1. Orijinal run çıktısı: Training and Validation Loss Curve.

Training loss genel olarak yaklaşık 0.709 seviyesinden 0.462 seviyesine kadar düşmüştür. Buna karşılık validation loss yaklaşık 0.65-0.68 bandında dalgalanmış ve eğitim lossuna paralel kalıcı bir düşüş göstermemiştir. Bu ayrışma, modelin eğitim verisine uyumunun artarken validation tarafındaki kazanımın sınırlı kaldığını; dolayısıyla orta düzey bir genelleme açığı oluştuğunu göstermektedir.

Validation lossun en düşük değeri yaklaşık 0.6456 ile kesintiden önceki 11. log epochunda görülmektedir. Ancak model seçimi loss değil ROC-AUC üzerinden yapıldığı için en iyi checkpoint başka bir noktada seçilmiştir. Bu tercih, sınıflandırma skorlarının sıralama kalitesini optimize etme hedefi açısından tutarlıdır.

Grafik uyarısı: Colab kesintisi sonrası history epoch sayacı 1'den yeniden başlamıştır. Bu nedenle orijinal loss grafiğinde aynı x koordinatlarına iki farklı eğitim fazı bağlanmış ve çizgide yapay çaprazlamalar oluşmuştur. Bu görsel checkpoint bozulmasını değil, log epoch etiketleme problemini yansıtır.


2.2 Accuracy ve validation ROC-AUC davranışı



Şekil 2. Orijinal run çıktısı: Training and Validation Accuracy.

Training accuracy yaklaşık %54.7 seviyesinden son history satırında %77.7 seviyesine yükselmiştir. Validation accuracy ise daha oynak davranmış, yaklaşık %49-%66 aralığında kalmıştır. Bu tablo training loss analizini desteklemektedir: model eğitim setinde daha iyi ayrım yapmayı öğrenirken validation performansı aynı hızda yükselmemektedir.

2.3 Validation ROC-AUC davranışı



Şekil 3. Orijinal run çıktısı: Validation ROC-AUC by Epoch.

Validation ROC-AUC ilk aşamada 0.5673'ten hızlı biçimde yükselmiş, sonrasında yaklaşık 0.68-0.71 bandında plato yapmıştır. History akışı global olarak yeniden numaralandırıldığında en yüksek ROC-AUC 0.7107 ile yaklaşık global epoch 15 noktasında oluşmaktadır. Run summary içindeki best_epoch=3 ifadesi kesinti sonrası ikinci fazdaki yerel epoch numarasıdır.

Seçilen en iyi checkpointten sonra validation ROC-AUC büyük bir artış göstermemiş; son history satırında 0.7019 seviyesinde kalmıştır. Bu, eğitimin sonraki kısmında kazanımın doymunlaştığını ve daha uzun eğitimin tek başına belirgin bir iyileşme sağlamadığını düşündürmektedir.

3. Kesinti, Resume ve Checkpoint Bütünlüğü

Training history 21 satırdan oluşmaktadır: ilk fazda epoch 1-12, kesinti/yeniden başlatma sonrasında tekrar epoch 1-9 kaydedilmiştir. Buna karşın öğrenme oranı ikinci fazın ilk satırında başlangıç değerine dönmemiş, önceki fazdaki scheduler seviyesinden devam etmiştir. Bu gözlem optimizier/scheduler state devamlılığı ile uyumludur.

21	12 epoch	9 epoch	Global 1-21
History satırı	İlk faz	İkinci faz	Rekonstrüksiyon

Run artifactlarında checkpoint_continuity testi passed, fresh_best_checkpoint_inference passed ve sayısal NaN/Inf kontrolü passed olarak raporlanmıştır. Bu nedenle kesinti, mevcut kanıtlara göre modelin bilimsel olarak kullanılabilirliğini bozan bir checkpoint hasarı yaratmamıştır.

Raporlama notu: Run summary'de best_epoch=3 yazsa da training history sürekliliğine göre bu nokta global epoch 15 olarak yorumlanmalıdır. Bu rapor iki bilgiyi karıştırmamak için 'yerel epoch 3 / rekonstrükte global epoch 15' ifadesini kullanır.

3.1 En iyi validation noktası

Metrik	Değer
Validation ROC-AUC	0.7107
Validation PR-AUC	0.7097
Validation accuracy	55.39%
Validation loss	0.6484
Training accuracy	76.06%
Seçilen threshold	0.12
Yerel / global epoch	3 / 15

Bu checkpointin validation accuracy değerinin en yüksek accuracy noktası olmaması normaldir; ROC-AUC threshold bağımsız bir sıralama metriğidir. Model seçimi ROC-AUC ile yapıldığı için farklı thresholdlarda doğruluk değişebilir.

4. Frame Düzeyi Test Sonuçları

53.57%

Accuracy

51.16%

Precision


92.63%

Recall

0.659

F1

4.1 Confusion matrix analizi



Şekil 4. Test confusion matrix. Pozitif sınıf: Fake.

Bileşen	Adet	Yorum
True Negative (Real->Real)	17	Doğru gerçek
False Positive (Real->Fake)	84	Gerçek ama sahte denmiş
False Negative (Fake->Real)	7	Sahte ama gerçek denmiş
True Positive (Fake->Fake)	88	Doğru sahte


Model 95 fake test frameinin 88'ini yakalamıştır; bu nedenle fake recall %92.63 gibi yüksek bir değerdedir. Buna karşılık 101 gerçek framein yalnızca 17'si doğru biçimde 'Real' sınıfında kalmış, 84 tanesi 'Fake' olarak işaretlenmiştir. Bu durum specificity'nin yalnızca %16.83, false-positive rate'in ise %83.17 olduğunu göstermektedir.

Balanced accuracy yaklaşık %54.73'dir. Bu değer normal accuracy'den daha açıklayıcıdır çünkü modelin bir sınıfı (Fake) yoğun biçimde tercih ettiğini hesaba katar. Buradaki temel sorun modelin fake örnekleri yakalayamaması değil, gerçek örneklerde yüksek yanlış alarm üretmesidir.

Threshold etkisi: Validation tarafından seçilen threshold=0.12 oldukça düşüktür. Düşük eşik, sahte sınıfa geçişi kolaylaştırarak recall'ü artırmış ancak gerçek sınıfta false positive sayısını büyütüştür. Bu nedenle deployment benzeri dengeli kullanım için threshold kalibrasyonu ayrıca incelenmelidir.

5. Threshold-Bağımsız Ayırt Edicilik

5.1 ROC eğrisi




Şekil 5. Test ROC Curve. Frame ROC-AUC = 0.6815.

ROC-AUC=0.6815 değeri modelin kaş ROI üzerinden rastgele tahminden daha iyi bir skor sıralaması üretebildiğini göstermektedir. Bu sonuç, accuracy'nin yalnızca %53.57 olmasına rağmen model skorlarında kullanılabilir ayırım sinyali bulunduğunu açıklamaktadır: sorun yalnızca temsil öğrenimi değil, aynı zamanda karar eşiği ve kalibrasyon davranışıdır.

ROC eğrisinin diyagonal rastgele sınıflandırıcı çizgisinin üzerinde kalması olumlu olmakla birlikte AUC seviyesi güçlü/nihai bir dedektör düzeyinde değildir. Kaş bölgesi tek başına orta seviyede ayırıcı bilgi taşıyor görünmektedir; daha iyi genelleme için ek veri, bölgesel füzyon veya özellik/temsil zenginleştirme denenmelidir.

5.2 Precision-Recall eğrisi



Şekil 6. Test Precision-Recall Curve. Average Precision (PR-AUC) = 0.6543.

PR-AUC=0.6543 değeri, modelin yüksek recall bölgelerinde precision kaybı yaşadığını göstermektedir. Seçilen çalışma noktası da bunun pratik karşılığıdır: recall çok yüksekken precision yaklaşık %51.16 seviyesinde kalmıştır. Yani model sahteyi kaçırmamak için gerçekleri de sıkça sahte işaretlemektedir.

6. Frame ve Video Düzeyinin Karşılaştırılması

Metrik	Frame	Video	Değişim
Accuracy	0.5357	0.6087	+0.0730
Precision	0.5116	0.6080	+0.0964
Recall	0.9263	0.9383	+0.0120
F1	0.6592	0.7379	+0.0787
ROC-AUC	0.6815	0.7091	+0.0276
PR-AUC	0.6543	0.7627	+0.1084

Video düzeyi birleştirme bütün temel metriklerde frame seviyesinden daha iyi sonuç üretmiştir. Accuracy %53.57 -> %60.87, F1 0.659 -> 0.738, ROC-AUC 0.682 -> 0.709 ve PR-AUC 0.654 -> 0.763 yükselmiştir.

Bu iyileşme, tek bir frame içindeki kaş sinyalinin gürültülü olabildiğini; ancak aynı videodan gelen tahminler birleştirildiğinde tesadüfi frame hatalarının kısmen dengelendiğini düşündürmektedir. Bu nedenle kaş tabanlı yaklaşım için nihai değerlendirmede video-level skorun frame-level accuracy'den daha anlamlı bir ana çıktı olması güçlü bir seçenektir.

Ana sonuç: Kaş ROI tek başına frame düzeyinde sınırlı ama gerçek bir ayırt edici sinyal sağlamaktadır. Bu sinyal video seviyesinde daha kararlı hale gelerek ROC-AUC'yi 0.682'ten 0.709'e çıkarmıştır.

6.1 Metriklerin birlikte okunması

- Yüksek recall: Fake örnekleri kaçırma oranı düşüktür.
- Düşük frame specificity: Gerçek örneklerde yanlış alarm yüksektir.
- ROC-AUC > accuracy: Skor sıralama kapasitesi, mevcut threshold kararından daha iyidir.
- Video-level artış: Zamansal/çok-frame birleştirme yaklaşımı kaş sinyalini daha kullanılabilir hale getirmektedir.

7. Sonuç, Sınırlılıklar ve Sonraki Deney Önerileri

7.1 Bilimsel yorum

Bu koşu, sadece kaş bölgesinden alınan görsel ipuçlarının deepfake tespitinde sıfır bilgi taşımadığını açık biçimde göstermektedir. Frame ROC-AUC 0.6815 ve video ROC-AUC 0.7091, modelin gerçek ve sahte örnekleri skor uzayında rastgele seviyenin üzerinde ayırabildiğini göstermektedir. Buna rağmen frame accuracy ve confusion matrix, karar eşiğinin dengesiz bir çalışma noktası seçtiğini ve gerçek örneklerde yüksek false positive problemi olduğunu ortaya koymaktadır.

Dolayısıyla bu deneyin en doğru sonucu “kaş bölgesi tek başına güçlü bir final dedektördür” değildir. Daha doğru çıkarım şudur: “kaş ROI içerisinde deepfake ayrımı için öğrenilebilir, orta düzeyde bir sinyal vardır; bu sinyal video-level aggregation ile güçlenmektedir fakat dengeli sınıflandırma için threshold/kalibrasyon ve temsil geliştirmesi gereklidir.”

7.2 Güçlü yönler

- Source-video bazlı split izolasyonu sağlanmış ve splitler arası video çakışması sıfırdır.
- Test seti yalnız final değerlendirmede kullanılmıştır; threshold validation üzerinden seçilmiştir.
- Checkpoint continuity ve fresh best-checkpoint inference kontrolleri geçmiştir.
- Sınıf dağılımları splitler içinde dengelidir.
- Frame ve video düzeyinde ayrı değerlendirme yapılmıştır.

7.3 Sınırlılıklar

- ROI başarı oranı $1962/3000 = \%65.4$; 1038 örneğin neden atlandığı bu raporda mevcut artifactlardan ayrıştırılamamıştır.
- Validation seti 204 frame olduğu için threshold ve bazı validation metrikleri örnekleme oynaklığı gösterebilir.
- Kaş ROI tek başına yüzün diğer deepfake ipuçlarını dışarıda bırakmaktadır; bu deney bölgesel katkıyı izole etmek için değerlidir ama maksimum performans hedefi değildir.
- Resume sonrasında epoch log numarası sıfırlanmıştır; orijinal eğitim grafikleri x ekseninde görsel bozulma taşımaktadır. Model/checkpoint bütünlüğü geçmiştir, ancak raporlamada global epoch kullanılmalıdır.

7.4 Önerilen sonraki deneyler

Öncelik	Deney	Amaç
1	Threshold kalibrasyonu / operating point analizi	False positive oranını düşürürken recall kaybını ölçmek
2	Aynı split ile farklı seedler (örn. 3-5 seed)	Sonucun rastlantısal varyansını ölçmek
3	Eye vs Eyebrow aynı protokol karşılaştırması	Bölgesel katkıyı adil biçimde karşılaştırmak
4	Eyebrow + eye/face fusion	Kaş sinyalinin diğer bölgelerle tamamlayıcılığını test etmek
5	Calibration (Platt/isotonic veya validation tabanlı)	Olasılık skorlarını daha güvenilir hale getirmek
6	Hata analizi: FP/FN örneklerinin görsel incelemesi	Modelin hangi kaş desenlerinde yanıldığını anlamak

8. Nihai Değerlendirme

Nihai karar: Deney geçerli ve raporlanabilir durumdadır. Kaş bölgesi için Swin V2 Tiny modeli orta düzeyde ayırt edici sinyal öğrenmiştir. En güçlü sonuç video-level ROC-AUC=0.7091 ve PR-AUC=0.7627'dir. Mevcut threshold ise fake sınıfı lehine agresiftir ve gerçek örneklerde yüksek false positive üretmektedir. Sonraki aşamada yeniden eğitimden önce threshold/kalibrasyon analizi ve aynı protokolle seed tekrarı en yüksek önceliğe sahiptir.

Kaynak Artifactlar

- run_summary.json
- config_resolved.yaml
- data_accounting.json
- dataset_summary.csv
- split_leakage_report.json
- training_history.csv
- test_frame_metrics.json
- test_video_metrics.json
- training_validation_loss.png
- training_validation_accuracy.png
- validation_roc_auc.png
- test_confusion_matrix.png
- test_roc_curve.png
- test_precision_recall_curve.png