

KAŞ BÖLGESİ TABANLI DEEPPFAKE TESPİTİ

Swin V2-Tiny + LBP + GLCM + Gabor + Wavelet Fusion

Ayrıntılı Deney, Görsel ve Sonuç Değerlendirme Raporu

Çalışma bölgesi	Kaş (eyebrow ROI)
Model	Swin V2-Tiny ve 240 boyutlu doku özelliklerinin füzyonu
Run ID	20260806_2124_eyebrow_swinv2_lbp_glcm_gabor_wavelet_seed42
Aktif deney modu	full
Hazırlayan	Nazlıcan Aydemir
Rapor tarihi	7 Ağustos 2026

İçindekiler

1. Yönetici Özeti
 2. Deneyin Amacı ve Kapsamı
 3. Veri Kümesi ve Veri Kalitesi
 4. Özellik Çıkarma ve Model Yaklaşımı
 5. Eğitim Protokolü ve Model Seçimi
 6. Nicel Sonuçlar
 7. Oluşturulan Görsellerin Ayrıntılı Analizi
 8. Hata Analizi ve Model Davranışı
 9. Güçlü Yönler, Sınırlılıklar ve Geçerlilik Tehditleri
 10. İyileştirme ve Sonraki Deney Önerileri
 11. Sonuç
- Ek A. Çıktı Dosyaları ve Denetim İzleri

1. Yönetici Özeti

Bu deneyde, kaş bölgesine kırılmış görüntüler kullanılarak gerçek ve sahte yüz görüntülerinin ayrıştırılması amaçlanmıştır. Model, Swin V2-Tiny tarafından öğrenilen derin görsel temsilleri; LBP, GLCM, Gabor ve Wavelet yöntemleriyle çıkarılan toplam 240 boyutlu el yapımı doku özelliğiyle birleştirmektedir. Çalışma, yalnızca “full” füzyon modunun nihai sonuçlarını içermektedir.

Temel bulgu: Model sahte örnekleri yakalamada yüksek duyarlılık göstermiş, ancak gerçek örnekleri sahte olarak işaretleme eğilimi nedeniyle dengeli doğruluk ve özgüllük sınırlı kalmıştır.

Gösterge	Frame düzeyi	Video düzeyi	Kısa yorum
Accuracy	%60,20	%65,22	Video birleştirme genel doğruluğu artırmıştır.
Balanced Accuracy	%60,92	%60,75	Sınıflar arası dengeli başarı yaklaşık aynı kalmıştır.
Precision	%55,94	%65,42	Video düzeyinde sahte tahminlerin güvenilirliği artmıştır.
Recall	%84,21	%86,42	Sahte örnekleri kaçırmama performansı yüksektir.
F1	%67,23	%74,47	Video düzeyinde belirgin iyileşme vardır.
ROC-AUC	%66,88	%68,27	Ayrıştırma gücü orta düzeydedir.
Average Precision	%67,08	%75,49	Pozitif sınıf sıralaması video düzeyinde daha güçlüdür.

- Toplam 3000 kaş ROI kaydının 1962 tanesi kullanılabilir bulunmuştur; kullanılabilirlik oranı %65,4’tür.
- Veri sınıf bakımından dengelidir: 993 real ve 969 fake örnek kullanılmıştır.
- Train/validation/test ayrımı video kimliği bakımından sızıntısızdır ve tüm kalite kapıları geçmiştir.
- En iyi model doğrulama ROC-AUC ölçütüne göre 5. epokta seçilmiş, karar eşiği validation F1 optimizasyonu ile 0,33 olarak belirlenmiştir.
- Video düzeyi sonuçlar daha iyi görünse de testte 196 frame ve 138 video bulunması, video başına ortalama yalnızca 1,42 frame düşmesi anlamına gelir; bu nedenle video birleştirmenin etkisi sınırlı bağlamda yorumlanmalıdır.

2. Deneyin Amacı ve Kapsamı

Deneyin temel araştırma sorusu, yüzün tamamı yerine yalnızca kaş bölgesindeki doku, yönelim ve çok ölçekli frekans örüntülerinin deepfake tespitinde ayırt edici bilgi taşıyıp taşımadığıdır. Kaş bölgesi; kıl yönelimi, ince kenarlar, lokal kontrast, cilt-kaş sınırı ve üretici modellerin yeniden örnekleme izleri nedeniyle incelenmeye değer bir yüz alt bölgesidir.

Bu rapor aşağıdaki kapsamı ele almaktadır:


- Kullanılan verinin nicel dağılımı ve veri kalitesi kontrolleri
- Dört doku özelliği grubunun boyutları ve Swin V2-Tiny ile füzyonu
- Eğitim ve doğrulama eğrilerinin yakınsama ve genelleme açısından yorumlanması
- Frame ve video düzeyinde tüm temel sınıflandırma metrikleri
- Karmaşıklık matrisleri, ROC, Precision-Recall ve tahmin olasılığı dağılımlarının yorumlanması
- Modelin hata örüntüsü, güçlü yönleri, sınırlılıkları ve sonraki deney önerileri

3. Veri Kümesi ve Veri Kalitesi

Ölçüt	Train	Validation	Test	Toplam
Frame sayısı	1562	204	196	1962
Real frame	786	106	101	993
Fake frame	776	98	95	969
Benzersiz video	1145	146	138	1429*

* Split bazındaki video sayılarının toplamıdır; splitler arasında video çakışması bulunmamaktadır.

Sınıf dağılımı her üç splitte de birbirine yakındır. Bu durum, modelin fake sınıfına yönelmesini basit sınıf dengesizliğiyle açıklamayı güçleştirir. Gözlenen fake yöneliminin daha çok seçilen 0,33 karar eşiği, temsil kalitesi ve sınıfların kaş dokusu uzayındaki örtüşmesiyle ilişkili olduğu düşünülmektedir.



Şekil 1. Train, validation ve test splitlerinde real/fake kaş ROI dağılımı.

Şekil 1’de train setinde yaklaşık 780’er, validation ve test setlerinde yaklaşık 100’er real/fake örnek bulunduğu görülmektedir. Barların birbirine yakın olması deneyin sınıf dengesini desteklemektedir. Bununla birlikte 3000 girişten yalnızca 1962 kaş ROI’nin başarıyla üretilebilmesi, %34,6 oranında veri kaybı bulunduğunu göstermektedir. Atlanan framelelerin belirli kafa pozları, çözünürlükler veya kaş görünürlük koşullarında yoğunlaşması durumunda seçim yanlılığı oluşabilir.

Veri kalitesi: Başarılı olarak işaretlenen 1962 dosyanın tamamı fiziksel olarak bulunmuş, eksik başarı dosyası tespit edilmemiştir. Metadata-video sızıntısı, tahmin tekilliği, checkpoint bütünlüğü, sayısal metrikler ve görsel çözünürlük kontrollerinin tümü PASSED durumundadır.

4. Özellik Çıkarma ve Model Yaklaşımı

Model iki tamamlayıcı bilgi akışını birleştirmektedir. Birinci akış, kaş görüntüsünü doğrudan işleyen Swin V2-Tiny omurgasıdır. İkinci akış, aynı kaş görüntüsünden çıkarılan el yapımı doku özellikleridir. Bu yaklaşım, derin ağın yüksek seviyeli temsillerini açıklanabilir ve belirli görüntü özelliklerine duyarlı klasik tanımlayıcılarla desteklemeyi amaçlar.


Özellik grubu	Boyut	Kaş bölgesinde temsil ettiği bilgi
LBP	54	Yerel mikro-doku, kıl-cilt geçişi ve küçük yoğunluk örüntüleri
GLCM	72	Gri seviye komşulukları, kontrast,

		homojenlik ve düzenlilik
Gabor	72	Farklı yön ve frekanslarda kaş kılları ile kenar yapıları
Wavelet	42	Çok ölçekli detay, kenar ve frekans bileşenleri
Toplam	240	Füzyon koluna verilen el yapımı özellik vektörü

Nihai sınıflandırıcı, Swin V2-Tiny temsili ile 240 boyutlu doku vektörünü füzyon katmanında birleştirerek tek bir real/fake logiti üretir. Bu koşuda yalnızca tüm özellik gruplarını içeren “full” mod çalıştırılmıştır; bu nedenle LBP, GLCM, Gabor veya Wavelet’in tekil katkısı mevcut sonuçlardan doğrudan çıkarılamaz.

5. Eğitim Protokolü ve Model Seçimi

Bileşen	Değer
Maksimum epok	30
Erken durdurma	Aktif
Model seçim metriği	Validation ROC-AUC
En iyi epok	5
En iyi validation ROC-AUC	0,72796
Seçilen karar eşiği	0,33
Test frame sayısı	196
Test video sayısı	138
Video birleştirme	Ortalama fake olasılığı



Şekil 2. Eğitim ve validation loss eğrileri (nihai koşunun 13 epoku).

Eğitim loss'u ilk epoktan dokuzuncu epoka kadar genel olarak azalırken validation loss yaklaşık 4-8. epok aralığında plato yapmaktadır. Validation loss'un 10. epokta belirgin yükselmesi ve sonrasında yeniden düşmesi, eğitimde dalgalanma bulunduğunu göstermektedir. Eğitim ve validation eğrileri arasında aşırı büyük bir ayrışma bulunmamakla birlikte, validation tarafında kalıcı iyileşme oluşmaması modelin erken dönemde doygunluğa ulaştığını düşündürmektedir.



Şekil 3. Eğitim ve validation F1 eğrileri.

Training F1 zamanla yükselirken validation F1 erken epoklarda hızlı biçimde 0,73 seviyesine çıkmakta ve ardından yaklaşık 0,70 çevresinde salınmaktadır. En yüksek validation F1 üçüncü epokta görülse de model seçimi F1'e değil ROC-AUC'ye göre yapıldığı için beşinci epok seçilmiştir. Bu tercih, tek bir eşikten bağımsız sıralama başarısını önceliklendirir; seçilen 0,33 eşik ise ayrıca validation F1'i maksimize edecek şekilde belirlenmiştir.

Yürütme notu: Pipeline logunda aynı full eğitimin aynı sonuç klasörü içinde iki kez başlatıldığı görülmektedir. Nihai checkpoint, epoch tablosu ve test metrikleri ikinci koşuya aittir. Bilimsel tekrarlanabilirlik için temiz runtime'da tek koşu, eğitim başlangıcında seed'in yeniden kurulması ve her koşu için ayrı run klasörü önerilir.

6. Nicel Sonuçlar


Metrik	Frame	Video	Fark (video-frame)	Değerlendirme
Accuracy	0,6020	0,6522	+0,0501	Video düzeyinde genel doğruluk artmıştır.
Balanced Accuracy	0,6092	0,6075	-0,0016	Sınıf dengesi açısından iyileşme yoktur.
Precision	0,5594	0,6542	+0,0948	Fake tahminlerinin doğruluğu belirgin artmıştır.
Recall	0,8421	0,8642	+0,0221	Fake yakalama oranı zaten yüksek, video düzeyinde biraz daha artmıştır.
F1	0,6723	0,7447	+0,0724	Video birleştirme en güçlü katkayı F1'de göstermiştir.
ROC-AUC	0,6688	0,6827	+0,0139	Sıralama kabiliyeti sınırlı fakat pozitif yönde artmıştır.
Average Precision	0,6708	0,7549	+0,0842	Pozitif sınıf sıralaması video düzeyinde daha başarılıdır.

Frame düzeyindeki %60,20 accuracy tek başına değerlendirildiğinde sınırlı görünmektedir. Ancak recall değerinin %84,21 olması modelin sahte örneklerin büyük bölümünü yakaladığını göstermektedir. Buna karşılık precision'ın %55,94 ve gerçek sınıf özgüllüğünün yaklaşık %37,62 olması, çok sayıda real örneğin fake olarak sınıflandırıldığını ortaya koyar.

Video düzeyinde F1'in %74,47'ye ve average precision'ın %75,49'a yükselmesi olumlu bir bulgudur. Bununla birlikte balanced accuracy'nin %60,75'te kalması, iyileşmenin iki sınıfa eşit dağılmadığını gösterir. Accuracy artışının bir kısmı test video setindeki fake video oranının daha yüksek olmasından da etkilenmektedir: 138 videonun 81'i fake, 57'si realdir.

7. Oluşturulan Görsellerin Ayrıntılı Analizi

7.1 Frame Düzeyi Karmaşıklık Matrisi




Şekil 4. Frame düzeyinde test karmaşıklık matrisi.

Gerçek / Tahmin	Real	Fake
-----------------	------	------

Real	38 (TN)	63 (FP)
Fake	15 (FN)	80 (TP)

Model 95 fake framein 80'ini doğru yakalamış, yalnızca 15 fake framei real olarak kaçırmıştır. Buna karşılık 101 real framein yalnızca 38'i doğru tanınmış, 63'ü fake olarak işaretlenmiştir. Bu yapı modelin yüksek duyarlılık fakat düşük özgüllük profiline sahip olduğunu açık biçimde göstermektedir. Yanlış pozitiflerin yüksekliği, modelin kaş dokusundaki doğal keskinlik, sıkıştırma veya düşük çözünürlüğü deepfake izi olarak yorumlayabildiğine işaret edebilir.

7.2 Video Düzeyi Karmaşıklık Matrisi




Şekil 5. Video düzeyinde test karmaşıklık matrisi.

Gerçek / Tahmin	Real	Fake
Real	20 (TN)	37 (FP)
Fake	11 (FN)	70 (TP)

Video düzeyinde 81 fake videonun 70'i doğru yakalanmıştır. Ancak 57 real videonun 37'si yine fake olarak tahmin edilmiştir. Video birleştirme fake tahminlerinin precision değerini yükseltse de


gerçek videoların doğru tanınma oranını yaklaşık %35,09 seviyesinde bırakmıştır. Bu nedenle video düzeyi başarı artışı, modelin sınıflar arasında dengeli hale geldiği anlamına gelmemektedir.

7.3 ROC Eğrileri



Şekil 6. Frame düzeyi ROC eğrisi; ROC-AUC = 0,6688.


Frame ROC eğrisi rastgele sınıflandırıcı doğrusunun üzerinde ilerlemektedir. AUC değerinin 0,6688 olması modelin real ve fake frameleri rastgele tahminden daha iyi sıraladığını, ancak sınıflar arasında güçlü bir ayırım oluşturamadığını gösterir. Eğrinin orta yanlış pozitif oranlarında yükselmesi, yüksek recall elde etmek için önemli miktarda yanlış pozitif kabul edildiğini doğrular.



Şekil 7. Video düzeyi ROC eğrisi; ROC-AUC = 0,6827.


Video ROC-AUC değeri frame düzeyine göre yaklaşık 0,014 artmıştır. Bu küçük fakat tutarlı yükseliş, aynı videoya ait olasılıkların ortalamasının gürültüyü bir miktar azalttığını düşündürür. Bununla birlikte AUC'nin 0,70'in altında kalması, henüz güçlü genelleme seviyesine ulaşılmadığını göstermektedir.

7.4 Precision-Recall Eğrileri



Şekil 8. Frame düzeyi Precision-Recall eğrisi; Average Precision = 0,6708.


Frame Precision-Recall eğrisi, recall yükseldikçe precision'ın kademeli biçimde düştüğünü göstermektedir. Seçilen 0,33 eşik yüksek recall bölgesinde çalıştığı için model sahte örneklerin çoğunu bulurken daha fazla real örneği yanlış alarm olarak üretmektedir.



Şekil 9. Video düzeyi Precision-Recall eğrisi; Average Precision = 0,7549.

Video düzeyi Precision-Recall eğrisi frame düzeyine göre belirgin biçimde daha yüksek kalmaktadır. Average precision'daki yaklaşık 0,084 artış, video ortalamasının fake sınıfını sıralama açısından yararlı olduğunu göstermektedir. Yine de eğrinin yüksek recall bölgesinde 0,60 civarına gerilemesi, yanlış pozitif sorununun devam ettiğini ortaya koyar.

7.5 Tahmin Olasılığı Dağılımı



Şekil 10. Real ve fake test framerleri için tahmin edilen fake olasılığı dağılımı.

Histogramda real ve fake dağılımlarının özellikle 0,35-0,60 aralığında yoğun biçimde üst üste bindiği görülmektedir. Fake örneklerde 0,70-0,90 aralığına uzanan daha belirgin bir sağ kuyruk vardır; bu durum bazı deepfake örneklerinin yüksek güvenle yakalandığını gösterir. Ancak real örneklerin önemli bir kısmının 0,33 eşliğinin üzerinde kalması, karmaşıklık matrisindeki yüksek yanlış pozitif sayısını açıklamaktadır. Modelin olasılıkları tam ayrışmadığı için yalnızca eşik değiştirerek tüm sorunların giderilmesi mümkün değildir.

8. Hata Analizi ve Model Davranışı

Hata/başarı göstergesi	Frame	Video	Yorum
Fake sınıf duyarlılığı	%84,21	%86,42	Model sahte içerikleri kaçırmamaya odaklıdır.
Real sınıf özgüllüğü	%37,62	%35,09	Gerçek içeriklerde yanlış alarm oranı yüksektir.
Yanlış pozitif oranı	%62,38	%64,91	En kritik performans sorunudur.
Yanlış negatif oranı	%15,79	%13,58	Fake kaçırma oranı görece düşüktür.

Modelin olası hata kaynakları aşağıdaki şekilde değerlendirilebilir:

- Kaş ROI'lerinin çok ince ve yatay olması: yeniden boyutlandırma sırasında geometrik bozulma, kıl yönelimlerini değiştirebilir.
- Doğal real görüntülerde sıkıştırma, bulanıklık, düşük ışık ve keskinleştirme izleri: model bunları üretim artefaktı sanabilir.
- Deepfake türleri arasında farklı kaş izleri: bazı manipülasyon yöntemleri kaş bölgesini güçlü biçimde etkilerken bazıları çok az etkileyebilir.
- Karar eşiğinin 0,33 olması: yüksek recall pahasına gerçek sınıfta daha fazla yanlış alarm üretir.
- Kaş ROI başarı filtresi: görünürlüğü kötü veya sınırda olan framerin elenmesi, kullanılan veri alt kümesini belirli poz ve kalite koşullarına kaydırabilir.
- Testte video başına ortalama 1,42 frame bulunması: video düzeyi ortalamanın gerçek bir zamansal tutarlılık analizine dönüşmesini sınırlar.

9. Güçlü Yönler, Sınırlılıklar ve Geçerlilik Tehditleri

9.1 Güçlü Yönler

- Video kimliği bazında split sızıntısı kontrol edilmiş ve kalite kapısı geçilmiştir.
- Klasik doku özellikleri ile derin görsel temsil aynı modelde birleştirilmiştir.
- Frame ve video düzeyinde ayrı değerlendirme yapılmıştır.
- Threshold validation setinden seçilmiş; test verisi eşik seçiminde kullanılmamıştır.
- Checkpoint, tahmin, metrik, grafik, ortam ve konfigürasyon dosyaları sonuç klasöründe saklanmıştır.
- Sınıf dağılımı dengeli olduğu için accuracy yanında balanced accuracy, ROC-AUC ve average precision raporlanmıştır.

9.2 Sınırlılıklar

- Yalnızca full mod çalıştırılmıştır; özellik gruplarının tekil katkısı bilinmemektedir.
- Tek seed ve tek nihai koşu, sonuçların varyansını göstermemektedir.
- 3000 girdinin 1038'i ROI üretiminde atlanmıştır; seçim yanlılığı olasılığı vardır.
- Gerçek sınıf özgüllüğü düşüktür; model pratik kullanımda fazla yanlış alarm üretebilir.
- Video düzeyi değerlendirme, video başına düşük frame sayısı nedeniyle sınırlı bir agregasyondur; zamansal model değildir.
- Pipeline logunda aynı full eğitimin iki kez başlatılması deney izini karıştırmaktadır.
- Sonuçlar yalnızca mevcut veri kaynağı ve split üzerinde geçerlidir; dış veri seti genellemesi ölçülmemiştir.

9.3 Sonuçların Yorumlanmasında Dikkat

Bu deney, kaş bölgesinin deepfake tespiti için bilgi taşıdığını destekleyen bir ön bulgu sunmaktadır; çünkü ROC-AUC değerleri rastgele seviyenin üzerindedir ve fake recall yüksektir. Ancak mevcut performans, kaş bölgesinin tek başına güvenilir bir üretim sistemi için yeterli olduğunu göstermez. Özellikle düşük özgüllük, modelin gerçek görüntülerdeki doğal doku varyasyonlarına karşı hassas olduğunu ortaya koymaktadır.

10. İyileştirme ve Sonraki Deney Önerileri

- 1. Ablation deneyleri:** swin_only, texture_only, swin_lbp, swin_lbp_glcmm, swin_lbp_glcmm_gabor ve full modlarını aynı seed/split ile çalıştırarak her özellik grubunun katkısını ölçün.
- 2. Çoklu seed:** En az 3-5 farklı seed ile ortalama ve standart sapma raporlayın; tek koşuya bağlı rastlantısal farkları azaltın.
- 3. Eşik stratejisi:** F1 yanında balanced accuracy, Youden J ve hedef özgüllük koşullarına göre alternatif eşikler raporlayın.
- 4. Hata örnekleri:** En yüksek güvenli false positive ve false negative kaş görüntülerini ayrı gridlerde inceleyin.
- 5. Manipülasyon türü analizi:** Deepfakes, Face2Face, FaceSwap, NeuralTextures, FaceShifter ve diğer yöntemler için ayrı recall/AUC hesaplayın.
- 6. ROI geometrisi:** Kaş görüntülerini kareye doğrudan esnetmek yerine aspect-ratio korumalı padding ile yeniden boyutlandırın.
- 7. ROI kalite özellikleri:** Blur, ROI boyutu, kafa pozu ve ışık koşullarına göre performans kırılımı yapın.
- 8. Daha çok frame/video:** Her videodan birden fazla kaş framei kullanarak ortalama, median, maksimum ve attention tabanlı agregasyonları karşılaştırın.
- 9. Kalibrasyon:** Reliability diagram, Brier score ve temperature scaling ile olasılıkların güvenilirliğini ölçün.
- 10. Dış doğrulama:** Celeb-DF veya farklı sıkıştırma seviyelerinde dış test gerçekleştirerek veri seti bağımlılığını ölçün.
- 11. Füzyon alternatifi:** Erken/orta/geç füzyon, attention-gated fusion ve özellik seçimi yöntemlerini karşılaştırın.
- 12. Temiz deney yönetimi:** Her koşu için benzersiz klasör oluşturun; train fonksiyonu başında seed'i yeniden kurun ve hücre tekrar çalıştırmasına karşı run kilidi kullanın.

11. Sonuç

Kaş bölgesi üzerinde Swin V2-Tiny ile LBP, GLCM, Gabor ve Wavelet özelliklerinin birleştirildiği bu deney, deepfake tespiti açısından orta düzeyde ayırt edici performans üretmiştir. Frame düzeyinde ROC-AUC 0,6688 ve F1 0,6723; video düzeyinde ROC-AUC 0,6827 ve F1 0,7447 elde edilmiştir. Video düzeyindeki yükseliş, olasılık birleştirmenin tahminleri bir miktar kararlı hale getirdiğini göstermektedir.

Bununla birlikte modelin en belirgin sorunu, gerçek örnekleri fake olarak işaretleme eğilimidir. Frame düzeyinde real özgüllüğü %37,62, video düzeyinde %35,09'dur. Dolayısıyla mevcut model, sahte örnekleri tarayan yüksek duyarlılıklı bir ön eleme aracı olarak umut verse de tek başına güvenilir karar sistemi olarak yeterli değildir.

Bir sonraki aşamada ablation deneyleri, çoklu seed, manipülasyon türü kırımları, aspect-ratio korumalı ROI işleme ve alternatif threshold stratejileri uygulanmalıdır. Bu çalışmalar, kaş bölgesinin hangi özelliklerinin gerçekten katkı sağladığını ve düşük özgüllük probleminin veri, eşik veya model mimarisinden hangisine daha çok bağlı olduğunu ortaya koyacaktır.

Nihai değerlendirme: Deney teknik olarak tamamlanmış, çıktı bütünlüğü ve veri sızıntısı kontrolleri geçmiştir. Bilimsel olarak sonuçlar anlamlı bir başlangıç sunmakta; ancak güçlü bir iddia için ablation, çoklu koşu ve dış veri doğrulaması gerekmektedir.

Ek A. Çıktı Dosyaları ve Denetim İzleri

Klasör / Dosya	Amaç
checkpoints/best.ckpt	Validation ROC-AUC'ye göre seçilen en iyi model ağırlıkları
checkpoints/last.ckpt	Son epok checkpointı ve devam ettirme durumu
metrics/epoch_metrics.csv	Epok bazında train/validation loss ve metrikleri
metrics/test_metrics_frame_level.json	Frame düzeyi nihai test metrikleri
metrics/test_metrics_video_level.json	Video düzeyi nihai test metrikleri
metrics/validation_threshold_search.csv	Validation F1 için eşik taraması
metrics/quality_gates.json	Çıktı, checkpoint, metrik, görsel ve sızıntı kontrolleri
predictions/test_predictions_frame_level.csv	Her frame için olasılık, tahmin ve doğruluk bilgisi
predictions/test_predictions_video_level.csv	Her video için ortalama olasılık ve tahmin
figures/*.png	Dağılım, eğitim eğrileri, karmaşıklık matrisleri, ROC ve PR grafikleri
artifacts/texture_features_*.npz	Split bazında çıkarılmış doku özellikleri
artifacts/texture_scaler.joblib	Yalnızca train splitte fit edilen özellik ölçekleyici
artifacts/metadata_used.csv	Deneyde gerçekten kullanılan 1962 örneğin metadata kaydı
run_summary.json	Koşunun veri, metrik ve kalite kontrol özetini bir arada sunan dosya
output_manifest.csv	Oluşturulan tüm çıktıların manifesti
environment.json / requirements_lock.txt	Çalışma ortamı ve paket sürümü kayıtları

Rapor sonu