

VGG16 FEATURE EXTRACTOR + SVM

Kaş Bölgesi Deepfake Tespiti Detaylı Deney Sonuç Raporu

Deney 1 - Nazlıcan
08 Ağustos 2026

Final Test Accuracy: 57.65% | F1: 57.87% | ROC-AUC: 0.6004

Sonuç: Model kaş bölgesinden sınırlı fakat ölçülebilir ayırtıcı bilgi çıkarmaktadır; mevcut haliyle güçlü ve tek başına kullanılabilir bir deepfake dedektörü değildir.

1. Yönetici Özeti

Bu deneyde **ImageNet üzerinde önceden eğitilmiş VGG16** ağı, kaş bölgesine kırılmış frameleden 512 boyutlu derin özellik vektörleri çıkarmak amacıyla kullanılmış; sınıflandırma aşamasında Support Vector Machine (SVM) uygulanmıştır. VGG16 sınıflandırma başlığı kullanılmamış, ağ yalnızca sabit bir feature extractor olarak görev yapmıştır.

En iyi SVM yapılandırması **RBF kernel, C=1.0, gamma=0.001** olarak seçilmiştir. Bu yapı validation setinde 66.67% accuracy, 65.66% F1 ve 0.6859 ROC-AUC üretmiştir. Final test setinde ise accuracy 57.65%, precision 55.88%, recall 60.00%, F1 57.87% ve ROC-AUC 0.6004 olarak ölçülmüştür.

Ana bulgu: Test seti dengeliye yakın olmasına rağmen model 57.65% doğrulukta kalmıştır. Çoğunluk sınıfını sürekli tahmin eden basit bir baseline yaklaşık 51.53% doğruluk üretirdi; dolayısıyla mevcut modelin mutlak kazancı yaklaşık 6.12 yüzde puandır. ROC-AUC değerinin 0.6004 olması, sınıfları sıralama/ayırma gücünün zayıf-orta düzeyde kaldığını göstermektedir.

Metrik	Değer	Yorum
Accuracy	57.65%	196 test frameinin doğru sınıflandırılma oranı.
Precision (FAKE)	55.88%	FAKE tahmini verilen frameilerin ne kadarının gerçekten FAKE olduğunu gösterir.
Recall (FAKE)	60.00%	Gerçek FAKE frameilerin ne kadarının yakalandığını gösterir.
F1-score (FAKE)	57.87%	Precision ve recall arasındaki dengeyi özetler.
ROC-AUC	0.6004	Karar eşiğinden bağımsız sınıf ayırma/ranking gücü; 0.5 rastgele seviyedir.
Average Precision	0.5975	PR performans özeti. Testte FAKE oranı 48.47% olduğundan baseline AP yaklaşık bu prevalans seviyesindedir.

2. Deney Tasarımı ve Veri Yapısı

2.1 Kullanılan veri dağılımı

Split	REAL	FAKE	Toplam
TRAIN	786	776	1562

Split	REAL	FAKE	Toplam
VAL	106	98	204
TEST	101	95	196
TOPLAM	993	969	1962

Veri dengesi: Train, validation ve test bölümlerinde REAL/FAKE sınıfları birbirine oldukça yakındır. Bu nedenle accuracy tek başına tamamen yanıltıcı değildir; ancak precision, recall, F1 ve ROC-AUC ile birlikte değerlendirilmesi yine de gereklidir.

Feature boyutu: Train 1562 x 512, validation 204 x 512, test 196 x 512. Her frame VGG16 global average pooling sonrasında 512 boyutlu bir vektörle temsil edilmiştir.

2.2 Modelleme hattı

1. Kaş bölgesine kırılmış RGB frame 224x224 boyutuna getirilir.
2. VGG16, ImageNet ağırlıklarıyla ve include_top=False biçiminde yüklenir.
3. Global Average Pooling (pooling=avg) ile her frame için 512 boyutlu özellik vektörü üretilir.
4. SVM öncesinde StandardScaler ile özellik ölçekleme uygulanır.
5. Kernel/C/gamma seçimi yalnızca validation sonuçlarına göre yapılır.
6. Seçilen parametrelerle train+validation birleştirilerek final SVM eğitilir ve test seti yalnızca final değerlendirmede kullanılır.

Not: Bu çalıştırmada video-level metrik üretilmemiştir (video_level = null). Bu rapordaki tüm performans yorumları frame-level sonuçlara dayanır.

3. SVM Hiperparametre Araması

Validation setinde farklı linear ve RBF SVM yapılandırmaları denenmiştir. Seçim metriği F1-score olduğundan final konfigürasyon, validation F1 değeri en yüksek kombinasyona göre belirlenmiştir.

Kernel	C	Gamma	Val Acc.	Val Prec.	Val Recall	Val F1
rbf	1	0.001	66.67%	65.00%	66.33%	65.66%
rbf	1	scale	64.71%	63.00%	64.29%	63.64%
linear	0.1	scale	60.29%	57.26%	68.37%	62.33%
rbf	10	0.001	62.25%	60.00%	64.29%	62.07%
rbf	100	scale	63.24%	61.62%	62.24%	61.93%
linear	1	scale	60.78%	58.33%	64.29%	61.17%

Seçilen yapılandırma: RBF kernel, C=1.0, gamma=0.001. Validation performansı: accuracy 66.67%, precision 65.00%, recall 66.33%, F1 65.66%, ROC-AUC 0.6859.

Arama sonuçlarının önemli bir noktası: gamma=0.01 kullanılan RBF kombinasyonlarında F1 belirgin şekilde düşmüştür. Bu, VGG16 özellik uzayında karar sınırının gamma parametresine duyarlı olduğunu göstermektedir. Buna karşılık C=1, gamma=0.001 kombinasyonu hem performans hem de eğitim süresi bakımından en dengeli sonuçlardan birini vermiştir.

4. Final Test Performansı

Metrik	Değer	Yorum
Accuracy	57.65%	113 / 196 frame doğru; 83 frame yanlış sınıflandırıldı.
Precision (FAKE)	55.88%	57 doğru FAKE / 102 toplam FAKE tahmini.
Recall / Sensitivity (FAKE)	60.00%	57 / 95 gerçek FAKE frame yakalandı.
Specificity (REAL)	55.45%	56 / 101 gerçek REAL frame doğru bulundu.
F1-score (FAKE)	57.87%	FAKE sınıfında precision-recall dengesini özetler.
Balanced Accuracy	57.72%	REAL ve FAKE recall değerlerinin ortalaması.
ROC-AUC	0.6004	Rastgele seviyenin üzerinde, ancak güçlü ayırım seviyesinin altında.
Average Precision	0.5975	FAKE prevalansı 0.4847; PR eğrisi baselineinin üzerinde fakat sınırlı.
Hata Oranı	42.35%	83 / 196 frame hatalı.


4.1 Sınıf bazında performans

Sınıf	Precision	Recall	F1	Support
REAL	59.57%	55.45%	57.44%	101
FAKE	55.88%	60.00%	57.87%	95

Yorum: FAKE recall (60.00%) REAL recall değerinden (55.45%) bir miktar yüksektir. Model gerçek sahte frameleri yakalamada biraz daha başarılı olsa da, FAKE precision değerinin 55.88% olması çok sayıda REAL framein de FAKE olarak işaretlendiğini gösterir. İki sınıfın F1 değerleri birbirine çok yakındır; dolayısıyla hata tek bir sınıfta yoğunlaşmamış, genel ayrıştırma kapasitesi sınırlı kalmıştır.

5. Confusion Matrix Analizi

196 test örneğinin 113 tanesi doğru, 83 tanesi yanlış sınıflandırılmıştır. Matris; 56 REAL → REAL, 45 REAL → FAKE, 38 FAKE → REAL ve 57 FAKE → FAKE sonucunu göstermektedir.




Şekil 1. VGG16 özellikleri + SVM için test confusion matrix.

- False Positive Rate: 44.55%. Gerçek REAL framelerin 45/101 tanesi yanlış biçimde FAKE etiketlenmiştir.
- False Negative Rate: 40.00%. Gerçek FAKE framelerin 38/95 tanesi REAL olarak kaçırılmıştır.
- Model toplam 102 kez FAKE, 94 kez REAL tahmini vermiştir. Tahmin dağılımı aşırı tek sınıfa kaymamış olsa da FAKE yönünde hafif bir eğilim vardır.

Pratik anlam: Deepfake tespitinde hem sahte içeriğin kaçırılması (false negative) hem de gerçek içeriğin yanlış alarm üretmesi (false positive) önemlidir. Burada iki hata türü de yaklaşık %40-45 bandındadır; bu nedenle model tek başına karar verici olarak kullanıldığında yüksek hata riski taşır.

6. ROC-AUC Analizi




Şekil 2. Test seti ROC eğrisi (AUC = 0.6004).

ROC-AUC = 0.6004. AUC=0.5 seviyesi rastgele sıralamaya karşılık gelir. 0.6004 değeri modelin FAKE ve REAL örnekleri rastgele tahminden daha iyi sıraladığını, ancak karar skorlarının iki sınıf arasında güçlü şekilde ayrışmadığını gösterir. Eğrinin diyagonale görece yakın seyretmesi de bu sınırlı ayırma gücüyle uyumludur.

Önemli çıkarım: Accuracy yaklaşık %57.7 iken AUC yaklaşık %60.0 seviyesindedir. Bu iki ölçüm birlikte değerlendirildiğinde sorun yalnızca 0.5 karar eşiğinin seçimi değildir; özellik uzayındaki sınıf ayrışması da sınırlıdır. Sadece threshold ayarlamak tek başına büyük bir performans sıçraması bekletmez.

7. Precision-Recall Eğrisi Analizi



Şekil 3. Test seti Precision-Recall eğrisi (Average Precision = 0.5975).

Average Precision = 0.5975. Test setinde pozitif sınıf (FAKE) oranı $95/196 = 48.47\%$ olduğundan, bilgisiz bir sıralayıcının PR baselinesi yaklaşık 0.4847 civarındadır. Modelin 0.5975 AP değeri bu baselinesin üzerindedir, ancak marj sınırlıdır.

Eğrinin davranışı: Recall yükseldikçe precisionın genel olarak düşmesi, daha fazla sahte frame yakalamak için karar eşiği gevşetildiğinde yanlış FAKE alarmlarının hızla arttığını göstermektedir. Dolayısıyla kullanım senaryosuna göre threshold optimizasyonu yapılabilir; ancak temel temsil gücünün artırılması daha kritik görünmektedir.

8. Tahmin Olasılıkları ve Belirsizlik

Gerçek sınıf	Ort. FAKE olasılığı	Medyan	Std. sapma
REAL	0.4670	0.4559	0.1776
FAKE	0.5328	0.5627	0.1928

Olasılık dağılımı ayrımı: Gerçek REAL framerde ortalama FAKE olasılığı 0.4670, gerçek FAKE framerde ise 0.5328 olmuştur. İki ortalama arasındaki fark yalnızca 0.0658 düzeyindedir; bu da sınıfların karar skorlarında ciddi örtüşme olduğunu desteklemektedir.

Belirsiz örnekler: 59/196 test framei (30.10%) 0.40-0.60 FAKE olasılığı aralığında kalmıştır. Ayrıca 7 REAL frame yüksek güvenle (≥ 0.75) FAKE olarak, 8 FAKE frame ise düşük FAKE olasılığıyla (≤ 0.25) yanlış sınıflandırılmıştır. Bu yüksek güvenli hataların görsel olarak incelenmesi, crop kalitesi veya manipülasyon türü kaynaklı sistematik problemleri ortaya çıkarabilir.

9. Validation - Test Genelleme Farkı

Metrik	Validation	Test	Düşüş
Accuracy	66.67%	57.65%	9.01 puan
Precision	65.00%	55.88%	9.12 puan
Recall	66.33%	60.00%	6.33 puan
F1	65.66%	57.87%	7.79 puan
ROC-AUC	0.6859	0.6004	0.0855

Değerlendirme: Validation accuracy 66.67% iken test accuracy 57.65% olmuştur; fark yaklaşık 9.01 yüzde puandır. F1 farkı 7.79 puan, ROC-AUC farkı 0.0855 seviyesindedir. Bu fark, model seçiminin validation setine özgü örüntülere kısmen uyum sağlamış olabileceğini veya validation ve test alt kümeleri arasında dağılım farkı bulunduğunu düşündürür. Tek bir split üzerinden kesin bir overfitting tanısı koymak doğru değildir; group/video bazlı tekrarlı değerlendirme ile doğrulanmalıdır.

10. Deneyin Güçlü Yönleri ve Sınırlılıkları

10.1 Güçlü yönler

- Train, validation ve test setleri ayrı tutulmuş; final test değerlendirmesi model seçiminden sonra yapılmıştır.
- VGG16 özellikleri ile SVM sınıflandırıcısı ayrıştırılarak basit, tekrarlanabilir ve yorumlanabilir bir baseline kurulmuştur.
- Dataset sınıf dağılımları dengeliye yakındır; tek sınıf baskınlığı düşüktür.
- Accuracy dışında precision, recall, F1, ROC-AUC, Average Precision ve confusion matrix raporlanmıştır.
- SVM parametre seçimi için birden fazla linear/RBF kombinasyonu denenmiştir.

10.2 Sınırlılıklar

- Final accuracy, F1 ve ROC-AUC değerleri sınırlı düzeydedir; model güçlü bir deepfake dedektörü seviyesine ulaşmamıştır.
- VGG16 tamamen frozen feature extractor olarak kullanılmıştır; kaş bölgesine özgü manipülasyon izlerine adapte olmamıştır.
- Video-level metrik bulunmadığı için frame tahminlerinin video kararına dönüştürüldüğünde performansın nasıl değişeceği bilinmemektedir.
- Tek bir train/validation/test split sonucu, veri bölünmesine bağlı varyansı ölçmez.
- Kaş crop kalitesi, hizalama, ölçek ve ışık/poz farklılıklarının özelliklere etkisi ayrıca analiz edilmemiştir.
- Manipülasyon yöntemi, kaynak video veya kimlik bazında alt grup performansları raporlanmamıştır.

11. Sonraki Deneyler İçin Önerilen Yol Haritası

- 1. Video bazlı ayrımı doğrula:** Aynı kaynak videodan gelen framelemlerin farklı splitlere düşmediğini metadata/video ID üzerinden kesin olarak kontrol et. GroupKFold veya StratifiedGroupKFold kullanımı daha güvenilir sonuç verir.
- 2. Kaş ROI standardizasyonunu iyileştir:** Her framede kaşın benzer konum, ölçek ve çevresel margin ile kırıldığını doğrula. İki kaş birlikte ve ayrı ayrı kullanan varyantları karşılaştır.
- 3. VGG16 fine-tuning deneyi yap:** Önce üst convolution bloklarından yalnızca son bloğu düşük learning rate ile açıp kaş verisine adapte et; ardından feature + SVM veya doğrudan classifier performansını karşılaştır.
- 4. Farklı pretrained backbone karşılaştır:** Aynı veri splitleriyle ResNet50, EfficientNet, Xception ve Swin/ViT tabanlı feature extractor'lar karşılaştırılarak kaş bölgesinde hangi temsili daha ayırt edici olduğu ölçülebilir.
- 5. Hand-crafted + deep feature fusion dene:** Kaş bölgesindeki ince doku bozulmaları için LBP, HOG, GLCM veya Gabor özelliklerini VGG16 featurelarıyla birleştiren fusion deneyleri ayrı deney olarak değerlendirilebilir.
- 6. SVM aramasını genişlet:** C ve gamma için logaritmik grid (ör. $1e-4$ - $1e2$) ve gerekirse PCA + SVM kombinasyonu denenebilir. Ancak tuning yalnızca validation/cross-validation üzerinde yapılmalıdır.
- 7. Video-level karar üret:** Bir videoya ait framelemlerin fake olasılıklarını ortalama, medyan, top-k veya temporal voting ile birleştirip video-level Accuracy/F1/AUC raporla.
- 8. Hata analizi yap:** Özellikle yüksek güvenli yanlış tahminleri tek tek incele. Crop hatası, bulanıklık, açığı, gözlük/saç kapaması, düşük çözünürlük ve manipölasyon tipi gibi ortak özellikleri etiketle.

12. Sonuç

VGG16 Feature Extractor + SVM yaklaşımı, kaş bölgesi deepfake tespiti için çalışan ve tekrarlanabilir bir baseline oluşturmuştur. **Final testte 57.65% accuracy, 57.87% F1, 0.6004 ROC-AUC ve 0.5975 Average Precision elde edilmiştir.** Model rastgele/çoğunluk baselineinin üzerinde sinyal yakalamaktadır; yani kaş cropunda deepfake ayırmasına katkı sağlayabilecek bilgi mevcuttur. Bununla birlikte sınıflar arasındaki skor örtüşmesi, yüksek false-positive/false-negative oranları ve validation-test performans düşüşü mevcut temsili yeterince genellenebilir olmadığını göstermektedir.

Bu nedenle deneyin en doğru konumu **başarılı bir baseline / referans deney** olarak değerlendirilmesidir. Bir sonraki adım, aynı splitleri koruyarak daha güçlü feature extractor'lar, kaş bölgesine özgü fine-tuning, texture/deep feature fusion ve video-level değerlendirme ile performansın sistematik biçimde artırılmasıdır.

Ek A. Deney Konfigürasyonu Özeti

Parametre	Değer
Bölge	Kaş (eyebrow)
Feature extractor	VGG16 - ImageNet pretrained
include_top	False

Pooling	Global Average Pooling
Feature dimension	512
Classifier	SVM
Final kernel	RBF
C	1.0
Gamma	0.001
Class weight	balanced
Train frame	1562
Validation frame	204
Test frame	196
Final SVM fit süresi	3.519 saniye
Video-level metric	Üretilmedi

Rapor kapsamı: Bu rapor yalnızca ilgili deney klasöründe üretilen run_summary, metrics, SVM validation search, test predictions ve üç değerlendirme görselindeki sonuçlar üzerinden hazırlanmıştır.