

KAŞ BÖLGESİ ÜZERİNDEN DEEPPFAKE TESPİTİ

Deney 1 - Sonuç ve Değerlendirme Raporu

VGG16 (sıfırdan eğitim) + HOG + GIST + RBF SVM

Deney klasörü

Nazlıcan / Deney 1

Run ID

20260806_1540_eyebrow_vgg16scratch_hog_gist_svm_seed42

Tamamlanma durumu

COMPLETED

Rapor tarihi

6 Ağustos 2026

Bu rapor, tamamlanan deney çıktıları ve üretilen grafikler temel alınarak hazırlanmıştır.

1. Yönetici Özeti

Bu deneyde kaş bölgesine kırılmış gerçek ve sahte framerler kullanılarak, önceden eğitilmiş ağırlık olmadan VGG16 mimarisi eğitilmiş; ardından VGG16 tarafından öğrenilen derin özellikler HOG ve GIST tabanlı doku/şekil özellikleriyle birleştirilmiş ve RBF çekirdekli SVM ile sınıflandırılmıştır.

Temel sonuç

Nihai model frame seviyesinde %53,06 doğruluk ve %54,50 ROC-AUC; video seviyesinde ise %52,17 doğruluk ve %54,58 ROC-AUC elde etmiştir. Bu değerler, modelin gerçek ve sahte kaş görüntülerini güvenilir biçimde ayıramadığını ve rastgele tahmin seviyesinin yalnızca biraz üzerinde kaldığını göstermektedir.


Buna karşın deney altyapısı açısından önemli bir olumlu bulgu vardır: train, validation ve test kümeleri arasında kaynak video kesişimi sıfırdır. Bu nedenle düşük performansın veri sızıntısından kaynaklanmadığı; daha çok veri miktarı, kaş ROI kalitesi, sıfırdan eğitilen büyük modelin veri ihtiyacı ve özelliklerin ayırt ediciliğiyle ilişkili olduğu değerlendirilmektedir.

2. Deney Tasarımı ve Kullanılan Yöntem

2.1 Veri ve bölme yapısı

Toplam giriş: 3.000 frame. **Başarıyla işlenen:** 1.962 frame. **Atlanan:** 1.038 frame. **Hata:** 0.

Başarıyla elde edilen kaş görüntüleri train, validation ve test kümelerine sınıf dengesi korunacak şekilde dağıtılmıştır. Train kümesinde 776 sahte ve 786 gerçek; validation kümesinde 98 sahte ve 106 gerçek; test kümesinde 95 sahte ve 101 gerçek örnek bulunmaktadır.



Şekil 1. Başarıyla işlenen kaş örneklerinin veri bölümü ve sınıfa göre dağılımı.

Veri sızıntısı kontrolü


Train-validation, train-test ve validation-test kümeleri arasındaki kaynak video kesişimleri 0 olarak doğrulanmıştır. Bu, sonuçların aynı videonun farklı framelelerinin farklı kümelere dağılmasından kaynaklanan yapay bir başarı içermediğini gösterir.

2.2 Model akışı

1. VGG16 mimarisi weights=None ile rastgele ağırlıklardan başlatılmış ve kaş görüntüleri üzerinde sıfırdan eğitilmiştir.
2. Her kaş görüntüsünden HOG ile kenar/yön bilgisi, GIST tarzı Gabor filtreleriyle genel doku bilgisi çıkarılmıştır.
3. Eğitilen VGG16 modelinin 512 boyutlu derin özellikleri alınmıştır.
4. HOG, GIST ve VGG16 özellikleri ayrı ayrı ölçeklenmiş, birleştirilmiş ve PCA ile indirgenmiştir.
5. RBF SVM için C, gamma ve karar eşiği validation kümesinde seçilmiş; test kümesi yalnız nihai değerlendirmede kullanılmıştır.


3. VGG16 Eğitim Davranışı

VGG16 eğitimi 9 epoch sonunda erken durdurma ile tamamlanmıştır. Eğitim süresi yaklaşık 165 saniyedir. Loss değerleri boyunca 0,693 civarında kalmış; eğitim ve validation doğrulukları ise çoğunlukla %48-%54 aralığında seyretnmiştir.



Şekil 2. VGG16 eğitim ve validation loss eğrileri.

İkili sınıflandırmada yaklaşık 0,693 loss, modelin tahminlerinin rastgele seviyeye yakın olduğunu gösteren önemli bir işarettir. Eğitim loss değerindeki düşüş çok sınırlı kaldığından, VGG16 kaş bölgesinden güçlü ve kararlı bir temsil öğrenememiştir.



Şekil 3. VGG16 eğitim ve validation doğruluk eğrileri.

Doğruluk eğrilerindeki dalgalanma ve düşük seviye, modelin bazı epochlarda tek bir sınıfa yönelme eğilimi gösterdiğini düşündürmektedir. Bu durum, sıfırdan eğitilen büyük bir ağ için 1.562 eğitim örneğinin ve mevcut görsel çeşitliliğinin yetersiz kalmış olabileceğini desteklemektedir.

4. Nihai SVM Sonuçları


Validation aşamasında seçilen SVM parametreleri $C=1,0$ ve $\gamma=0,0001$; karar eşiği ise $-0,2699$ olarak belirlenmiştir. Aşağıdaki tablo, test kümesindeki frame ve video seviyeli performansı özetlemektedir.

Metrik	Frame seviyesi	Video seviyesi	Kısa yorum
Accuracy	%53.06	%52.17	Genel doğruluk; rastgele seviyenin yalnızca biraz üzerinde.
Precision	%51.38	%59.74	Sahte denilen örneklerin ne kadarının gerçekten sahte olduğu.
Recall	%58.95	%56.79	Gerçek sahte örneklerin ne kadarının yakalandığı.
F1-score	%54.90	%58.23	Precision ve recall arasındaki dengeli özet.
Specificity	%47.52	%45.61	Gerçek örnekleri doğru

Metrik	Frame seviyesi	Video seviyesi	Kısa yorum
			tanıma oranı.
ROC-AUC	%54.50	%54.58	Sınıfları ayırma gücü; 0.50 rastgele seviyeyi temsil eder.
Average Precision	%55.35	%65.59	Özellikle sahte sınıf için sıralama kalitesinin özeti.


Sonuçların anlamı

Frame seviyesinde %53,06 accuracy ve %54,50 ROC-AUC, gerçek ve sahte sınıflar arasında sınırlı bir ayrım bulunduğunu gösterir. Video seviyesinde F1 puanı %58,23'e çıksa da accuracy ve ROC-AUC değerleri anlamlı biçimde iyileşmemiştir.



Şekil 4. Frame seviyesinde test confusion matrix.

Confusion matrix incelendiğinde 101 gerçek frameden 48'i doğru biçimde gerçek, 53'ü yanlış biçimde sahte olarak sınıflandırılmıştır. 95 sahte frameden 56'sı doğru şekilde sahte olarak bulunmuş, 39'u gerçek olarak kaçırılmıştır. Model sahte örnekleri yakalamada gerçek örnekleri tanımaya göre biraz daha başarılıdır; ancak her iki sınıfta da hata oranı yüksektir.



Şekil 5. Frame seviyesinde test ROC eğrisi.

ROC eğrisinin rastgele sınıflandırmayı temsil eden köşegen çizgiye yakın ilerlemesi ve AUC değerinin 0,545 olması, model skorlarının iki sınıfı güvenilir biçimde sıralayamadığını doğrulamaktadır.

5. Bulguların Değerlendirilmesi

- **Deney yapısı güvenilir:** Kaynak video bazlı ayırım uygulanmış ve kümeler arası kesişim sıfırdır. Düşük başarı, veri sızıntısı olmayan daha gerçekçi bir ölçümdür.
- **Sıfırdan VGG16 yeterince öğrenemedi:** Loss ve accuracy eğrileri VGG16'nın güçlü bir temsil geliştiremediğini göstermektedir.
- **Özellik füzyonu belirgin kazanç üretmedi:** HOG, GIST ve VGG16 özellikleri birleştirilmesine rağmen nihai ROC-AUC yaklaşık %54,5 seviyesinde kalmıştır.
- **Video birleştirme sınırlı fayda sağladı:** Video seviyesinde F1 yükselmiş, ancak genel doğruluk ve ayırma gücü belirgin biçimde artmamıştır.
- **ROI kaybı yüksek:** 3.000 girdinin 1.038'i atlanmıştır. Yaklaşık %34,6'lık kayıp hem veri miktarını hem de çeşitliliği azaltmıştır.

6. Önerilen Sonraki Adımlar

6. Ablation deneyleri yapılmalı: HOG+SVM, GIST+SVM, VGG16+SVM ve ikili özellik birleşimleri ayrı ayrı çalıştırılmalıdır.
7. VGG16 yerine daha küçük ve sıfırdan eğitime uygun bir CNN baseline denenmelidir; böylece veri miktarına daha uygun kapasite kullanılabilir.
8. Kaş çıkarma pipeline'ında atlanan örneklerin nedenleri incelenmeli ve ROI başarısı artırılmalıdır.

9. Daha fazla kaynak video ve daha çeşitli kaş örneği eklenmelidir; ardışık ve çok benzer framelerin oranı azaltılmalıdır.
10. Mevcut deney korunarak, karşılaştırma amacıyla önceden eğitilmiş bir modelle ayrı bir transfer learning deneyi yürütülebilir.
11. SVM özellik füzyonunda PCA boyutu, özellik blok ağırlıkları ve linear/RBF çekirdekleri sistematik biçimde karşılaştırılmalıdır.

Genel sonuç

Bu deney, kaş bölgesinden deepfake tespiti için HOG, GIST ve sıfırdan eğitilmiş VGG16 özelliklerinin birleşiminin mevcut veri ve ayarlar altında yeterli olmadığını göstermiştir. Model performansı düşük olsa da deney; veri sızıntısının önlenmesi, kayıtların tutulması, checkpoint ve test çıktılarının üretilmesi bakımından geçerli bir baseline sunmaktadır.

7. Kullanılan Deney Çıktıları ve Yorumları

Rapor yalnızca nihai metriklere değil, deney sırasında üretilen veri, eğitim ve değerlendirme çıktılarına birlikte dayanır. Aşağıdaki dosyalar modelin nasıl davrandığını, sonuçların neden düşük kaldığını ve deneyin tekrar üretilebilir olup olmadığını gösteren temel kanıtlardır.

7.1 Performansın yorumlanmasında kullanılan temel çıktılar

Deney çıktısı	İçeriği ve bu deneydeki yorumu
run_summary.json	Deneyin tek özet kayıdır. Çalışmanın COMPLETED durumunda bittiğini; 3.000 girdiden 1.962 kaş görüntüsünün kullanılabildiğini, 1.038 örneğin atlandığını ve kaynak video kesişimlerinin 0 olduğunu doğrular. Ayrıca seçilen SVM ayarlarını (C=1, gamma=0,0001, eşik=-0,2699) ve nihai frame/video metriklerini içerir. Bu dosya, rapordaki sayısal sonuçların ana doğruluk kaynağıdır.
training_history.csv	Dokuz epoch boyunca train ve validation loss, accuracy, precision, recall, F1, specificity ve ROC-AUC değerlerini kaydeder. Train loss 0,6937'den yalnızca 0,6921'e, train accuracy ise %50,32'den %53,27'ye çıkmıştır. Validation accuracy %47,06-%54,41 arasında dalgalanmıştır. Bazı epochlarda recall=%100 ve specificity=%0; bazı epochlarda ise recall=%0 ve specificity=%100 görülmesi, modelin dönem dönem bütün örnekleri tek sınıfa atadığını ve kararlı bir temsil öğrenemediğini gösterir.
dataset_distribution.png	Train kümesinde 776 sahte ve 786 gerçek, validation kümesinde 98 sahte ve 106 gerçek, test kümesinde 95 sahte ve 101 gerçek örnek bulunduğunu görselleştirir. Sınıflar birbirine yakın sayıda olduğu için düşük başarının temel nedeni ciddi bir sınıf dengesizliği değildir. Bununla birlikte 3.000 girdinin yaklaşık %34,6'sının ROI aşamasında kaybedilmesi, eğitim çeşitliliğini azaltmıştır.
cnn_loss_curve.png	VGG16'nın train ve validation kayıp değerlerini epoch bazında gösterir. Her iki eğri de yaklaşık 0,69 çevresinde kalmış ve düzenli bir düşüş göstermemiştir. Train ve validation eğrilerinin birbirine yakın ama yüksek seviyede bulunması, klasik aşırı öğrenmeden çok underfitting durumuna; yani modelin eğitim verisini bile yeterince öğrenememesine işaret eder.

Deney çıktısı	İçeriği ve bu deneydeki yorumu
cnn_accuracy_curve.png	Train ve validation doğruluklarının çoğunlukla %50 çevresinde hareket ettiğini gösterir. Eğrilerde kalıcı ve düzenli bir yükseliş yoktur; validation doğruluğundaki ani değişimler modelin sınıflar arasında dengesiz karar verdiğini destekler. Bu grafik, sıfırdan VGG16 için mevcut veri miktarı ve çeşitliliğinin yetersiz kaldığı yorumunu güçlendirir.
test_confusion_matrix_frame_level.png	Testte 101 gerçek frameden 48'i doğru gerçek, 53'ü yanlış sahte; 95 sahte frameden 56'sı doğru sahte, 39'u yanlış gerçek olarak sınıflandırılmıştır. Model sahte örnekleri yakalamada (%58,95 recall), gerçek örnekleri doğru tanımayla (%47,52 specificity) göre biraz daha başarılıdır; ancak iki sınıfta da hata sayısı yüksektir.
test_roc_curve_frame_level.png	Modelin farklı eşiklerde gerçek ve sahte sınıfları ayırma gücünü gösterir. Eğrinin rastgele sınıflandırma çizgisine yakın kalması ve ROC-AUC değerinin 0,545 olması, SVM karar skorlarının sınıfları güvenilir biçimde sıralayamadığını gösterir. Bu nedenle %53,06 accuracy tek başına başarı olarak yorumlanmamalıdır.

7.2 Ek değerlendirme ve tekrar üretilebilirlik çıktıları

Destekleyici çıktı	Ne sağlar?
Video-level confusion matrix, ROC ve precision-recall grafikleri	Frame skorlarının kaynak video düzeyinde ortalanmasından sonraki performansı gösterir. Video F1 değeri %58,23'e yükselse de accuracy %52,17 ve ROC-AUC %54,58'de kalmıştır. Yani birden fazla frame'i birleştirmek sınırlı fayda sağlamış, temel ayırma problemi çözülmemiştir.
test_decision_score_distribution.png	Gerçek ve sahte örneklerin SVM karar skorlarının dağılımını ve seçilen karar eşiğini gösterir. İki sınıfın skorlarının geniş ölçüde üst üste binmesi, tek bir eşikle temiz ayırım yapılamamasının görsel karşılığıdır.
test_predictions_frame_level.csv ve test_predictions_video_level.csv	Her örneğin gerçek etiketi, tahmin edilen etiketi, karar skoru ve doğru/yanlış bilgilerini içerir. Bir sonraki hata analizi aşamasında yanlış pozitif ve yanlış negatif örneklerin görüntü kalitesi, kaş tipi, sıkıştırma ve kaynak video özelliklerine göre incelenmesini mümkün kılar.
best.ckpt, last.ckpt ve epoch checkpointleri	Sıfırdan eğitilmiş VGG16'nın en iyi, son ve ara epoch durumlarını saklar. Model ağırlıklarının yanı sıra optimizer, scheduler, konfigürasyon ve rastgelelik durumlarını içerdiğinden eğitim kesintisinden devam etme ve modeli yeniden değerlendirme olanağı sağlar.
config_resolved.yaml, environment.json, requirements_lock.txt ve output_manifest.csv	Kullanılan hiperparametreleri, çalışma ortamını, paket sürümlerini ve üretilen dosyaların hash/manifest kayıtlarını saklar. Bu çıktılar performansı doğrudan artırmaz; ancak deneyin aynı koşullarda tekrar çalıştırılabilmesi ve sonuç dosyalarının bütünlüğünün doğrulanabilmesi için gereklidir.

Çıktıların birlikte gösterdiği sonuç

Düşük performans tek bir metrikten veya raporlama hatasından kaynaklanmamaktadır. Veri dağılımı dengeli ve split izolasyonu doğru olmasına rağmen eğitim eğrileri öğrenmenin zayıf kaldığını, confusion matrix yüksek hata oranlarını, ROC ve skor dağılımları ise sınıfların karar uzayında yeterince ayrılmadığını tutarlı biçimde göstermektedir. Bu nedenle deney, güvenilir biçimde kaydedilmiş ancak performans açısından zayıf bir baseline olarak değerlendirilmelidir.