

Xception ile Kaş Bölgesi Tabanlı Deepfake Tespiti

Detaylı Eğitim, Test ve Görsel Sonuç Analiz Raporu

Deney Kimliği: 20260807_123945_xception_eyebrow

Model: ImageNet ön-eğitilmiş Xception | Bölge: Eyebrow ROI | Sınıflar: REAL / FAKE

Rapor, deney klasöründe üretilen metrikler, eğitim geçmişleri, tahmin dosyası ve figürler temel alınarak hazırlanmıştır.

1. Yönetici Özeti

Ana bulgu: Fine-tuning validation performansını artırmış olsa da modelin test setindeki ayrıştırma gücü zayıf kalmıştır. Test ROC-AUC değeri 0.551 ve accuracy değeri 0.515 olduğundan model, bağımsız test verisinde rastgele sınıflandırıcının yalnızca sınırlı ölçüde üzerindedir.

- Test Accuracy: 0.515 (%51.5)
- Test ROC-AUC: 0.551
- FAKE Recall/Sensitivity: 0.632 (%63.2)
- REAL Specificity: 0.406 (%40.6)
- FAKE F1-score: 0.558
- Validation AUC: frozen aşamada 0.614, fine-tuning sonrasında 0.671
- Fine-tuning, validation AUC açısından doğru yönde etki etmiş; ancak eğitim ve validation eğrileri arasındaki açılma, overfitting işareti göstermiştir.
- Sonuç, “kaş bölgesi deepfake tespiti için kullanılamaz” anlamına gelmez. Mevcut Xception + ROI + veri bölme/eğitim düzeninin test genellemesi yetersizdir.

2. Deney Tasarımı ve Kullanılan Model

Model yaklaşımı: ImageNet üzerinde önceden eğitilmiş Xception backbone kullanılmış, önce backbone dondurularak transfer learning yapılmış, ardından son katmanların bir bölümü açılarak düşük öğrenme oranıyla fine-tuning uygulanmıştır.

Metrik	Değer	Yorum
Backbone	Xception	ImageNet ön-eğitimli görsel özelliklerden yararlanılmıştır.
Girdi	224 x 224 x 3	Yalnızca kaş ROI görüntüleri modele verilmiştir.
İlk eğitim	Backbone frozen	Önce sınıflandırıcı başlığı eğitilmiştir.
Fine-tuning	Son 30 katman hedeflenmiş; 21 Xception katmanı trainable	Kaş bölgesine daha özgü yüksek seviye özelliklerin öğrenilmesi amaçlanmıştır.
Optimizer	Adam	İlk LR=1e-4, fine-tune LR=1e-5.
Loss	Binary Cross-Entropy	REAL=0, FAKE=1 ikili sınıflandırması.
Classifier head	GlobalAveragePooling + Dense(256, ReLU) + Dropout + Sigmoid	Backbone özelliklerini REAL/FAKE kararına dönüştürür.

Augmentation: Kaş bölgesindeki ince doku ve kıl yapısını aşırı bozmamak için kontrollü augmentation kullanılmıştır: horizontal flip kapalı, rotation factor 0.015, zoom ± 0.03 , contrast 0.03; blur ve random erasing uygulanmamıştır. Validation ve test verisine augmentation uygulanmamıştır.


3. Veri Seti Dağılımı

Metrik	Değer	Yorum
Train	1562	FAKE=776, REAL=786
Validation	204	FAKE=98, REAL=106
Test	196	FAKE=95, REAL=101
Toplam ROI	1962	Başarıyla üretilmiş kaş ROI görüntüleri

Sınıf dağılımı train, validation ve test setlerinde oldukça dengeli olduğu için test accuracy değerinin düşük olması sınıf dengesizliği ile açıklanamaz. Bu önemli bir bulgudur: problem daha çok modelin ayrıştırıcı özellikleri genelleştirememesi veya veri dağılımları arasındaki farkla ilişkilidir.

4. Aşama 1 - Frozen Xception Analizi


Eğitim özeti: 15 epoch planlanmış, EarlyStopping nedeniyle 7 epoch tamamlanmıştır. En iyi validation AUC 0.614 ve bu değer 3. epochta elde edilmiştir. En iyi validation accuracy 0.598 olmuştur.



Şekil 1. Frozen Xception eğitim ve validation accuracy eğrileri.


Şekil 1 yorumu: Training accuracy epochlar boyunca yaklaşık 0.52'den 0.64'e yükselirken validation accuracy 0.54-0.60 bandında dalgalanmıştır. Eğitim performansının düzenli artmasına karşı validation tarafının plato yapması, backbone dondurulmuş halde bile modelin training örneklerine

giderek daha fazla uyum sağladığını ancak bunun validation genellemesine sınırlı yansıdığını gösterir.



Şekil 2. Frozen Xception eğitim ve validation AUC eğrileri.

Şekil 2 yorumu: Training AUC 0.538'den yaklaşık 0.695'e sürekli yükselirken validation AUC yaklaşık 0.60-0.614 civarında kalmıştır. En iyi validation AUC 3. epochta görülmüş, sonraki epochlar training AUC'yi artırmasına rağmen validation AUC'yi artırmamıştır. Bu, erken aşamada başlayan genelleme açığının güçlü bir göstergesidir.




Şekil 3. Frozen Xception training ve validation loss eğrileri.

Şekil 3 yorumu: Training loss düzenli olarak 0.706'dan 0.632'ye düşerken validation loss yaklaşık 0.678-0.689 aralığında sabit kalmıştır. Training loss azalırken validation loss'un iyileşmemesi, modelin öğrendiği ayrımın validation verisinde aynı ölçüde karşılık bulmadığını doğrular.


5. Aşama 2 - Fine-Tuning Analizi

Fine-tuning özeti: Xception'ın son 30 katmanı hedeflenmiş ve 21 katman trainable hale gelmiştir. 10 epoch tamamlanmıştır. En iyi validation AUC 0.671 ile 9. epochta elde edilmiştir; en iyi validation accuracy 0.627 değerine çıkmıştır.




Şekil 4. Fine-tuning sırasında training ve validation accuracy.

Şekil 4 yorumu: Fine-tuning training accuracy'yi yaklaşık 0.60'dan 0.80'e taşımıştır. Buna karşılık validation accuracy yaklaşık 0.61-0.63 bandında kalmıştır. 10. epochta training accuracy 0.795 iken validation accuracy 0.618'dir; yaklaşık 0.177 puanlık fark belirgin overfitting göstermektedir.



Şekil 5. Fine-tuning sırasında training ve validation AUC.


Şekil 5 yorumu: Training AUC çok güçlü şekilde artarak 0.873'e kadar çıkmıştır. Validation AUC ise yalnızca 0.671 civarına kadar yükselmiştir. 9. epochta training AUC yaklaşık 0.859, validation AUC 0.671'dir; aradaki yaklaşık 0.189 puanlık fark modelin training örneklerini iyi ayırmayı öğrendiğini ancak bu ayrımın yeni örneklerle yeterince taşınmadığını gösterir.



Şekil 6. Fine-tuning sırasında training ve validation loss.

Şekil 6 yorumu: Training loss 0.662'den 0.459'a kadar düzenli düşmüştür. Validation loss ise 0.65-0.68 bandında kalmış ve son epochlarda tekrar yükselmiştir. Bu desen klasik overfitting görünümüdür: model training setinde daha emin hale gelirken validation tahminlerinin kalitesi aynı hızda iyileşmemektedir.

6. Frozen ve Fine-Tuned Model Karşılaştırması



Şekil 7. Frozen ve fine-tuned Xception'ın en iyi validation sonuçlarının karşılaştırılması.


Fine-tuning faydalı mıydı? Evet, validation açısından faydalıydı. AUC 0.614 → 0.671 (+0.057) yükselmiştir. Validation accuracy de yaklaşık 0.598 → 0.627 yükselmiştir. Bu nedenle model seçiminde fine-tuned checkpoint'ın tercih edilmesi metodolojik olarak doğrudur.

Ancak bu artışın test setinde doğrulanmaması çok önemlidir. Validation AUC 0.671 iken test AUC 0.551'e düşmüştür. Yaklaşık 0.119 puanlık bu düşüş, validation performansının gerçek genelleme başarısını olduğundan iyimser göstermiş olabileceğini düşündürür.

7. Final Test Performansı

Metrik	Değer	Yorum
Accuracy	0.515	196 test örneğinin yaklaşık yarısı doğru sınıflandırılmıştır.
Balanced Accuracy	0.519	Sınıflar dengeli ele alındığında sonuç yine yaklaşık şans seviyesindedir.
Precision - FAKE	0.500	FAKE denilen örneklerin yarısı gerçekten FAKE'tir.
Recall/Sensitivity - FAKE	0.632	Gerçek FAKE örneklerin


		%63.2'si yakalanmıştır.
Specificity - REAL	0.406	Gerçek REAL örneklerin yalnızca %40.6'sı doğru REAL bulunmuştur.
F1 - FAKE	0.558	FAKE precision ve recall dengesi düşük-orta seviyededir.
ROC-AUC	0.551	Sınıfları olasılık sıralamasıyla ayırma gücü rastgeleye yakındır.
FPR	0.594	REAL örneklerin %59.4'ü yanlışlıkla FAKE denmiştir.
FNR	0.368	FAKE örneklerin %36.8'i kaçırılmıştır.



Şekil 8. Final test metriklerinin toplu görünümü.

Şekil 8 yorumu: En yüksek metrik FAKE recall (0.632) iken en düşük metrik specificity (0.406)'dir. Bu kombinasyon modelin FAKE sınıfına doğru eğilim gösterdiğini düşündürür. Nitekim 196 örneğin 95'i gerçekten FAKE olmasına rağmen model 120 örneği FAKE olarak tahmin etmiştir.

8. Confusion Matrix ve Hata Profili




Şekil 9. Final test confusion matrix.

Confusion matrix: 41 True Negative, 60 False Positive, 35 False Negative ve 60 True Positive elde edilmiştir.

- 101 REAL örneğin yalnızca 41'i doğru REAL; 60'ı yanlış FAKE olarak sınıflandırılmıştır.
- 95 FAKE örneğin 60'ı doğru FAKE; 35'i yanlış REAL olarak sınıflandırılmıştır.
- Modelin FAKE sınıfına eğilimi nedeniyle sensitivity, specificity'den belirgin biçimde yüksektir.
- Toplam 95 hata ve 101 doğru tahmin vardır; hata sayısının doğru sayısına çok yakın olması modelin testte kararsız olduğunu gösterir.

9. ROC Eğrisi ve Ayırma Gücü



Şekil 10. Final test ROC eğrisi.

ROC eğrisi büyük ölçüde rastgele sınıflandırıcıyı temsil eden diyagonal çizgiye yakın seyretmektedir. AUC=0.551 değeri, rastgele seçilmiş bir FAKE örneğe rastgele seçilmiş bir REAL örnekten daha yüksek FAKE skoru verme olasılığının yalnızca yaklaşık %55 olduğunu ifade eder. Bu nedenle mevcut test setinde kaş ROI + Xception skoru güçlü bir sıralama sinyali üretmemektedir.

10. Tahmin Olasılıklarının Ayrıntılı İncelenmesi

Olasılık dağılımı: REAL örneklerin ortalama FAKE olasılığı 0.555, FAKE örneklerin ortalama FAKE olasılığı 0.595 olmuştur. Aradaki fark yalnızca 0.040 puandır. Bu küçük fark, iki sınıfın model skorlarında ciddi biçimde üst üste bindiğini açıklar.

- Model test örneklerinin %61.2'ini FAKE tahmin etmiştir; gerçek FAKE oranı ise %48.5'dir.
- Yanlış tahminlerin 25 tanesi %80 veya daha yüksek model güveniyle yapılmıştır. Bunların 17 tanesi gerçek REAL, 8 tanesi gerçek FAKE'tir.

- Yüksek güvenli yanlışlar, yalnızca 0.5 karar eşiğinin kötü seçildiği bir problemde daha fazlasına işaret eder; model bazı örneklerde yanlış görsel ipuçlarını güçlü biçimde öğrenmiş olabilir.

11. İstatistiksel Belirsizlik ve Sonucun Güvenilirliği

Test seti 196 örnekten oluşmaktadır. Bu büyüklükte tek bir test koşusunda metriklerin belirsizliği göz ardı edilmemelidir. Hesaplanan yaklaşık %95 Wilson güven aralığı accuracy için 0.446-0.584'tür. Test tahminlerinden bootstrap ile elde edilen yaklaşık %95 ROC-AUC aralığı 0.471-0.632'dir. Bu aralık 0.50 şans seviyesini içerdiği için, mevcut test seti üzerinde modelin rastgele sınıflandırıcıdan istatistiksel olarak açık ve güçlü biçimde üstün olduğu söylenemez.

Bu bölüm ek bir istatistiksel analizdir; deney klasöründeki ham tahminler kullanılarak rapor hazırlanırken hesaplanmıştır. Final deney metriği olarak yine kaydedilmiş 0.5 eşikli sonuçlar esas alınmıştır.

12. Sonuçların Düşük Kalmasının Olası Nedenleri

Kaş ROI bilgisinin sınırlı olması: Deepfake artefaktları her üretim yönteminde kaş çevresinde aynı yoğunlukta bulunmayabilir. Sadece küçük bir yüz bölgesine odaklanmak, yüzün diğer bölgelerindeki daha güçlü tutarsızlıkları dışarıda bırakır.

Fine-tuning overfitting: Training AUC'nin 0.87'ye yaklaşırken validation AUC'nin 0.67 civarında kalması, model kapasitesinin veri miktarına göre yüksek kaldığını düşündürür.

ROI kalite varyasyonu: Kaş kırpmalarında poz, ölçek, kısmi kaş, saç/göz/deri karışımı veya düşük çözünürlük gibi değişimler varsa model kaş artefaktı yerine crop kalitesini öğrenebilir.

Domain / split farkı: Validation AUC 0.671'den testte 0.551'e düşmüştür. Bu, test görüntülerinin video, kişi, manipülasyon veya kalite dağılımının validation'dan farklı olabileceğini düşündürür.

Frame korelasyonu: Eğer aynı videodan gelen çok benzer frame'ler farklı splitlere girebiliyorsa validation tahmini iyimser olabilir. Deneylerde video-bazlı split kullanılması kritik önemdedir.

ImageNet feature uyumsuzluğu: ImageNet ön-eğitimi genel görsel özellikler için faydalıdır; ancak deepfake'e özgü yüksek frekanslı veya sıkıştırma tabanlı izler doğrudan ImageNet hedefi değildir.

Tek eşik kullanımı: 0.5 standart bir başlangıçtır fakat sınıf maliyetleri ve validation davranışına göre eşik önceden validation setinde belirlenebilir. Eşik test setinde optimize etmek metodolojik olarak doğru değildir.

13. Bir Sonraki Deney İçin Önerilen İyileştirmeler

1. Veri bölmesini kesinlikle video-bazlı ve mümkünse kişi-bazlı bağımsızlık kontrolüyle doğrula. Aynı kaynaktan çok benzer framelerin train/val/test arasında dağılmasını engelle.
2. ROI kalite kontrolü yap: düşük çözünürlüklü, boş/eksik kaş, yanlış crop ve aşırı arka plan içeren görüntüleri otomatik kalite filtresinden geçir.
3. Xception fine-tuning kapasitesini azaltarak dene: örneğin son 10-15 katman, daha güçlü weight decay veya daha yüksek dropout. Mevcut eğriler overfitting gösteriyor.
4. Validation AUC odaklı EarlyStopping'i fine-tuning aşamasında daha sıkı kullan; 9. epoch sonrası gelişme olmadığı için daha uzun eğitim gerekli görünmüyor.
5. Kaş ROI için ConvNeXt-Tiny, EfficientNetV2-S/B0, ResNet50 veya Swin-Tiny gibi alternatif pretrained backbone'larla aynı split üzerinde karşılaştırmalı deney yap.
6. Deep feature + hand-crafted texture fusion dene: LBP, GLCM, Gabor veya wavelet gibi kaş dokusuna duyarlı özellikler deep feature'larla birleştirilebilir.
7. Tek frame yerine video-level aggregation uygula. Aynı videodan birden fazla kaş frame skorunu ortalama/median veya temporal model ile birleştirmek gürültüyü azaltabilir.
8. Karar eşiğini test setine bakmadan yalnızca validation setinde seç ve daha sonra sabit eşikle test setine uygula.
9. Mümkünse manipülasyon yöntemi bazında sonuç üret: hangi deepfake türlerinde kaş bölgesi sinyal taşıyor, hangilerinde taşıyor ayrı görülebilir.
10. Grad-CAM/attention haritası ekle. Modelin gerçekten kaş kılları/deri sınırı gibi ilgili bölgeye mi yoksa crop kenarı/arka plan gibi yanlış ipuçlarına mı baktığı incelenmeli.

14. Bilimsel Olarak Nasıl Yazılmalı?

Uygun yorum: “ImageNet ön-eğitilmiş Xception modelinin kaş ROI üzerinde transfer learning ve fine-tuning ile eğitilmesi validation performansını artırmış; ancak bağımsız test setinde ROC-AUC 0.551 ve accuracy 0.515 seviyesinde kalmıştır. Fine-tuning sırasında training-validation performans farkının giderek açılması overfitting eğilimine işaret etmektedir. Bu sonuçlar, mevcut veri ve eğitim protokolünde yalnızca kaş ROI bilgisinin Xception için yeterince kararlı bir deepfake ayırım sinyali oluşturmadığını göstermektedir.”

Kaçınılması gereken yorum: “Kaş bölgesi deepfake tespitinde işe yaramaz.” Bu deney tek model, tek veri hazırlama protokolü ve tek test koşulunu değerlendirir; bölgenin genel olarak faydasız olduğunu kanıtlamaz.

15. Çıktı Dosyaları ve Teknik Tutarlılık Notları

- Fine-tuned checkpoint validation AUC temelinde doğru şekilde seçilmiş ve final model olarak kaydedilmiştir.
- Test metrikleri JSON, CSV, classification report, prediction CSV ve figürlerle birbirini tutarlı biçimde desteklemektedir.

- run_summary.json içinde model_selection altındaki frozen_best_val_auc ve finetuned_best_val_auc alanları null görünmektedir; ancak model_selection_and_test_summary.json ve eğitim özetlerinde gerçek değerler (0.614 ve 0.671) mevcuttur. Bu yalnızca raporlama/serialization seviyesinde küçük bir tutarsızlıktır; model seçim sonucunu değiştirmemektedir.
- Test threshold 0.5 olarak sabittir. Bu raporda test seti üzerinde alternatif threshold seçilmemiştir; test setini tuning amacıyla kullanmamak gerekir.

16. Sonuç

Genel değerlendirme: Deney teknik olarak başarıyla tamamlanmış, pretrained Xception ile transfer learning ve fine-tuning akışı doğru biçimde uygulanmış ve fine-tuning validation performansını iyileştirmiştir. Buna rağmen final test sonuçları güçlü bir deepfake dedektörü seviyesinde değildir. En belirgin problem, training performansının hızla yükselmesine rağmen validation performansının plato yapması ve test AUC'nin 0.551'e gerilemesidir. Model FAKE sınıfına eğilim göstermekte, özellikle REAL örneklerde yüksek false-positive oranı üretmektedir. Bu nedenle mevcut model nihai bir dedektör olarak kullanılmamalı; ancak kaç ROI deneyleri için değerli bir baseline ve sonraki model/feature/split karşılaştırmaları için güçlü bir referans noktasıdır.

Ek A - Kritik Sayılar

Metrik	Değer	Yorum
Toplam ROI	1962	Train 1562 / Val 204 / Test 196
Frozen best val AUC	0.6137	Epoch 3
Fine-tuned best val AUC	0.6707	Epoch 9
Test Accuracy	0.5153	101/196 doğru
Test ROC-AUC	0.5513	Rastgeleye yakın ayırım
TP / TN / FP / FN	60 / 41 / 60 / 35	FAKE yönlü tahmin eğilimi
Predicted FAKE	120 / 196	%61.2
Actual FAKE	95 / 196	%48.5