

EFFICIENTNET-B0

GÖZ ROI DEEPPFAKE TESPİTİ

Deney Sonuç ve Değerlendirme Raporu

TEST ROC-AUC	TEST F1	TEST RECALL
0.729	0.721	91.03%

Deney Bilgisi	Değer
Run ID	20260808_0803_eye_efficientnet_b0_seed42
Model	torchvision EfficientNet-B0
Ön-eğitim	EfficientNet_B0_Weights.DEFAULT
Girdi	224x224 combined eye ROI
Seed	42
Çalışma cihazı	CPU
Validation threshold	0.22
Inference reload testi	PASSED

Kısa sonuç: Model test setinde yüksek fake yakalama oranına ulaştı; ancak specificity düşük kaldığı için gerçek örneklerin önemli bir bölümü fake olarak işaretlendi. ROC-AUC ve Average Precision değerleri modelin rastgele tahminden belirgin biçimde daha iyi ayrıştırma yaptığını gösteriyor.

1. Deney ve Veri Seti Özeti

Bu deney, iki gözün birlikte bulunduğu combined-eye ROI görüntülerinden real/fake ayrımı yapmak üzere ImageNet ön-eğitimli EfficientNet-B0 kullanılarak yürütüldü. Model iki aşamada eğitildi: önce feature extractor dondurularak yalnızca binary classifier eğitildi, ardından tüm ağ düşük learning rate ile fine-tune edildi.


Split	Fake	Real	Toplam
Train	1191	1197	2388
Validation	141	155	296
Test	156	146	302

Toplam kullanılabilir örnek: 2986 göz ROI örneği. Sınıflar splitler içinde birbirine yakın tutulmuş.

Run özeti, deneyin tamamlandığını ve inference reload kalite testinin PASSED olduğunu raporluyor; yani kaydedilen final checkpoint bağımsız olarak tekrar yüklenip olasılık üretebildi.

2. Eğitim Sürecinin Analizi

Fine-tuning boyunca train loss düzenli biçimde azalırken validation ROC-AUC genel olarak yükseldi. 1. epoch'ta validation ROC-AUC yaklaşık 0.623 iken 15. epoch'ta 0.713 seviyesine ulaştı. Learning rate 14. epoch'ta $2e-5$ 'ten $1e-5$ 'e düşürüldü.



Şekil 1. Training ve validation loss eğrileri.

- Train loss 0.7009'dan 0.4430'a kadar düştü.

- Validation loss yaklaşık 0.626-0.646 bandında plato yaptı; son epochlarda train-val farkının açılması hafif overfitting işareti olarak okunabilir.
- Validation ROC-AUC'nin son epochlarda 0.70 üzerini koruması, modelin ayrıştırma yeteneğinin öğrenme boyunca geliştiğini gösteriyor.

3. Validation Threshold Seçimi

Karar eşiği sabit 0.50 olarak bırakılmadı. Validation setinde yapılan tarama sonunda threshold 0.22 seçildi. Bu eşikte validation F1=0.678, recall=88.65%, specificity=33.55% ve ROC-AUC=0.713 elde edildi.

Threshold etkisi: 0.22 gibi düşük bir threshold, fake sınıfını kaçırmamayı önceliklendirir. Bu nedenle recall yükselirken real örneklerde false positive sayısı da artar.


4. Final Test Sonuçları

Metrik	Değer	Yorum
Accuracy	63.58%	Tüm test örneklerinde doğru sınıflandırma oranı.
Balanced Accuracy	62.64%	Real/fake sınıflarını dengeli ağırlıklandıran doğruluk.
Precision	59.66%	Fake tahminlerinin yaklaşık %59.7'si gerçekten fake.
Recall / Sensitivity	91.03%	Fake örneklerin yaklaşık %91.0'i yakalandı.
F1-score	0.721	Precision ve recall dengesinde güçlü sonuç.
Specificity	34.25%	Real örneklerin yaklaşık %34.2'si doğru real tanındı.
ROC-AUC	0.729	Threshold bağımsız ayrıştırma gücü.
Average Precision	0.743	PR eğrisi altında pozitif sınıf performansı.

En önemli bulgu: Modelin test recall değeri 91.03% ile oldukça yüksek. Buna karşılık specificity 34.25% seviyesinde kaldı. Yani model fake örnekleri kaçırmamaya güçlü biçimde eğilim gösterirken real örnekleri fake olarak işaretleme problemi devam ediyor.

4.1 Confusion Matrix Analizi


Gerçek durum	Tahmin sonucu	Adet
Real	Real (TN)	50
Real	Fake (FP)	96
Fake	Real (FN)	14
Fake	Fake (TP)	142



Şekil 2. Test confusion matrix.


Test setinde 156 fake örneğin 142 tanesi doğru yakalanmış, sadece 14 fake örnek real olarak kaçırılmıştır. Buna karşılık 146 real örneğin 96 tanesi false positive olarak fake sınıfına gitmiştir. Bu dağılım, modelin yüksek sensitivity - düşük specificity karakterini doğrudan göstermektedir.

5. ROC ve Precision-Recall Analizi



Şekil 3. Test ROC eğrisi.

ROC-AUC=0.729. Bu değer 0.5 rastgele ayırım seviyesinin belirgin üzerindedir; modelin real ve fake örnekleri olasılık skorları üzerinden orta düzeyde ayırabildiğini gösterir.



Şekil 4. Test Precision-Recall eğrisi.

Average Precision=0.743. Pozitif sınıf fake olarak tanımlandığı için bu değer, farklı recall seviyelerinde fake tespit precision performansını özetler.

6. Sonuçların Teknik Yorumu

- Modelin ana güçlü yönü fake örnekleri yakalamaktır: test recall 91.03%.
- F1-score 0.721 ve Average Precision 0.743; pozitif sınıf açısından kullanılabilir bir baseline üretildiğini gösteriyor.
- ROC-AUC 0.729; göz ROI'sinin deepfake sinyali taşıdığını, fakat ayrımın tek başına kusursuz olmadığını gösteriyor.
- Specificity 34.25%; real sınıfta yüksek false-positive problemi olduğunu ortaya koyuyor.
- Validation'da seçilen 0.22 threshold recall odaklı bir çalışma noktası yaratıyor. Uygulama senaryosu yanlış alarmı azaltmayı gerektiriyorsa threshold farklı bir hedefe göre yeniden seçilebilir.

6.1 Overfitting / Genelleme Gözlemi

Fine-tuning'in son bölümünde train loss azalmaya devam ederken validation loss daha yatay ve zaman zaman yükselen bir seyir gösteriyor. Bu durum hafif overfitting başlangıcıyla uyumludur. Buna rağmen validation ROC-AUC son epochta 0.713'e kadar çıktığı için modelin ranking/ayırıştırma gücü gelişmeye devam etmiştir.

7. Güçlü Yönler ve Sınırlılıklar

Güçlü Yön	Sınırlılık
Yüksek fake recall	Düşük real specificity
ROC-AUC 0.729 ile rastgele seviyeden belirgin iyi	False-positive sayısı 96
AP 0.743 ve F1 0.721	Accuracy tek başına yüksek değil
Validation'dan threshold seçimi	Threshold recall lehine agresif
Checkpoint reload testi PASSED	Sonuç yalnızca mevcut göz ROI veri dağılımında doğrulandı

8. Bir Sonraki Deney İçin Öneriler

- Threshold'u yalnızca F1 yerine balanced accuracy, Youden J veya belirli minimum specificity hedefiyle de karşılaştırmak.
- Real sınıftaki false positive örnekleri tek tek inceleyip ortak görüntü özelliklerini analiz etmek.
- Class-balanced loss / focal loss gibi yöntemleri deneyerek karar sınırını dengelemek.
- Göz ROI'ye ek olarak iris/pupil/reflection veya texture branch ile hibrit özellikleri kullanmak.
- Aynı split üzerinde Xception, SwinV2 ve klasik HOG/LBP/KAZE deneyleriyle ROC-AUC/F1/specificity kıyaslaması yapmak.
- Mümkünse video-level kimliği doğrulanmış metadata ile leakage kontrolünü video seviyesinde kesinleştirmek.

9. Arkadaşlara Kısa Anlatım

30 saniyelik özet: EfficientNet-B0 modelini göz ROI'lerinde real/fake ayrımı için transfer learning ile eğittik. Testte ROC-AUC 0.729, F1 0.721 ve recall 91.03% elde ettik. Model fake örnekleri çok iyi yakalıyor; fakat specificity 34.25% olduğu için real örneklerde fazla yanlış alarm veriyor. Yani bu deney güçlü bir recall odaklı baseline oluşturdu, fakat daha dengeli real/fake ayrımı için specificity tarafının geliştirilmesi gerekiyor.

10. Nihai Değerlendirme

Bu EfficientNet-B0 deneyi, combined-eye ROI yaklaşımının deepfake ayrımı için anlamlı sinyal taşıdığını göstermektedir. Test ROC-AUC 0.729 ve Average Precision 0.743 değerleri baseline düzeyinde olumlu bir ayrıştırma gücüne işaret eder. Bununla birlikte seçilen threshold altında model fake sınıfını önceliklendirdiği için gerçek örneklerde yüksek false-positive oranı oluşmuştur. Bu nedenle deney sonucu 'yüksek fake yakalama kabiliyeti, düşük real özgüllüğü' şeklinde özetlenmelidir.

Deney run'ı başarıyla tamamlanmış, 27 çıktı dosyası üretilmiş ve inference reload testi PASSED olarak raporlanmıştır.