

DEEPPFAKE DETECTION

Eye ROI - Swin V2 Tiny

Deney Sonuçları ve Performans Analiz Raporu

TEST ACCURACY

69.9%

302 test frame üzerinde

ROC-AUC

0.787

Sınıf ayırma kapasitesi

F1-SCORE

72.8%

Validation seçili threshold ile

PR-AUC

0.794

Precision-recall dengesi

Run ID

20260807_1031_eye_swinv2_tiny_seed42

Model

Swin V2 Tiny

Girdi Bölgesi

Combined Eye ROI

En İyi Epoch / Threshold

Epoch 8 / 0.275

Raporun odağı

Bu doküman kod tasarımımdan çok, çalıştırılmış deney klasöründeki gerçek eğitim geçmişini, test metriklerini, tahmin dosyalarını, audit çıktıları ve üretilmiş grafiklerini birlikte yorumlar. Sonuçlar yalnızca bu run çıktılarından türetilmiştir.

1

Yönetici Özeti

Deneyin tek sayfalık teknik özeti ve ana çıkarımlar

Swin V2 Tiny modeli, birleştirilmiş göz ROI görüntüleri üzerinde real/fake frame sınıflandırması için eğitilmiştir. Run toplam 2388 train, 296 validation ve 302 test frame kullanmıştır. En yüksek validation ROC-AUC 0.845 ile epoch 8 sırasında elde edilmiş; final test değerlendirmesi bu best checkpoint üzerinden yapılmıştır.

ACCURACY

0.699

Doğru sınıflandırma oranı

PRECISION

0.682

Fake tahminlerinin doğruluk payı

RECALL

0.782

Fake framelerin yakalanma oranı

F1

0.728

Precision-recall dengesi

En güçlü bulgu

Modelin test ROC-AUC değeri 0.787, PR-AUC değeri 0.794. Bu değerler modelin rastgele sınıflandırmadan belirgin biçimde daha iyi bir ayırım sinyali öğrendiğini, ancak tek başına göz ROI üzerinde hâlâ anlamlı hata payı bulunduğunu gösteriyor.

Karar eşiğinin etkisi

Validation F1 optimizasyonu ile seçilen threshold 0.275; standart 0.50'den daha düşük. Bu seçim fake sınıfı recall değerini 78.2% düzeyine çıkarırken real framelerde false-positive sayısını artırmıştır.

Kritik metodolojik sınır

video_identity_audit çıktısı, metadata içindeki video_id alanının gerçek kaynak video kimliği yerine label/split kovalarını temsil ettiğini bildiriyor. Bu nedenle run, per-original-video metriklerini bilinçli olarak devre dışı bırakmıştır. Rapor video-level başarı iddiasında bulunmaz.

2

Deney Tasarımı ve Model Konfigürasyonu

Final run içinde gerçekten kullanılan ayarlar

Parametre	Değer	Teknik anlam
Mimari	Swin V2 Tiny	ImageNet pretrained backbone + binary head
Girdi	Combined Eye ROI	224 x 224 RGB
Seed	42	Tekrar üretilebilirlik


Epoch bütçesi	20	Maksimum; early stopping daha önce durdurabilir
Early stopping	6	Validation ROC-AUC iyileşmezse 6 epoch bekleme
Backbone LR	1e-05	Pretrained katmanları düşük LR ile koruma
Head LR	1e-04	Yeni sınıflandırıcı başlığını daha hızlı uyarlama
Optimizer	AdamW	weight decay = 0.01
Scheduler	CosineAnnealingLR	LR eğitim boyunca kademeli düşürülür
Precision	FP32	mixed_precision = False
Gradient clip	1.0	Gradient patlamasına karşı güvenlik
Monitor	roc_auc	Best checkpoint seçimi

Model neden bu şekilde kurulmuştur? Swin V2 Tiny, görüntüyü sabit pencere blokları içinde attention ile işler ve shifted-window mekanizması sayesinde komşu pencereler arasında bilgi alışverişi kurar. Göz ROI gibi lokal fakat ince dokusal/şekil farklılıklarının önemli olduğu bir bölgede, CNN tabanlı klasik yerel filtrelere alternatif olarak çok-ölçekli dikkat temsili sağlar. Tiny sürümü, daha büyük Swin varyantlarına göre deney maliyetini sınırlayarak güçlü bir transformer baseline elde etmeyi amaçlar.

20 epoch değeri “modelin optimum epoch sayısı” olarak kabul edilmemiştir; yalnızca üst eğitim bütçesidir. Gerçek model seçimi validation ROC-AUC üzerinden best.ckpt ile yapılmıştır. Deney 14 epoch sonunda early stopping ile sonlanmış, en iyi checkpoint epoch 8 olarak kalmıştır.

3 Veri Dağılımı ve Girdi Kalitesi

Train/validation/test frame muhasebesi ve sayısal sanity kontrolü



Şekil 1. Run çıktılarından türetilen train/validation/test frame dağılımı.

Split	Sınıf	Frame	metadata video_id
Train	Real	1197	1
Train	Fake	1191	1
Val	Real	155	1
Val	Fake	141	1
Test	Real	146	1
Test	Fake	156	1

Sınıf dengesi


Frame sayıları her split içinde oldukça dengeli: train 1197 real / 1191 fake, validation 155 real / 141 fake, test 146 real / 156 fake. Bu nedenle sonuçları ağır sınıf dengesizliğiyle açıklamak doğru değildir.

Input numerical sanity gate

İlk batch şekli [32, 3, 224, 224]; dtype torch.float32. Normalize edilmiş tensor aralığı -2.118 ile 2.640; images_finite=True, labels_finite=True. Eğitim başlamadan NaN/Inf girdi problemi olmadığı doğrulanmıştır.


4 Eğitim Dinamikleri

14 epoch tam geçmiş, best checkpoint ve early stopping davranışı



Şekil 2. training_history.csv kullanılarak oluşturulan 14 epoch tam loss geçmişi.

Train loss genel olarak sürekli düşerken validation loss epoch 8 civarında en düşük bölgesine ulaşmış ve sonrasında yataylaşmış ve hafif yükselmiştir. Bu desen, modelin train verisine uyum sağlamaya devam ederken validation performansındaki kazanımların sınırlanmaya başladığını gösterir. Best checkpoint mekanizması bu nedenle yalnızca son epoch ağırlıklarını değil, validation performansı en iyi olan ara noktayı korur.




Şekil 3. Validation ROC-AUC tam geçmişi. En yüksek değer epoch 8: 0.8454.

Early stopping neden epoch 14'te devreye girdi?


En iyi ROC-AUC epoch 8'de görüldü. Epoch 9-14 aralığında bu değer aşılmadı. patience=6 olduğu için 6 ardışık iyileşmesiz epoch tamamlandıktan sonra eğitim durduruldu. Böylece 20 epoch üst bütçesinin tamamı gereksiz yere kullanılmadı.

5 Run İçinde Üretilen Eğitim Grafiklerinin Okunması

Best-checkpoint history snapshot ile tam history.csv arasındaki fark



Şekil 4. Run klasöründeki orijinal Training and Validation Loss Curve.



Şekil 5. Run klasöründeki orijinal Training and Validation Accuracy grafiği.

Önemli not: Grafikler 8 epoch gösteriyor


Klasördeki bu iki orijinal grafik, best.ckpt içinde saklanan history üzerinden üretilmiştir; dolayısıyla yalnızca epoch 1-8 aralığını gösterir. training_history.csv ise eğitim döngüsünün 14 epoch sürdüğünü doğrular. Bu raporda tam

eğitim davranışı yorumlanırken CSV esas alınmıştır; orijinal grafikler de run çıktısı olarak ayrıca sunulmuştur.

6 Best Epoch Analizi

Epoch 8 neden final model olarak seçildi?

Ep	Train L	Val L	Val Acc	Val F1	Val AUC	Val PR	Thr
6	0.5230	0.5104	0.736	0.771	0.831	0.817	0.240
7	0.5039	0.5292	0.750	0.777	0.830	0.805	0.190
8	0.4794	0.4933	0.774	0.793	0.845	0.831	0.275
9	0.4556	0.5123	0.770	0.790	0.837	0.821	0.225
10	0.4299	0.5131	0.740	0.762	0.834	0.823	0.275




Şekil 6. Run klasöründeki validation ROC-AUC grafiği (best checkpoint history snapshot).

Epoch 8, validation ROC-AUC = 0.8454 ile run boyunca ulaşılan en yüksek doğrulama ayırım performansıdır. Aynı epoch validation threshold 0.275 olarak seçilmiştir. Sonraki epochlarda train loss azalmaya devam etmiş olsa da validation ROC-AUC bu tepeyi geçememiştir; dolayısıyla final değerlendirmede epoch 8 ağırlıklarının kullanılması metodolojik olarak tutarlıdır.

7 Final Test Performansı

Best checkpoint ile frame-level test sonuçları



Şekil 7. Final frame-level test metriklerinin özet görünümü.

ACCURACY

69.87%

Toplam doğru tahmin

PRECISION

68.16%

Fake tahminlerinin isabeti

RECALL

78.21%

Fake yakalama oranı

F1-SCORE

72.84%

Precision-recall harmonik dengesi

ROC-AUC

0.7868

Threshold bağımsız ayırım

PR-AUC

0.7942


Positive sınıf odaklı alan

Test accuracy yaklaşık %69.9 iken F1-score %72.8'dir. Recall (%78.2) precision'dan (%68.2) daha yüksektir. Bu fark, seçilen düşük threshold nedeniyle modelin fake sınıfını kaçırmamak yönünde daha hassas çalıştığını; bunun karşılığında real framelerin bir bölümünü fake olarak işaretlediğini gösterir.

8

Confusion Matrix ve Hata Yapısı

Model hangi tür hatayı daha çok yapıyor?



Şekil 8. Run klasöründeki final test confusion matrix.

Durum	Adet	Yorum
True Negative (Real -> Real)	89	61.0% real specificity
False Positive (Real -> Fake)	57	39.0% real frame false-positive oranı
False Negative (Fake -> Real)	34	21.8% fake frame kaçırma oranı
True Positive (Fake -> Fake)	122	78.2% fake recall


Denge yorumu

Model 156 fake frame'in 122'sini doğru yakalamış, 34'ünü kaçırmıştır. Buna karşılık 146 real frame'in 57'sini fake olarak işaretlemiştir. Specificity 61.0%, negative predictive value 72.4% ve türetilmiş balanced accuracy 69.6%'dir.

Hata yapısı, recall öncelikli karar sınırıyla uyumludur.

9 ROC Eğrisi

Threshold bağımsız sınıf ayırma kapasitesi



Şekil 9. Test ROC eğrisi; AUC = 0.7868.


ROC-AUC 0.7868, model skorlarının real ve fake frameri sıralama açısından rastgele sınıflandırmadan belirgin biçimde daha iyi olduğunu gösterir. Değer 1.0'a yakın kusursuz ayırım düzeyinde değildir; göz ROI tek başına yararlı bir sinyal taşısa da örneklerin önemli bir bölümü skor uzayında örtüşmektedir.

Nasıl yorumlanmalı?

Bu AUC, seçilen 0.275 threshold'dan bağımsız bir ölçüdür. Bu nedenle final accuracy/F1 ile birlikte okunmalıdır: modelin skor üretme kalitesi makul, fakat belirli karar eşiğinde hata maliyetleri farklı yönlelere dağılmaktadır.

10 Precision-Recall Analizi

Fake sınıfı açısından pozitif tahmin kalitesi




Şekil 10. Test Precision-Recall eğrisi; PR-AUC = 0.7942.

PR-AUC 0.7942. Test seti yaklaşık dengeli olduğu için ROC ve PR sonuçları birlikte değerlendirilebilir. Recall'ın yüksek tutulduğu bölgelerde precision kaybı görülmesi, confusion matrixteki 57 false-positive ile uyumludur. Bu sonuç, göz bölgesinin fake sinyali taşıdığını ancak yalnızca tek bölge kullanıldığında kesin karar için sınırlı kaldığını düşündürür.

11 Threshold ve Skor Dağılımı

0.275 karar eşiği neden önemli?



Şekil 11. Test tahmin dosyasından türetilen fake-probability dağılımı ve validation seçili threshold.

Karar eşiği validation F1 optimizasyonundan 0.275 olarak gelmiştir. Bu değer, 0.50 varsayılanından düşük olduğu için daha fazla örnek fake kabul edilir. Sonuçta fake recall %78.2'ye çıkarken real sınıfın specificity değeri %61.0 düzeyinde kalmıştır. Uygulama senaryosunda yanlış alarm maliyeti yüksekse threshold yeniden kalibre edilebilir; ancak bu run'ın raporlanan test metrikleri validation'da seçilmiş 0.275 eşiğine aittir.

Kalibrasyon notu

Threshold seçimi test setinden yapılmamıştır; test yalnızca final değerlendirilmede kullanılmıştır. Bu, test leakage riskini azaltan doğru deneysel ayırmadır.

12 Güvenilirlik ve Kalite Kapıları

Sonucun yalnızca metrik değil, süreç olarak da doğrulanması

Kontrol	Durum	Kanıt / Sonuç
Input finite kontrolü	PASS	images_finite=True, labels_finite=True
Checkpoint continuity	PASS	loss before/after = 0.60025591; fark 0.0e+00
Normalization leakage	PASS	ImageNet pretrained mean/std; val/test istatistiği öğrenilmiyor
Best checkpoint	PASS	Epoch 8 validation ROC-AUC ile seçildi
Threshold izolasyonu	PASS	Threshold 0.275 validation F1 üzerinden

Video-level metric guard	PASS (guard)	Kimlik güvenilirmez bulunduğu için per-video metrik kapatıldı
--------------------------	--------------	---

Checkpoint süreklilik testi

Atomik kayıttan sonra model yeniden yüklenmiş ve aynı deterministik batch üzerinde loss değeri 0.60025591 -> 0.60025591 olarak birebir korunmuştur. Bu testin mutlak farkı 0.0e+00 olarak raporlanmıştır.

Run klasöründe ayrıca environment.json, requirements_runtime.lock.txt, source_hash_manifest.json ve source_snapshot bulunması deneyin daha sonra denetlenebilmesini kolaylaştırır. Bu dosyalar performans skorunu artırmaz; fakat deney tekrar üretilebilirliği ve kod sürümü izlenebilirliği açısından önemlidir.

13 Sınırlılıklar ve Sonuçların Geçerlilik Sınırı

Bu deneyden hangi iddialar çıkarılabilir, hangileri çıkarılamaz?

1. Video kimliği güvenilir değil

If false, video_id appears to encode only label/split buckets. Frame-level training may continue because upstream splits already exist, but true source-video-level leakage cannot be independently verified and video-level metrics must not be interpreted as per-original-video performance.

- Frame-level sonuçlar raporlanabilir: test setinde 302 frame için accuracy, F1, ROC-AUC ve PR-AUC doğrudan hesaplanmıştır.
- Per-original-video başarı raporlanamaz: video_id gerçek kaynak video kimliği olarak güvenilir bulunmamıştır.
- Bu metadata ile gerçek kaynak-video düzeyinde train/val/test sızıntısı bağımsız olarak yeniden doğrulanamaz. Upstream split alanı kullanılmıştır, fakat source-video kimliği eksikliği metodolojik bir sınırdır.
- Model yalnızca Combined Eye ROI ve tek-frame uzamsal sinyal kullanır; temporal göz hareketi, blink dinamiği veya video boyunca tutarlılık bu run'da modellenmemiştir.
- Klasördeki orijinal eğitim grafikleri best checkpoint history üzerinden üretildiği için epoch 9-14'ü göstermemektedir; tam analiz training_history.csv ile yapılmıştır.
- SSOT schema audit tarafından eksik raporlanan alanlar: frame_index, roi_state, run_id, sha256.

Sonuçların doğru kapsamı

Bu run, “göz ROI frame’leri üzerinde Swin V2 Tiny belirli bir ayırma sinyali öğrenebiliyor” sonucunu destekler. “Model video düzeyinde %X başarıyla deepfake tespit ediyor” veya “source-video leakage kesin olarak yok” iddialarını bu klasör tek başına desteklemez.

14 Sonuç ve Teknik Değerlendirme

Deney 1’in genel yorumu

Deney 1, Swin V2 Tiny’nin Combined Eye ROI üzerinde kullanılabilir bir baseline oluşturduğunu göstermiştir. En iyi validation checkpoint epoch 8’de ROC-AUC 0.845 ile seçilmiş; final frame-level testte accuracy 69.9%, F1 72.8%, ROC-AUC 0.787 ve PR-AUC 0.794 elde edilmiştir.

Sonuçlar özellikle fake sınıfını yakalama açısından daha güçlüdür: recall %78.2. Bunun karşılığında real sınıfta yanlış alarm sayısı yüksektir ve specificity yaklaşık %61.0’dır. Dolayısıyla bu baseline, güçlü bir “fake duyarlılığı” sağlarken karar güvenilirliğini tek başına tamamlamamaktadır.

Eğitim geçmiş, epoch 8 sonrasında train loss düşmeye devam etse de validation ROC-AUC’nin tepeyi aşmadığını gösterir. Best-checkpoint + early-stopping tasarımı bu nedenle doğru çalışmış ve epoch 14’te gereksiz devamı sonlandırmıştır.

Run: 20260807_1031_eye_swinv2_tiny_seed42 | Deney 1 Sonuç Raporu

BEST VAL AUC

0.845

Epoch 8

TEST ROC-AUC

0.787

Frame-level

FAKE RECALL

78.2%

122 / 156 fake doğru

REAL SPECIFICITY

61.0%

89 / 146 real doğru

Deney 1'in ana çıktısı

Swin V2 Tiny göz bölgesi için anlamlı fakat tek başına sınırlı bir baseline üretmiştir. Modelin güçlü yanı fake örnekleri yakalama duyarlılığı; temel zayıflığı ise real framelerdeki false-positive oranıdır. Bu nedenle sonraki karşılaştırmalar yapılırken aynı split/ROI üzerinde F1, ROC-AUC, confusion matrix ve threshold davranışı birlikte izlenmelidir.

A Ek - Tam Epoch Özeti

training_history.csv içindeki 14 epoch performans tablosu

Ep	Tr L	Val L	Tr Acc	Val Acc	Val F1	Val AUC	Val PR	Thr
1	0.6979	0.6599	0.544	0.601	0.667	0.672	0.633	0.395
2	0.6544	0.6117	0.607	0.682	0.713	0.744	0.722	0.370
3	0.6225	0.5860	0.652	0.716	0.742	0.789	0.757	0.290
4	0.5720	0.5304	0.699	0.753	0.765	0.823	0.803	0.465
5	0.5479	0.5089	0.723	0.750	0.772	0.832	0.811	0.390
6	0.5230	0.5104	0.744	0.736	0.771	0.831	0.817	0.240
7	0.5039	0.5292	0.754	0.750	0.777	0.830	0.805	0.190
8	0.4794	0.4933	0.769	0.774	0.793	0.845	0.831	0.275
9	0.4556	0.5123	0.793	0.770	0.790	0.837	0.821	0.225
10	0.4299	0.5131	0.807	0.740	0.762	0.834	0.823	0.275
11	0.4090	0.5218	0.820	0.747	0.769	0.835	0.822	0.240

12	0.4069	0.5151	0.822	0.757	0.775	0.838	0.823	0.270
13	0.3858	0.5245	0.817	0.753	0.771	0.835	0.819	0.230
14	0.3894	0.5266	0.823	0.753	0.771	0.838	0.826	0.320

Rapor sonu

Kaynak: 20260807_1031_eye_swinv2_tiny_seed42 run klasöründeki experiment_summary, metrics, predictions, audit ve figures çıktıları.