

GÖZ ÜZERİNDEN DEEPPAKE TESPİTİ

Eğitilebilecek modellerin öncelik sırası ve dayandıkları makaleler

Değerlendirme ölçütleri: göz bölgesine doğrudan uygunluk, mevcut frame-bağımsız göz ROI pipeline'ına uyum, uygulanabilirlik, hesaplama maliyeti, açıklanabilirlik ve akademik karşılaştırma değeri. "Doğrudan" ifadesi yöntemin göz üzerinde kullanıldığını; "uyarlama" ise genel yüz veya başka bir bölge yaklaşımının göz ROI'sine aktarılacağını gösterir.

Öncelik	Model / Yöntem	Göz Bölgesinde Kullanım	Atıf Alınacak Makale	Durum	Neden Bu Sırada?
1	Pupil Segmentasyonu + Kornea Yansıma Tutarlılığı (CNN)	Önce pupil bölgesi segmentlenir; ardından sağ ve sol gözdeki kornea yansımalarının biçim ve konum tutarlılığı CNN ile karşılaştırılır.	Tchaptchet vd. (2025) The Eyes: A Source of Information for Detecting Deepfakes	DOĞRUDAN	Tamamen göze özel, tek görüntüyle çalışıyor ve mevcut frame-bağımsız göz ROI pipeline'ına doğrudan uyuyor. Tabloda FFHQ+StyleGAN2 için %96,8 doğruluk raporlanmıştır.
2	Swin-Tiny / Swin V2 + LBP + GLCM + Gabor + Wavelet	Swin genel ve semantik göz özelliklerini; LBP, GLCM, Gabor ve Wavelet mikro doku, yönelim ve frekans bozukluklarını çıkarır. Özellikler Dense/MLP katmanında birleştirilir.	Shivaprakash vd. (2026) Hybrid Facial Deepfake Detection Framework Using Swin V2 Vision Transformers and Multi-Scale Textural Descriptors	UYARLAMA	Mevcut Swin-Tiny ve klasik doku baseline'larını tek bir gerçek hibrit mimariye dönüştürür. Frame sırası gerektirmez. FF++ için %96,9 doğruluk ve 0,992 AUC raporlanmıştır.
3	Swin Transformer Tiny	Birleşik göz, sol göz ve sağ göz ROI'leri ayrı deneylerde Swin-Tiny'ye verilir. Shifted-window attention ile lokal ve daha geniş göz yapıları birlikte öğrenilir.	Shivaprakash vd. (2026) çalışmasındaki Swin V2 kolu	UYARLAMA	Mevcut pipeline ile doğrudan çalışır ve hibrit modelde Transformer kolunun tek başına başarısını ölçmek için gereklidir. Tabloda Swin V2 kolu tek başına yaklaşık %92 doğruluk vermiştir.
4	EfficientNet-B0	224x224 göz ROI'lerinden transfer learning ile özellik çıkarılır ve son sınıflandırma katmanı gerçek/sahte olarak düzenlenir.	AISC derleme tablosundaki yaygın CNN backbone'ları ve proje görüşmelerindeki ortak baseline kararı	BASELINE	Hafif, hızlı ve göz-kaş-ağız bölgelerinde aynı koşullarda kullanılabilecek ortak CNN baseline'dır. Swin ve hibrit modelin katkısını ölçmek için referans sağlar.
5	Con-GAN + DSRes	Göz kırpmalı özellikleri Convolutional Attention GAN ve Depthwise Separable Residual Network ile işlenir; makalede SABiW ve 2D Haar DWT tabanlı ön işleme de kullanılmıştır.	Agrawal & Haneef (2025) Eye Blinking Feature Processing Using Convolutional GAN for Deep Fake Video Detection	KOŞULLU	Tabloda %98,91 doğruluk ve %98,32 precision verilmiştir. Ancak frame/video sırası ile veri bölme ayrıntıları net olmadığı için tam metin teyidinden sonra uygulanmalıdır.
6	TimeSformer	Her video için 32 karelik sıralı göz ROI dizisi kullanılır. Uzamsal-zamansal attention ile gaze ve blink örüntüleri birlikte analiz edilir.	Javed vd. (2025) Real-Time Deepfake Detection via Gaze and Blink Patterns: A Transformer Framework	DOĞRUDAN / TEMPORAL	Göze özel ve güçlü bir temporal modeldir; tabloda dört veri setinde %95,8-%97,5 doğruluk bildirilmiştir. Fakat mevcut frame-bağımsız pipeline'ın video-seviyeli yeniden düzenlenmesini gerektirir.
7	MesoNet4 + ResNet101 + Göz Hareketi	MesoNet4 lokal manipülasyon izlerini, ResNet101 daha derin yapısal özellikleri öğrenir; göz hareketi analiziyle birlikte ensemble uygulanır.	Javed vd. (2024) Real-Time Deepfake Video Detection Using Eye Movement Analysis with a Hybrid Deep Learning Approach	DOĞRUDAN / TEMPORAL	Göz odaklı ve yüksek sonuçlu bir hibrit CNN yaklaşımıdır. Tabloda FF++ için %98,73 doğruluk verilmiştir; ancak hesaplama maliyeti yüksektir ve sıralı video verisi ister.
8	LRCN: VGG16/CNN + LSTM	Ardışık göz karelerinden CNN özellikleri çıkarılır; LSTM gözün açık-kapalı durumunu ve kırpmalı örüntüsünü zaman içinde sınıflandırır.	Li, Chang & Lyu (2018) In Ictu Oculi: Exposing AI Created Fake Videos by Detecting Eye Blinking	DOĞRUDAN / TEMPORAL	Göz kırpmalı tabanlı deepfake tespitinin temel temporal referansıdır. Tabloda LRCN için 0,99 AUC verilmiştir; sıralı kare pipeline'ı gerektirir.

Öncelik	Model / Yöntem	Göz Bölgesinde Kullanım	Atıf Alınacak Makale	Durum	Neden Bu Sırada?
9	HOG + LBP + GLCM + SVM	HOG göz biçimi ve yönelimini; LBP lokal mikro dokuyu; GLCM gri seviye komşuluk ilişkilerini temsil eder. Özellikler SVM ile sınıflandırılır.	Shivaprakash vd. (2026) doku tanımlayıcıları; proje içindeki klasik baseline yaklaşımı	BASELINE / UYARLAMA	Hızlı, düşük maliyetli ve açıklanabilir bir klasik baseline'dır. Hibrit modelin doku dalının tek başına başarısını ölçmek için de gereklidir.
10	ViT + Linformer	Göz landmark çevrelerinden küçük patch'ler oluşturulur; ViT yapısı Linformer attention ile hafifletilerek tek frame üzerinden sınıflandırma yapılır.	Rani vd. (2025) Lightweight and Hybrid Transformer-Based Solution for Quick and Reliable Deepfake Detection	UYARLAMA	Tek frame ile çalışır ve hafif Transformer deneyi sunar. Tabloda %93,95-%95,25 doğruluk ve 0,984-0,989 AUC raporlanmıştır; ancak göze özel değildir.
11	Gradient-Intensity + CNN + ESR	Gradient-intensity operatörü iris merkezini, hafif CNN ve Explicit Shape Regression ise göz köşelerini yerleştirir; sınıflandırma öncesi özellik çıkarıcı olarak kullanılabilir.	Ahmed & Laskar (2021) Evaluation of Accurate Iris Center and Eye Corner Localization Method...	YÖNTEM TRANSFERİ	Deepfake dedektörü değildir; göz lokalizasyonu için güçlü bir yardımcı yöntemdir. Mevcut MediaPipe aşamasını tekrar ettiği için ana model değil, alternatif ön işleme seçeneğidir.
12	PEP Pupil Edge Points Network	Pupil kenar noktalarını hafif bir sinir ağıyla belirler; pupil segmentasyonu ve kornea modülünün ön aşamasında kullanılabilir.	Zhang, Liu, Lv, Li vd. (2025) PEP: An Accurate and Efficient Pupil Detection Framework Based on Pupil Edge Points	YÖNTEM TRANSFERİ	Deepfake tespiti için değerlendirilmemiştir. Pupil lokalizasyonunu hafifletmek amacıyla yardımcı modül olabilir; tek başına sınıflandırma modeli değildir.

ÖNERİLEN DENEY SIRASI

1. EfficientNet-B0 ORTAK CNN BASELINE Göz, kaş ve ağız bölgelerinde aynı koşullarda eğitilerek bölgeler arası adil karşılaştırma sağlar. Swin ve hibrit modelin katkısını ölçmek için referanstır.	2. Swin Transformer Tiny ANA STATİK MODEL Mevcut frame-bağımsız göz ROI pipeline'ında doğrudan eğitilir. Hibrit model kurulmadan önce Transformer kolunun tek başına performansı alınır.
3. Swin-Tiny + LBP + GLCM ANA HİBRİT MODEL Swin'in derin özellikleri ile LBP ve GLCM doku özellikleri feature-level fusion ile birleştirilir. İlk hibrit aşamada Gabor ve Wavelet eklenmeden başlanır.	4. Swin-Tiny + LBP + GLCM + Gabor/Wavelet GELİŞTİRİLMİŞ HİBRİT İlk hibrit modelden sonra Gabor ve Wavelet dalları kademeli biçimde eklenir. Her doku bileşeninin katkısı ablation çalışmasıyla ölçülür.

Kritik metodoloji notları

- Train-test ayrımı frame bazında değil, video veya kişi bazında yapılmalıdır. Aynı videodan gelen benzer karelerin farklı gruplara düşmesi veri sızıntısı oluşturur.
- Ana statik deneylerde combined-eye, sol göz ve sağ göz sonuçları ayrı raporlanabilir; ana karşılaştırma için aynı ROI biçimi ve aynı eğitim ayarları korunmalıdır.
- Hibrit model için önce Swin-Tiny, doku kolu ve füzyon modeli ayrı ayrı eğitilmeli; ardından LBP, GLCM, Gabor ve Wavelet katkıları ablation ile ölçülmelidir.
- Pupil-kornea yaklaşımı ana hibrite doğrudan eklenmeden önce bağımsız bir göze özel deney olarak doğrulanmalıdır.
- LRCN, TimeSformer ve göz hareketi modelleri sıralı frame gerektirdiği için frame-bağımsız modellerden ayrı bir temporal deney fazında raporlanmalıdır.
- Accuracy tek başına yeterli değildir; F1-score, ROC-AUC, precision ve recall birlikte raporlanmalıdır.

Kaynaklar: AISC Makale İnceleme ve Literatür Tarama Tablosu; Göz Bölgesi Deepfake Modelleri tablosu; ekip içi son model değerlendirmesi. Öncelik sırası yalnızca bu kaynaklardaki bilgi ve son görüşmede kararlaştırılan model hattına göre hazırlanmıştır.