

DENEY SONUÇ RAPORU

Pupil Segmentasyonu ve Korneal Yansima Tutarlılığına Dayalı Fusion CNN ile Deepfake Tespiti

Deney Kimliği	20260806_1534_eye_pupil_reflection_fusion_seed42
Model Modu	Fusion (RGB CNN + 19 fizyolojik özellik)
Veri Boyutu	2.986 birleştirilmiş göz ROI görüntüsü
Rastgelelik Tohumu	42
Rapor Tarihi	6 Ağustos 2026

Hazırlayan: Kader Terik

AISC Deepfake Detection - Göz Bölgesi Deneyi

Özet

Bu raporda, göz bölgesindeki deepfake izlerini belirlemek amacıyla geliştirilen pupil segmentasyonu ve korneal yansıma tutarlılığı tabanlı Fusion CNN deneyinin veri yapısı, yöntem tasarımı, eğitim süreci ve test sonuçları sunulmuştur. Deneyde toplam 2.986 birleştirilmiş göz ROI görüntüsü kullanılmış; RGB görüntü özellikleri önceden eğitilmiş bir CNN kolu ile, pupil geometrisi ve korneal yansıma ilişkisini temsil eden 19 sayısal özellik ise ayrı bir özellik kolu ile işlenmiştir. İki kolun birleştirilmesiyle ikili gerçek/sahte sınıflandırma gerçekleştirilmiştir.

Standart 0,50 karar eşiğinde modelin test doğruluğu %67.88, F1 skoru %70.15, ROC-AUC değeri %74.12 ve PR-AUC değeri %75.96 olarak ölçülmüştür. Model sahte örnekleri yakalamada %73.08 duyarlılık gösterirken, gerçek örnekleri doğru dışlama oranı %62.33 düzeyinde kalmıştır. Elde edilen sonuçlar yaklaşımın ayırt edici sinyal ürettiğini, ancak gerçek ve sahte sınıflar arasındaki hata dengesinin geliştirilmesi gerektiğini göstermektedir.

İçindekiler

1. Deneyin Amacı ve Araştırma Sorusu
2. Veri Seti ve Örnek Dağılımı
3. Önerilen Yöntem ve Model Mimarisi
4. Eğitim Yapılandırması
5. Eğitim ve Doğrulama Bulguları
6. Test Sonuçları
7. Eşik ve Hata Analizi
8. Fizyolojik Özelliklerin Yorumu
9. Açıklanabilirlik ve Grad-CAM
10. Genel Değerlendirme ve Öneriler

1. Deneyin Amacı ve Araştırma Sorusu


Bu deneyin temel amacı, deepfake üretim süreçlerinde göz bebeği geometrisi, iki göz arasındaki pupil tutarlılığı ve korneal yansıma örüntülerinde oluşabilecek fiziksel tutarsızlıkların sınıflandırma performansına katkısını incelemektir. Yalnızca ham RGB görüntüsüne dayanan bir model yerine, görüntüsel ve fizyolojik ipuçlarını aynı karar mekanizmasında birleştiren çok kollu bir Fusion CNN yaklaşımı kullanılmıştır.

Araştırma sorusu şu şekilde tanımlanmıştır: Birleştirilmiş sağ-sol göz görüntülerinden öğrenilen derin görsel özellikler ile pupil segmentasyonundan ve korneal yansıma analizinden türetilen sayısal özellikler birlikte kullanıldığında gerçek ve deepfake örnekleri güvenilir biçimde ayırt edilebilir mi?


2. Veri Seti ve Örnek Dağılımı

Bölüm	Sınıf	Örnek Sayısı	Toplamdaki Pay
TRAIN	REAL	1197	%40.1
TRAIN	FAKE	1191	%39.9
VAL	REAL	155	%5.2
VAL	FAKE	141	%4.7
TEST	REAL	146	%4.9
TEST	FAKE	156	%5.2

Toplam veri sayısı 2,986 örnektir. Eğitim kümesi 2,388, doğrulama kümesi 296 ve test kümesi 302 görüntü içermektedir. Genel sınıf dağılımı gerçek sınıfta 1,498, sahte sınıfta 1,488 örnek olacak şekilde oldukça dengelidir.



Şekil 1. Eğitim, doğrulama ve test kümelerindeki gerçek/sahte örnek dağılımı.



Şekil 2. Birleştirilmiş göz ROI görüntülerinden rastgele gerçek ve sahte örnekler.

3. Önerilen Yöntem ve Model Mimarisi

Model iki ana bilgi kaynağını bir araya getirmektedir. Birinci kol, 224 x 224 piksel boyutuna getirilen birleştirilmiş göz görüntülerini önceden eğitilmiş CNN omurgasıyla işler. İkinci kol ise pupil segmentasyonu, iki göz arasındaki geometrik farklar, gradyan benzerliği ve korneal yansıma ölçümlerinden oluşan 19 boyutlu sayısal özellik vektörünü işler. Her iki temsil katmanı füzyon aşamasında birleştirilerek gerçek/sahte olasılığı üretilir.

3.1 Kullanılan Fizyolojik ve Geometrik Özellikler

- left_pupil_detected, right_pupil_detected, left_pupil_circularity, right_pupil_circularity, pupil_circularity_absdiff
- left_pupil_eccentricity, right_pupil_eccentricity, pupil_eccentricity_absdiff, left_pupil_area_ratio, right_pupil_area_ratio
- pupil_area_ratio_absdiff, pupil_center_distance, gradient_iou, gradient_correlation, left_highlight_count_norm
- right_highlight_count_norm, highlight_count_absdiff, highlight_centroid_distance, highlight_area_absdiff

Bu özellikler; pupil tespitinin başarılı olup olmaması, pupil daireselliği ve eksantrikliği, sağ-sol pupil alan oranı farkı, pupil merkezleri arasındaki uzaklık, gözler arası gradyan örtüşmesi/korelasyonu ve korneal parlama noktalarının sayısı, alan ve merkez uzaklığı ilişkilerini kapsar. Amaç, gerçek görüntülerde fiziksel olarak daha tutarlı olması beklenen iki göz ilişkisini sayısallaştırmaktır.



Şekil 3. Gerçek ve sahte sınıflar için ortalama göz görüntülerinin karşılaştırılması.


4. Eğitim Yapılandırması

Parametre	Değer
Görüntü boyutu	224 x 224
Batch size	16
Maksimum epoch	30
Gerçekleşen epoch	13
Öğrenme oranı	0.0002
Weight decay	0.0001
Dropout	0.3
Early stopping patience	7
Önceden eğitilmiş ağırlık	Evet
Seed	42


Eğitim, en iyi doğrulama ROC-AUC değeri takip edilerek gerçekleştirilmiş ve iyileşme görülmeyen dönemler için erken durdurma uygulanmıştır. En iyi checkpoint ile son checkpoint ayrı olarak saklanmıştır. Bu yapı, aşırı uyum riskini azaltırken deneyin tekrar üretilebilirliğini desteklemektedir.

5. Eğitim ve Doğrulama Bulguları


En yüksek doğrulama ROC-AUC değeri 6. epochta %78.54 olarak elde edilmiştir. Aynı epochta doğrulama doğruluğu %67.57, F1 skoru %66.67 ve doğrulama kaybı 0.5596 seviyesindedir. Eğitim ilerledikçe eğitim performansının artmasına karşın doğrulama kaybının son dönemlerde yükselmesi, modelde aşırı uyum eğilimi oluştuğunu göstermektedir.



Şekil 4. Epochlara göre eğitim ve doğrulama kaybı.

Validation Performance by Epoch

Şekil 5. Doğrulama kümesinde doğruluk, F1, ROC-AUC ve PR-AUC değişimi.


Learning Rate Schedule

Şekil 6. Eğitim boyunca öğrenme oranı planı.


6. Test Sonuçları

Metrik	Sonuç
Test kaybı	0.6177
Doğruluk	%67.88
Precision	%67.46
Recall / Sensitivity	%73.08
Specificity	%62.33
F1 skoru	%70.15
ROC-AUC	%74.12
PR-AUC	%75.96


Model, test kümesinde orta düzeyin üzerinde ayırt etme başarısı göstermiştir. ROC-AUC ve PR-AUC değerlerinin 0,74-0,76 aralığında olması, sınıfların tamamen ayrışmadığını ancak modelin rastgele tahminden belirgin biçimde daha güçlü bir sıralama ürettiğini göstermektedir. Duyarlılığın özgüllükten yüksek olması, modelin sahte örnekleri yakalamaya daha eğilimli olduğunu; bunun karşılığında bazı gerçek örnekleri sahte olarak işaretlediğini göstermektedir.




Şekil 7. Test kümesindeki temel sınıflandırma metriklerinin özeti.



Şekil 8. Test kümesi karmaşıklık matrisi (TN=91, FP=55, FN=42, TP=114).



Şekil 9. ROC eğrisi ve modelin eşiklerden bağımsız ayırt etme gücü.


Precision-Recall Curve*Şekil 10. Precision-Recall eğrisi.*

7. Eşik ve Hata Analizi


Standart 0,50 eşik değeri test doğruluğunu %67.88 ile en yüksek seviyeye taşımaktadır. Buna karşılık F1 skorunu en yüksek yapan eşik 0,35'tir. Bu eşikte F1 %72.11, duyarlılık %87.82 ve özgüllük %40.41 olmaktadır. Dolayısıyla sahte içeriği kaçırmamanın öncelikli olduğu bir senaryoda daha düşük eşik tercih edilebilir; ancak bu seçim yanlış pozitif sayısını artıracaktır.

Hata Türü	Adet	Oran
Correct	205	%67.88
False Positive	55	%18.21
False Negative	42	%13.91


302 test örneğinin 205'i doğru sınıflandırılmıştır. Yanlış pozitif sayısı 55, yanlış negatif sayısı 42'dir. Yanlış pozitiflerin daha fazla olması, modelin gerçek örneklerdeki bazı düşük kaliteli, asimetrik veya sıra dışı göz özelliklerini deepfake izi olarak yorumlayabildiğine işaret etmektedir.



Şekil 11. Gerçek ve sahte sınıflar için tahmin olasılığı dağılımları.



Şekil 12. Farklı karar eşiklerinde metriklerin değişimi.


Calibration Curve

Şekil 13. Model olasılıklarının kalibrasyon eğrisi.


8. Fizyolojik Özelliklerin Yorumu

Fizyolojik özellik grafiklerinde gerçek ve sahte sınıfların dağılımları önemli ölçüde örtüşmektedir. Bu durum, tek bir pupil veya korneal yansıma ölçüsünün bağımsız olarak kesin bir deepfake göstergesi olmadığını göstermektedir. Buna karşın çok sayıda zayıf sinyalin CNN tarafından öğrenilen görüntü temsiliyle birlikte kullanılması, toplam sınıflandırma başarısına katkı sağlayabilir.


Eğitim kümesindeki sınıf ortalamaları karşılaştırıldığında en belirgin farklar korneal parlama merkez uzaklığı, pupil merkez uzaklığı, iki göz arasındaki pupil dairesellik farkı ve pupil alan oranı farkında görülmüştür. Ancak farkların büyüklüğü sınırlıdır; bu nedenle bu özelliklerin bireysel kurallar olarak değil, çok değişkenli bir füzyon yapısı içinde değerlendirilmesi daha uygundur.




Şekil 14. Korneal yansıma merkez uzaklığının sınıflara göre dağılımı.

Real vs Fake Distribution — Pupil Area Ratio Absdiff

Şekil 15. Sağ-sol pupil alan oranı mutlak farkı.

Real vs Fake Distribution — Pupil Circularity Absdiff


Şekil 16. Sağ-sol pupil dairesellik mutlak farkı.

Real vs Fake Distribution — Gradient Correlation

Şekil 17. İki göz bölgesi arasındaki gradyan korelasyonu.

9. Açıklanabilirlik ve Grad-CAM

RGB kolunun karar verirken hangi bölgelere odaklandığını incelemek için Grad-CAM görselleştirmesi üretilmiştir. Isı haritası, modelin yalnızca göz bebeğine değil; göz kapakları, iris çevresi, göz köşeleri ve iki göz arasındaki genel doku ilişkisine de dikkat ettiğini göstermektedir. Bu bulgu, model kararının fizyolojik özellik koluyla sınırlı olmadığını ve CNN kolunun tamamlayıcı görüntü ipuçları öğrendiğini desteklemektedir.



Şekil 18. Fusion modelinin RGB kolu için Grad-CAM açıklaması.

10. Genel Değerlendirme ve Öneriler

Deney, pupil segmentasyonu ve korneal yansıma tutarlılığının deepfake tespitinde kullanılabilir yardımcı sinyaller ürettiğini göstermiştir. Modelin %74,12 ROC-AUC ve %75,96 PR-AUC değerlerine ulaşması, yaklaşımın anlamlı bir ayırt etme kapasitesine sahip olduğunu göstermektedir. Bununla birlikte %67,88 doğruluk, gerçek dünya kullanımından önce performansın geliştirilmesi gerektiğini ortaya koymaktadır.

10.1 Güçlü Yönler

- Gerçek ve sahte sınıflarının tüm bölümlerde büyük ölçüde dengeli olması.
- Görüntüsel ve fiziksel/fizyolojik özelliklerin tek bir füzyon modelinde birleştirilmesi.
- Checkpoint, erken durdurma, seed ve öğrenme oranı planı ile tekrar üretilebilir eğitim yapısı.
- ROC, PR, kalibrasyon, eşik, hata ve Grad-CAM analizlerinin birlikte sunulması.
- Tüm 35 görselin en az 600 piksel kısa kenar çözünürlük kontrolünü geçmesi.

10.2 Sınırlılıklar

- Fizyolojik özelliklerin sınıflar arası dağılımlarının önemli ölçüde örtüşmesi.
- Eğitim performansı yükselirken doğrulama kaybının artması nedeniyle aşırı uyum eğilimi.
- Özgüllüğün duyarlılıktan düşük olması ve gerçek örneklerde daha fazla yanlış alarm oluşması.
- Kare tabanlı değerlendirme nedeniyle video boyunca zamansal pupil/yansıma tutarlılığının doğrudan modellenmemesi.

10.3 Sonraki Çalışmalar

- Video veya kimlik bazlı grup ayrımı ile olası veri sızıntısının ayrıca doğrulanması.
- Temporal modelleme eklenerek ardışık karelerde pupil ve korneal yansıma hareket tutarlılığının ölçülmesi.
- Segmentasyon güven skorlarının ve düşük kaliteli ROI filtrelerinin modele dahil edilmesi.

- RGB-only, scalar-only ve fusion modellerinin aynı split üzerinde ablation karşılaştırmasının yapılması.
- Class-weight, focal loss, daha güçlü augmentation ve düzenleme yöntemlerinin denenmesi.
- Eşik seçiminin kullanım senaryosuna göre doğrulama kümesinde belirlenmesi ve olasılık kalibrasyonunun iyileştirilmesi.

Sonuç

Fusion CNN deneyi, göz bölgesindeki pupil geometrisi ve korneal yansıma ilişkilerinin deepfake tespiti için katkı sağlayabildiğini ortaya koymuştur. En güçlü sonuç, modelin farklı eşiklerde istikrarlı bir ayırt etme sinyali üretmesi ve PR-AUC değerinin %75,96'ya ulaşmasıdır. Bununla birlikte modelin tek başına kesin karar sistemi olarak değil, yüzün kaş ve ağız gibi diğer bölgeleriyle birleştirilecek çok bölgeli bir deepfake tespit sisteminin göz modülü olarak değerlendirilmesi daha uygundur.