

DENEY SONUÇ RAPORU

Göz Bölgesi Deepfake Tespiti

Swin V2 ve Çoklu Doku Özellik Füzyonu

Deney adı	eye_swinv2_texturefusion_seed42
Aktif çalışma modu	Full fusion
Model	Swin V2 Tiny (önceden eğitilmiş)
Rastgelelik tohumu	42
Rapor tarihi	6 Ağustos 2026

Hazırlayan: Kader Terik

Akademik değerlendirme ve deney sunumu amacıyla hazırlanmıştır.

Özet ve Temel Bulgular

Bu deneyde, videolardan çıkarılan birleşik göz bölgesi görüntülerinin gerçek ve deepfake olarak sınıflandırılması amaçlanmıştır. Görsel temsil için ImageNet üzerinde önceden eğitilmiş Swin V2 Tiny omurgası kullanılmış; bu temsil LBP, GLCM, Gabor ve dalgacık tabanlı el yapımı doku özellikleriyle birleştirilmiştir. Böylece model, göz çevresinin hem yüksek seviyeli görsel örüntülerini hem de ince doku düzensizliklerini birlikte değerlendirecek biçimde tasarlanmıştır.

2.986	302	5	0,265
Toplam örnek	Test örneği	En iyi epoch	Seçilen eşik

0.698	0.709	0.865	1.000
Test F1	Test ROC-AUC	Test recall	Video düzeyi F1

Örnek düzeyinde modelin en güçlü yönü %86,54 recall değeridir. Bu sonuç, sahte göz örneklerinin büyük bölümünün yakalandığını göstermektedir. Buna karşılık %58,44 precision ve karmaşıklık matrisindeki 96 yanlış pozitif, modelin gerçek örnekleri zaman zaman sahte olarak işaretlediğini ortaya koymaktadır. Video düzeyinde iki test videosunun ortalama olasılıkla ayrılması sonucunda tüm metrikler 1,00 olarak hesaplanmıştır; ancak testte yalnızca iki video bulunduğu için bu sonuç genellenebilir başarı göstergesi olarak değil, sınırlı bir ön bulgu olarak değerlendirilmelidir.


Raporun Kapsamı

- Veri kümesinin sınıf ve bölüm bazlı dağılımı
- Swin V2 + doku özellik füzyonu mimarisinin açıklaması
- Eğitim ve doğrulama sürecinin epoch bazlı analizi
- Test metrikleri, karmaşıklık matrisi, ROC ve PR eğrileri
- Örnek düzeyi ile video düzeyi sonuçların karşılaştırılması
- Sınırlılıklar ve sonraki deneyler için öneriler

1. Veri Kümesi ve Deney Bölünmesi

Deney, ön işleme aşamasında başarıyla çıkarılmış birleşik göz ROI görüntüleri üzerinde gerçekleştirilmiştir. Etiketler gerçek ve sahte olarak iki sınıfta tutulmuş; eğitim, doğrulama ve test ayrımı önceden belirlenmiş metadata alanına göre korunmuştur. Toplam 2.986 örnek bulunmaktadır. Sınıflar genel olarak dengeli olsa da doğrulama ve test alt kümelerinde küçük farklılıklar vardır.

Bölüm	Sahte	Gerçek	Toplam	Pay
Eğitim	1.191	1.197	2.388	%79,97
Doğrulama	141	155	296	%9,91
Test	156	146	302	%10,11
Toplam	1.488	1.498	2.986	%100



Şekil 1. Göz ROI örneklerinin veri bölümleri ve sınıflara göre dağılımı.

Eğitim kümesinde 1.191 sahte ve 1.197 gerçek örnek bulunması, modelin bir sınıfa belirgin biçimde eğilim göstermeden öğrenebilmesi açısından olumludur. Test kümesinde ise 156 sahte ve 146 gerçek örnek yer almaktadır. Dengeli doğruluk metriğinin ayrıca raporlanması, bu küçük sınıf farkının performans yorumuna etkisini azaltmaktadır.

2. Yöntem ve Model Mimarisi

Model iki ana bilgi akışını birleştiren bir füzyon yaklaşımıdır. İlk akışta 224 x 224 piksel boyutuna getirilen birleşik göz görüntüsü Swin V2 Tiny omurgasına verilir. İkinci akışta aynı görüntüden dört farklı doku ailesi çıkarılır. Bu özellikler 240 boyutlu bir vektör oluşturur ve görsel omurgadan gelen temsil ile birleştirilerek tam bağlantılı sınıflandırma başlığına aktarılır.


Bileşen	Deneydeki yapı	Amaç
Görsel omurga	Swin V2 Tiny, pretrained	Yerel ve küresel görsel örüntüleri öğrenmek
LBP	Yarıçap 1/2/3; nokta 8/16/24	Mikro-doku ve yerel parlaklık geçişlerini temsil etmek
GLCM	Mesafe 1/2/4; açı 0/45/90/135 derece; 32 seviye	Piksel eş-oluşum ve yönlü doku ilişkilerini ölçmek
Gabor	6 yön ve 3 frekans	Yönelimli kenar ve frekans tepkilerini yakalamak
Dalgacık	db2, seviye 2	Çok ölçekli frekans bileşenlerini ayırmak
Füzyon başlığı	256 gizli boyut, dropout 0,30	Öğrenilmiş ve el yapımı özellikleri ortak karara dönüştürmek

2.1. Eğitim Yapılandırması

Parametre	Değer	Açıklama
Batch size	16	Her optimizasyon adımındaki örnek sayısı
Maksimum epoch	30	Erken durdurma uygulanmadan üst sınır
Gerçekleşen epoch	13	Patience nedeniyle eğitim bu noktada sonlandırılmıştır
Başlangıç öğrenme oranı	0,0002	Füzyon ve sınıflandırma katmanları
Omurga öğrenme oranı	0,00002	Önceden eğitilmiş ağı daha düşük hızla güncelleme
Weight decay	0,0001	Aşırı uyumu sınırlayan düzenleştirme
Omurga dondurma	İlk 5 epoch	Başlangıçta yalnızca üst katmanların öğrenmesi
Early stopping patience	8	Doğrulama AUC iyileşmezse durdurma
AMP	Açık	Karma hassasiyetli eğitim
Gradient clipping	1,0	Kararsız gradyanları sınırlama


3. Eğitim ve Doğrulama Süreci

Model seçimi doğrulama ROC-AUC değerine göre yapılmıştır. En yüksek doğrulama ROC-AUC değeri 5. epochta 0,7222 olarak elde edilmiş ve bu epocha ait checkpoint test değerlendirmesinde kullanılmıştır. En iyi doğrulama eşiği 0,265 olarak belirlenmiştir. Eğitim 13 epoch sürmüştür, son sekiz epochta en iyi AUC değerinin geçilememesi nedeniyle erken durdurma devreye girmiştir.



Şekil 2. Eğitim ve doğrulama kaybının epoch boyunca değişimi.

Eğitim kaybı ilk epochlardan itibaren azalırken doğrulama kaybı 5. epoch civarında en düşük seviyesine ulaşmış, sonrasında yükselme eğilimi göstermiştir. Bu ayrışma, modelin eğitim örneklerine uyum sağlamaya devam ederken doğrulama genellemesinin sınırlanmaya başladığını ve erken durdurmanın gerekli olduğunu göstermektedir.



Şekil 3. Eğitim ve doğrulama F1 skorlarının epoch boyunca değişimi.


Doğrulama F1 değeri en iyi epoch çevresinde yaklaşık 0,71 seviyesine ulaşmıştır. Daha sonraki epochlarda eğitim F1 değerinin görece korunmasına karşın doğrulama performansının dalgalanması, modelin karar sınırının veri alt kümelerine duyarlı olduğunu göstermektedir.

Gösterge	En iyi epoch değeri
Epoch	5
Train loss	0.6050
Val loss	0.6157
Val F1	0.7115
Val ROC-AUC	0.7222
Val average precision	0.7068
Doğrulama eşiği	0.265

4. Test Sonuçları


En iyi doğrulama checkpointi, 302 örnekten oluşan test kümesi üzerinde değerlendirilmiştir. Standart 0,50 eşiği yerine doğrulama kümesinde seçilen 0,265 eşiği kullanılmıştır. Düşük eşik sahte örnekleri kaçırmamayı önceliklendirmiş ve yüksek recall sağlamıştır; bunun bedeli gerçek örneklerde artan yanlış alarm oranıdır.

Metrik	Değer	Yorum
Accuracy	0.6126	Tüm örneklerde doğru tahmin oranı
Balanced accuracy	0.6039	İki sınıf recall değerlerinin ortalaması
Precision	0.5844	Sahte denilen örneklerin gerçekten sahte olma oranı
Recall	0.8654	Sahte örneklerin yakalanma oranı
F1	0.6977	Precision ve recall dengesi
ROC-AUC	0.7090	Eşiklerden bağımsız ayırıştırma gücü
Average precision	0.7335	Precision-recall alanındaki özet başarı



Şekil 4. Test kümesindeki temel performans metrikleri.

0,709 ROC-AUC ve 0,734 average precision değerleri, modelin iki sınıfı rastlantısal seviyenin üzerinde ayırdığını göstermektedir. Bununla birlikte accuracy ve balanced accuracy değerlerinin yaklaşık 0,61 seviyesinde kalması, seçilen eşikte kararların gerçek sınıf için yeterince özgül olmadığını göstermektedir.




Şekil 5. Test kümesi karmaşıklık matrisi.

Gerçek sınıf	Gerçek tahmini	Sahte tahmini	Toplam
Gerçek	50	96	146
Sahte	21	135	156


Model 156 sahte örneğin 135 tanesini doğru yakalamış, 21 tanesini gerçek olarak kaçırmıştır. Buna karşın 146 gerçek örneğin yalnızca 50 tanesi doğru sınıflandırılmış; 96 gerçek örnek yanlış biçimde sahte olarak işaretlenmiştir. Bu hata yapısı, uygulamanın sahte içerik taramasında duyarlı fakat yanlış alarm üretmeye açık olduğunu göstermektedir.

5. Eşik Bağımsız Performans ve Olasılık Analizi




Şekil 6. Test ROC eğrisi ve sınıfları ayırma performansı.

ROC eğrisi, farklı eşiklerde doğru pozitif oranı ile yanlış pozitif oranı arasındaki değiş tokuşu göstermektedir. 0,709 AUC değeri orta düzeyde ayırıştırma gücüne işaret etmektedir. Eğrinin ideal sol üst köşeden uzak olması, yanlış pozitifleri azaltırken sahte örnekleri yakalama oranının da düşeceğini göstermektedir.



Şekil 7. Test precision-recall eğrisi.

Precision-recall eğrisi özellikle sahte sınıfın pozitif kabul edildiği senaryoda daha açıklayıcıdır. Average precision değerinin 0,7335 olması, modelin örnekleri olasılık skoruna göre sıralamada anlamlı bilgi ürettiğini; ancak yüksek recall bölgesinde precision kaybı yaşandığını göstermektedir.



Şekil 8. Gerçek ve sahte örnekler için tahmin olasılığı dağılımları ve seçilen karar eşiği.

Sahte örneklerin ortalama sahte olasılığı 0,5266, gerçek örneklerin ortalaması ise 0,3578 olarak hesaplanmıştır. İki dağılım arasında fark bulunmakla birlikte belirgin bir örtüşme vardır. 0,265 eşiğinin düşük seçilmesi, örtüşme bölgesindeki çok sayıda gerçek örneğin sahte sınıfına geçmesine neden olmaktadır.

6. Video Düzeyi Değerlendirme

Örnek düzeyi olasılıkları video kimliğine göre ortalananarak video düzeyi karar üretilmiştir. Test kümesinde yalnızca iki video kimliği bulunduğundan, biri sahte ve biri gerçek olmak üzere iki karar değerlendirilmiştir.

Video	Gerçek etiket	Örnek sayısı	Ort. sahte olasılığı	Tahmin	Doğru mu?
fake_test	Sahte	156	0.5266	Sahte	Evet
real_test	Gerçek	146	0.3578	Gerçek	Evet

İki videonun da doğru sınıflandırılması sonucunda video düzeyi accuracy, precision, recall, F1 ve ROC-AUC değerleri 1,00 çıkmıştır. Bununla birlikte örneklem yalnızca iki videodan oluştuğu için bu değer istatistiksel olarak kararlı değildir. Video düzeyi gerçek performansı değerlendirmek için farklı kimlik, sıkıştırma türü, manipülasyon yöntemi ve çekim koşullarını içeren daha geniş bir test kümesi gereklidir.

7. Kalite Kontrolleri ve Deney Güvenilirliği

Deney çıktıları otomatik kalite kapılarından geçirilmiştir. Gerekli dosyaların varlığı, checkpoint bütünlüğü, metriklerin sayısal geçerliliği ve tahmin kayıtlarının benzersizliği başarıyla doğrulanmıştır.

Kontrol	Durum
Required Outputs	PASSED
Checkpoint Integrity	PASSED
Numeric Metrics	PASSED
Prediction Uniqueness	PASSED

8. Sınırlılıklar

- Video düzeyi test yalnızca iki video içerdiği için 1,00 sonuçları genellenebilir değildir.
- Ablasyon dosyasında yalnızca full modu çalıştırılmıştır; Swin-only, texture-only ve ara füzyon modları için karşılaştırmalı sonuç bulunmamaktadır.
- Seçilen 0,265 eşik yüksek recall üretirken gerçek örneklerde 96 yanlış pozitif oluşturmuştur.
- Test örneklerinin iki video kimliğinden gelmesi, kareler arası benzerlik nedeniyle örnek düzeyi metriklerin bağımsızlık varsayımını zayıflatır.
- Modelin farklı veri kümeleri, sıkıştırma düzeyleri ve manipülasyon yöntemlerindeki dış genellemesi bu deneye ölçülmemiştir.

9. Sonuç ve Öneriler

Swin V2 ve çoklu doku özellik füzyonu, göz bölgesinden deepfake izlerini yakalama konusunda orta düzeyde ayrıştırma başarısı göstermiştir. Modelin temel avantajı yüksek sahte yakalama oranıdır; temel problemi ise gerçek örneklerdeki yanlış alarm sayısıdır. Bu nedenle mevcut model, tek başına kesin karar mekanizması olmaktan çok yüksek duyarlılıklı bir ön eleme bileşeni olarak değerlendirilebilir.

Bir sonraki aşamada tüm ablasyon modlarının aynı veri bölünmesi ve seed ile çalıştırılması, eşik seçiminin kullanım amacına göre yeniden optimize edilmesi, video sayısının artırılması ve kimlik bazlı çapraz doğrulama yapılması önerilmektedir. Özellikle Swin-only ile full fusion karşılaştırması, el yapımı doku özelliklerinin gerçek katkısını doğrudan gösterecektir. Yanlış pozitifleri azaltmak için sınıf ağırlığı, focal loss, kalibrasyon ve video içi zamansal tutarlılık yöntemleri ayrıca denenebilir.

4/4 geçti	185/302	135/156	96/146
Kalite kapıları	Doğru test kararı	Yakalanan sahte	Yanlış alarm

Ek A. Deney Yapılandırmasının Özeti

Alan	Değer
Görüntü sütunu	combined_eye_path
Etiket sütunu	label

Bölüm sütunu	split
Video sütunu	video_id
Görüntü boyutu	224 x 224
Model adı	swin_v2_t
Önceden eğitim	Evet
Doku boyutu	240
Aktif mod	full
Seed	42
Checkpoint seçimi	val_roc_auc
En iyi doğrulama AUC	0,7222
Test karar eşiği	0,265