

GÖZ BÖLGESİ DEEPFAKE TESPİTİ

VGG16 (Scratch) + HOG + GIST-style Gabor + RBF SVM

Alan	Değer
Run ID	20260806_170247_eye_combined_vgg16scratch_hog_gist_rbf_svm_seed42
Girdi görünümü	Combined Eye ROI
CNN	VGG16 - sıfırdan eğitim
Ön-eğitimli ağırlık	False
Özellik füzyonu	HOG, GIST-style Gabor, VGG16 learned features
Sınıflandırıcı	RBF SVM
Seed	42
Durum	COMPLETED

Deney sonuç raporu - veri dağılımı, CNN eğitimi, özellik füzyonu, SVM seçimi ve frame/video test performansı

1. Deneyin Amacı ve Genel Yaklaşım

Bu deneyde göz bölgesinden çıkarılan combined-eye ROI görüntüleri kullanılarak hibrit bir deepfake tespit hattı kurulmuştur. Sistem tek bir modelden oluşmamaktadır: önce VGG16 mimarisi ön-eğitim kullanılmadan sıfırdan eğitilmiş, ardından bu CNN'den öğrenilen temsil; HOG ve GIST-style Gabor özellikleriyle birleştirilmiş ve son karar RBF çekirdekli SVM ile verilmiştir.

Bu yaklaşımın temel avantajı, CNN'in öğrendiği yüksek seviyeli temsili; kenar/yönelim bilgisini özetleyen HOG ve çok ölçekli-yönelimli doku bilgisini temsil eden Gabor tabanlı özelliklerle bir araya getirmesidir. Böylece göz ROI'sindeki hem öğrenilmiş hem de el yapımı doku ipuçlarının birlikte kullanılması hedeflenmiştir.


Toplam çalışma süresi yaklaşık 5.57 dakika ve üretilen görsel sayısı 11 olarak raporlanmıştır.

2. Veri Seti ve Veri Muhasebesi

Split	REAL	FAKE	Toplam
Train	1197	1191	2388
Validation	155	141	296
Test	146	156	302

Orijinal metadata satır sayısı 3,097. Temel temizlik sonrası satır sayısı değişmemiştir. Statü dağılımında 2,986 örnek kullanılabilir, 111 örnek yüz bulunamadığı için kullanılamaz durumdadır. Nihai combined-eye kullanılabilir örnek sayısı 2,986.

Tam aynı satırdan kaynaklı duplicate kaldırımı 0 ve splitler arası exact-hash çakışması 0 olarak raporlanmıştır.



Şekil 1. Train/validation/test sınıf dağılımı.

3. Model Yapısı ve Çalışma Mantığı

3.1. VGG16 - sıfırdan eğitim

CNN bileşeni VGG16 mimarisidir; run özetine göre pretrained_weights=false, yani ImageNet gibi dış kaynaklardan ön-eğitilmiş ağırlık kullanılmamıştır. Bu tercih deneyin göz ROI verisinden tamamen sıfırdan temsil öğrenip öğrenemediğini ölçmeye yöneliktir.

VGG16, ardışık 3x3 konvolüsyon blokları ve pooling katmanlarıyla görüntüde giderek daha soyut uzamsal örüntüler öğrenen klasik bir CNN mimarisidir. Bu deneyde modelin nihai sınıflandırmasından ziyade öğrenilmiş feature temsili de hibrit sistemin bir parçası olarak kullanılmıştır.

3.2. HOG

HOG (Histogram of Oriented Gradients), görüntüdeki yerel gradyan yönelimlerinin histogramını çıkarır. Göz çevresindeki kenar, kirpik, kapak sınırı ve lokal geometrik değişim gibi ipuçlarının daha düzenli bir vektör temsiline dönüştürülmesi amaçlanır.

3.3. GIST-style Gabor özellikleri

Gabor filtreleri belirli frekans ve yönelimlerde doku yanıtları üretir. GIST-style kullanım, bu filtre yanıtlarını daha küresel/özet bir doku betimine dönüştürür. Deepfake üretiminde göz bölgesindeki mikro-doku, yumuşatma, yeniden örnekleme veya frekans içeriği farklılıklarının yakalanması hedeflenmiştir.

3.4. RBF SVM


Birleştirilmiş HOG + Gabor + VGG16 özellikleri doğrusal olmayan RBF çekirdekli SVM'e verilmiştir. RBF çekirdeği, sınıfları basit bir doğrusal sınırla ayırmanın yetersiz kaldığı durumlarda özellik uzayında daha esnek karar sınırları kurabilir.

Seçilen SVM parametresi	Değer
Kernel	rbf
C	10.0
Gamma	0.0001
Class weight	balanced
Karar threshold	-0.799299
Seçim split'i	val
Seçim metriği	f1


4. CNN Eğitim Sonuçları

CNN eğitimi 11 epoch tamamlamış ve en iyi validation F1 değeri 0.6453 olarak kaydedilmiştir. En iyi model best.ckpt olarak saklanmıştır.


Eğitim geçmişine göre loss yaklaşık 0.693 çevresinde seyretmiş ve validation çıktıları epochlar arasında ciddi sınıf-eşik davranışı göstermiştir. Bu, sıfırdan VGG16 eğitiminin tek başına güçlü ve dengeli bir sınıflandırıcı oluşturamadığını; hibrit özellik + SVM aşamasının deneyde önemli rol taşıdığını göstermektedir.



Şekil 2. CNN train/validation loss eğrileri.



Şekil 3. CNN train/validation accuracy eğrileri.



Şekil 4. CNN train/validation F1 eğrileri.

5. SVM Validation Seçimi


Metrik	Validation
Accuracy	0.5811
Precision	0.5333
Recall	0.9645
F1	0.6869
Specificity	0.2323
ROC-AUC	0.6680
Average Precision	0.6320

SVM seçimi F1 metriği üzerinden validation setinde yapılmıştır. Seçilen eşik negatiftir (-0.7993 civarı); bu, decision score üzerinde FAKE sınıfını yakalamaya daha duyarlı bir karar politikasına işaret eder. Validation recall 0.9645 iken specificity 0.2323'tür; yani sistem seçim aşamasında da sahteyi kaçırmama yönünde belirgin şekilde agresiftir.


6. Nihai Test Sonuçları - Frame Level

Metrik	Frame-level test
Accuracy	0.5596
Precision	0.5437
Recall	0.9167
F1	0.6826
Specificity	0.1781
ROC-AUC	0.6226
Average Precision	0.5953


Frame-level testte recall 0.9167 ile yüksek, specificity 0.1781 ile oldukça düşüktür. Bu dağılım modelin FAKE örnekleri yakalamaya odaklandığını fakat çok sayıda REAL frame'i yanlış biçimde FAKE olarak işaretlediğini gösterir. Accuracy 0.5596 ve ROC-AUC 0.6226, ayırma gücünün rastgele seviyenin üzerinde fakat sınırlı olduğunu göstermektedir.




Şekil 5. Frame-level confusion matrix.



Şekil 6. Frame-level ROC eğrisi.



Şekil 7. Frame-level Precision-Recall eğrisi.




Şekil 8. Test decision score dağılımı.

7. Nihai Test Sonuçları - Video Level


Metrik	Video-level test
Accuracy	0.5000
Precision	0.5000
Recall	1.0000
F1	0.6667
Specificity	0.0000
ROC-AUC	1.0000
Average Precision	1.0000

Video-level sonuçlarda ROC-AUC ve Average Precision 1.0 görünmesine rağmen accuracy 0.5, specificity 0.0 ve recall 1.0'dır. Bu görünürde çelişkili tablo, video örnek sayısının çok küçük olmasına ve karar threshold'unun tüm videoları FAKE yönünde sınıflandırmasına karşılık skor sıralamasının yine de sınıfları doğru sıraya koyabilmesine bağlanabilir.


Data accounting dosyasında source_video_count train/val/test için yalnızca 2'şer video olarak raporlanmıştır. Bu nedenle video-level ROC-AUC=1.0 sonucu genellenebilir güçlü performans kanıtı olarak yorumlanmamalıdır; örnek sayısı son derece küçüktür.



Şekil 9. Video-level confusion matrix.



Şekil 10. Video-level ROC eğrisi.



Şekil 11. Video-level Precision-Recall eğrisi.

8. Frame ve Video Sonuçlarının Karşılaştırılması

Değerlendirme	Accuracy	Precision	Recall	F1	Specificity	ROC-AUC	AP
Frame	0.560	0.544	0.917	0.683	0.178	0.623	0.595
Video	0.500	0.500	1.000	0.667	0.000	1.000	1.000

Frame seviyesinde daha çok örnek bulunduđu için metrikler daha anlamlı bir performans resmi sunar. Video seviyesindeki 1.0 ROC-AUC değeri, veri sayısının çok küçük olması nedeniyle dikkatle ele alınmalıdır. Özellikle specificity=0 olması, seçilen threshold ile bütün video kararlarının FAKE tarafına kaydığını gösterir.

9. Deney Sonucunun Genel Yorumu

Olumlu taraflar. Hibrit yapı sahte örnekleri kaçırmama açısından yüksek recall üretmiştir; validation recall 0.9645, frame-level test recall 0.9167 ve video-level recall 1.0'dır. VGG16 öğrenilmiş özelliklerine HOG ve Gabor tabanlı doku özelliklerinin eklenmesi, tek başına CNN eğitimindeki zayıf/dalgali davranışa rağmen SVM aşamasında kullanılabilir bir ayırım sinyali sağlamıştır.

Sınırlamalar. Frame-level specificity yalnızca 0.1781'dir. Bu nedenle model gerçek örneklerde yüksek yanlış alarm üretmektedir. ROC-AUC 0.6226 da sınıflar arasında orta-alt düzeyde ayırım gücüne işaret eder. Video-level metrikler ise yalnızca çok az video üzerinden üretildiğinden genellenebilir değildir.

Nihai sonuç. VGG16-scratch + HOG + GIST-style Gabor + RBF SVM yaklaşımı göz ROI'sinden deepfake sinyali çıkarabilmektedir ve FAKE yakalama duyarlılığı yüksektir; ancak dengeli gerçek/sahte sınıflandırma performansı sınırlıdır. Deney, özellikle specificity ve threshold kalibrasyonu yönünden iyileştirmeye ihtiyaç duymaktadır. Video-level sonuçlar küçük video sayısı nedeniyle yalnızca yardımcı/keşifsel bulgu olarak sunulmalıdır.