

DenseNet121 ile Ağız ROI Deepfake Tespiti - Deney ve Sonuç Analiz Raporu

Amaç, literatür dayanağı, deney protokolü, eğitim davranışı, bağımsız test sonuçları ve bilimsel yorum

Belge kapsamı

Gerçek deney çıktılarından oluşturulmuş sonuç raporudur. DFT-MF literatür bağlantısını, DenseNet121 seçimini, veri/protokol güvenliğini, eğitim eğrilerini, görüntü ve kaynak düzeyi metrikleri, sınırlılıkları ve sonraki araştırma adımlarını kapsar.

Alan	Değer
Run ID	20260808_0856_mouth_densenet121_seed42
Notebook	DenseNet121_Mouth_Deepfake_Colab_FIXED.ipynb
Model	ImageNet ön eğitilmiş DenseNet121
Veri	2.987 ağız ROI: 2.389 train, 296 validation, 302 test
Hazırlayan	Dilara Öztürk
Tarih	8 Ağustos 2026

Bu rapor, yüklenen notebook ve doğrulanmış deney ZIP paketindeki gerçek konfigürasyon, log, metrik, tahmin ve grafiklerden hazırlanmıştır.

Özet

Bu deneyde yalnızca ağız bölgesinden kırılmış 2.987 ROI görüntüsü kullanılarak gerçek/sahte deepfake sınıflandırması yapılmıştır. ImageNet ön eğitilmiş DenseNet121 önce sabit özellik çıkarıcı olarak, ardından son dense block kontrollü biçimde açılarak fine-tuning ile eğitilmiştir. Model seçimi validation ROC-AUC üzerinden yapılmış; karar eşiği yalnız validation kümesinde Youden J ölçütüyle 0,508568 olarak belirlenmiştir. Bağımsız 302 görüntülük test kümesinde accuracy %69,54, F1 %72,46, ROC-AUC %76,08 ve PR-AUC %74,93 elde edilmiştir.

Ana bulgu

Fine-tuning validation ROC-AUC'yi 0,7335'ten 0,7800'a yükseltmiş; testte recall %77,56 ile sahte örneklerin çoğu yakalanmış, ancak specificity %60,96 düzeyinde kaldığı için gerçek örneklerde yanlış alarm alanı sürmüştür.

Anahtar kelimeler: deepfake, ağız ROI, diş dokusu, DenseNet121, transfer learning, fine-tuning, biyometrik bölge, ROC-AUC.

1. Amaç ve araştırma sorusu

Araştırma sorusu, tam yüz yerine yalnız ağız ve diş bölgesinin deepfake sentezleme izlerini ne ölçüde taşıdığı ve DenseNet121'in bu izleri küçük bir veri setinde transfer learning ile öğrenip öğrenemeyeceğidir. Deney ayrıca daha önce tamamlanan Xception yaklaşımından farklı bir yoğun bağlantı temsili karşılaştırma amacı taşır.

2. Literatür dayanağı ve model seçimi

Elhassan ve arkadaşlarının DFT-MF çalışması, ağız ve diş karelerini deepfake üretiminde kusursuz sentezlenmesi zor biyolojik işaretler olarak ele alır ve DenseNet121 dahil çeşitli transfer-learning modellerini bu bölge üzerinde karşılaştırır [1]. Bu doğrudan konu uyumu, DenseNet121 seçiminin temel literatür gerekçesidir.

DenseNet mimarisi, bir dense block içindeki her katmana önceki katmanların özellik haritalarını kanal boyutunda birleştirerek verir. Bu düzen gradyan akışını kolaylaştırır, özellik yeniden kullanımını teşvik eder ve düşük/orta/yüksek seviyeli temsilleri sonraki katmanlara taşır [2]. Ağız ROI bağlamında bu özellikler; dudak sınırları, diş kenarları, ağız-cilt geçişleri, bulanıklık, doku süreksizliği ve birleşik ağız içi biçim örüntülerini kapsayabilir.

Sonuç aktarımı uyarısı

DFT-MF'de raporlanan yüksek DenseNet121 başarısı bizim veri setimiz için beklenti veya garanti değildir. Dataset, kare seçimi, sıkıştırma ve split protokolü farklı olduğundan yalnızca model seçimine literatür dayanağı olarak kullanılır.

2.1. Neden custom CNN değil?

2.987 görüntü, sıfırdan eğitilen bir CNN için sınırlıdır. ImageNet ön eğitimi kenar, doku ve biçim gibi genel görsel temsilleri hazır getirir. İki aşamalı eğitim, önce küçük başlığı öğrenip ardından üst düzey DenseNet özelliklerini ağız artefaktlarına düşük öğrenme oranıyla uyarlayarak aşırı öğrenme riskini kontrol eder.

3. Veri seti ve kalite güvence protokolü

Split	Real	Fake	Toplam	Oran
Train	1.197	1.192	2.389	%79,11
Validation	155	141	296	%9,80
Test	146	156	302	%10,00
Toplam	1.498	1.489	2.987	%100

Sınıf dağılımı dengelidir; bu nedenle accuracy tek başına yanıltıcı olacak ölçüde sınıf dengesizliği yoktur. Yine de hata yönünü görebilmek için balanced accuracy, recall, specificity, F1 ve MCC raporlanmıştır.

Kalite kontrolü	Sonuç	Yorum
Metadata muhasebesi	3.098 = 2.987 SUCCESS + 111 SKIPPED	Hiçbir kayıt sessizce kaybolmadı
Kaynak kesişimi	Tüm split çiftlerinde 0	Kaynak kimliği izolasyonu
SHA-256 kesişimi	Tüm split çiftlerinde 0	Aynı PNG içeriği splitler arasında yok
Test izolasyonu	PASS	Eşik/model seçimi validation'da
Grafik kalite kapağı	PASS	Kısa kenar 726-1.626 px

Metadata 3.000 benzersiz kaynak kimliği içerirken model manifestinde 2.889 benzersiz kaynak vardır; bazı kaynaklardan birden fazla yüz ROI'si üretildiği için görüntü sayısı kaynak sayısından yüksektir. Testte 302 görüntü, kaynak bazında olasılık ortalaması alındığında 292 kayda indirgenmiştir.

4. Deney yöntemi

Bileşen	Ayar
Girdi	224x224 RGB ağız ROI
Backbone	DenseNet121, ImageNet, include_top=False
Başlık	GlobalAveragePooling2D -> Dropout(0,40) -> Dense(1, sigmoid)
Batch	16
Seed	42
Mixed precision	mixed_float16; çıktı float32
Frozen LR	1e-3; ReduceLROnPlateau ile 5e-4
Fine-tuning LR	1e-5
Model seçimi	Maksimum validation ROC-AUC
Eşik	Validation Youden J

Frozen aşama 12 epoch, fine-tuning aşaması 10 epoch sürmüştür. Son dense block açılırken Batch Normalization katmanları donmuş tutulmuştur. Global best model, fine-tuning aşamasının 21. epochunda validation ROC-AUC 0,779959 ile kaydedilmiştir.


4.1. Ön işleme ve augmentation

Bütün görüntüler DenseNet girişine uygun normalize edilmiştir. Yalnız train splitinde horizontal flip, küçük rotation, zoom, translation ve contrast dönüşümleri kullanılmıştır. Validation/test üzerinde augmentation uygulanmamıştır.

Deney güvenliği

Best/last tam model, iki ayrı BackupAndRestore alanı, atomik checkpoint doğrulaması ve temiz yükleme inference testi başarıyla tamamlanmıştır.

5. Eğitim davranışı



Şekil 1. Frozen ve fine-tuning aşamalarında loss, ROC-AUC ve accuracy eğrileri. Dikey kesikli çizgi fine-tuning başlangıcını gösterir.

Frozen aşamada validation ROC-AUC ilk epochta 0,6779'dan 9. epochta 0,7335'e yükselmiştir. 10-12. epochlarda belirgin ilerleme olmaması, yalnızca başlığın kapasitesinin sınıra yaklaştığını gösterir. Fine-tuning ile training AUC 0,6876'dan 0,7798'e, validation AUC ise 0,7380'den 21. epochta 0,7800'a çıkmıştır.

22. epochta training AUC yükselmeye devam ederken validation AUC 0,7755'e hafif gerilemiştir. Bu nedenle global best olarak 21. epochun seçilmesi uygundur. Training-validation eğrileri arasında aşırı büyük kopma görülmemekle birlikte daha büyük ve kimlik çeşitliliği yüksek veriyle dış doğrulama gereklidir.

6. Bağımsız test sonuçları


Metrik	Görüntü düzeyi	Kaynak düzeyi
Örnek sayısı	302	292
Accuracy	%69.54	%69.52
Balanced accuracy	%69.26	%69.47
Precision	%67.98	%67.06
Recall	%77.56	%77.55
Specificity	%60.96	%61.38
F1-score	%72.46	%71.92
ROC-AUC	%76.08	%75.65
PR-AUC	%74.93	%72.98
MCC	0.391	0.395

Görüntü ve kaynak düzeyi accuracy değerlerinin neredeyse aynı olması, çoklu ROI ortalamasının genel kararı kökten değiştirmediyi gösterir. Kaynak düzeyinde false positive 57'den 56'ya, false negative 35'ten 33'e düşmüştür; ancak kaynak sayısı da 302'den 292'ye iner.

Pratik yorum

Model sahte örnekleri yakalamada görece güçlüdür (recall %77,56), ancak gerçek örneklerin %39,04'ünü yanlışlıkla fake olarak işaretler. Bu nedenle tek başına kesin karar verici olmaktan çok, başka yüz bölgeleri veya zamansal sinyallerle birleşen bir bileşen olarak daha uygundur.

7. Confusion matrix analizi




Şekil 2. Görüntü ve kaynak düzeyi bağımsız test confusion matrix sonuçları.

Gerçek sınıf	Doğru	Yanlış	Yorum
Real (146)	TN=89	FP=57	Gerçek örneklerde %60,96 özgüllük
Fake (156)	TP=121	FN=35	Sahte örneklerde %77,56 duyarlılık

Hata dağılımı fake sınıfı lehine asimetriktir: model sahte örnek kaçırmaktan ziyade gerçek örneklerle yanlış alarm verme eğilimindedir. Güvenlik odaklı bir tarama senaryosunda yüksek recall tercih edilebilir; ancak yanlış alarm maliyeti yüksekse eşik, yalnız validation verisi kullanılarak farklı bir maliyet fonksiyonuna göre yeniden belirlenmelidir. Mevcut test sonucuna bakarak eşik değiştirmek protokol ihlalidir.

8. ROC ve Precision-Recall analizi




Şekil 3. Görüntü düzeyi test ROC ve Precision-Recall eğrileri.

ROC-AUC 0,7608, modelin rastgele seçilen bir fake örneğe rastgele seçilen bir real örnekten daha yüksek fake skoru verme olasılığının yaklaşık %76 olduğunu ifade eder. PR-AUC 0,7493, pozitif sınıf olan fake açısından precision-recall dengesinin orta-iyi düzeyde olduğunu gösterir.

ROC-AUC'nin accuracy'den yüksek görünmesi çelişki değildir: AUC tüm olası eşiklerdeki sıralama kalitesini, accuracy ise tek bir karar eşiğindeki doğru sınıflandırma oranını ölçer. Bu model olasılık sıralamasında kullanılabilir bilgi taşımakta, fakat sınıflar tam ayrışmadığı için tek eşikte hatalar kalmaktadır.

9. Olasılık dağılımı ve eşik



Şekil 4. Real ve fake test örneklerinin tahmin edilen fake olasılık dağılımları; kesikli çizgi validation eşiğidir.

Real ve fake dağılımlarında ayrışma olmakla birlikte belirgin örtüşme vardır. Bu örtüşme 57 false positive ve 35 false negative hatanın görsel karşılığıdır. Eşik 0,508568 ile varsayılan 0,5 birbirine çok yakındır; bu nedenle seçilen eşiğin test accuracy'si %69,54 ile aynı kalmış, recall %78,21'den %77,56'ya inerken specificity %60,27'den %60,96'ya yükselmiştir.

Kalibrasyon notu

Sigmoid çıktısı sınıflandırma skoru olarak kullanılmıştır; mutlak olasılık kalibrasyonu ayrıca ECE, Brier score veya reliability diagram ile test edilmemiştir. 0,8 skorunun gerçek dünyada tam %80 güven anlamına geldiği varsayılmamalıdır.

10. Tartışma

Sonuçlar ağız ROI'nin tek başına rastgele seviyenin belirgin üzerinde bilgi taşıdığını göstermektedir. DenseNet121'in yoğun bağlantıları, ince doku ve kenar örüntülerini yeniden kullanarak Xception'dan farklı bir temsil sunar. Fine-tuning kazanımı, ImageNet temsillerinin ağız/diş deepfake işaretlerine uyarlanmasının gerekli olduğunu destekler.

Bununla birlikte %69,54 accuracy, yalnız ağız bölgesinin bütün deepfake türleri ve gerçek dünya koşulları için yeterli olmadığını gösterir. Sıkıştırma, çözünürlük, dış görünürlüğü, ağız açıklığı, konuşma durumu ve ROI kalitesi performansı etkileyebilir. Model spatial kare özellikleri kullanır; ağız hareketinin zaman içindeki tutarlılığını doğrudan modellemez.

Güçlü yön	Sınırlılık
Doğrudan ağız/diş literatürüne dayalı model seçimi	Tek veri kaynağı ve sınırlı örnek sayısı
Video/kaynak ve SHA-256 sızıntı kontrolü	Dış veri setinde cross-dataset test yok
Validation-only model/eşik seçimi	Zamansal ağız hareketi modellenmedi
Görüntü ve kaynak düzeyi ayrı raporlama	Specificity %60,96; yanlış alarm görece yüksek
Atomik checkpoint, recovery ve temiz inference testi	Grad-CAM/kalibrasyon analizi henüz yok

11. Sonuç ve öneriler

DenseNet121 ağız ROI deneyinde en iyi validation ROC-AUC 0,7800, bağımsız test ROC-AUC 0,7608 ve F1 0,7246 elde edilmiştir. Model sahte örnekleri yakalamada gerçek örnekleri korumaya göre daha başarılıdır. Sonuçlar, ağız/diş bölgesinin deepfake tespitinde yararlı ama tek başına sınırlı bir biyometrik alt bölge olduğunu destekler.

Sıradaki kontrollü karşılaştırma aynı split, seed, ön işleme ve metriklerle EfficientNetB0; hesaplama maliyeti/gerçek zamanlılık odağı için MobileNetV2 olabilir. Ayrıca hata analizi, Grad-CAM, ağız açıklığına göre alt grup performansı, kalibrasyon ve dış veri seti testi önerilir.

12. Raporlanabilir sonuç paragrafı

Akademik yazım örneği

ImageNet ön eğitimli DenseNet121 modeli, 2.389 eğitim, 296 doğrulama ve 302 bağımsız test ağız ROI görüntüsü üzerinde iki aşamalı transfer learning ile eğitilmiştir. Model seçimi validation ROC-AUC, karar eşiği ise yalnız validation kümesinde Youden J ölçütü kullanılarak yapılmıştır. En iyi model 21. epochta 0.7800 validation ROC-AUC değerine ulaşmıştır. Bağımsız testte accuracy 0.6954, precision 0.6798, recall 0.7756, F1 0.7246, ROC-AUC 0.7608 ve PR-AUC 0.7493 olarak ölçülmüştür. Kaynak-video ve SHA-256 kesişim kontrollerinde splitler arasında sızıntı tespit edilmemiştir.

13. Kaynakça

- [1] Elhassan, A., Al-Fawa'reh, M., Jafar, M. T., Ababneh, M., & Jafar, S. T. (2022). DFT-MF: Enhanced deepfake detection using mouth movement and transfer learning. SoftwareX, 19, 101115. <https://doi.org/10.1016/j.softx.2022.101115>
- [2] Huang, G., Liu, Z., van der Maaten, L., & Weinberger, K. Q. (2017). Densely Connected Convolutional Networks. Proceedings of CVPR, 4700-4708. <https://arxiv.org/abs/1608.06993>
- [3] Keras Applications. DenseNet model API. <https://keras.io/api/applications/densenet/>

Not: Bu rapordaki sayısal sonuçlar yüklenen final_evaluation_summary.json, CSV metrikleri ve test tahminlerinden alınmıştır; DFT-MF sonucu ile doğrudan yüzde karşılaştırması yapılmamıştır.