EfficientNet_B0_Agiz_ROI_Deney_Sonuc_Raporu.pdf - local repository text copy

DENEY RAPORU
EFFICIENTNET-B0 AĞIZ ROI
DENEYİ
Amaç, Yöntem, Bulgular ve Sonuç Raporu
MODEL
GİRDİ
SINIFLAR
EfficientNet-B0
Ağız ROI
Real / Fake
Deney kimliği
Run ID: 20260808_1257_mouth_efficientnet_b0_seed42
Seed: 42 | Görüntü: 224x224 RGB | Toplam örnek: 2.987
Hazırlanma tarihi: 8 Ağustos 2026
Bu rapor, tamamlanan Colab çalıştırmasının gerçek metrikleri ve kaydedilmiş deney tasarımı temel alınarak hazırlanmıştır.

Yönetici özeti
Bu deneyde 2.987 ağız ROI görüntüsü kullanılarak gerçek ve sahte yüz karelerini ayıran EfficientNet-B0 tabanlı bir model geliştirilmiştir. ImageNet ön-eğitimli model önce dondurulmuş omurga ile, ardından tüm katmanlar açılarak fine-tuning yaklaşımıyla eğitilmiştir. Validation setinden seçilen 0,19 karar eşiği
302 örnekli test setine uygulanmıştır.
Accuracy
F1
ROC-AUC
Recall
%71,52
%76,76
%83,32
%91,03
Ana bulgu
Model testte ROC-AUC=0,8332 ve average precision=0,8528 elde etmiştir. Fake örnekleri yakalama oranı yüksektir (recall=%91,03); buna karşılık real örnekleri doğru tanıma oranı daha düşüktür (specificity=%50,68).
Çalışma, ağız bölgesindeki görsel izlerin deepfake ayrımı için anlamlı sinyal taşıdığını göstermektedir. Ancak seçilen F1 odaklı eşik yanlış pozitifleri artırmıştır; kullanım senaryosuna göre eşik yeniden dengelenebilir.
Deney kimliği
Alan
Değer
Run ID
20260808_1257_mouth_efficientnet_b0_seed42
Model
torchvision EfficientNet-B0
ROI
Mouth / ağız
Sınıflar
real=0, fake=1
Seed
42
Cihaz
CPU
Tamamlanma
24/24 hücre, inference reload PASSED

1. Amaç ve araştırma sorusu
Deneyin amacı, yalnızca ağız bölgesi kırpımlarından yararlanarak bir görüntünün gerçek veya deepfake

olup olmadığını sınıflandırmaktır. Böylece yüzün tamamı yerine lokal bir anatomik bölgenin ayırt edici gücü ölçülür.

Araştırma sorusu

Soru

ImageNet ön-eğitimli EfficientNet-B0, ağız ROI görüntülerinde bulunan sentezleme izlerini öğrenerek real/fake ayrımını güvenilir biçimde yapabilir mi?

Beklenti

Deepfake üretiminde dudak sınırı, diş görünümü, ağız içi doku, keskinlik geçişleri, renk uyumsuzlukları ve lokal birleştirme artefaktları oluşabilir. EfficientNet-B0'ın çok ölçekli evrişimsel özelliklerinin bu izleri öğrenmesi beklenmiştir.

Kapsam

• Analiz birimi frame içindeki ağız ROI görüntüsüdür.
• Zamansal dudak hareketi veya video dizisi modellenmemiştir.
• Deney frame düzeyinde ikili sınıflandırma yapar.
• Nihai test eşiği test verisinden değil validation verisinden seçilmiştir.

Bu ayrım önemlidir: model ağız hareket dinamiğini değil, tek karede görülen ağız bölgesi görsel ipuçlarını kullanır.

2. Veri seti ve deney bölmesi

Split	Real	Fake	Toplam	Pay
Train	1.197	1.192	2.389	%79,98
Validation	155	141	296	%9,91
Test	146	156	302	%10,11
Toplam	1.498	1.489	2.987	%100

Sınıf dengesi

Toplam dağılım yaklaşık dengelidir: real 1.498 (%50,15), fake 1.489 (%49,85). Bu nedenle ağır sınıf dengesizliği düzeltmesi kullanılmamıştır. Train, validation ve test alt kümelerinde de sınıflar birbirine yakındır.

Veri güvenliği

• sample_id ve dosya yolu tekilliği True olarak doğrulandı.
• 2.987/2.987 görüntü dosyası cache'e eksiksiz alındı.
• Splitler arası yol ve metadata video_id kesişimleri kontrol edildi.
• Test seti threshold seçimi veya model seçimi için kullanılmadı.

Ön işleme

Aşama	Ayar
Renk	RGB
Boyut	224x224
Train augmentation	Horizontal flip p=0,5; brightness/contrast 0,10
Validation/test	Augmentation yok

Normalizasyon
ImageNet mean/std
Karşılaştırılabil
irlik
Göz ROI taban çizgisindeki mimari ve temel ön işleme korunmuş,
yalnızca ROI girdisi ağıza çevrilmiştir. Böylece bölgesel etkinin daha adil
karşılaştırılması hedeflenmiştir.

3. Yöntem
EfficientNet-B0, ImageNet ön-eğitimli ağırlıklarla başlatılmıştır. Orijinal sınıflandırıcı tek logit
üreten
Dropout(0,2) + Linear başlığıyla değiştirilmiştir. Kayıp BCEWithLogitsLoss, optimizer AdamW'dur.
Bileşen
Ayar
Toplam parametre
4.008.829
Çıkış
P(fake) için tek logit
Loss
BCEWithLogitsLoss
Optimizer
AdamW, weight decay=1e-4
Scheduler
ReduceLROnPlateau, factor=0,5, patience=2
Early stopping
Patience=4
Gradient clipping
1,0
Hesaplama
FP32
3.1 Stage 1: Frozen backbone
EfficientNet özellik omurgası dondurulmuş ve yalnızca 1.281 parametreli sınıflandırıcı 5 epoch, LR=1e-3
ile eğitilmiştir. Amaç, ön-eğitimli genel özellikleri bozmadan yeni real/fake karar başlığını ağız ROI
dağılımına uyarlamaktır.
3.2 Stage 2: Full fine-tuning
Stage 1'in en iyi checkpoint'i yüklenmiş, tüm 4.008.829 parametre açılmış ve LR=2e-5 ile fine-tuning
yapılmıştır. Düşük öğrenme oranı, ön-eğitimli temsilleri korurken ağız bölgesine özgü filtre uyarlamasını
destekler.
3.3 Model ve eşik seçimi
Epoch seçimi validation ROC-AUC ile yapılmıştır. Final best checkpoint üzerinde validation olasılıkları
alınmış, eşik aramasında önce F1, sonra balanced accuracy, ardından 0,5'e yakınlık sıralanmıştır.
Seçilen eşik 0,19'dur.
3.4 Güvenilirlik kontrolleri
- İki batch smoke test: forward, backward ve gradient PASSED.
- Her epoch atomik last.ckpt; iyileşmede best.ckpt.
- RNG durumu ve optimizer/scheduler state saklama.
- En iyi checkpoint'i yeni model nesnesinde yükleyerek inference reload PASSED.

4. Eğitim bulguları
Aşama
Başlangıç val AUC
En iyi val AUC
Değişim
Frozen
0,71229
0,75484
+0,04255
Fine-tuning
Stage 1 best
0,79689
+0,04205
Toplam
0,71229
0,79689

+0,08460
Frozen aşamada classifier giderek daha iyi ayrım öğrenmiştir. Beşinci epoch validation ROC-AUC=0,75484 ile en iyi frozen checkpoint'i üretmiştir. Fine-tuning, omurganın ağız bölgesindeki lokal doku ve sınır örüntülerine uyarlanmasıyla validation AUC'yi 0,79689'a taşımıştır.
Gözlenen genelleme
Test ROC-AUC değerinin 0,83316 ile validation ROC-AUC değerinden yüksek olması, test örneklerinin model tarafından daha iyi sıralandığını gösterir. Bu tek başına veri kaçağı kanıtı değildir; sınırlı örneklemde split zorluklarının farklı olmasıyla açıklanabilir. Yine de sonuçlar farklı seed ve çapraz doğrulama ile doğrulanmalıdır.
Overfitting değerlendirmesi
Fine-tuning geçmişinin son görünen epochunda train ROC-AUC yaklaşık 0,933 iken validation ROC-AUC yaklaşık 0,789'dur. Bu fark, modelin eğitim örneklerine daha güçlü uyum sağladığını ve düzenlileştirme/erken durdurmanın önemli olduğunu gösterir. Nihai model son epoch değil, en yüksek validation AUC üreten best.ckpt'tir.
Doğru model
seçimi
Nihai test, last.ckpt yerine finetune/best.ckpt üzerinde yapılmıştır. Bu, son epoch dalgalanmalarının test sonucunu bozmasını önler.

5. Nihai test sonuçları
Accuracy
F1
ROC-AUC
Recall
%71,52
%76,76
%83,32
%91,03
Acc
Bal.Acc
Prec
Recall
F1
Spec
AUC
AP
0
20
40
60
80
100
Nihai Test Metrikleri (%)
Metrik
Değer
Threshold
0,19
Accuracy
0,71523
Balanced accuracy
0,70855
Precision
0,66355
Recall
0,91026
F1
0,76757
Specificity
0,50685
ROC-AUC
0,83316
Average precision
0,85277

6. Confusion matrix ve hata analizi
Test Confusion Matrix (eşik = 0,19)
74
72
14
142
Real
Fake
Tahmin
Real
Fake
Gerçek
Sonuç
Adet
Yorum
TN
74
Real örnek doğru real
FP
72
Real örnek yanlış fake
FN
14
Fake örnek yanlış real
TP
142
Fake örnek doğru fake
Fake sınıfındaki 156 örneğin 142'si doğru yakalanmış, yalnızca 14'ü kaçırılmıştır. Bu nedenle recall yüksektir. Buna karşılık 146 real örneğin 72'si fake olarak işaretlenmiş, specificity yaklaşık %50,68'de kalmıştır.
Eşiğin etkisi
0,19 eşiği düşük olduğu için model fake kararını daha kolay verir. Bu, güvenlik/tarama senaryosunda sahte içeriği kaçırmama açısından yararlı olabilir; ancak yanlış alarm sayısını artırır. Eşiği yükseltmek specificity ve precision'ı artırabilir, recall'ı düşürür.
Kullanım
senaryosu
Ön eleme sistemi için yüksek recall tercih edilebilir. Otomatik engelleme
veya kesin karar sistemi için specificity ve kalibrasyon iyileştirilmeden
tek başına kullanılmamalıdır.

7. Sonuçların bilimsel yorumu
ROC-AUC=0,8332, modelin rastgele sıralamanın belirgin biçimde üzerinde olduğunu ve ağız ROI içinde ayırt edici deepfake sinyali bulunduğunu gösterir. Average precision=0,8528, fake sınıfına yönelik precision-recall performansının da güçlü olduğunu destekler.
Accuracy neden tek başına yeterli değil?
Accuracy %71,52 olmasına rağmen recall ve specificity arasında büyük fark vardır. Dengeli sınıflarda bile tek accuracy değeri hangi hata türünün baskın olduğunu gizler. Bu deneyde ana hata türü false positive'dir; yani gerçek ağız görüntülerinin sahte sanılmasıdır.
Ağız ROI ne öğrenmiş olabilir?
• Dudak kenarı ve yüz derisi arasında keskinlik/renk geçişleri.
• Diş ve ağız içi dokulardaki sentez artefaktları.
• Sıkıştırma ve yeniden örnekleme izleri.
• Lokal doku tutarsızlıkları ve blending sınırları.
Bunlar modelin kesin açıklaması değildir; Grad-CAM veya benzeri açıklanabilirlik analizi yapılmadan yalnızca makul hipotezlerdir.
Validation-test farkı
Test AUC'nin validation AUC'den yaklaşık 0,036 yüksek olması olumlu olsa da tek split üzerinden genellenmemelidir. 302 test örneği sonuç belirsizliği taşır. Video veya kişi düzeyinde bootstrap güven aralıkları, çoklu seed ve harici veri seti testi daha güçlü kanıt sağlar.

8. Güçlü yönler
• Dengeli real/fake veri dağılımı.
• Testten bağımsız validation threshold seçimi.
• Best checkpoint ile final değerlendirme.

• Atomik checkpoint ve resume desteği.
• NaN/Inf, gradient ve accounting kontrolleri.
• Örnek bazlı test tahminlerinin saklanması.
• 600 DPI, ortak renk paletli altı grafik.
• Reload/inference kalite kapısı ve çıktı manifesti.

9. Sınırlılıklar

• Frame tabanlıdır; dudak hareketlerinin zamansal dinamiğini modellemez.
• Tek run ve tek seed sonucu raporlanmıştır.
• Test seti 302 örnekle sınırlıdır.
• Fine-tuning train-validation farkı overfitting olasılığına işaret eder.
• Specificity düşüktür ve false positive sayısı yüksektir.
• Olasılık kalibrasyonu ayrıca ölçülmemiştir.
• Harici veri setinde domain genellemesi test edilmemiştir.
• ROI'ler aynı video/kişiden gelebileceği için sonuçlar bağımsız frame varsayımıyla istatistiksel güven aralığına dönüştürülmemelidir.

Bu sınırlılıklar sonucu geçersiz kılmaz; elde edilen performansın hangi kapsamda yorumlanması gerektiğini belirler.

10. Önerilen sonraki çalışmalar

Öncelik	Çalışma	Beklenen katkı
1	3-5 farklı seed ile tekrar	Sonucun rastgeleliğe duyarlılığını ölçer
2	Video/kişi düzeyinde bootstrap CI	Belirsizliği doğru örnekleme biriminde raporlar
3	Threshold kullanım senaryosu analizi	Recall-specificity maliyetini dengeler
4	Temperature scaling veya isotonic calibration	Olasılıkların güvenilirliğini artırır
5	Grad-CAM hata analizi	Modelin ağız içinde nereye baktığını inceler
6	Harici veri seti testi	Domain genellemesini sınar
7	Video düzeyi birleştirme	Frame tahminlerini video kararına dönüştürür
8	Göz/kaş/ağız bölge karşılaştırması	Hangi ROI'nin daha ayırt edici olduğunu ölçer

11. Nihai sonuç

EfficientNet-B0 ağız ROI deneyi teknik olarak eksiksiz tamamlanmıştır. Model, 302 örnekli test setinde ROC-AUC=0,8332 ve F1=0,7676 elde etmiş; fake sınıfında %91,03 recall göstermiştir. Bulgular, ağız bölgesinin deepfake tespitinde anlamlı görsel ipuçları taşıdığını destekler.

Bununla birlikte specificity=%50,68 ve 72 false positive, seçilen eşiğin gerçek örnekleri korumada yetersiz kaldığını gösterir. Bu nedenle model, mevcut haliyle yüksek duyarlılıklı bir tarama bileşeni olarak değerlendirilmeli; kesin karar uygulamasından önce threshold maliyet analizi, kalibrasyon, çoklu seed ve harici doğrulama yapılmalıdır.

Deney durumu

EXPERIMENT COMPLETE | 24/24 hücre | 26 çıktı dosyası | 6 adet 600 DPI grafik | Inference reload PASSED

Kaydedilen ana çıktı klasörü

Deney1_Source/AISC Çalışmalar/Deneyler/Dilara/Deney 1/Sonuçlar/20260808_1257_mouth_efficientnet_b0_seed42