

AĞIZ BÖLGESİ ÜZERİNDEN DEEPPFAKE TESPİTİ

Deney 1 - Sonuç ve Değerlendirme Raporu Xception (ImageNet Transfer Learning + Fine-Tuning)

Kodun amacı, deney mantığı, model mimarisi ve üretilen çıktılar

Deney klasörü	Dilara / Deney 1
Bölge	Mouth ROI
Nihai model	Fine-tuned Xception
Tamamlanma durumu	COMPLETED

Çalışma ortamı: Google Colab / TensorFlow / Keras
Ağustos 2026

1. Yönetici Özeti


Temel sonuç

Nihai fine-tuned Xception modeli 302 örnekli bağımsız test kümesinde %70,20 accuracy, 0,7222 F1-score ve 0,7662 ROC-AUC elde etmiştir. FAKE recall değeri %75,00 iken REAL specificity %65,07'dir. Model, sahte ağız görüntülerini yakalamada gerçek örnekleri doğru tanımaya göre daha başarılıdır.

Deney iki aşamalı transfer learning ile yürütülmüştür. Frozen-backbone aşamasında en iyi validation AUC 0,7280 iken fine-tuning sonrasında 0,8228'e yükselmiştir. Bu artış, Xception'ın üst katmanlarının ağız bölgesine özgü veriye adapte edilmesinin validation ayırma gücünü belirgin şekilde geliştirdiğini göstermektedir. Test ROC-AUC'nin 0,7662'ye gerilemesi ise validation-test genelleme farkının ayrıca izlenmesi gerektiğini gösterir.

2. Deney Tasarımı ve Veri Yapısı

Split	Fake	Real	Toplam
Train	1192	1197	2389
Validation	141	155	296
Test	156	146	302
Toplam	1489	1498	2987



Şekil 1. Geçerli Mouth ROI örneklerinin split ve sınıfa göre dağılımı.

ROI başarı oranı

3000 başlangıç frame'inden 2987 tanesinde geçerli Mouth ROI elde edilmiştir. 13 örnek kullanılamamış; kayıp oranı yaklaşık %0,43, başarı oranı yaklaşık %99,57 olmuştur.

2.1 Kaynak-Video İzolasyonu ve Leakage Kontrolü

Model sonuçlarının güvenilirliğini doğrulamak için frame'lerin yalnızca dosya adına göre değil, geldikleri kaynak video düzeyinde de Train / Validation / Test ayrımı kontrol edilmiştir. Metadata içindeki orijinal_yol alanından kaynak video kimliği çıkarılmış ve aynı kaynak videonun birden fazla splitte bulunup bulunmadığı incelenmiştir.

Split	Benzersiz kaynak video
Train	1620
Validation	197
Test	201

Splitler Arası Kaynak-Video Örtüşmesi

Karşılaştırma	Ortak kaynak video sayısı
Train ↔ Validation	0
Train ↔ Test	0
Validation ↔ Test	0

Kontrol Sonucu

Source-video leakage bulunmamıştır. Train, Validation ve Test kümelerindeki kaynak videolar birbirinden tamamen ayrıdır. Başka bir ifadeyle, aynı videodan alınan farklı frame'lerin farklı splitlere dağılması nedeniyle oluşabilecek yapay performans artışı bu kontrolde gözlenmemiştir.

Bu Neden Önemli?

Deepfake çalışmalarında aynı videodan gelen birbirine çok benzeyen frame'lerin hem eğitim hem test kümesine girmesi, modelin gerçek genelleme yeteneği yerine videoya özgü ayrıntıları ezberlemesine yol açabilir. Bu nedenle video-level izolasyon, frame tabanlı bir deneyin metodolojik güvenilirliğini artıran önemli bir kontroldür.

Deney açısından yorum: Xception Mouth ROI modelinin test ROC-AUC = 0,7662 ve accuracy = %70,20 sonuçları, tespit edilen bir kaynak-video sızıntısıyla açıklanamamaktadır. Böylece bağımsız test sonuçlarının yorumlanması için daha güçlü bir deneysel dayanak elde edilmiştir.

Rapor güncellemesi: Önceki sürümde “kaynak-video bağımsızlığı ayrıca metadata düzeyinde doğrulanmalı” bir sonraki adım olarak belirtilmişti. Bu kontrol artık gerçekleştirilmiş ve Train / Validation / Test arasında kaynak-video overlap değerlerinin tamamının 0 olduğu doğrulanmıştır.

3. Kullanılan Model ve Deney Mantığı

3.1 Neden Mouth ROI?

Ağız bölgesi dudak sınırları, ağız köşeleri, dış/ağız içi yapısı, cilt-dudak geçişleri ve konuşmayla değişen geometrisi nedeniyle deepfake sentezinde lokal tutarsızlıkların kalabileceği bir bölgedir. Bu deney, tüm yüz yerine yalnız Mouth ROI kullanarak ağız bölgesinin tek başına ne kadar ayırt edici deepfake sinyali taşıdığını ölçmeyi amaçlamaktadır.

3.2 Xception ile hangi özellikler öğrenildi?

Bu deneyde HOG, LBP veya Gabor gibi el yapımı özellikler ayrı çıkarılmamıştır. ImageNet üzerinde önceden eğitilmiş Xception backbone, ağız görüntülerinden kenar, doku, renk geçişi ve daha yüksek seviyeli uzamsal/yapısal temsilleri otomatik öğrenmek üzere kullanılmıştır. Global Average Pooling sonrası 2048 boyutlu deep feature temsili classifier katmanlarına aktarılmıştır.


3.3 İki aşamalı eğitim

1. Frozen aşama: Xception backbone sabit tutuldu; yalnız yeni classifier katmanları eğitildi.
2. Fine-tuning: en iyi frozen checkpoint yüklendi; son 30 katmandan BatchNormalization dışındakiler açıldı ve $1e-5$ learning rate ile ağız verisine adapte edildi.
3. Model seçimi: frozen ve fine-tuned modeller yalnız validation AUC ile karşılaştırıldı.
4. Nihai test: seçilen fine-tuned model 302 örneklik test kümesinde bir kez değerlendirildi.


4. Frozen Xception Eğitim Davranışı

Gösterge	Sonuç
Gerçekleşen epoch	14
En iyi epoch	10
En iyi validation AUC	0.7280
En iyi validation accuracy	0.6892
Eğitim süresi	147.30 dakika

Frozen aşama modelin ImageNet'ten taşıdığı genel görsel temsillerin ağız sınıflandırması için ne kadar yeterli olduğunu ölçen başlangıç baseline'ıdır. Validation AUC'nin yaklaşık 0,73 düzeyinde kalması, yalnız sabit Xception özellikleriyle orta seviyede bir ayırma gücü bulunduğunu ancak ağız verisine daha fazla adaptasyon ihtiyacı olduğunu göstermiştir.



Şekil 2. Frozen Xception train ve validation AUC eğrileri (Cell 11 çıktısı).




Şekil 3. Frozen Xception loss eğrileri (Cell 11 çıktısı).

5. Fine-Tuning Sonuçları


Gösterge	Frozen	Fine-Tuned	Değişim
Best validation AUC	0.7280	0.8228	+0.0948
Best validation accuracy	0.6892	0.7669	+0.0777
En iyi epoch	10	9	-
Süre (dk)	147.30	159.62	-

Ana bulgu

Fine-tuning, validation AUC'yi yaklaşık 9,5 puan ve validation accuracy'yi yaklaşık 7,8 puan artırmıştır. Bu, üst Xception katmanlarının ağız bölgesindeki veri dağılımına uyarlanması anlamı katkısı sağladığını göstermektedir.




Şekil 4. Fine-tuned Xception train ve validation accuracy eğrileri.



Şekil 5. Fine-tuning loss eğrileri.

6. Nihai Test Sonuçları

Metrik	Test değeri	Kısa yorum
Accuracy	%70.20	Tüm test örneklerindeki genel doğruluk.
Balanced Accuracy	%70.03	İki sınıfın dengeli başarı özeti.
Precision (FAKE)	%69.64	FAKE tahmini verilenlerin gerçekten FAKE olma oranı.
Recall / Sensitivity	%75.00	Gerçek FAKE örneklerin yakalanma oranı.
Specificity	%65.07	Gerçek REAL örnekleri doğru tanıma oranı.
F1-score	0.7222	Precision ve recall dengesi.
ROC-AUC	0.7662	Eşikten bağımsız sınıf ayırma gücü.
NPV	0.7090	REAL tahmini verilenlerin gerçekten REAL olma oranı.




Şekil 6. Nihai Xception Mouth ROI test metrikleri.

Sonuçların anlamı

ROC-AUC=0,7662 değeri modelin gerçek ve sahte ağız örneklerini rastgele sınıflandırmanın belirgin üzerinde ayırabildiğini gösterir. Bununla birlikte %70,20 accuracy ve %65,07 specificity, özellikle gerçek örneklerin bir bölümünün sahte olarak işaretlendiğini ve modelin hâlâ geliştirmeye açık olduğunu göstermektedir.

7. Confusion Matrix ve Hata Analizi

Gerçek / Tahmin	REAL	FAKE
REAL	95 (TN)	51 (FP)
FAKE	39 (FN)	117 (TP)




Şekil 7. Nihai test confusion matrix.

146 gerçek ağız ROI'sinin 95'i doğru REAL, 51'i yanlış FAKE olarak sınıflandırılmıştır. 156 sahte ağız ROI'sinin 117'si doğru FAKE, 39'u yanlış REAL olarak tahmin edilmiştir. Bu dağılım modelin FAKE sınıfına daha duyarlı olduğunu doğrular: recall %75 iken specificity %65,07'dir.

7.1 Hata eğilimi

- False positive sayısı (51), false negative sayısından (39) yüksektir.
- Model gerçek örnekleri sahte olarak işaretlemeye görece daha yatkındır.
- Bu durum güvenlik odaklı deepfake taramasında yüksek recall açısından avantajlı olabilir; ancak yanlış alarm maliyeti uygulamaya göre ayrıca değerlendirilmelidir.
- Karar eşiği bu deneyde 0,50 olarak sabit tutulmuştur; ileride validation tabanlı threshold optimizasyonu ayrı bir ablation olarak denenebilir.

8. ROC Eğrisi ve Genelleme Yorumu




Şekil 8. Test ROC eğrisi; ROC-AUC = 0,7662.

ROC eğrisi rastgele sınıflandırma çizgisinin üzerinde ilerlemektedir. AUC=0,7662, model skorlarının iki sınıfı orta-iyi düzeyde sıraladığını gösterir. Fine-tuning validation AUC 0,8228 iken test AUC 0,7662'dir. Yaklaşık 0,0566'lık fark, validation performansının bağımsız testte tamamen korunmadığını gösterir; bu nedenle sonraki deneylerde daha fazla kaynak video, daha çeşitli ağız koşulları ve farklı backbone karşılaştırmaları önemlidir.

8.1 Frozen → Fine-tuned → Test

Aşama	AUC / Accuracy	Yorum
Frozen validation	AUC 0.7280 / Acc 0.6892	ImageNet genel özellikleri orta düzey baseline sağladı.
Fine-tuned validation	AUC 0.8228 / Acc 0.7669	Ağız verisine adaptasyon belirgin kazanç sağladı.
Independent test	AUC 0.7662 / Acc 0.7020	Genelleme validation'dan düşük, ancak rastgele seviyenin üzerinde.



Şekil 9. Validation aşamasında fine-tuning kazancı.

9. Bulguların Değerlendirilmesi ve Projeye Katkısı

- Ağız bölgesi tek başına kullanılabilir bir deepfake sinyali üretmiştir: test ROC-AUC 0,7662 ve F1 0,7222.
- Fine-tuning gereklidir: frozen modelin validation AUC'si 0,7280'den 0,8228'e yükselmiştir.
- Model FAKE sınıfını yakalamada daha güçlüdür: recall %75, specificity %65,07.
- Sınıf dengesi güçlüdür; düşük/orta performans ciddi class imbalance ile açıklanamaz.
- ROI çıkarma başarısı çok yüksektir: 3000 frame'in yalnız 13'ü kullanılamamıştır.
- Test seti yalnız final değerlendirmede kullanıldığı için model seçimi kaynaklı test sızıntısı önlenmiştir.

9.1 Göz ve kaş deneylerine uyarlanabilirlik

Aynı deney protokolü göz ve kaş ROI'lerine uyarlanabilir. Göz ve kaş için ayrı Xception modelleri eğitilir; mimari ve metrikler mümkün olduğunca aynı tutulursa bölgesel karşılaştırma daha kontrollü olur. Ağızda eğitilmiş ağırlıklar doğrudan diğer bölgelere aktarılmamalı; her bölge kendi train/validation/test verisi üzerinde bağımsız eğitilmelidir.

```
Mouth ROI -> Xception -> P(fake | mouth)
Eye ROI   -> Xception -> P(fake | eye)
Eyebrow ROI -> Xception -> P(fake | eyebrow)
      ↓
    Fusion Model
      ↓
    Final P(fake)
```

10. Önerilen Sonraki Adımlar

5. Aynı Mouth ROI splitleri üzerinde EfficientNet-B0, ConvNeXt-Tiny, Custom CNN ve klasik HOG/LBP+SVM baseline'ları denenmeli.
6. Validation tabanlı karar eşiği optimizasyonu ile 0,50 threshold karşılaştırılmalı.
7. Grad-CAM kullanılarak modelin ağız içinde hangi bölgelere odaklandığı analiz edilmeli.
8. Aynı video/kimliklerin farklı splitlerde bulunmadığı kaynak-video bağımsızlığı ayrıca metadata düzeyinde doğrulanmalı.
9. Göz ve kaş ekipleri aynı Xception protokolünü uygulayarak bölgesel metrik tablosu üretmeli.
10. Son aşamada bölgesel skorların sabit veya öğrenilebilir ağırlıklarla füzyonu denenmeli.

11. Genel Sonuç

Genel değerlendirme

Xception tabanlı ağız modeli, mevcut veri ve deney protokolünde deepfake tespiti için anlamlı fakat kusursuz olmayan bir bölgesel baseline üretmiştir. Fine-tuning net biçimde fayda sağlamış, testte ROC-AUC 0,7662 ve FAKE recall %75 elde edilmiştir. Deneyin asıl değeri yalnız tek model sonucu değil; ağız, göz ve kaş bölgelerinin aynı mimari altında karşılaştırılmasına ve daha sonra adaptif bölgesel füzyona aktarılmasına uygun, tekrar üretilebilir bir baseline oluşturmaktır.